

MAT5508 (10182) Modelos Lineales Generalizados

Jacob Cancino Romero

Julio–Septiembre, 2026

Maestría en Estadística

Facultad de Ciencias Actuariales, Universidad Anáhuac

1. Estimación por máxima verosimilitud
2. La familia exponencial y modelos lineales generalizados
3. Métodos para el análisis de datos binarios
4. Modelos log-lineales
5. Datos sobredispersos

Syllabus

La teoría de los modelos lineales generalizados ha tenido un efecto profundo y unificador en la manera en que estudiamos y aplicamos métodos avanzados de regresión y ha aportado perspectivas valiosas para la conexión entre una gran variedad de procedimientos estadísticos.

El curso es una introducción al estudio de los modelos lineales generalizados. Nos enfocaremos, principalmente, en la teoría y aplicaciones relacionadas con datos binarios, categóricos y de conteo, aunque preservaremos la formulación general del modelo lineal generalizado para respuestas con distribuciones de la familia exponencial.

Se presentarán distintas técnicas de regresión útiles para el análisis de datos en varios contextos (medicina, salud pública, psicología, economía, finanzas, etc.). Cada tema es ilustrado con ejemplos aplicados.

El modelo lineal ordinario es el modelo de regresión más conocido, y está dado por

$$y_i = \mathbf{x}_i^\top \boldsymbol{\beta} + \varepsilon_i, \quad i = 1, \dots, n$$

donde y_i es la variable respuesta. Este modelo tiene un componente determinístico $\mathbf{x}_i^\top \boldsymbol{\beta}$ y un componente aleatorio ε_i . Se asume linealidad en los coeficientes $\boldsymbol{\beta}$ y las variables explicativas $\mathbf{x}_i$, las cuales se asume que son fijas.

El supuesto fundamental de este modelo es que los errores son variables aleatorias normales independientes e idénticamente distribuidas con media cero y varianza constante, esto es $\varepsilon_i \stackrel{\text{iid}}{\sim} \mathcal{N}(0, \sigma^2) \forall i$.

Por consiguiente, la respuesta también se asume como una variable aleatoria normal con media $\mathbf{x}_i^\top \boldsymbol{\beta}$ y varianza constante.

Denotemos por

$$\eta_i = \mathbf{x}_i^\top \boldsymbol{\beta}$$

el *predictor lineal*. Los modelos lineales generalizados son una generalización del modelo lineal ordinario debido a:

1. Relajan el supuesto de normalidad de la distribución de la respuesta dando paso a cualquier distribución de la familia exponencial, la cual incluye distribuciones tales como normal, binomial, Poisson, gamma, exponencial, binomial negativa, etc.
2. En lugar de modelar $\mu_i = \mathbb{E}(y_i)$ directamente como una función del predictor lineal $\mathbf{x}_i^\top \boldsymbol{\beta}$, modelan una función $g(\mu_i)$ de la media μ_i . Entonces el modelo se vuelve

$$g(\mu_i) = \eta_i = \mathbf{x}_i^\top \boldsymbol{\beta}.$$

Syllabus y métodos didácticos

1. Estimación por máxima verosimilitud (repaso)
2. La familia exponencial y modelos lineales generalizados
3. Métodos para el análisis de datos binarios
4. Modelos log-lineales
5. Datos sobredispersos

Los temas se cubrirán con una combinación de exposición del instructor, discusiones y dinámicas grupales en clase, tareas individuales, un trabajo trimestral y un examen final.

Se hará uso extensivo del programa estadístico R. Se asume que ya cuentan con éste y que lo tienen disponible en la computadora que usen en el curso.

Objetivos

1. Comprender los fundamentos teóricos de los modelos lineales generalizados.
2. Especificar modelos lineales generalizados para el análisis de datos y usar paquetes estadísticos para su análisis y evaluar su ajuste.
3. Analizar con profundidad, interpretar, explicar los resultados y escribir reportes de la aplicación de los modelos lineales generalizados.
4. Identificar cuando hay sobredispersión en los datos y aplicar soluciones pertinentes.
5. Aprender a simular datos a partir de un modelo lineal generalizado y su uso como herramienta de autoaprendizaje e investigación.

Referencias bibliográficas

1. Dobson, A. J. and Barnett, A. G. (2018). *An introduction to generalised linear models*. Chapman and Hall/CRC
2. Olsson, U. (2002). *Generalised linear models. An applied approach*. Studentlitteratur, Lund, 18
3. McCullagh, P. (2019). *Generalized linear models*. Routledge
4. Dunn, P. K., Smyth, G. K. et al. (2018). *Generalized linear models with examples in R*, volume 53. Springer
5. Agresti, A. (2015). *Foundations of linear and generalized linear models*. John Wiley & Sons
6. Fox, J. (2015). *Applied regression analysis and generalized linear models*. Sage publications

Criterios de evaluación


Criterios de evaluación La calificación final se calculará como un promedio ponderado de los ejercicios de tarea, un trabajo trimestral en equipo (2 a 3 integrantes) y un examen final (a libro cerrado) con los siguientes ponderadores:

- 30% Tareas (escritas, entregar individualmente)
- 40% Trabajo final. Se entrega un único reporte por equipo
- 30% Examen final (1.5 horas)

Cada alumno **entregará los ejercicios de tarea de manera individual**, habiéndola escaneado previamente para enviarla por correo electrónico a jacob.cancino@anahuac.mx.

El examen final se aplicará el 10 de septiembre de 2026 en el salón de clases, será escrito, individual y a libro cerrado.

Calendario de entregas



¡Bienvenidos!

Introducción

Los métodos estadísticos que veremos en el curso son *modelos de regresión* y se refieren al análisis de la relación entre mediciones multivariadas hechas en una muestra o grupo de individuos u objetos.

Por ejemplo, las mediciones podrían referirse a la altura, peso y edades de un grupo de niños y niñas de distintas regiones del país, o el largo, ancho de las hojas y cantidad de frutos de plantas que crecen en distintas condiciones.

Introducción

En análisis de regresión usamos el término *variable respuesta o dependiente* para referirnos a mediciones que varían en función de otras variables que denominamos *variables independientes o explicativas o predictores*. De manera general,

$$y_i = f(\mathbf{x}_i), \quad i = 1, \dots, n$$

donde y_i es la variable respuesta del i -ésimo individuo en una muestra de tamaño n y $\mathbf{x}_i$ es un vector de variables explicativas asociadas a este individuo.

La variable respuesta se asume aleatoria y las explicativas usualmente se tratan como determinísticas y, en ocasiones, sus valores son controlados en el diseño de experimentos.

Tipos de variables

Tanto variables respuesta como covariables pueden ser

- **Ordinal:** en su clasificación hay un orden intrínseco o *ranqueo* entre las categorías. Por ejemplo, niño, joven, adulto y anciano; presión distólica en grupos como ≤ 70 , $71 - 90$, $91 - 110$, $111 - 130$, ≥ 131 mmHg (milímetros de mercurio).
- **Nominal:** representan categorías que no obedecen a una clasificación intrínseca, colores por ejemplo. En particular, las *variables binarias, dicotómicas o binomiales* son aquellas con solo dos categorías: hombre/mujer, muerto/vivo, hojas serradas/lisas. Si una variable nominal tiene mas de dos categorías entonces se le denomina *multinomial*.

- **Continuas:** mediciones donde las observaciones pueden, en teoría por lo menos, caer en cualquier valor sobre un continuo. Por ejemplo, altura, longitud y tiempo. Esta escala incluye ambas *escala de intervalo* y *escala de proporción* (la última con zero bien definido). Un ejemplo particular de medición continua es *el tiempo transcurrido hasta que un evento específico ocurre*, tal como el tiempo antes de que falle un componente electrónico, y este tiempo desde un momento inicial conocido lo denominamos **tiempo hasta el evento** *time-to-event or failure time*.

Tipos de variables

Las variables categóricas y nominales también se conocen como variables **categóricas** o **discretas** y el usualmente las resumimos en número de observaciones, **conteos** o **frecuencias** en cada categoría.

El término **cuantitativo** es usualmente utilizado para mediciones en una escala continua y el término **cualitativo** para las nominales y, en ciertos contextos, para las ordinales.

Una variable explicativa cualitativa se denomina **factor** y sus categorías **niveles**. Una variable explicativa cuantitativa se le denomina también **covariable**.

Modelo lineal ordinario

El modelo lineal ordinario es sin duda el modelo de regresión más conocido, y está dado por

$$y_i = \mathbf{x}_i^\top \boldsymbol{\beta} + \varepsilon_i, \quad i = 1, \dots, n$$

donde y_i es la variable respuesta. Este modelo tiene un componente determinístico $\mathbf{x}_i^\top \boldsymbol{\beta}$ y un componente aleatorio ε_i . Se asume linealidad en los coeficientes $\boldsymbol{\beta}$ y las variables explicativas $\mathbf{x}_i$, las cuales se asume que son fijas.

El supuesto fundamental de este modelo es que los errores son variables aleatorias normales independientes e idénticamente distribuidas con media cero y varianza constante, esto es $\varepsilon_i \stackrel{\text{iid}}{\sim} \mathcal{N}(0, \sigma^2) \forall i$. Por consiguiente, la respuesta también se asume como una variable aleatoria normal con media $\mathbf{x}_i^\top \boldsymbol{\beta}$ y varianza constante.

Violación a los supuestos del modelo lineal ordinario

En la práctica es común que el supuesto de normalidad no sea razonable y, más aún, que no sea una medición de escala. Ejemplos de respuestas que podemos encontrar en la práctica son:

- Continuas,
- Dicotómicas,
- Proporciones,
- Conteos,
- Tasas,
- Ordinales.

Modelo lineal generalizado

Denotemos el *predictor lineal* por

$$\eta_i = \mathbf{x}_i^\top \boldsymbol{\beta}.$$

Los modelos lineales generalizados son una generalización del modelo lineal ordinario en distintas maneras:

1. Relajamos el supuesto de normalidad de la distribución de la respuesta dando paso a cualquier distribución de la familia exponencial, la cual incluye distribuciones tales como normal, binomial, Poisson, gamma, exponencial, binomial negativa.
2. En lugar de modelar $\mu_i = \mathbb{E}(y_i)$ directamente como una función del predictor lineal $\mathbf{x}_i^\top \boldsymbol{\beta}$, modelamos una función $g(\mu_i)$ de la media μ_i . Entonces el modelo se vuelve

$$g(\mu_i) = \eta_i = \mathbf{x}_i^\top \boldsymbol{\beta}.$$

La función g la llamamos la *función de ligadura*.

Especificar un modelo lineal generalizado consta de tres elementos:

1. la distribución de la respuesta,
2. la función de ligadura g y
3. el predictor lineal $\mathbf{x}_i^\top \boldsymbol{\beta}$.

En el curso estudiaremos fundamentos teóricos de los modelos lineales generalizados y los casos más representativos; explicaremos cómo especificar estos modelos y su aplicación para analizar datos de distintas áreas de conocimiento haciendo uso extensivo del software estadístico R, y evaluaremos el ajuste de los modelos a los datos.

Cubriremos los temas siguientes:

1. Estimación por máxima verosimilitud (repaso)
2. La familia exponencial y modelos lineales generalizados
3. Métodos para el análisis de datos binarios
4. Modelos log-lineales
5. Datos sobredispersos

Estimación por máxima verosimilitud

Máxima verosimilitud: Teoría donde subyacen los procedimientos de estimación en muchos contextos.

Esta sección es un breve repaso como preparación para el estudio de los modelos lineales generalizados.

Máxima verosimilitud θ escalar

Supongamos que Y es una variable aleatoria (escalar) con función de densidad (o probabilidad) $f(y; \theta)$, donde $\theta \in \Omega$ es un parámetro continuo.

Asumimos que θ es desconocido y que deseamos hacer inferencia estadística acerca de este parámetro i.e. deseamos estimarlo y hacer pruebas de hipótesis respecto de θ . La llamada *función de máxima verosimilitud* se define como cualquier función proporcional a la probabilidad de observar los datos observados.

Máxima verosimilitud θ escalar

Habiendo observado y , construimos la función de verosimilitud para θ como

$$L(\theta; y) = c \Pr(y = y; \theta). \quad (1)$$

c : constante de proporcionalidad, cualquier función positiva que no dependa de θ .

En ocasiones es conveniente escalar la función de verosimilitud eligiendo una forma específica de c que simplifique la expresión de $L(\theta; y)$.

$L(\theta; y)$ contiene toda la información en los datos relativa a θ . Las propiedades de la función de verosimilitud son útiles para inferencias respecto de θ y son la base de muchos procedimientos estadísticos.

Máxima verosimilitud θ escalar

$L(\theta; y)$ rankea los valores de θ en términos de su consistencia con los datos o su plausibilidad dados los datos observados.

Para efectos de estimación, es deseable hallar el valor de θ para el cual los datos observados sean más verosímiles (de aquí el nombre de *máxima verosimilitud*).

El valor de θ que maximiza $L(\theta)$ es en, cierto sentido, el valor estimado óptimo. Por lo tanto, en este contexto la estimación de θ es un problema de optimización.

Máxima verosimilitud θ escalar

Con frecuencia es más fácil maximizar

$$\ell(\theta; y) = \log L(\theta; y), \quad (2)$$

dado que la función logaritmo es monotónica es indistinto maximizar $L(\theta)$ que $\ell(\theta)$, i.e. conducen mismo máximo en θ .

Usamos un circunflejo ($\hat{}$) para distinguir el valor particular de θ que maximiza $L(\theta)$ y lo denominamos *el estimador de máxima verosimilitud*.

En ocasiones omitimos el argumento y al escribir la función de verosimilitud y otras funciones relacionadas, sin embargo debe entenderse que estas funciones dependen de los datos.

Máxima verosimilitud θ escalar

Supongamos que $\hat{\theta}$, el estimador de máxima verosimilitud, existe y que pertenece a Ω (el espacio de θ). Definimos las siguientes funciones:

$$\ell(\theta) = \log L(\theta) : \text{función log-verosimilitud (log-likelihood)} \quad (3a)$$

$$S(\theta) = \ell'(\theta) : \text{función de puntuación (score function)} \quad (3b)$$

$$I(\theta) = -\ell''(\theta) : \text{función de información} \quad (3c)$$

$$\mathcal{I}(\theta) = \mathbb{E}\{I(\theta)\} : \text{función de información esperada} \quad (3d)$$

$$R(\theta) = \frac{L(\theta)}{L(\hat{\theta})} : \text{función de verosimilitud relativa} \quad (3e)$$

$$r(\theta) = \log R(\theta) = \log \left(\frac{L(\theta)}{L(\hat{\theta})} \right) = \ell(\theta) - \ell(\hat{\theta}) : \quad (3f)$$

(7g) es la función de verosimilitud log-relativa (log-relative likelihood).

Máxima verosimilitud θ escalar

Deseamos un valor de θ que maximice $\ell(\theta)$ o, equivalentemente, sea la solución de $S(\theta) = 0$. En ocasiones $S(\theta) = 0$ puede resolverse analíticamente, pero en otras debe resolverse por métodos numéricos iterativamente.

Newton Raphson Algorithm

El método de Newton-Raphson (o método de Newton) es un algoritmo para encontrar las raíces de una función.

Recordemos la forma general de la expansión de Taylor. Si $f(x)$ es una función genérica diferenciable, entonces

$$f(x) = f(a) + \frac{f'(a)(x-a)}{1!} + \frac{f''(a)(x-a)^2}{2!} + \dots + \frac{f^{(n)}(a)(x-a)^n}{n!} + \dots$$

Supongamos que deseamos hallar $\hat{\theta}$, la raíz de $S(\theta) = 0$ y que θ_0 es un valor “cercano” a $\hat{\theta}$. Considere la expansión de Taylor de $S(\theta)$ alrededor de θ_0 :

$$S(\theta) = S(\theta_0) + \frac{S'(\theta_0)(\theta - \theta_0)}{1!} + \frac{S''(\theta_0)(\theta - \theta_0)^2}{2!} + \dots$$

Newton Raphson Algorithm

Para $|\theta - \theta_0|$ pequeño podemos ignorar los términos de segundo orden y superiores y tendríamos la aproximación

$$\begin{aligned} S(\theta) &\approx S(\theta_0) + S'(\theta_0)(\theta - \theta_0) \\ &= S(\theta_0) - I(\theta_0)(\theta - \theta_0). \end{aligned}$$

Fundamentalmente, estamos aproximando $S(\theta)$ con una función lineal que tiene el mismo valor y pendiente que $S(\theta)$ en $\theta = \theta_0$. Entonces, en $\theta = \hat{\theta}$,

$$S(\hat{\theta}) \approx S(\theta_0) - I(\theta_0)(\hat{\theta} - \theta_0),$$

y dado que $\hat{\theta}$ es el valor que maximiza S entonces $S'(\hat{\theta}) = 0$, resultando en

$$\begin{aligned} I(\theta_0)(\hat{\theta} - \theta_0) &\approx S(\theta_0) \\ (\hat{\theta} - \theta_0) &\approx I^{-1}(\theta_0)S(\theta_0) \\ \hat{\theta} &\approx \theta_0 + I^{-1}(\theta_0)S(\theta_0) \end{aligned}$$

Newton Raphson Algorithm

Esto sugiere utilizar

$$\theta_1 \approx \theta_0 + I^{-1}(\theta_0)S(\theta_0) \quad (4)$$

como una actualización de la aproximación de $\hat{\theta}$. Aplicando (4) recursivamente tenemos procedimiento iterativo para maximizar

$$\theta^{(i+1)} \approx \theta^{(i)} + I^{-1}(\theta^{(i)})S(\theta^{(i)}). \quad (5)$$

La iteración en (5) continúa hasta que $\theta^{(i+1)} - \theta^{(i)} < \epsilon$ donde ϵ es un nivel de tolerancia previamente fijo. Para confirmar si se trata de un máximo, deberemos revisar que $I(\hat{\theta}) > 0$.

Cantidad pivotal

Una vez que obtenemos un estimado para θ , es común realizar pruebas estadísticas y construir intervalos de confianza. Hay una diversidad de técnicas disponibles, todas se basan de cierta forma en la función de verosimilitud. Los siguientes son resultados distribucionales, generalmente aproximados, cuyas aproximaciones mejoran a medida que el tamaño de muestra aumenta.

$$-2r(\theta) \sim \chi^2_{(1)} \quad (6a)$$

$$\frac{(S(\theta))^2}{I(\theta)} \sim \chi^2_{(1)} \quad (6b)$$

$$\left(\hat{\theta} - \theta\right)^2 I(\hat{\theta}) \sim \chi^2_{(1)} \quad (6c)$$

Expresiones como (6a)–(6c), las cuales son funciones de los datos y del parámetro de interés θ y su distribución no depende de θ , se denominan *cantidades pivotaes*.

Pruebas de hipótesis

Supongamos que deseamos someter a prueba el siguiente sistema de hipótesis:

$$H_0 : \theta = \theta_0$$

$$\text{vs. } H_1 : \theta \neq \theta_0.$$

La *prueba de razón de verosimilitud* se basa en (6a), su estadística de prueba es

$$-2 \left\{ \ell(\theta_0) - \ell(\hat{\theta}) \right\}$$

y tiene un nivel de significancia dado por

$$\Pr(\chi^2_{(1)}) > -2r(\theta_0).$$

Pruebas de hipótesis

La cantidad pivotal (6c) conduce a una prueba tipo Wald en donde la estadística de prueba es

$$(\hat{\theta} - \theta)^2 I(\hat{\theta})$$

y su nivel de significancia

$$\Pr \left\{ \chi^2_{(1)} > (\hat{\theta} - \theta)^2 I(\hat{\theta}) \right\}.$$

Equivalentemente, la prueba tipo Wald también puede usarse con la estadística de prueba

$$(\hat{\theta} - \theta) \sqrt{I(\hat{\theta})}$$

y su nivel de significancia

$$\Pr \left\{ |Z| > (\hat{\theta} - \theta) \sqrt{I(\hat{\theta})} \right\}.$$

Intervalos de confianza

Supongamos que deseamos construir un intervalo de confianza para θ al un nivel de $100(1 - \alpha)\%$. La cantidad pivotal (6a) conduce al intervalo definido por

$$\{\theta : -2r(\theta) < \chi_1^2(1 - \alpha)\},$$

donde $\chi_1^2(1 - \alpha)$ es el cuantil $\alpha\%$ de la distribución χ_1^2 .

La cantidad tipo Wald (6c) tiene el intervalo de confianza definido por

$$\left(\hat{\theta} - 1.96 \times I^{-1/2}(\hat{\theta}), \quad \hat{\theta} + 1.96 \times I^{-1/2}(\hat{\theta})\right)$$

Todos estos resultados son exactos para inferencia estadística en el caso de un modelo lineal donde θ es la media y σ^2 desconocida, y aproximados para otras distribuciones.

Ejemplo 1.1 - Distribución binomial (Inferencia MLE)

Estudio para examinar la toxicidad de un insecticida $\rightarrow$ 10 cucarachas se expusieron a concentración fija de disulfuro de carbono durante 15 minutos, después se contaron los sobrevivientes.

Se definió como un “éxito” cuando el insecto sobrevivió, lo que ocurre con probabilidad θ . Supongamos que 6 de los insectos originales sobrevivieron. Deseamos hacer inferencia sobre θ .

Es razonable definir el problema en términos generales de una binomial. Sea $Y_i, i = 1, \dots, n$, una variable aleatoria indicadora para el estatus de cada uno de los 10 insectos, donde

$$Y_i = \begin{cases} 1 & \text{con probabilidad } \theta \\ 0 & \text{con probabilidad } 1 - \theta \end{cases}$$

Ejemplo 1.1 - Distribución binomial (Inferencia MLE)

Asumimos que $Y_1, \dots, Y_n$ son independientes e idénticamente distribuidos, y sea $Y = \sum_{i=1}^n Y_i$. Dado que conocemos el total de los insectos que sobrevivieron, entonces tenemos $Y \sim \text{Bin}(n, \theta)$ y por lo tanto

$$\Pr(Y = y; \theta) = \binom{n}{y} \theta^y (1 - \theta)^{n-y}.$$

Ejemplo 1.1 - Distribución binomial (Inferencia MLE)

El parámetro θ es desconocido y la función de verosimilitud para θ dado y es

$$L(\theta; y) = c \Pr(Y = y; \theta),$$

donde $c > 0$ es una constante (i.e. no es función de θ). En este caso tomaríamos

$$c = \frac{1}{\binom{n}{y}}$$

para simplificar $L(\theta)$. La inferencia estadística la basamos en $L(\theta)$ o, equivalentemente, en cualquier función biyectiva de $L(\theta)$. A menudo, es más conveniente trabajar con $\ell(\theta) = \log L(\theta)$, lo cual haremos aquí.

Entonces tenemos

$$L(\theta) = \theta^y (1 - \theta)^{n-y}$$

$$\ell(\theta) = y \log \theta + (n - y) \log(1 - \theta).$$

Ejemplo 1.1 - Distribución binomial (Inferencia MLE)

La función $S(\theta) = \ell'(\theta)$ es la primera derivada de $\ell(\theta)$ y es la función de puntuación. Esto es,

$$S(\theta) = \frac{\partial \ell(\theta)}{\partial \theta} = \frac{\partial}{\partial \theta} \{y \log \theta + (n - y) \log(1 - \theta)\} = \frac{y}{\theta} - \frac{n - y}{1 - \theta}.$$

La función $I(\theta) = -\ell''(\theta)$, la función de información, es el negativo de la segunda derivada de $\ell(\theta)$ (función de información observada), y está dada por

$$I(\theta) = -\frac{\partial^2 \ell(\theta)}{\partial \theta^2} = -\frac{\partial}{\partial \theta} \left\{ \frac{y}{\theta} - \frac{n - y}{1 - \theta} \right\} = \frac{y}{\theta^2} + \frac{n - y}{(1 - \theta)^2}.$$

Resolviendo para $\ell(\theta) = 0$ tenemos

$$\hat{\theta} = \frac{y}{n}$$

y dado que $I(\hat{\theta}) = I(0.6) = 41.67 > 0$, se corresponde con un máximo.

Ejemplo 1.1 - Distribución binomial (Inferencia MLE)

En este ejemplo tenemos que $n = 10$ y $y = 6$, por lo que

$$L(\theta) = \theta^6(1 - \theta)^4$$

y

$$\ell(\theta) = 6 \log \theta + 4 \log(1 - \theta).$$

Evaluando tenemos

$$\hat{\theta} = \frac{6}{10} = 0.6$$

y

$$\ell(0.6) = -6.73$$

es el punto crítico de $\ell(\theta)$. Dado que $I(\hat{\theta}) > 0$, sabemos que es un máximo y, por lo tanto, $\hat{\theta} = 0.6$ es el valor estimado por máxima verosimilitud (MLE - maximum likelihood estimate) de θ . Las Figuras 1a y 1b muestran las curvas de las funciones de verosimilitud y log-verosimilitud así como el MLE.


Ejemplo 1.1 - Distribución binomial (Inferencia MLE)

La función log-verosimilitud relativa está dada por


$$r(\theta) = \ell(\theta) - \ell(\hat{\theta}) = 6 \log \theta + 4 \log(1 - \theta) + 6.73$$

y la función de verosimilitud relativa es $R(\theta) = e^{r(\theta)}$. Las Figuras 1c y 1d muestran las curvas de las funciones de verosimilitud relativa y log-relativa.


Ejemplo 1.1 - Distribución binomial (Inferencia MLE)




(a) (—) $L(\theta; y)$; $\bullet \hat{\theta}$



(b) (—) $\ell(\theta; y)$; $\bullet \hat{\theta}$



(c) (—) $R(\theta; y)$; $\bullet \hat{\theta}$



(d) (—) $r(\theta; y)$; $\bullet \hat{\theta}$


Ejemplo 1.1 - Distribución binomial (Inferencia MLE)

En las Figuras 2a y 2b graficamos las curvas de $R(\theta)$ y $r(\theta)$ para otros dos experimentos hipotéticos con tamaños de muestra más grandes, $n = 100$ con $y = 60$ insectos sobrevivientes y $n = 1000$ con $y = 600$ insectos sobrevivientes.


En los tres experimentos $\hat{\theta} = 0.6$ pero la forma de la curva de sus funciones es muy diferente, a medida que aumenta el tamaño de muestra el área debajo de estas dos funciones se concentra en mayor medida alrededor del MLE.

Intuitivamente esto tiene sentido porque el rango de valores plausibles de θ debe ser más estrecho cuando hay más datos (i.e. obtenemos estimaciones más precisas de θ cuando hay más datos).

Ejemplo 1.1 - Distribución binomial (Inferencia MLE)



(a) (—) $R(\theta; y)$; $\bullet \hat{\theta}$



(b) (—) $r(\theta; y)$; $\bullet \hat{\theta}$

Figure 2: Likelihood and related functions for Binomial data.

Ejemplo 1.1 - Distribución binomial (Inferencia MLE)

Supongamos que estamos interesados en el sistema de hipótesis

$$H_0 : \theta = 0.20$$

$$\text{vs. } H_1 : \theta \neq 0.20.$$

La prueba de razón de verosimilitud para $\theta_0 = 0.20$ es

$$\begin{aligned} -2r(\theta_0) &= -2(y \log \theta_0 + (n - y) \log(1 - \theta_0) + \ell(\hat{\theta})) \\ -2r(0.2) &= -2(6 \log(0.2) + 4 \log(1 - 0.2) + 6.73) \\ &= 7.64 \end{aligned}$$

El correspondiente nivel de significancia es

$$\Pr(\chi_1^2 > 7.64) = 0.006$$

por lo que rechazamos la hipótesis nula.

Ejemplo 1.1 - Distribución binomial (Inferencia MLE)

Para la prueba tipo Wald tenemos el siguiente valor de la estadística de prueba

$$(\hat{\theta} - \theta_0)^2 I(\hat{\theta}) = (0.6 - 0.2)^2 \times 41.67 = 6.67$$

con un nivel de significancia

$$\Pr(\chi_1^2 > 6.67) = 0.01,$$

lo que nos conduce a rechazar la hipótesis nula también, aunque la evidencia es menos contundente que en la razón de verosimilitud (de cualquier forma es muy fuerte).

Ejemplo 1.1 - Distribución binomial (Inferencia MLE)

Ahora construyamos intervalos de confianza aproximados para θ con un nivel de 95%. Con base en la razón de verosimilitud, este estimador de intervalo es

$$\begin{aligned} & \{\theta : -1r(\theta) < \chi_1^2(0.95)\} \\ &= \{\theta : -2(6 \log \theta + 4 \log(1 - \theta) + 6.73) < 3.84\} \\ &= (0.300, 0.854). \end{aligned}$$


En ocasiones es necesario recurrir a métodos numéricos para encontrar el intervalo de confianza con base en la razón de verosimilitud, para lo cual podemos usar paquetes estadísticos como R.

Ejemplo 1.1 - Distribución binomial (Inferencia MLE)


De manera general el procedimiento consiste en desplazar la curva de $-2r(\theta)$ el cuantil correspondiente a $\chi_1^2(0.95)$, esto es $\chi_1^2(0.95) = 3.84$, y encontrar las raíces de la función desplazada.

En este ejemplo, tendríamos que encontrar las raíces de $-2r(\theta) - 3.84$ (ver Figura 3b).

Ejemplo 1.1 - Distribución binomial (Inferencia MLE)



(a) $\bullet \hat{\theta}$



(b) $\bullet \hat{\theta}; \bullet (\hat{\theta}_L, \hat{\theta}_U)$

Figure 3: $-2r(\theta)$ for Binomial data

La función $-2r(\theta) - 3.84$ cruza el eje horizontal en $(\hat{\theta}_L, \hat{\theta}_U) = (0.3, 0.854)$.

Ejemplo 1.1 - Distribución binomial (Inferencia MLE)

```
> Newtons method to find the MLE and its CI based on the  
> likelihood ratio statistic  
> Likelihood functions  
n <- 10  
y <- 6  
theta <- 0.2  
theta.hat <- y/n; theta.hat  
[1] 0.6  
l <- function(n,y,theta){  
  l <- y*log(theta) + (n-y)*log(1-theta)  
  return(l)}  
  
r <- function(n,y,theta,theta.hat){  
  r <- l(n,y,theta)-l(n,y,theta.hat)  
  return(r)}  
  
f.l <- function(n,y,theta){  
  return(y/theta^2 + (n-y)/(1-theta)^2)}
```

Ejemplo 1.1 - Distribución binomial (Inferencia MLE)

```
l(n,y,theta)
[1] -10.5492
r(n,y,theta, 0.8)
[1] -2.772589
f.l(n,y,theta.hat)
[1] 156.25
S(n,y,theta.hat)
[1] 0
```

> Define a **function** to be evaluated iteratively

```
mle <- function(n, y, theta){
  l.inv <- (f.l(n,y,theta))^-1 % Information
  score <- S(n,y,theta) % Score
  mle <- theta + l.inv * score
  return(mle)}

```

```
ci <- function(n,y,theta,theta.hat,alpha){
  cv <- qchisq(1-alpha, df=1)
  ci <- theta - (r(n,y,theta,theta.hat)
    + cv/2) / S(n,y,theta)
  return(ci)}

```

Ejemplo 1.1 - Distribución binomial (Inferencia MLE)

> Setup arguments

```
n <- 10
```

```
y <- 6
```

> There are many ways to iterate. Consider the `while` loop.

> Initialize iteration parameters

> First the MLE

```
i <- 1
```

```
d <- 5
```

```
eps <- 1e-5
```

```
theta <- c(0.1) % Initial values
```

```
while(d > eps){  
  theta <- c(theta, mle(n,y,theta[i]))  
  d <- max(abs(theta[i+1]-theta[i]))  
  i <- i+1}
```

```
theta
```

```
[1] 0.1000000 0.1918367 0.3474693 0.5359575 0.6012083
```

```
[6] 0.6000012 0.6000000
```


Ejemplo 1.1 - Distribución binomial (Inferencia MLE)

> Now the approximate 95% CI

```
i <- 1
d <- 5
eps <- 1e-5
theta <- matrix(c(0.1, 0.9), nrow=1) % Initial values

while(d > eps){ % i<-1
  theta <- rbind(theta, ci(n,y,theta[i,],theta.hat,
                           alpha))
  d <- max(abs(theta[i+1,]-theta[i,]))
  i <- i+1
}
theta
[1,] 0.1000000 0.9000000
[2,] 0.2005499 0.8642503
[3,] 0.2761945 0.8548254
[4,] 0.2985427 0.8543591
[5,] 0.2999730 0.8543581
[6,] 0.2999783 0.8543581
```

Ejemplo 1.1 - Distribución binomial (Inferencia MLE)

El intervalo de confianza aproximado al 95% para la cantidad pivotal Wald está dado por

$$\begin{aligned}\left(\hat{\theta} - \frac{1.96}{\sqrt{I(\hat{\theta})}}, \quad \hat{\theta} + \frac{1.96}{\sqrt{I(\hat{\theta})}}\right) &= \left(0.6 - \frac{1.96}{\sqrt{41.67}}, \quad 0.6 + \frac{1.96}{\sqrt{41.67}}\right) \\ &= (0.296, 0.904)\end{aligned}$$

Notese que ambos intervalos de confianza son muy parecidos,

$$\begin{aligned}\left(\hat{\theta}_L^{\text{LRS}}, \hat{\theta}_U^{\text{LRS}}\right) &= (0.300, 0.854) \\ \left(\hat{\theta}_L^{\text{Wald}}, \hat{\theta}_U^{\text{Wald}}\right) &= (0.296, 0.904)\end{aligned}$$

Ejemplo 1.1 - Distribución binomial (Inferencia MLE)

Los métodos de inferencia de la prueba tipo Wald descansan en el supuesto de que la función log-verosimilitud puede aproximarse con precisión por una función cuadrática. Considere la expansión de Taylor de $\ell(\theta)$ respecto de $\hat{\theta}$

$$\begin{aligned}\ell(\theta) &= \ell(\hat{\theta}) + \frac{(\theta - \hat{\theta})\ell'(\hat{\theta})}{1!} + \frac{(\theta - \hat{\theta})^2\ell''(\hat{\theta})}{2!} + \frac{(\theta - \hat{\theta})^3\ell'''(\hat{\theta})}{3!} + \dots \\ \ell(\theta) - \ell(\hat{\theta}) &= \underbrace{\frac{(\theta - \hat{\theta})\ell'(\hat{\theta})}{1!}}_{=0} + \frac{(\theta - \hat{\theta})^2\ell''(\hat{\theta})}{2!} + \frac{(\theta - \hat{\theta})^3\ell'''(\hat{\theta})}{3!} + \dots \\ r(\theta) &= -\frac{(\theta - \hat{\theta})^2 I(\hat{\theta})}{2!} + \frac{\ell'''(\hat{\theta})(\theta - \hat{\theta})^3}{3!} + \dots\end{aligned}$$

Ejemplo 1.1 - Distribución binomial (Inferencia MLE)

Si ignoramos los términos de tercer orden y superiores, podemos ver la siguiente relación entre la estadística de razón de verosimilitud y la estadística Wald

$$-2r(\theta) \approx (\theta - \hat{\theta})^2 I(\hat{\theta}).$$

El término $\ell'''(\hat{\theta})$ representa el sesgo $\ell(\theta)$. Cuando no hay sesgo entonces este término es cero y, si los términos de orden superior son cero, las inferencias con base en la estadística de razón de verosimilitud y con base en la estadística Wald son perfectamente equivalentes.

Este es el caso del modelo normal cuando la varianza es conocida ¡verifíquelo!.

Ejemplo 1.1 - Distribución binomial (Inferencia MLE)

Cuando la $\ell(\theta)$ es sesgada entonces los dos métodos difieren con el método de Wald dando generalmente resultados más pobres (i.e. los intervalos de confianza al nivel de confianza $100(1 - \alpha)$ no tendrán la probabilidad de cobertura $(1 - \alpha)$).


El sesgo puede eliminarse, sin embargo, si reparametrizamos la densidad. Esto lo veremos en las siguientes secciones.




Ejemplo 1.2 - Distribución binomial (Sesgo de $L(\theta)$)

Supongamos que vemos resultados más extremos en el estudio de las cucarachas y que hubiéramos obtenido $n = 10$ y $y = 9$. Las Figuras 4a y 4b muestran el fuerte sesgo en las funciones de verosimilitud relativa y log-relativa.

Ejemplo 1.2 - Distribución binomial (Sesgo de $L(\theta)$)



(a) (—) $R(\theta; y)$; $\bullet \hat{\theta}$



(b) (—) $r(\theta; y)$; $\bullet \hat{\theta}$

Figure 4: Relative and log-relative likelihood for binomial data with $n = 10$ and $y = 9$.

Ejemplo 1.2 - Distribución binomial (Sesgo de $L(\theta)$)

Es atractivo trabajar con la cantidad pivotal tipo Wald para inferencias debido a que tenemos una fórmula para la pruebas de hipótesis e intervalos de confianza. Por lo tanto, queremos remover el sesgo de función de verosimilitud.

La solución es que en lugar de trabajar con θ lo hagamos con $g(\theta)$, una función 1-1. La función g mapea θ , definido en un rango finito, en los reales. Ejemplos:

1. $g(\theta) = \log\left(\frac{\theta}{1-\theta}\right) = \text{logit}(\theta)$
2. $g(\theta) = \Phi^{-1}(\theta)$, donde Φ es la función de densidad acumulativa de una variable aleatoria normal estándar.
3. $g(\theta) = \log(-\log \theta)$
4. $g(\theta) = \log(-\log(1 - \theta))$

Ejemplo 1.2 - Distribución binomial (Sesgo de $L(\theta)$)

Los estimadores de máxima verosimilitud e inferencias con base en estos métodos son invariantes ante reparametrizaciones, de forma que podemos construir intervalos de confianza para $g(\theta)$ y aplicar g^{-1} para obtener intervalos en términos de θ .

Este mecanismo está resumido en la Tabla 1. Esta técnica es muy usada en modelos lineales generalizados.

Ejemplo 1.2 - Distribución binomial (Sesgo de $L(\theta)$)

	Enfoque 1 Usar parametrización θ	Enfoque 2 Usar parametrización $\eta = g(\theta)$
lik	$\ell(\theta)$	$\ell(\eta)$
MLE	$\hat{\theta}$	$\hat{\eta}$
$\text{var}(\theta)$	$I_{\theta\theta}(\theta) = -\frac{\partial^2 \ell}{\partial \theta^2}$	$I_{\eta\eta}(\eta) = -\frac{\partial^2 \ell}{\partial \eta^2}$
95% CIs	$(\hat{\theta}_L, \hat{\theta}_U) = \{\hat{\theta} \pm 1.96 \times I^{-1/2}(\hat{\theta})\}$	$(\hat{\eta}_L, \hat{\eta}_U) = \{\hat{\eta} \pm 1.96 \times I^{-1/2}(\hat{\eta})\}$ $(\hat{\theta}_L, \hat{\theta}_U) = (g^{-1}(\hat{\eta}_L), g^{-1}(\hat{\eta}_U))$

Table 1: Construcción de intervalos de confianza al reparametrizar mediante una función 1-1.



Ejemplo 1.3 - Distribución Poisson (MLE)

Se llevó a cabo un estudio para examinar la tasa a la que las personas mayores se caen en un complejo de retiro. Se dio seguimiento a un total de 10 residentes en el transcurso de un año y se registró el número de caídas que sufrió cada persona.

En la muestra se observó un promedio de 2 caídas en el transcurso del periodo de seguimiento.

Comenzamos definiendo las variables aleatorias $Y_1, \dots, Y_{10}$, asumimos que son independientes e idénticamente distribuidas como variables aleatorias Poisson donde Y_i representa el número de caídas de la persona $i, i = 1, \dots, 10$. Tenemos que

$$\Pr(Y_i = y_i) = \frac{\theta^{y_i} e^{-\theta}}{y_i!}, \quad y_i = 0, 1, 2, 3, \dots, \quad i = 1, 2, \dots, 10$$

donde $\mathbb{E}(Y_i) = \theta$ y $\text{var}(Y_i) = \theta$.

Ejemplo 1.3 - Distribución Poisson (MLE)

Más generalmente, supongamos n datos observados $y_1, \dots, y_n$ de una distribución Poisson. La función de verosimilitud de θ es

$$L(\theta) = \prod_{i=1}^n \theta^{y_i} e^{-\theta} = \theta^{n\bar{y}} e^{-n\theta}$$

habiendo elegido cuidadosamente la constante $c = y_1! y_2! \dots y_n!$. Las funciones log-verosimilitud, de puntuación y de información observada son

$$\ell(\theta) = n\bar{y} \log \theta - n\theta,$$

$$S(\theta) = \ell'(\theta) = \frac{n\bar{y}}{\theta} - n$$

$$I(\theta) = -\ell''(\theta) = \frac{n\bar{y}}{\theta^2}$$

Obtenemos el MLE resolviendo $S(\theta) = 0$, lo que resulta en

$$\hat{\theta} = \bar{y}.$$

Ejemplo 1.3 - Distribución Poisson (MLE)

Evaluamos las funciones de log-verosimilitud y de información observada en $\theta = \hat{\theta}$ para obtener

$$\begin{aligned}\ell(\hat{\theta}) &= n\bar{y} \log \hat{\theta} - n\hat{\theta} = n\bar{y} \log \bar{y} - n\bar{y}, \\ I(\hat{\theta}) &= \frac{n\bar{y}}{\hat{\theta}^2} = \frac{n\bar{y}}{\bar{y}^2} = \frac{n}{\bar{y}}.\end{aligned}$$

La función de verosimilitud relativa es

$$\begin{aligned}r(\theta) &= \ell(\theta) - \ell(\hat{\theta}) = n\bar{y} \log \theta - n\theta - n\bar{y} \log \bar{y} + n\bar{y} \\ &= n\bar{y} \log \left(\frac{\theta}{\bar{y}} \right) - n(\theta - \bar{y})\end{aligned}$$


Al analizar la expresión $r(\theta)$ debe ser claro que estamos comparando los valores de la función log-verosimilitud de un cierto valor θ contra el MLE $\hat{\theta} = \bar{y}$.

Ejemplo 1.3 - Distribución Poisson (MLE)


La Figura 5a grafica la función de verosimilitud log-relativa para dos diferentes muestras hipotéticas de tamaños distintos, $n = 10$ y $n = 100$, en ambos casos con el mismo MLE $\bar{y} = 2$.

Se ilustra que a medida que el tamaño de muestra aumenta, la precisión de los estimadores de intervalo es mejor así como la calidad de la aproximación cuadrática de la función log-verosimilitud.

Ejemplo 1.3 - Distribución Poisson (MLE)



(a) $\bullet \hat{\theta}; \bullet (\hat{\theta}_L, \hat{\theta}_U)$



(b) $\bullet \hat{\theta}; \bullet (\hat{\theta}_L, \hat{\theta}_U)$

Figure 5: Log-relative likelihood for Poisson data, MLE, and 95% CIs with $n = 10$ and $n = 100$ both with $\bar{y} = 2$.

Ejemplo 1.3 - Distribución Poisson (MLE)

Los intervalos de confianza con base en $r(\theta)$ se construyen de la siguiente forma. Dado que $-2r(\theta)$ tiene una distribución aproximada χ_1^2 como los valores de θ tales que

$$-2r(\theta) < \chi_1^2(1 - \alpha) = 3.841$$

o, equivalentemente,

$$r(\theta) > -\frac{3.841}{2} = -1.92.$$

Estos valores de θ son los que se corresponden con los puntos sobre $r(\theta)$ que corta la línea horizontal (- - -) en la Figura 5a.

Los intervalos de confianza con base en $r(\theta)$ para las dos muestras de tamaños $n = 10$ y $n = 100$ los podemos encontrar desplazando $r(\theta)$ hacia arriba 1.92 unidades como se muestra en la Figura 5b, de tal forma que ahora cruzan 0 exactamente en los puntos de la curva que se corresponden con $\hat{\theta}_L$ y $\hat{\theta}_U$).

Ejemplo 1.3 - Distribución Poisson (MLE)

Encontramos los valores $\hat{\theta}_L$ y $\hat{\theta}_U$) como las raíces de la ecuación $r(\theta) + 1.92 = 0$, las cuales son

$$\{\theta : r(\theta; n = 10) > -1.92\} = (1.25, 3.01)$$

$$\{\theta : r(\theta; n = 100) > -1.92\} = (1.74, 2.29)$$

Al comparar estos dos intervalos de confianza nos damos cuenta de que aquel con $n = 100$ es mucho más estrecho.

Ejemplo 1.3 - Distribución Poisson (MLE)

Los intervalos de confianza al 95% utilizando la aproximación normal están dados por

$$\begin{aligned} & \left(\hat{\theta} - 1.96 \times I^{-1/2}(\hat{\theta}), \quad \hat{\theta} + 1.96 \times I^{-1/2}(\hat{\theta}) \right) \\ &= \left(\bar{y} - 1.96 \times \sqrt{\frac{\bar{y}}{n}}, \quad \bar{y} + 1.96 \times \sqrt{\frac{\bar{y}}{n}} \right). \end{aligned}$$

Los intervalos de confianza para $n = 10$ y $n = 100$ son

$$\begin{aligned} & \left(2 - 1.96 \times \sqrt{\frac{2}{10}}, \quad 2 + 1.96 \times \sqrt{\frac{2}{10}} \right) = (1.12, 2.88) \\ & \left(2 - 1.96 \times \sqrt{\frac{2}{100}}, \quad 2 + 1.96 \times \sqrt{\frac{2}{100}} \right) = (1.72, 2.28) \end{aligned}$$

Ejemplo 1.3 - Distribución Poisson (MLE)

Comparando los intervalos de confianza calculados a partir de $r(\theta)$ contra los de la aproximación normal vemos que son mucho más parecidos aquellos con $n = 100$ debido a que la aproximación cuadrática es mejor a medida que aumenta el tamaño de muestra.

Podemos utilizar el método de Newton para calcular el intervalo de confianza con base en $r(\theta)$. Nos interesa resolver la ecuación $-2r(\theta) = 3.841$ o, equivalentemente, $r(\theta) + 1.92 = 0$. La fórmula del algoritmo es

$$\theta^{(i+1)} = \theta^{(i)} - \frac{r(\theta^{(i)}) + 1.92}{S(\theta^{(i)})} = \theta^{(i)} - \frac{n\bar{y} \log(\theta^{(i)}/\bar{y}) - n(\theta^{(i)} - \bar{y}) + 1.92}{n\bar{y}/\theta^{(i)} - n}$$

¡Verifique cómo derivar esta fórmula!

Ejemplo 1.3 - Distribución Poisson (MLE)

Utilizando como valores iniciales $(\hat{\theta}_{L1}, \hat{\theta}_{U1}) = (0.1, 10)$ para el caso de $n = 10$ y $\hat{y} = 2$, las iteraciones se muestran en la Tabla 2

i	$\hat{\theta}_{Li}$	$\hat{\theta}_{Ui}$
1	0.10000	10.00000
2	0.30502	4.26859
3	0.64156	3.22181
4	0.98139	3.03137
5	1.18300	3.02068
6	1.23685	3.02064
7	1.24011	3.02064
8	1.24012	3.02064
9	1.24012	3.02064

Table 2: Iteraciones del método de Newton para calcular los intervalos de confianza al 95% con base en $r(\theta)$.

Ejemplo 1.3 - Distribución Poisson (MLE)

El código de R para las iteraciones se muestra en el código de R a continuación. Vea el archivo GLM_Examples.R para más detalles y otras opciones del algoritmo.

- > Newtons method to find the CIs
- > Define a function to be evaluated iteratively

> Option 1: f() has an explicit form

```
f <- function(n, y, theta, theta.hat, alpha){  
  cv <- qnorm(1-alpha/2)           % critical value  
  rl <- n*y*log(theta/y)-n*(theta-y) % relative likelihood  
  sc <- n*y/theta - n              % score  
  out <- theta-(rl+cv)/sc  
  return(out)  
}  
f(n=10,y=2,theta=c(0.1,10),theta.hat=2,0.05)  
[1] 0.3050246 4.2685903
```

Ejemplo 1.3 - Distribución Poisson (MLE)

```
> Setup functions arguments
```

```
n <- 10  
ybar <- 2  
theta.hat <- ybar  
alpha <- 0.05
```

```
> Initialize iteration parameters
```

```
i <- 1  
d <- 5  
eps <- 1e-5  
theta <- matrix(c(0.1, 10), ncol=2) % Initial values
```

Ejemplo 1.3 - Distribución Poisson (MLE)

```
> There are many ways to iterate. Consider the while loop
while(d > eps){
  theta <- rbind(theta ,
                  f(n,ybar , theta [ i , ] , theta .hat , alpha ))
  d <- max(abs(theta [ i+1,]-theta [ i , ]))
  i <- i+1 }
```

theta

	[,1]	[,2]
[1 ,]	0.1000000	10.000000
[2 ,]	0.3050246	4.268590
[3 ,]	0.6415550	3.221814
[4 ,]	0.9813892	3.031369
[5 ,]	1.1830020	3.020675
[6 ,]	1.2368518	3.020639
[7 ,]	1.2401114	3.020639
[8 ,]	1.2401227	3.020639
[9 ,]	1.2401227	3.020639

Máxima verosimilitud para vectores de parámetros

Supongamos que $f(y; \boldsymbol{\theta})$ es una función de densidad (probabilidad) donde $\boldsymbol{\theta} \in \Omega$ es un vector de p parámetros continuos. definimos las funciones siguientes:

$$L(\boldsymbol{\theta}) : \text{función de verosimilitud} \quad (7a)$$

$$\ell(\boldsymbol{\theta}) = \log L(\boldsymbol{\theta}) : \text{función log-verosimilitud} \quad (7b)$$

$$S(\boldsymbol{\theta}) = \frac{\partial \ell(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} : \text{vector de puntuación } p \times 1 \quad (7c)$$

$$I(\boldsymbol{\theta}) = -\frac{\partial^2 \ell(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}^2} : \text{matriz de información } p \times p \quad (7d)$$

$$\mathcal{I}(\boldsymbol{\theta}) = \mathbb{E}\{I(\boldsymbol{\theta})\} : \text{función de información esperada} \quad (7e)$$

$$R(\boldsymbol{\theta}) = \frac{L(\boldsymbol{\theta})}{L(\hat{\boldsymbol{\theta}})} : \text{función de verosimilitud relativa} \quad (7f)$$

$$r(\boldsymbol{\theta}) = \log R(\boldsymbol{\theta}) = \log \left(\frac{L(\boldsymbol{\theta})}{L(\hat{\boldsymbol{\theta}})} \right) = \ell(\boldsymbol{\theta}) - \ell(\hat{\boldsymbol{\theta}}) \quad (7g)$$

Máxima verosimilitud para vectores de parámetros

Enfatizamos que S es ahora una p -vector (el gradiente de ℓ) y ahora I es una matriz $p \times p$ (el negativo del Hessiano de ℓ).

El algoritmo de Newton-Raphson es igualmente aplicable que en caso de parámetros escalares, pero ahora con los vectores y matrices como sigue

$$\boldsymbol{\theta}^{(i+1)} = \boldsymbol{\theta}^{(i)} + I^{-1}(\boldsymbol{\theta}^{(i)})S(\boldsymbol{\theta}^{(i)}).$$

Aplicamos iterativamente la fórmula hasta lograr convergencia, pero ahora requerimos que $I(\hat{\boldsymbol{\theta}})$ sea una matriz definida positiva).

Máxima verosimilitud para vectores de parámetros

Las distribuciones de probabilidad utilizadas con mayor frecuencia tienen vectores de parámetros (i.e. varios aspectos de la distribución de la respuesta son desconocidos, tal como la media y la varianza), pero el interés se centra en un parámetro en particular (tal como la media).

Supongamos que $\theta = (\alpha, \beta)$, donde α es un vector de nuisance parameters **¿parámetros molestos?** y β es un parámetro escalar de interés.

Cuando la dimensión de α es pequeña, es posible aplicar métodos estándar de máxima verosimilitud para problemas de parámetros múltiples.

Máxima verosimilitud para vectores de parámetros

Sea $I = I(\boldsymbol{\alpha}, \beta)$ la matriz de información por bloques con la forma

$$I = I(\boldsymbol{\alpha}, \beta) = \begin{bmatrix} I_{\alpha\alpha}(\boldsymbol{\alpha}, \beta) & I_{\alpha\beta}(\boldsymbol{\alpha}, \beta) \\ I_{\beta\alpha}(\boldsymbol{\alpha}, \beta) & I_{\beta\beta}(\boldsymbol{\alpha}, \beta) \end{bmatrix}$$

donde

$$I_{\alpha\alpha} = -\frac{\partial^2 \ell}{\partial \boldsymbol{\alpha} \partial \boldsymbol{\alpha}^\top} \quad \text{es } p \times p$$

$$I_{\alpha\beta} = -\frac{\partial^2 \ell}{\partial \boldsymbol{\alpha} \partial \beta} \quad \text{es } p \times 1$$

$$I_{\beta\alpha} = -\frac{\partial^2 \ell}{\partial \beta \partial \boldsymbol{\alpha}^\top} \quad \text{es } 1 \times p$$

$$I_{\beta\beta} = -\frac{\partial^2 \ell}{\partial \beta \partial \beta} \quad \text{es escalar}$$

Máxima verosimilitud para vectores de parámetros

Sea $\hat{\alpha}\beta$ el valor estimado por máxima verosimilitud de α para un valor particular de β . Podemos hacer inferencia con base en los siguientes resultados:

$$-2 \left(\ell(\hat{\alpha}, \beta) - \ell(\hat{\alpha}, \hat{\beta}) \right) \sim \chi^2_1 \quad (8a)$$

$$S^2_{\beta}(\hat{\alpha}, \beta) I^{\beta\beta}(\hat{\alpha}, \hat{\beta}) \sim \chi^2_{(1)} \quad (8b)$$

$$\frac{(\hat{\beta} - \beta)^2}{I^{\beta\beta}(\hat{\alpha}, \hat{\beta})} \sim \chi^2_{(1)} \quad (8c)$$

donde $S_{\beta} = \partial \ell / \partial \beta$ y $I^{\beta\beta}$ es el (β, β) elemento de la inversa de la matriz de información evaluada en $(\hat{\alpha}, \hat{\beta})$ y dada por

$$I^{\beta\beta}(\hat{\alpha}, \hat{\beta}) = [I_{\beta\beta} - I_{\beta\alpha} I_{\alpha\alpha}^{-1} I_{\alpha\beta}]^{-1}.$$

Máxima verosimilitud para vectores de parámetros θ

Notemos que cuando el parámetro de interés $\beta^\top$ es un vector, entonces los resultados distribucionales se sostienen, pero en (8b) y (8c) los resultados son en términos de los vectores S_β y $\beta^\top$ y sus correspondientes matrices de información, y las correspondientes distribuciones serán χ_k^2 donde los grados de libertad k pueden ser mayor que 1.

Específicamente, sea $\theta = (\alpha^\top, \beta^\top)^\top$ donde α es un vector de nuisance parameters **¿parámetros perturbadores?** de dimensión p y $\beta^\top$ es un vector de parámetros de interés de dimensión q . Sea I la matriz de información observada por bloques partida de acuerdo con $(\alpha^\top, \beta^\top)$ tomando la forma siguiente:

Máxima verosimilitud para vectores de parámetros θ

$$I = I(\alpha, \beta) = \begin{bmatrix} I_{\alpha\alpha}(\alpha, \beta) & I_{\alpha\beta}(\alpha, \beta) \\ I_{\beta\alpha}(\alpha, \beta) & I_{\beta\beta}(\alpha, \beta) \end{bmatrix}$$

donde

$$I_{\alpha\alpha} = -\frac{\partial^2 \ell}{\partial \alpha \partial \alpha^\top} \quad \text{es } p \times p$$

$$I_{\alpha\beta} = -\frac{\partial^2 \ell}{\partial \alpha \partial \beta^\top} \quad \text{es } p \times q$$

$$I_{\beta\alpha} = -\frac{\partial^2 \ell}{\partial \beta \partial \alpha^\top} \quad \text{es } q \times p$$

$$I_{\beta\beta} = -\frac{\partial^2 \ell}{\partial \beta \partial \beta^\top} \quad \text{es } q \times q$$

Máxima verosimilitud para vectores de parámetros θ

Sea $\hat{\alpha}\beta$ el valor estimado por máxima verosimilitud de α para un valor particular de β . Entonces podemos hacer inferencia con base en los siguientes resultados:

$$-2 \left(\ell(\hat{\alpha}, \beta) - \ell(\hat{\alpha}, \hat{\beta}) \right) \sim \chi_q^2 \quad (9a)$$

$$S_{\beta}^{\top}(\hat{\alpha}, \beta) I^{\beta\beta}(\hat{\alpha}, \hat{\beta}) S_{\beta}^{\top}(\hat{\alpha}, \beta) \sim \chi_{(q)}^2 \quad (9b)$$

$$(\hat{\beta} - \beta)^{\top} \left[I^{\beta\beta}(\hat{\alpha}, \hat{\beta}) \right]^{-1} (\hat{\beta} - \beta) \sim \chi_{(q)}^2 \quad (9c)$$

donde

$$S_{\beta} = \frac{\partial \ell}{\partial \beta}$$

y

$$I^{\beta\beta}(\hat{\alpha}, \hat{\beta}) = [I_{\beta\beta} - I_{\beta\alpha} I_{\alpha\alpha}^{-1} I_{\alpha\beta}]^{-1}$$

es evaluada en $\hat{\theta} = (\hat{\alpha}, \hat{\beta})^T$. Hay ocasiones en las que estos resultados más generales son útiles.

Estadísticos suficientes

Supongamos $\mathbf{y}^\top = [y_1, y_2, \dots, y_n]$ es la realización de una variable aleatoria multivariada $\mathbf{Y}^\top = [Y_1, Y_2, \dots, Y_n]$.

Un estadístico es una función de $\mathbf{Y}$, $T(\mathbf{Y})$, que tiene valor observado $T(\mathbf{y})$.

Supongamos que la función de densidad (probabilidad) de $\mathbf{Y}$ es $f(\mathbf{y}; \theta)$ y que nos interesa estimar θ . Usualmente restringimos la atención al caso en que $Y_1, \dots, Y_n$ son independientes e idénticamente distribuidas, pero por ahora consideramos el caso mas general.

La función de verosimilitud para estimar θ es proporcional a $f(\mathbf{y}; \theta)$. Supongamos que podemos factorizar esta función como

$$f(\mathbf{y}; \theta) = f_1(T(\mathbf{y}); \theta) f_2(\mathbf{y} \mid T(\mathbf{y}); \theta).$$

Un *estadístico suficiente* (*sufficient statistic*) para estimar el parámetro θ es aquel que, en cierto sentido, captura toda la información de θ contenida en los datos. Cualquier información adicional en la muestra, aparte del valor del estadístico suficiente, no está relacionada con θ .

Estas consideraciones conducen a la técnica de reducción de los datos conocida como el *principio de suficiencia*.

Principio de suficiencia

Principio de suficiencia. Si $T(\mathbf{Y})$ es un estadístico suficiente de θ , entonces cualquier inferencia acerca de θ debe depender de la muestra $\mathbf{Y}$ únicamente mediante el valor $T(\mathbf{Y})$.

Esto es, si $\mathbf{y}$ y $\mathbf{x}$ son dos muestras tales que $T(\mathbf{y}) = T(\mathbf{x})$, entonces las inferencias acerca de θ serían las mismas sin importar si la muestra que observamos es $\mathbf{Y} = \mathbf{y}$ o $\mathbf{X} = \mathbf{x}$.

Es conveniente notar que ambos eventos $\{\mathbf{Y} = \mathbf{y}\}$ y $\{\mathbf{X} = \mathbf{x}\}$ son un subconjunto del evento $\{T(\mathbf{Y}) = T(\mathbf{y})\}$ y que las probabilidades condicionales

$$\Pr\{\mathbf{Y} = \mathbf{y} \mid T(\mathbf{Y}) = T(\mathbf{y})\} = \Pr\{\mathbf{X} = \mathbf{x} \mid T(\mathbf{Y}) = T(\mathbf{y})\}$$

no dependen de θ .

Decimos entonces que el estadístico $T(\mathbf{Y})$ es *suficiente* para estimar θ si la densidad condicional $f_2(\mathbf{y} \mid T(\mathbf{y}); \theta)$ no depende de θ . Más aún, si $T(\mathbf{Y})$ es suficiente, también lo es cualquier función uno a uno de $T(\mathbf{Y})$.

Por lo tanto, es esta forma de la función de verosimilitud la que determina un estadístico suficiente y formalizamos este argumento en el *Teorema de factorización* (*Factorization theorem*).

Theorem

(Factorization theorem) Una condición necesaria y suficiente para que $T(\mathbf{Y})$ sea suficiente para θ es que existan funciones $m_1(T(\mathbf{y}), \theta)$ y $m_2(\mathbf{y})$ tales que para toda $\theta \in \Omega$,

$$L(\theta; \mathbf{y}) = m_1(T(\mathbf{y}), \theta)m_2(\mathbf{y}).$$

Proof.

No demostraremos este teorema en clase.



Estadísticos suficientes (Distribución Poisson)

En el Ejemplo 1.3 [??] analizamos la distribución Poisson. En este caso la función de verosimilitud está determinada por $\bar{y}$ y, por lo tanto, $\bar{y}$ es el estimador suficiente minimal de θ .

Estadísticos suficientes (Muestra Bernoulli)

Si el Ejemplo 1.1 [??] se trata de una serie de n experimentos Bernoulli, entonces la suma de estas variables aleatorias Bernoulli con y denotando el número de éxitos sería el estadístico suficiente minimal.

Este ejemplo, formulado como una muestra binomial, ilustra una situación en la que la manera más natural de caracterizar el problema es mediante una reducción preliminar de los datos con consideraciones de suficiencia implícitas.

Estadísticos suficientes (Vectores de parámetros)

Notemos que si $\boldsymbol{\theta}^T = (\alpha, \beta)$ entonces la noción de suficiencia se extiende al tomar $T(\mathbf{Y})$ como suficiente para α si es suficiente para α considerando β conocido. Esto implicaría que la distribución condicional $\Pr(\mathbf{Y} = \mathbf{y} \mid T(\mathbf{Y}) = T(\mathbf{y}))$ depende solamente de β pero no de α . Esto es relevante para las funciones de verosimilitud condicionales.

La familia exponencial y modelos lineales generalizados

Supongamos que Y_i es una variable aleatoria con función de densidad (probabilidad) $f(y_i; \theta_i, \phi)$. Decimos que la distribución de Y es un miembro de la *familia exponencial* si $f(y_i; \theta_i, \phi)$ puede factorizarse como

$$f(y_i; \theta_i, \phi) = \exp \left\{ \frac{y_i \theta_i - b(\theta_i)}{a_i(\phi)} + c(y_i; \phi) \right\} \quad (10)$$

para funciones específicas a_i, b y c , con ϕ conocida.

- θ se denomina el *parámetro canónico* (*canonical parameter*)
- ϕ se denomina *parámetro de escala* (*scale parameter*) y es constante para todo $i = 1, \dots, n$. Por ahora consideremos ϕ especificado.

Consideremos la función log-verosimilitud para una única observación de la familia exponencial

$$\ell(\theta, \phi; y) \propto \log f(y; \theta, \phi) = \frac{y\theta - b(\theta)}{a(\phi)} + c(y; \phi) \quad (11a)$$

$$S(\theta) = \frac{\partial \ell}{\partial \theta} = \frac{y - b'(\theta)}{a(\phi)} \quad (11b)$$

$$I(\theta) = -\frac{\partial^2 \ell}{\partial \theta^2} = \frac{b''(\theta)}{a(\phi)}. \quad (11c)$$

En los resultados generales siguientes debe entenderse que los límites de las integrales son sobre el soporte de Y .

Teoría general

$$1. \mathbb{E}\{S(\theta)\} = 0.$$

$$\begin{aligned}\int f(y; \theta, \phi) dy &= 1 \\ \frac{\partial}{\partial \theta} \int f(y; \theta, \phi) dy &= \frac{\partial 1}{\partial \theta} \\ \int \frac{\partial}{\partial \theta} f(y; \theta, \phi) dy &= 0 \quad \text{under weak regularity conditions}\end{aligned}$$

Sabemos que

$$\frac{\partial}{\partial \theta} \log f(y; \theta, \phi) = \frac{1}{f(y; \theta, \phi)} \frac{\partial}{\partial \theta} f(y; \theta, \phi)$$

Por lo tanto,

$$\begin{aligned}\int \frac{\partial}{\partial \theta} \log f(y; \theta, \phi) f(y; \theta, \phi) dy &= 0 \\ \mathbb{E}\{S(\theta)\} &= 0\end{aligned} \tag{12}$$

$$2. \mathbb{E} \left(-\frac{\partial^2}{\partial \theta^2} \log f(y; \theta, \phi) \right) = \mathbb{E} \left(\left\{ \frac{\partial}{\partial \theta} \log f(y; \theta, \phi) \right\}^2 \right)$$

Diferenciando (12) tenemos

$$\begin{aligned} \frac{\partial}{\partial \theta} \int \frac{\partial}{\partial \theta} \log f(y; \theta, \phi) f(y; \theta, \phi) dy &= \frac{\partial}{\partial \theta} \int \frac{\partial^2}{\partial \theta^2} \log f(y; \theta, \phi) f(y; \theta, \phi) dy + \int \frac{\partial}{\partial \theta} \log f(y; \theta, \phi) \frac{\partial}{\partial \theta} f(y; \theta, \phi) dy = 0 \\ \int \frac{\partial^2}{\partial \theta^2} \log f(y; \theta, \phi) f(y; \theta, \phi) dy + \int \left(\frac{\partial}{\partial \theta} \log f(y; \theta, \phi) \right)^2 dy &= 0, \end{aligned}$$

lo que implica

$$\mathbb{E} \left(-\frac{\partial^2}{\partial \theta^2} \log f(y; \theta, \phi) \right) = \mathbb{E} \left(\left\{ \frac{\partial}{\partial \theta} \log f(y; \theta, \phi) \right\}^2 \right) \quad (13)$$

Estos resultados son útiles para derivar los siguientes.

3. Media:

$$\mathbb{E}\{S(\theta)\} = 0 \implies \frac{\mathbb{E}(Y - b'(\theta))}{a(\phi)} = 0 \quad \text{por (12) and (11b)}$$

lo que a su vez implica que $\mathbb{E}(Y) = b'(\theta) = \mu$. El resultado clave es

$$\mu = b'(\theta). \quad (14)$$

4. Varianza:

El resultado (13) implica que

$$\mathbb{E}\left(\frac{b''(\theta)}{a(\phi)}\right) = \mathbb{E}\left(\left\{\frac{Y - b'(\theta)}{a(\phi)}\right\}^2\right) \quad \text{por (11b) y (11c)}$$

lo que a su vez implica

$$\frac{b''(\theta)}{a(\phi)} = \frac{\mathbb{E}\{(Y - \mu)^2\}}{a^2(\phi)} = \frac{\text{var}(Y)}{a^2(\phi)}.$$

4. La varianza de Y es, entonces

$$\text{var}(Y) = b''(\theta)a(\phi), \quad (15)$$

esto es un producto de

- $b''(\theta)$
- Una función del parámetro canónico y , por lo tanto, de la media de la distribución.
 - También se conoce como la *función de varianza* y denotada por $V(\mu)$ cuando es una función de μ , la media. Entonces también podemos escribir (15) como

$$\text{var}(Y) = V(\mu)a(\phi). \quad (16)$$

- Nótese que no es en general la varianza de Y .
- $a(\phi)$
- Una función únicamente de ϕ .
 - También puede escribirse como $a(\phi) = \phi/w$, donde ϕ se conoce como un *parámetro de dispersión* y w es un peso *a priori* para esta observación

4. Notemos finalmente que $\mathbb{E}\{S(\theta)\} = 0$ implica que

$$\begin{aligned}\text{var}\{S^2(\theta)\} &= \mathbb{E}\{S(\theta)\} = \mathbb{E}\left(\left\{\frac{\partial}{\partial\theta} \log f(y; \theta, \phi)\right\}^2\right) \\ &= \mathbb{E}\left(-\frac{\partial^2}{\partial\theta^2} \log f(y; \theta, \phi)\right) \\ &= \frac{b''(\theta)}{a(\phi)} \\ &= \frac{\text{var}(Y)}{\{a(\phi)\}^2}.\end{aligned}$$

Modelo Lineal Generalizado (Básicos)

El modelo lineal generalizado (Generalized Linear Model - GLM) unifica una variedad de métodos estadísticos.

El GLM se define en términos las variables respuesta $Y_1, \dots, Y_n$, variables aleatorias cada una de la familia exponencial.

La distribución de cada Y_i tiene la forma canónica y depende de un único parámetro θ_i (las θ_i no son necesariamente todas iguales), entonces su densidad es de la forma (10). La densidad conjunta de las n variables respuesta sería

$$\begin{aligned} f(\mathbf{y}; \boldsymbol{\theta}, \phi) &= \prod_{i=1}^n \exp \left\{ \frac{y_i \theta_i - b(\theta_i)}{a_i(\phi)} + c(y_i; \phi) \right\} \\ &= \exp \left\{ \sum_{i=1}^n \frac{y_i \theta_i}{a_i(\phi)} - \sum_{i=1}^n \frac{b(\theta_i)}{a_i(\phi)} + \sum_{i=1}^n c(y_i; \phi) \right\}. \end{aligned}$$

Modelo Lineal Generalizado (Básicos)

Los parámetros θ_i usualmente no son de interés directo (bien podría haber uno de estos parámetros para cada observación). En la especificación del modelo nos interesa estimar un conjunto de parámetros de dimensión $p < n$, $\boldsymbol{\beta}^\top = [\beta_0, \dots, \beta_{p-1}]$.

Supongamos que $E(Y_i) = \mu_i$, donde μ_i es una función de θ_i . En un modelo lineal generalizado hacemos una transformación de μ_i tal que

$$g(\mu_i) = \mathbf{x}_i^\top \boldsymbol{\beta}. \quad (17)$$

Modelo Lineal Generalizado (Básicos)

En (17):

1. g es monótonica, diferenciable y se denomina **función de ligadura (link function)**. Esto es, g es plana, creciente o decreciente con μ_i , pero no puede ser creciente para ciertos valores de μ_i y decreciente para otros.
2. El vector $\mathbf{x}_i$ es un vector $p \times 1$ de variables explicativas (covariables o predictores).
3. β es un vector $p \times 1$ de parámetros.
4. Relacionamos los dos vectores $\mathbf{x}_i$ y β mediante la combinación lineal $\mathbf{x}_i^\top \beta$. Denominamos esta combinación lineal como **predictor lineal (linear predictor)** y la denotamos por η_i

$$\eta_i = \mathbf{x}_i^\top \beta.$$

Modelo Lineal Generalizado (Básicos)

La función de ligadura relaciona el predictor lineal $\mathbf{x}_i^\top \boldsymbol{\beta} = \eta_i$ con la media μ_i (el valor esperado de la variable aleatoria Y_i).

En síntesis, los GLM constan de tres componentes:

1. **Componente aleatorio.** Un supuesto es que las variables respuestas $Y_1, \dots, Y_n$ son variables aleatorias independientes, cada una proviene de una distribución de la familia exponencial, e.g. binomial, Poisson o normal.
2. **Componente sistemático.** Es el predictor lineal $\mathbf{x}_i^\top \boldsymbol{\beta}$ y es esencialmente modelo.
3. **Función de ligadura (link function).** Es el vínculo entre los otros dos componentes postulando que $g(\mu_i) = \mathbf{x}_i^\top \boldsymbol{\beta} = \eta_i$.

Consideremos la función log-verosimilitud de la familia exponencial

$$\ell(\theta, \phi; y) = \frac{y\theta - b(\theta)}{a(\phi)} + c(y; \phi).$$

Si $\mathbf{y}^\top = [y_1, \dots, y_n]$ es una muestra aleatoria de n observaciones, introducimos el subíndice i y entonces la función log-verosimilitud para la muestra sería

$$\ell(\boldsymbol{\theta}, \phi; \mathbf{y}) = \sum_{i=1}^n \frac{y_i \theta_i - b(\theta_i)}{a_i(\phi)} + c(y_i; \phi).$$

Si hacemos que

$$\theta_i = \eta_i = \mathbf{x}_i^\top \boldsymbol{\beta}$$

decimos que tenemos el **link canónico** (i.e.

parámetro canónico = predictor lineal y ℓ toma la forma

$$\begin{aligned}\ell(\boldsymbol{\beta}, \phi; \mathbf{y}) &= \sum_{i=1}^n \frac{y_i \mathbf{x}_i^\top \boldsymbol{\beta} - b(\mathbf{x}_i^\top \boldsymbol{\beta})}{a_i(\phi)} + c(y_i; \phi) \\ &= \sum_{j=1}^p \beta_j \left(\sum_{i=1}^n \frac{y_i x_{ij}}{a_i(\phi)} \right) - \sum_{i=1}^n \frac{b(\mathbf{x}_i^\top \boldsymbol{\beta})}{a_i(\phi)} + \sum_{i=1}^n c(y_i; \phi).\end{aligned}$$

Si ϕ es conocido, $\sum_{i=1}^n y_i x_{ij}$ es un estimador suficiente de β_j o, equivalentemente, $X\mathbf{y}$ es un estimador suficiente de $\boldsymbol{\beta}$.

Las ligaduras canónicas son útiles por sus propiedades estadísticas, pero el contexto y la bondad de ajuste son los que deberían motivar la elección de la función de ligadura.

Con frecuencia la ligadura canónica es de hecho apropiada (i.e. regresión lineal con observaciones normalmente distribuidas, regresión logística).

Analizamos las distribuciones más comunes a continuación.

Distribución normal y la familia exponencial

Omitamos el subíndice i , consideremos una única observación de la distribución $\mathcal{N}(\mu, \sigma^2)$. Tiene densidad

$$\begin{aligned} f(y; \mu, \sigma^2) &= \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{y - \mu}{2\sigma^2} \right\} \\ &= \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{y^2 + \mu^2 - 2y\mu}{2\sigma^2} \right\} \\ &= \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{y\mu - \mu^2/2}{\sigma^2} - \frac{y^2}{2\sigma^2} \right\} \\ &= \exp \left\{ -\frac{y\mu - \mu^2/2}{\sigma^2} - \frac{y^2}{2\sigma^2} - \frac{\log \sqrt{2\pi\sigma^2}}{2} \right\} \end{aligned}$$

Distribución normal y la familia exponencial

$$f(y; \mu, \sigma^2) = \exp \left\{ -\frac{y\mu - \mu^2/2}{\sigma^2} - \frac{y^2}{2\sigma^2} - \frac{\log \sqrt{2\pi\sigma^2}}{2} \right\}$$

Empatando términos con la expresión general de la familia exponencial (10) vemos que

$$\theta = \mu \tag{18a}$$

$$\phi = \sigma^2 \tag{18b}$$

$$a(\phi) = \phi \tag{18c}$$

$$b(\theta) = \frac{\theta^2}{2} = \frac{\mu^2}{2} \tag{18d}$$

$$c(y; \phi) = -\frac{1}{2} \left(\frac{y^2}{\phi} + \log \sqrt{2\pi\sigma^2} \right) \tag{18e}$$

$$f(y; \theta, \phi) = \exp \left\{ -\frac{y\mu - \mu^2/2}{\sigma^2} - \frac{1}{2} \left(\frac{y^2}{\sigma^2} + \log \sqrt{2\pi\sigma^2} \right) \right\} \tag{18f}$$

Distribución normal y la familia exponencial

$$\theta = \mu$$

$$\phi = \sigma^2$$

$$a(\phi) = \phi$$

$$b(\theta) = \frac{\theta^2}{2} = \frac{\mu^2}{2}$$

$$\text{media : } b'(\theta) = \theta = \mu \quad (19a)$$

$$\text{varianza : } \text{var}(Y) = b''(\theta)a(\phi) = 1 \cdot \phi = \sigma^2 \quad (19b)$$

$$\text{función de varianza : } V(\mu) = b''(\theta) = 1 \quad (19c)$$

$$\text{ligadura canónica : } \eta = \theta = \mu \quad (\text{identity}). \quad (19d)$$

Distribución Poisson y la familia exponencial

La densidad de la distribución Poisson es

$$f(y; \theta) = \frac{\lambda^y e^{-\lambda}}{y!}$$

y reorganizando la expresión tenemos

$$f(y; \theta, \phi) = \exp \{y \log \lambda - \lambda - \log y!\}$$

Empatando términos con la expresión general de la familia exponencial (10) tenemos

$$\theta = \log \lambda \tag{20a}$$

$$\phi = 1 \tag{20b}$$

$$a(\phi) = 1 \tag{20c}$$

$$b(\theta) = e^\theta = \lambda \tag{20d}$$

$$c(y; \phi) = -\log y! \tag{20e}$$

Distribución Poisson y la familia exponencial

$$\theta = \log \lambda$$

$$\phi = 1$$

$$a(\phi) = 1$$

$$b(\theta) = e^{\theta} = \lambda$$

$$\text{media : } b'(\theta) = e^{\theta} = \mu = \lambda \quad (21a)$$

$$\text{varianza : } \text{var}(Y) = b''(\theta)a(\phi) = e^{\theta} \cdot 1 = \mu \quad (21b)$$

$$\text{función de varianza : } V(\mu) = b''(\theta) = e^{\theta} = \mu. \quad (21c)$$

$$\text{ligadura canónica : } \eta = \theta = \log \mu = \eta \text{ (log link).} \quad (21d)$$

Distribución Binomial y la familia exponencial

Si $V \sim \text{Bin}(n, \pi)$ entonces su función de probabilidad es

$$f(v; \pi) = \binom{n}{v} \pi^v (1 - \pi)^{n-v}; \quad v = 0, 1, \dots, n.$$

Consideremos la transformación $Y = V/n$. Entonces,

$$f(y; \pi) = \binom{n}{ny} \pi^{ny} (1 - \pi)^{n-ny}, \quad y = 0, 1/n, 2/n, \dots, 1.$$

Podemos escribir $f(y; \pi)$ como

$$\begin{aligned} f(y; \pi) &= \exp \left\{ ny \log \pi + (n - ny) \log(1 - \pi) + \log \binom{n}{ny} \right\} \\ &= \exp \left\{ ny \log \{ \pi / (1 - \pi) \} + n \log(1 - \pi) + \log \binom{n}{ny} \right\} \\ &= \exp \left\{ \frac{y \log \{ \pi / (1 - \pi) \} + n \log(1 - \pi)}{n^{-1}} + \log \binom{n}{ny} \right\}. \end{aligned}$$

Distribución Binomial y la familia exponencial

$$f(y; \pi) = \exp \left\{ \frac{y \log\{\pi/(1 - \pi)\} + n \log(1 - \pi)}{n^{-1}} + \log \binom{n}{ny} \right\}.$$

Tenemos entonces que

$$\theta = \log \left(\frac{\pi}{1 - \pi} \right) \quad (22a)$$

$$\phi = 1; w = n \quad (22b)$$

$$a(\phi) = \frac{\phi}{w} = \frac{1}{n} \quad (22c)$$

$$b(\theta) = \log(1 + \exp\{\theta\}) = -\log(1 - \pi) \quad (22d)$$

$$c(y; \phi) = \log \binom{n}{ny}. \quad (22e)$$

Distribución Binomial y la familia exponencial

$$\theta = \text{logit } \pi; \phi = 1/n; a(\phi) = 1/n; b = \log(1 + \exp\{\theta\}).$$

$$\text{media : } b'(\theta) = \frac{e^\theta}{1 + e^\theta} = \mu = \pi \quad (23a)$$

$$\text{varianza : } \text{var}(Y) = b''(\theta)a(\phi) = \frac{e^\theta(1 + e^\theta) - e^\theta e^\theta}{(1 + e^\theta)^2} \left(\frac{1}{n}\right) \quad (23b)$$

$$= \left(\frac{e^\theta}{1 + e^\theta}\right) \left(\frac{1}{1 + e^\theta}\right) \left(\frac{1}{n}\right) \quad (23c)$$

$$= \mu(1 - \mu) \left(\frac{1}{n}\right) \quad (23d)$$

$$= \pi(1 - \pi) \left(\frac{1}{n}\right) \quad (23e)$$

$$\text{función de varianza : } V(\mu) = b''(\theta) = \mu(1 - \mu) = \pi(1 - \pi) \quad (23f)$$

$$\text{ligadura canónica : } \eta = \theta = \log \left(\frac{\mu}{1 - \mu}\right) \quad (\text{logit link}). \quad (23g)$$

	Normal	Poisson	Binomial
θ	μ	$\log \lambda$	$\log\{\pi/(1 - \pi)\}$
ϕ	σ^2	1	$\frac{1}{n}$
$a(\phi)$	ϕ	1	ϕ
$b(\theta)$	$\frac{\theta^2}{2} = \frac{\mu^2}{2}$	$e^\theta = \lambda$	$\log(1 + e^\theta)$ $= -\log(1 - \pi)$
$c(y; \phi)$	$-\frac{1}{2} \left(\frac{y^2}{\phi} + \log \sqrt{2\pi\sigma^2} \right)$	$-\log y!$	$\log \binom{n}{ny}$
$b'(\theta) = \mu$	θ	e^θ	$e^\theta / (1 + e^\theta) = \mu = \pi$
$b''(\theta)a(\phi) = \text{var}(Y)$	$1 \cdot \phi = \sigma^2$	$e^\theta \cdot 1 = \mu$	$\left(\frac{e^\theta}{1+e^\theta} \right) \left(\frac{1}{1+e^\theta} \right) \left(\frac{1}{n} \right)$ $= \mu(1 - \mu)/n$ $= \pi(1 - \pi)/n$
$b''(\theta) = V(\mu)$	1	$e^\theta = \mu$	$\left(\frac{e^\theta}{1+e^\theta} \right) \left(\frac{1}{1+e^\theta} \right) \left(\frac{1}{n} \right)$
canonical link ($\eta = \theta$)	μ [identity]	$\log \mu$ [log]	$\log\{\mu/(1 - \mu)\}$ [logit]

Table 3: Distribuciones normal, Poisson y binomial como miembros de la familia exponencial, media, varianza y ligadura canónica.

Mínimos cuadrados ponderados iterativamente (IRLS)

Tema pendiente. Dependiendo del progreso del curso, lo veremos al inicio de sección Datos sobre-dispersos.

Métodos para el análisis de datos binarios

El análisis de datos con variables respuesta binarias generalmente requieren técnicas diferentes a las que utilizadas para respuestas de tipo continuo, en particular diferentes a la regresión lineal.

Ejemplos de respuestas binarias son el estatus respecto de alguna enfermedad (enfermo/sano) y el estatus de supervivencia (muerto/vivo).

Adicional a la respuesta binaria, con frecuencia tenemos también una covariable o variable independiente de interés, por ejemplo, *tratamiento* (experimental/control) o *exposición* (expuesto a radiación/no expuesto a radiación).

Matriz de confusión

Para resumir los datos, usualmente construimos una tabla de contingencia o matriz de confusión como la Tabla 4 en la cual la variable las columnas se refieren al estatus de las personas respecto de alguna enfermedad, y los renglones a dos grupos de la población (podrían ser dos ciudades, genero, dos grupos de edad, etc.).

Covariable (x_i)	Estatus (y_k)		
	Enfermo	Sano	Sum
0	y_1	$n_1 - y_1$	n_1
1	y_2	$n_2 - y_2$	n_2
Sum	y	$n - y$	n

Table 4: General design of a confusion matrix.

Matriz de confusión

Los totales por renglón, n_1 y n_2 son los tamaños de muestra en el grupo 1 y el grupo 2, respectivamente, y $n = n_1 + n_2$ es el tamaño de muestra total.

En los totales por columna y es el total de “enfermos” y $n - y$ el total de “sanos”.

El número de enfermos en el grupo i es y_k y el número de sanos $n_k - y_k$, $k = 1, 2$.

Si tenemos n_1 y n_2 fijos, usualmente asumimos que tenemos dos muestras binomiales independientes con

$$Y_k \sim \text{Bin}(n_k, \pi_k), \quad k = 1, 2.$$

Hay varias medidas de asociación que podemos relacionar con una matriz de confusión como la Tabla 4, en esta sección nos enfocaremos en la *razón de momios*.

Razón de momios (odds ratio)

Los *momios* de un evento respecto de otro son la razón de sus respectivas probabilidades. Por lo tanto, los momios de “enfermedad” contra “no enfermedad” en el Grupo 1 son $\pi_1/(1 - \pi_1)$.

De manera abreviada podemos referirnos a esta cantidad como “los momios de enfermedad en el Grupo 1”.

En este contexto, los momios son una función de π 1-1 monotónica creciente que toma valores en $\mathbb{R}^+$. Los momios de enfermedad en el Grupo 2 son $\pi_2/(1 - \pi_2)$.

La *razón de momios* que se refiere a los momios relativos de enfermedad en el Grupo 1 contra el Grupo 2 es

$$\psi = \frac{\pi_1/(1 - \pi_1)}{\pi_2/(1 - \pi_2)}. \quad (24)$$

Razón de momios y riesgo relativo

Nótese que si se tratara de una enfermedad “rara” (i.e. cuando π_1 y π_2 son pequeñas, entonces la razón de momios ψ se aproxima al “riesgo relativo”, π_1/π_2 . Esto es más fácil de notar si escribimos

$$\psi = \frac{\pi_1/(1 - \pi_1)}{\pi_2/(1 - \pi_2)} = \frac{\pi_1}{\pi_2} \left(\frac{1 - \pi_2}{1 - \pi_1} \right),$$

donde la cantidad entre paréntesis tiene a 1 cuando $\pi_1 \approx \pi_2$ y son cantidades pequeñas.

Estimación de la razón de momios

Usamos la teoría de máxima verosimilitud para estimar ψ para lo cual formulamos la función de verosimilitud. Notemos que

$$\Pr(Y_1 = y_1, Y_2 = y_2) = \binom{n_1}{y_1} \pi_1^{y_1} (1 - \pi_1)^{n_1 - y_1} \binom{n_2}{y_2} \pi_2^{y_2} (1 - \pi_2)^{n_2 - y_2}$$

y la función de verosimilitud es

$$\begin{aligned} L(\pi_1, \pi_2) &= \pi_1^{y_1} (1 - \pi_1)^{n_1 - y_1} \pi_2^{y_2} (1 - \pi_2)^{n_2 - y_2} \\ &= \pi_1^{y_1} \frac{(1 - \pi_1)^{n_1}}{(1 - \pi_1)^{y_1}} \pi_2^{y_2} \frac{(1 - \pi_2)^{n_2}}{(1 - \pi_2)^{y_2}} \\ &= \left(\frac{\pi_1}{1 - \pi_1} \right)^{y_1} (1 - \pi_1)^{n_1} \left(\frac{\pi_2}{1 - \pi_2} \right)^{y_2} (1 - \pi_2)^{n_2} \\ &= \left(\frac{\pi_1 / (1 - \pi_1)}{\pi_2 / (1 - \pi_2)} \right)^{y_1} \left(\frac{\pi_2}{1 - \pi_2} \right)^{y_1 + y_2} (1 - \pi_1)^{n_1} (1 - \pi_2)^{n_2} \\ &= \left(\frac{\pi_1 / (1 - \pi_1)}{\pi_2 / (1 - \pi_2)} \right)^{y_1} \left(\frac{\pi_2}{1 - \pi_2} \right)^{y_1} (1 - \pi_1)^{n_1} (1 - \pi_2)^{n_2}, \end{aligned}$$

Estimación de la razón de momios

Reparametrizamos para librarnos de π_1 . Para ello, note que

$$\psi = \frac{\pi_1/(1 - \pi_1)}{\pi_2/(1 - \pi_2)} = \frac{\pi_1}{\pi_2} \left(\frac{1 - \pi_2}{1 - \pi_1} \right) \iff \pi_1 = \frac{\psi\pi_2}{1 - \pi_2 + \psi\pi_2}. \quad (26)$$

Substituyendo (26) en (25) tenemos

$$L(\psi, \pi_2) = \psi^{y_1} \left(\frac{\pi_2}{1 - \pi_2} \right)^y \left(\frac{1 - \pi_2}{1 - \pi_2\psi\pi_2} \right)^{n_1} (1 - \pi_2)^{n_2}, \quad (27)$$

una función de nuestro ψ , el parámetro de interés. Podemos reparametrizar de nuevo (27) y así construir estimadores tipo Wald y sus estadísticas de prueba.

Estimación de la razón de momios

Los estimadores tipo Wald son más atractivos cuando sus correspondientes parámetros no tienen restricción (i.e. el espacio de los parámetros es $\mathbb{R}$). Por lo tanto, consideremos la parametrización

$$\beta = \log \psi \quad (28a)$$

$$\alpha = \log \left(\frac{\pi_2}{1 - \pi_2} \right). \quad (28b)$$

Tenemos, entonces,

$$L(\alpha, \beta) = e^{y_1 \beta} e^{y \alpha} \left(1 + e^{\alpha + \beta} \right)^{-n_1} (1 + e^{\alpha})^{-n_2}. \quad (29)$$

Y el logaritmo de la función de verosimilitud es

$$\ell(\alpha, \beta) = y_1 \beta + y \alpha - n_1 \log \left(1 + e^{\alpha + \beta} \right) - n_2 \log (1 + e^{\alpha}). \quad (30)$$

Diferenciando ℓ respecto de α y β tenemos

$$S_{\alpha}(\alpha, \beta) = \frac{\partial \ell(\alpha, \beta)}{\partial \alpha} = y - \frac{n_1 e^{\alpha+\beta}}{1 + e^{\alpha+\beta}} - \frac{n_2 e^{\alpha}}{1 + e^{\alpha}} \quad (31a)$$

$$S_{\beta}(\alpha, \beta) = \frac{\partial \ell(\alpha, \beta)}{\partial \beta} = y_1 - \frac{n_1 e^{\alpha+\beta}}{1 + e^{\alpha+\beta}}. \quad (31b)$$

Estimación de la razón de momios

Encontramos los MLE resolviendo para α y β las ecuaciones $S_\alpha(\alpha, \beta) = 0$ y $S_\beta(\alpha, \beta) = 0$, y resultan en

$$\hat{\alpha} = \log \left(\frac{y_2}{n_2 - y_2} \right) \quad (32a)$$

$$\hat{\beta} = \log \left(\frac{y_1/(n_1 - y_1)}{y_2/(n_2 - y_2)} \right). \quad (32b)$$

Derivación en clase

Estos estimadores implican

$$\hat{\pi}_2 = \frac{e^{\hat{\alpha}}}{1 + e^{\hat{\alpha}}} = \frac{y_2}{n_2},$$

$$\hat{\pi}_1 = \frac{e^{\hat{\alpha} + \hat{\beta}}}{1 + e^{\hat{\alpha} + \hat{\beta}}} = \frac{y_1}{n_1},$$

$$\hat{\psi} = e^{\hat{\beta}} = \frac{\hat{\pi}_1/(1 - \hat{\pi}_1)}{\hat{\pi}_2/(1 - \hat{\pi}_2)}.$$

Estimación de la razón de momios

La varianza de los estimadores de máxima verosimilitud los obtenemos a partir de la inversa de la matriz de información. Note que

$$\begin{aligned} I_{\alpha\alpha} &= - \left[-n_1 \frac{e^{\alpha+\beta}(1 + e^{\alpha+\beta}) - e^{\alpha+\beta}e^{\alpha+\beta}}{(1 + e^{\alpha+\beta})^2} - n_2 \frac{e^{\alpha}(1 + e^{\alpha}) - e^{2\alpha}}{(1 + e^{\alpha})^2} \right] \\ &= n_1 \frac{e^{\alpha+\beta}}{(1 + e^{\alpha+\beta})^2} + n_2 \frac{e^{\alpha}}{(1 + e^{\alpha})^2} \\ I_{\alpha\beta} &= - \left[-n_1 \frac{e^{\alpha+\beta}(1 + e^{\alpha+\beta}) - e^{\alpha+\beta}e^{\alpha+\beta}}{(1 + e^{\alpha+\beta})^2} \right] = n_1 \frac{e^{\alpha+\beta}}{(1 + e^{\alpha+\beta})^2} \\ I_{\beta\beta} &= - \left[-n_1 \frac{e^{\alpha+\beta}(1 + e^{\alpha+\beta}) - e^{\alpha+\beta}e^{\alpha+\beta}}{(1 + e^{\alpha+\beta})^2} \right] = n_1 \frac{e^{\alpha+\beta}}{(1 + e^{\alpha+\beta})^2} \end{aligned}$$

Estimación de la razón de momios

Nos interesa la entrada (β, β) de I^{-1} , la cual denotamos por $I^{\beta\beta}$ en §1.4 [??]. Esta está dada por $I^{\beta\beta}(\alpha, \beta) = [I_{\beta\beta} - I_{\beta\alpha}I_{\alpha\alpha}^{-1}I_{\alpha\beta}]^{-1}$, y en este caso obtenemos

$$\text{var}(\beta) = I^{\beta\beta}(\alpha, \beta) = \frac{1}{\mathbb{E}(Y_1)} + \frac{1}{\mathbb{E}(n_1 - Y_1)} + \frac{1}{\mathbb{E}(Y_2)} + \frac{1}{\mathbb{E}(n_2 - Y_2)}, \quad (33)$$

la cual evaluada en $\hat{\alpha}, \hat{\beta}$ resulta en

$$\text{var}(\hat{\beta}) = I^{\beta\beta}(\hat{\alpha}, \hat{\beta}) = \frac{1}{y_1} + \frac{1}{n_1 - y_1} + \frac{1}{y_2} + \frac{1}{n_2 - y_2}, \quad (34)$$

Derivación en clase

Estimación de la razón de momios

Dado este resultado podemos construir intervalos de confianza aproximados tipo Wald

$$\left(\hat{\beta} + z_{(\alpha/2)} \sqrt{\text{var}(\hat{\beta})}, \quad \hat{\beta} + z_{(1-\alpha/2)} \sqrt{\text{var}(\hat{\beta})} \right) \quad (35)$$

donde $\text{var}(\hat{\beta}) = \frac{1}{y_1} + \frac{1}{n_1 - y_1} + \frac{1}{y_2} + \frac{1}{n_2 - y_2}$, $z_{(q)}$ es el q -ésimo cuantil de la distribución $\mathcal{N}(0, 1)$ y $1 - \alpha$ el nivel de confianza, $\alpha \in (0, 1)$ (por ejemplo, para un nivel de confianza $1 - \alpha = 0.95$, $z_{0.025} = -1.96$ y $z_{(0.975)} = 1.96$).

Denotamos los intervalos de confianza por $(\hat{\beta}_L, \hat{\beta}_U)$. Los intervalos de confianza aproximados para ψ están dados por

$$\left(e^{\hat{\beta}_L}, e^{\hat{\beta}_U} \right). \quad (36)$$

En tablas de 2×2 típicamente no estamos interesados en α o π_2 .

Nótese que dados los resultados asintóticos (muestras grandes) de máxima verosimilitud de §3, podríamos conducir inferencias sobre β y, por lo tanto, ψ .

El intervalo de confianza tipo Wald que construimos aquí es más conveniente y dado que el rango de β es libre (sin restricciones), los resultados generalmente coinciden con los de máxima verosimilitud.

Regresión múltiple para respuestas binarias

Los resultados de las secciones 1 y 2 se enfocaron en el caso con un único factor con dos niveles y una respuesta binaria. Este es una configuración simple, con frecuencia necesitamos la metodología de regresión múltiple con los siguientes propósitos:

1. Controlar por variables de confusión y, por lo tanto, examinar simultáneamente el efecto de varias variables (posiblemente colineales).
2. Examinar simultáneamente la relación de entre variables categóricas (≥ 2 niveles) o variables continuas y una respuesta binaria.
3. Desarrollar modelos más sofisticados que describan relaciones complejas, como interacciones.

Ejemplo 3.1 - Análisis de datos binarios (Cuidado perinatal)

Consideremos los datos de la Tabla 5 que describe la relación entre el nivel de cuidado prenatal y mortalidad prenatal. Los datos provienen de dos clínicas, nos referiremos a ellas como Clínica A y Clínica B.

Nivel de cuidado	Estatus		
	Muere	Vive	Suma
Intensivo	20	316	336
Regular	46	373	419
Suma	66	689	755

Table 5: Datos de cuidado prenatal de las clínicas A y B juntas.

Ejemplo 3.1 - Análisis de datos binarios (Cuidado perinatal)

La razón de momios es

$$\hat{\psi} = \frac{\hat{\pi}_1/(1 - \hat{\pi}_1)}{\hat{\pi}_2/(1 - \hat{\pi}_2)} = \frac{20/316}{46/373} = 0.51,$$

la varianza de $\log \hat{\psi} = \hat{\beta}$ es

$$\begin{aligned}\text{var}(\log \hat{\psi}) = \text{var}(\hat{\beta}) &= \frac{1}{y_1} + \frac{1}{n_1 - y_1} + \frac{1}{y_2} + \frac{1}{n_2 - y_2} \\ &= \frac{1}{20} + \frac{1}{316} + \frac{1}{46} + \frac{1}{373} = 0.078,\end{aligned}$$

el intervalo de confianza de $\log \hat{\psi}$ al 95% es

$$\begin{aligned}(\log \hat{\psi}_L, \log \hat{\psi}_U) &= (\hat{\beta}_L, \hat{\beta}_U) = \left\{ \log(0.51 \pm 1.96 * \sqrt{0.078}) \right\} \\ &= (-1.213, -0.121)\end{aligned}$$

y el intervalo de confianza de $\hat{\psi}$

$$(\hat{\psi}_L, \hat{\psi}_U) = (e^{\hat{\beta}_L}, e^{\hat{\beta}_U}) = (e^{-1.213}, e^{-0.121}) = (0.297, 0.886).$$

Ejemplo 3.1 - Análisis de datos binarios (Cuidado perinatal)

Esto sugiere una asociación fuerte entre el nivel de cuidado y la mortalidad prenatal (menor mortalidad prenatal con cuidados intensivos). Sin embargo, analizamos por separado los datos de cada clínica, como se muestra en las Tablas 6 y 7 tenemos lo siguiente.

- La razón de momios en la Clínica A es $\hat{\psi} = 0.80$ con un intervalo de confianza al 95% de $(\hat{\psi}_L, \hat{\psi}_U) = (0.37, 1.73)$. A pesar de que la razón de momios sugiere un efecto protector del cuidado prenatal $\hat{\psi} < 1$, el intervalo de confianza es muy amplio e incluye valores mayores que uno, los cuales se corresponden con un riesgo aumentado de mortalidad. El beneficio estimado del nivel de cuidado prenatal es considerablemente menor entre los pacientes de la Clínica A respecto del observado en los datos combinados.

Ejemplo 3.1 - Análisis de datos binarios (Cuidado perinatal)

- La razón de momios en la Clínica B es $\hat{\psi} = 1.01$ con un intervalo de confianza al 95% de $(\hat{\psi}_L, \hat{\psi}_U) = (0.33, 3.10)$.
Notemos que la reducción en mortalidad prenatal por el nivel de cuidado que observamos en los datos combinados al parecer se desvanece entre los pacientes de la Clínica B.

Ejemplo 3.1 - Análisis de datos binarios (Cuidado perinatal)

Nivel de cuidado	Estatus		
	Muere	Vive	Suma
Intensivo	16	293	309
Regular	12	176	188
Suma	28	469	497
$\hat{\psi}$ $(\hat{\psi}_L, \hat{\psi}_U)$	$\frac{16/293}{12/176} = 0.80$ (0.37, 1.73)		

Table 6: Asociación entre mortalidad y cuidado prenatal, Clínica A.

Nivel de cuidado	Estatus		
	Muere	Vive	Suma
Intensivo	4	23	27
Regular	34	197	231
Suma	38	220	258
$\hat{\psi}$ $(\hat{\psi}_L, \hat{\psi}_U)$	$\frac{4/23}{34/197} = 1.01$ (0.33, 3.10)		

Table 7: Asociación entre mortalidad y cuidado prenatal, Clínica B.

Ejemplo 3.1 - Análisis de datos binarios (Cuidado perinatal)

Para investigar más a fondo examinemos la relación entre clínicas y el nivel de cuidado que se muestra en la Tabla 8.

Nivel de cuidado	Clínica		Suma
	A	B	
Intensivo	309	27	336
Regular	188	231	419
Suma	497	258	755
$\hat{\psi}$ $(\hat{\psi}_L, \hat{\psi}_U)$	$\frac{309/27}{188/231} = 14.06$ $(9.07, 21.79)$		

Table 8: Asociación entre clínica y nivel de cuidado prenatal.

En este caso la razón de momios $\hat{\psi} = 14.06$ y su intervalo de confianza al 95% $(\hat{\psi}_L, \hat{\psi}_U) = (9.07, 21.79)$ sugieren una fuerte asociación estadísticamente significativa entre clínica y el nivel de cuidado prenatal. Específicamente, podemos ver que la proporción de pacientes de la Clínica A que reciben cuidado intensivo es considerablemente mayor que en la Clínica B.

Ejemplo 3.1 - Análisis de datos binarios (Cuidado perinatal)

Ahora analicemos la asociación entre clínica y mortalidad en la Tabla 8.

Nivel de cuidado	Clínica		Suma
	A	B	
Intensivo	28	38	66
Regular	469	220	689
Suma	497	258	755
$\hat{\psi}$ $(\hat{\psi}_L, \hat{\psi}_U)$	$\frac{28/38}{469/220} = 0.35$ (0.21, 0.59)		

Table 9: Asociación entre clínica y mortalidad prenatal.

La razón de momios $\hat{\psi} = 0.35$ y el intervalo de confianza al 95% $(\hat{\psi}_L, \hat{\psi}_U) = (0.21, 0.59)$ sugieren una más alta tasa de mortalidad en la Clínica B, y que la diferencia respecto de la Clínica A es estadísticamente significativa a un nivel de significancia del 5% (el intervalo de confianza al 95% no incluye uno).

Ejemplo 3.1 - Análisis de datos binarios (Cuidado perinatal)

Finalmente, la Tabla 10 muestra la asociación entre clínica y mortalidad estratificando por nivel de cuidado prenatal.

Analizaremos esta table en la siguiente sección.

Clínica	Intensivo			Regular		
	Muere	Vive	Suma	Muere	Vive	Suma
A	16	293	309	12	176	188
B	4	23	27	34	197	231
Suma	20	316	336	46	373	419
$\hat{\psi}$ $(\hat{\psi}_L, \hat{\psi}_U)$	$\frac{16/293}{4/23} = 0.31$ (0.10, 1.00)			$\frac{12/176}{34/197} = 0.40$ (0.20, 0.79)		

Table 10: Asociación entre clínica y mortalidad estratificando por nivel de cuidado prenatal.

Ejemplo 3.1 - Análisis de datos binarios (Cuidado perinatal)

Resumiendo, encontramos una aparente asociación fuerte entre el nivel de cuidado prenatal y mortalidad.

Cuando estratificamos por clínica, la evidencia de tal asociación disminuye drásticamente.

Al estratificar por cuidado prenatal, se observa un riesgo reducido en los pacientes de la Clínica A respecto de la Clínica B.

Estudiaremos cómo se representan estos hallazgos en un modelo de regresión.

Configuración del modelo de regresión binomial

Sea

$$x_{i1}, \dots, x_{ip-1}$$

un conjunto de $p - 1$ variables y

$$\mathbf{x}_i^\top = [1 \quad x_{i1} \quad \dots \quad x_{ip-1}]$$

un (p) -vector de variables o covariables.

Sea

$$\boldsymbol{\beta}^\top = [\beta_0 \quad \beta_1 \quad \dots \quad \beta_{p-1}]$$

un p -vector de coeficientes.

El escalar

$$\eta_i = \eta(\mathbf{x}_i) = \mathbf{x}_i^\top \boldsymbol{\beta} \tag{37}$$

se conoce como “predictor lineal”.

Configuración del modelo de regresión binomial

En una muestra de n individuos, cada uno con su respectivo vector de variables, podemos definir la matriz de diseño

$$X_{n \times p} = \begin{bmatrix} 1 & x_{11} & x_{12} & \cdots & x_{1p-1} \\ 1 & x_{21} & x_{22} & \cdots & x_{2p-1} \\ \vdots & \vdots & \vdots & x_{ri} & \vdots \\ 1 & x_{n1} & x_{n2} & \cdots & x_{np-1} \end{bmatrix} = \begin{bmatrix} \mathbf{1}^\top \\ \mathbf{x}_1^\top \\ \mathbf{x}_2^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix},$$

donde el i -ésimo renglón de X es el vector transpuesto de las observaciones del i -ésimo individuo. Típicamente la primera columna de X , $\mathbf{x}_{(1)} = [1 \ \dots \ 1]$ es un n -vector unitario y representa el intercepto del modelo (más adelante abundaremos sobre su interpretación).

Configuración del modelo de regresión binomial

Entonces el vector de predictores lineales está dado por

$$\boldsymbol{\eta} = \begin{pmatrix} \eta_1 \\ \vdots \\ \eta_n \end{pmatrix} = X\boldsymbol{\beta}. \quad (38)$$

Recordemos que en el contexto de regresión lineal normal el modelo $y_i \sim \mathcal{N}(\mu_i, \sigma^2)$ son independientes por lo que

$$\mathbb{E}(y_i) = \mu_i = \eta_i = \beta_0 + \beta_1 x_{i1} + \dots + \beta_{p-1} x_{ip-1}.$$

Para el caso de datos binomiales con $y_i \sim \text{Bin}(n_i, \pi_i)$ podemos pensar en un modelo de regresión de la forma

$$\mathbb{E}(y_i/n_i) = \mu_i = \eta_i = \beta_0 + \beta_1 x_{i1} + \dots + \beta_{p-1} x_{ip-1}.$$

Configuración del modelo de regresión binomial

¿Es éste un modelo razonable? No es particularmente conveniente trabajar con él porque tendríamos que imponer restricciones al lado derecho de la igualdad porque $0 \leq \pi_i \leq 1, i = 1, 2, \dots, n$. Por lo tanto, en lugar de modelar directamente π_i trabajamos con una función monotónica de π_i . La *función de ligadura (link function)* define tal transformación, la cual mapea $[0, 1] \rightarrow (-\infty, +\infty)$. Denotamos la función de ligadura por $g(\pi)$.

Nombre de la ligadura	Forma funcional (g)
Identity	$g(\pi) = \pi$
log-log	$g(\pi) = \log(-\log(\pi))$
Probit [†]	$g(\pi) = \Phi(\pi)$
Logit	$g(\pi) = \log(\pi/(1 - \pi))$

[†] Φ es la CDF de una variable aleatoria normal estandarizada.

Configuración del modelo de regresión binomial

Habiendo elegido la función de ligadura, el modelo de regresión toma la forma

$$g(\pi) = \eta.$$

Introduciendo el subíndice i para distinguir a los individuos, tenemos

$$\log \left(\frac{\pi}{1 - \pi} \right) = \mathbf{x}_i^\top \boldsymbol{\beta} = \beta_0 + \beta_1 x_{i1} + \dots + \beta_{p-1} x_{ip-1}.$$

La ligadura Logit y la razón de momios

Sean Y_1 y Y_2 el número de individuos con la respuesta en los Grupos 1 y 2 respectivamente.

Sea $Y_k \sim \text{Bin}(n_k \pi_k)$, $k = 1, 2$.

Sea

$$x_i = \begin{cases} 1 & \text{si el } i\text{-ésimo individuo pertenece al Grupo 1} \\ 0 & \text{si el } i\text{-ésimo individuo pertenece al Grupo 2.} \end{cases}$$

Consideremos un modelo (M) para la respuesta de cada individuo (la cual es binaria, no binomial) de la siguiente forma

$$M_1 : \quad \log \left(\frac{\pi_i}{1 - \pi_i} \right) = \beta_0 + \beta_1 x_i. \quad (39)$$

La ligadura Logit y la razón de momios

Para un individuo en el grupo 1 los log momios son

$$\log \left(\frac{\pi_i}{1 - \pi_i} \right) = \beta_0 + \beta_1$$

y para un individuo en el grupo 2 los log momios son

$$\log \left(\frac{\pi_i}{1 - \pi_i} \right) = \beta_0.$$

Esto implica que

$$\log \left(\frac{\pi_i}{1 - \pi_i} \right) - \log \left(\frac{\pi_j}{1 - \pi_j} \right) = \beta_1,$$

esto es, $\log \psi = \beta_1$ donde ψ es la razón de momios comparando los momios del evento para un sujeto en el Grupo 1 respecto de un sujeto en el Grupo 2.

Por lo tanto, el coeficiente de este modelo de regresión logística, β_1 , puede interpretarse como

la razón de momios en escala logarítmica de la asociación entre el grupo de pertenencia y la respuesta.

La ligadura Logit y la razón de momios

Típicamente nos interesa el parámetro π . Notemos que

$$\log\left(\frac{\pi_i}{1 - \pi_i}\right) = \beta_0 + \beta_1 x_i \iff \frac{\pi}{1 - \pi_i} = e^{\beta_0 + \beta_1 x_i}$$
$$\pi_i = \frac{e^{\beta_0 + \beta_1 x_i}}{1 + e^{\beta_0 + \beta_1 x_i}}.$$

En un modelo gaussiano, dado $\hat{\beta}$, el valor estimado de $\mathbb{E}(Y_i) = \hat{\mu}_i(x_i) = \mathbf{x}_i^\top \hat{\beta}$. En este modelo de regresión binomial, el valor estimado de $\mathbb{E}(Y_i/n_i)$ es

$$\widehat{\mathbb{E}(Y_i/n_i)} = \hat{\pi}_i = \hat{\pi}_i(x_i) = \frac{e^{\hat{\beta}_0 + \hat{\beta}_1 x_{i1}}}{1 + e^{\hat{\beta}_0 + \hat{\beta}_1 x_{i1}}},$$

o de manera más general

$$\hat{\pi}_i = \hat{\pi}_i(x_i) = \frac{\exp\{\mathbf{x}_i^\top \hat{\beta}\}}{1 + \exp\{\mathbf{x}_i^\top \hat{\beta}\}}.$$

La ligadura Logit y la razón de momios

Ahora consideremos el caso con dos variables explicativas binarias.

Sea

$$x_{i1} = \begin{cases} 1 & \text{si el factor } A \text{ está presente} \\ 0 & \text{en otro caso} \end{cases}$$

$$x_{i2} = \begin{cases} 1 & \text{si el factor } B \text{ está presente} \\ 0 & \text{en otro caso} \end{cases}$$

$$x_{i3} = \begin{cases} 1 & \text{si ambos } A \text{ y } B \text{ están presentes} \\ 0 & \text{en otro caso} \end{cases}$$

Considere el modelo M_{12}

$$M_{12} : \quad \log \left(\frac{\pi_i}{1 - \pi_i} \right) = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} \quad (40)$$

La ligadura Logit y la razón de momios

Interpretemos el efecto de x_{i1} . Primero calculamos los log momios cuando ambos factores A y B están presentes, i.e. cuando $\mathbf{x}_i^\top = [1 \quad 1 \quad 1]$ tenemos

$$\log \left(\frac{\pi_i}{1 - \pi_i} \right) = \beta_0 + \beta_1 + \beta_2. \quad (41)$$

Despues calculamos los log momios cuando el factor A es ausente pero B está presente, i.e. cuando $\mathbf{x}_j^\top = [1 \quad 0 \quad 1]$ tenemos

$$\log \left(\frac{\pi_i}{1 - \pi_i} \right) = \beta_0 + \beta_2. \quad (42)$$

Tomando la diferencia (42) – (41) resulta en

$$\log \left(\frac{\pi_i}{1 - \pi_i} \right) - \log \left(\frac{\pi_j}{1 - \pi_j} \right) = \log \left(\frac{\pi_i/(1 - \pi_i)}{\pi_j/(1 - \pi_j)} \right) = \beta_1. \quad (43)$$

Por lo tanto, β_1 es otra vez el logaritmo de la razón de momios y representa el efecto del factor A , pero esta vez estamos controlando por el factor B , específicamente cuando B está presente.

Notemos que el efecto del factor A es el mismo sin importar el nivel de B .

La ligadura Logit y la razón de momios

Para verlo con claridad examinemos los log momios cuando el factor A está presente pero ahora con B ausente, donde

$\mathbf{x}_i^\top = [1 \quad 1 \quad 0]$ y

$$\log \left(\frac{\pi_i}{1 - \pi_i} \right) = \beta_0 + \beta_1 \quad (44)$$

y los log momios cuando ambos factores A y B están ausentes, donde $\mathbf{x}_j^\top = [1 \quad 0 \quad 0]$ y

$$\log \left(\frac{\pi_i}{1 - \pi_i} \right) = \beta_0 \quad (45)$$

De nueva cuenta, la diferencia (42) – (41) resulta en

$$= \log \left(\frac{\pi_i / (1 - \pi_i)}{\pi_j / (1 - \pi_j)} \right) = \beta_1. \quad (46)$$

Ahora consideremos el modelo

$$M_{123} : \quad \log \left(\frac{\pi_i}{1 - \pi_i} \right) = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \beta_3 x_{i3} \quad (47)$$

donde hemos introducido un término de interacción.

La ligadura Logit y la razón de momios

Los log momios cuando ambos factores A y B están presentes se corresponden con $\mathbf{x}_i^\top = [1 \ 1 \ 1 \ 1]$ y

$$\log \left(\frac{\pi_i}{1 - \pi_i} \right) = \beta_0 + \beta_1 + \beta_2 + \beta_3. \quad (48)$$

Cuando el factor A es ausente y B está presente, $\mathbf{x}_j^\top = [1 \ 0 \ 1 \ 0]$ y

$$\log \left(\frac{\pi_i}{1 - \pi_i} \right) = \beta_0 + \beta_2. \quad (49)$$

La diferencia (49) – (48) resulta en

$$= \log \left(\frac{\pi_i / (1 - \pi_i)}{\pi_j / (1 - \pi_j)} \right) = \beta_1 + \beta_3. \quad (50)$$

La ligadura Logit y la razón de momios

Ahora, los log momios cuando el factor A está presente pero B ausente se corresponden con $\mathbf{x}_i^\top = [1 \quad 1 \quad 0 \quad 0]$ y

$$\log \left(\frac{\pi_i}{1 - \pi_i} \right) = \beta_0 + \beta_1. \quad (51)$$

Cuando ambos factores A y B están ausentes, $\mathbf{x}_j^\top = [1 \quad 0 \quad 0 \quad 0]$ y

$$\log \left(\frac{\pi_i}{1 - \pi_i} \right) = \beta_0. \quad (52)$$

La diferencia (49) – (48) resulta en

$$= \log \left(\frac{\pi_i / (1 - \pi_i)}{\pi_j / (1 - \pi_j)} \right) = \beta_1. \quad (53)$$

Con el término de interacción vemos que el efecto del factor A depende de la presencia o ausencia del factor B . Si el factor B es ausente, el logaritmo de la razón de momios de la asociación de A con la respuesta es β_1 , pero si el factor B está presente entonces es $\beta_1 + \beta_3$.

Consideremos los datos de cuidado prenatal y su modelo de regresión en el Ejemplo 3.1.

Ejemplo 3.2 Regresión para datos binarios (Cuidado prenatal)

Examinemos la relación entre mortalidad prenatal y nivel de cuidado. La variable respuesta es $Y_i \sim \text{Bin}(n_i \pi_i)$, $i = 1, 2, \dots, n$. Definimos el modelo de regresión 11 y covariables

$$M_{12} : \quad \log \left(\frac{\pi_i}{1 - \pi_i} \right) = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2}$$

y las variables explicativas

$$x_{i1} = \begin{cases} 1 & \text{Clínica A} \\ 0 & \text{Clínica B} \end{cases}$$

$$x_{i2} = \begin{cases} 1 & \text{cuidado intensivo} \\ 0 & \text{cuidado regular} \end{cases}$$

$$x_{i3} = \begin{cases} 1 & \text{cuidado intensivo en la Clínica A} \\ 0 & \text{en otro caso} \end{cases}$$

Ejemplo 3.2 Regresión para datos binarios (Cuidado prenatal)

Antes de iniciar con el análisis de los datos, podemos hacer una tabla para registrar los coeficientes del modelo y así facilitar su interpretación. Para el modelo M_{12} definido anteriormente en (40) tenemos la Tabla

Clínica	Nivel de cuidado	$\mathbf{x}$	$\pi_i/(1 - \pi_i)$
B	regular	$[1 \ 0 \ 0]^\top$	e^{β_0}
B	intensivo	$[1 \ 0 \ 1]^\top$	$e^{\beta_0 + \beta_2}$
A	regular	$[1 \ 1 \ 0]^\top$	$e^{\beta_0 + \beta_1}$
A	intensivo	$[1 \ 1 \ 1]^\top$	$e^{\beta_0 + \beta_1 + \beta_2}$

Table 11: Coeficientes del modelo de regresión logística M_{12} para la relación entre mortalidad y nivel de cuidado prenatal.

Ejemplo 3.2 Regresión para datos binarios (Cuidado prenatal)

Aquí usamos la relación $\pi_i/(1 - \pi_i) = \exp\{\mathbf{x}_i^\top \beta\}$. La última columna reporta los momios de mortalidad para las cuatro combinaciones de los niveles de los factores de riesgo. La división de cualquier par de términos resulta en una razón de momios. Por ejemplo, entre los pacientes de la Clínica *B*, la razón de momios del cuidado prenatal intensivo contra regular es

$$\frac{e^{\beta_0 + \beta_2}}{e^{\beta_0}} = e^{\beta_2}$$

Entre los pacientes de la Clínica *A*, la razón de momios de mortalidad de los pacientes en cuidado intensivo respecto aquellos en cuidado regular son

$$\frac{e^{\beta_0 + \beta_1 + \beta_2 + \beta_3}}{e^{\beta_0 + \beta_1}} = e^{\beta_2}$$

i.e. la misma expresión que obtuvimos previamente para los pacientes en la Clínica *B*.

Ejemplo 3.2 Regresión para datos binarios (Cuidado prenatal)

Consideremos en la Tabla 12 los distintos momios de M_{123}

$$M_{123} : \log \left(\frac{\pi_i}{1 - \pi_i} \right) = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \beta_3 x_{i3}$$

donde ahora $\mathbf{x}_i^\top = [1 \ x_{i1} \ x_{i2} \ x_{i3}]$ y $\boldsymbol{\beta}^\top = [\beta_0 \ \beta_1 \ \beta_2 \ \beta_3]$.

Clínica	Nivel de cuidado	$\mathbf{x}$	$\pi_i/(1 - \pi_i)$
B	regular	$[1 \ 0 \ 0 \ 0]^\top$	e^{β_0}
B	intensivo	$[1 \ 0 \ 1 \ 0]^\top$	$e^{\beta_0 + \beta_2}$
A	regular	$[1 \ 1 \ 0 \ 0]^\top$	$e^{\beta_0 + \beta_1}$
A	intensivo	$[1 \ 1 \ 1 \ 1]^\top$	$e^{\beta_0 + \beta_1 + \beta_2 + \beta_3}$

Table 12: Coeficientes del modelo de regresión logística M_{123} para la relación entre mortalidad y nivel de cuidado prenatal.

Ejemplo 3.2 Regresión para datos binarios (Cuidado prenatal)

En este caso la razón de momios de mortalidad de los pacientes con cuidado intensivo respecto de los pacientes con cuidado regular en la Clínica B es

$$\frac{e^{\beta_0+\beta_2}}{e^{\beta_0}} = e^{\beta_2};$$

sin embargo la razón de momios correspondiente con la Clínica A es

$$\frac{e^{\beta_0+\beta_1+\beta_2+\beta_3}}{e^{\beta_0+\beta_1}} = e^{\beta_2+\beta_3}.$$

Cuando $\beta_3 = 0$ entonces el efecto del nivel de cuidado prenatal no depende de la clínica, y viceversa. Cuando tanto $\beta_3 = 0$ como $\beta_2 = 0$, no solo el efecto del nivel de cuidado no depende de la clínica sino también tal efecto es inexistente.

Ejemplo 3.2 Regresión para datos binarios (Cuidado prenatal)

El archivo `prenatal.txt` contiene datos de mortalidad y nivel de cuidado prenatal para dos clínicas A y B . La primera línea contiene los nombres de las variables y el resto los datos.

Continuando con la misma notación usamos indicadores para las variables explicativas y la respuesta es binaria.

Exploraremos la relación entre mortalidad, clínica y nivel de cuidado prenatal mediante los siguientes modelos de regresión logística.

Nombramos los modelos siguiendo la convención de agregar como subíndice aquellos de las variables que ingresamos al modelo.

Ejemplo 3.2 Regresión para datos binarios (Cuidado prenatal)

$$M_2 : \quad \log \left(\frac{\pi_i}{1 - \pi_i} \right) = \beta_0 + \beta_1 x_{i2} \quad [\text{care}]$$

$$M_{12} : \quad \log \left(\frac{\pi_i}{1 - \pi_i} \right) = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} \quad [\text{clinic} + \text{care}]$$

$$M_{123} : \quad \log \left(\frac{\pi_i}{1 - \pi_i} \right) = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \beta_3 x_{i3} \\ [\text{clinic} + \text{care} + \text{clinic*care}]$$

$$M_1 : \quad \log \left(\frac{\pi_i}{1 - \pi_i} \right) = \beta_0 + \beta_1 x_{i1} \quad [\text{clinic}]$$

El script de R utilizado para analizar los datos se muestra a continuación.

Ejemplo 3.2 Regresión para datos binarios (Cuidado prenatal)

```
datwd <- 'C:/.../Data'  
setwd(datwd); getwd()  
d <- read.table('prenatal.txt', header=TRUE)  
head(d)
```

	clinic	loc	y	n
1	0	0	34	231
2	0	1	4	27
3	1	0	12	188
4	1	1	16	309

> To construct the response resp we bind columns y and n-y.

```
d$resp <- cbind(d$y, d$n-d$y)
```

Ejemplo 3.2 Regresión para datos binarios (Cuidado prenatal)

Usemos un modelo de regresión logística para explorar la relación entre mortalidad y nivel de cuidado prenatal. El objeto M2 almacena los resultados del ajuste de este modelo y usamos la función `summary()` para desplegar una parte de los resultados.

```
> Fit the model using the glm function. Store results in M2.  
> We must indicate that the response is binomial and  
> we want to use the logistic link function
```

```
M2 <- glm(resp ~ loc, family=binomial(link=logit), data=d)  
summary(M2)
```

Ejemplo 3.2 Regresión para datos binarios (Cuidado prenatal)

Call:

```
glm(formula = resp ~ loc, family = binomial(link = logit),  
     data = d)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)	
(Intercept)	-2.0929	0.1563	-13.393	<2e-16	***
loc	-0.6671	0.2785	-2.395	0.0166	*

Signif. codes:

0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 16.918 on 3 degrees of freedom
Residual deviance: 10.814 on 2 degrees of freedom
AIC: 31.969
Number of Fisher Scoring iterations: 4

Ejemplo 3.2 Regresión para datos binarios (Cuidado prenatal)

```
> The “names” function lists the contents of the object  
> M2 and following this statement we examine some of the  
> contents of these objects (try it)
```

```
names(M2)  
M2$family  
M2$formula  
M2$coefficients  
M2$deviance  
M2$fitted.values  
M2$residuals
```

Ejemplo 3.2 Regresión para datos binarios (Cuidado prenatal)

Los números bajo el encabezado Estimate son los coeficientes de regresión estimados por máxima verosimilitud $\hat{\beta}_0$ y $\hat{\beta}_1$.

Estamos usando la convención de que los subíndices de los coeficientes de regresión coincide con los subíndices de las variables.

Los números bajo el encabezado Std. Error son los errores estándar calculados con base en la inversa de la matriz de información, esto es $(\text{var}(\hat{\beta}_k))^{1/2}$. Finalmente, los números bajo el encabezado Pr(>|z|) son los p -value de la estadística de prueba Wald para el sistema de hipótesis $H_0 : \beta_k = 0$ vs. $H_1 : \beta_k \neq 0$. Recuerde que son de la forma

$$\frac{\hat{\beta}_k - 0}{\sqrt{\text{var}(\hat{\beta}_k)}}$$

Ejemplo 3.2 Regresión para datos binarios (Cuidado prenatal)

Esta estadística de prueba es aproximadamente $\mathcal{N}(0, 1)$ bajo el supuesto de que H_0 se sostiene. Para verificar los cálculos notemos que el valor de la estadística de prueba para la relación de nivel de cuidado prenatal y mortalidad con base en M_2 tenemos

$$\frac{-0.667}{0.278} = -2.395.$$

El p -value lo calculamos como

$$p\text{-value} = 2 \times \Pr \left(Z > \left| \frac{\hat{\beta}_k - 0}{\sqrt{\text{var}(\hat{\beta}_k)}} \right| \right),$$

donde $Z \sim \mathcal{N}(0, 1)$. Por lo tanto, para someter a prueba la hipótesis de que no hay relación entre nivel de cuido y mortalidad ($H_0 : \beta_2 = 0$) tenemos

$$p\text{-value} = 2 \times \Pr(Z > 2.395) = 2 * (1 - \text{pnorm}(2.395)) = 0.0166.$$

Ejemplo 3.2 Regresión para datos binarios (Cuidado prenatal)

En este caso debemos concluir que aquellos pacientes que reciben cuidado intensivo están en un riesgo de mortalidad considerablemente menor que aquellos que reciben cuidado estándar, y que la evidencia en los datos es fuerte.

Para caracterizar de otra manera esta dependencia entre nivel de cuidado y mortalidad hacemos inferencia en términos de la razón de momios. Recordemos que $\exp\{\beta_2\}$ es el parámetro de la razón de momios y que su MLE es $\exp\{\hat{\beta}_2\}$, por lo que

$$\left(\exp \left\{ \hat{\beta}_2 - 1.96 \times \sqrt{\hat{\beta}_2} \right\}, \exp \left\{ \hat{\beta}_2 + 1.96 \times \sqrt{\hat{\beta}_2} \right\} \right)$$

es un intervalo de confianza aproximado al 95% de la razón de momios.

Ejemplo 3.2 Regresión para datos binarios (Cuidado prenatal)

El valor estimado puntual de la razón de momios en este caso es

$$\exp(\hat{\beta}_2) = \exp(-0.667) = 0.513,$$

con un intervalo de confianza al 95% de

$$\begin{aligned} & (\exp \{-0.667 - 1.96(0.278)\}, \exp \{-0.667 + 1.96(0.278)\}) \\ & = (0.297, 0.886), \end{aligned}$$

tal como lo calculamos anteriormente en el Ejemplo 3.1.

Ejemplo 3.2 Regresión para datos binarios (Cuidado prenatal)

De hecho, el análisis que hicimos anteriormente es exactamente igual a éste y los resultados deberán ser idénticos excepto por el redondeo de cifras.

Finalmente, notemos que mientras el estadístico tipo Wald se calcula para β_0 , éste raramente es de interés, el foco tiende a estar en el coeficiente de las variables explicativas, las cuales tienen interpretaciones útiles.

Ahora introduzcamos `clinic` al modelo, esto es un M_{12} es un modelo en donde examinamos el efecto de nivel de cuidado pero ajustado por la clínica a la que atienden los pacientes.

```
> Examine the relationship between level of care  
> and mortality adjusting for clinic  
M12 <- glm(resp ~ clinic + loc, family=binomial(link=logit),  
            data=d)  
summary(M12)
```

Ejemplo 3.2 Regresión para datos binarios (Cuidado prenatal)

Call:

```
glm(formula = resp ~ clinic + loc,  
     family = binomial(link = logit), data = d)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)	
(Intercept)	-1.7410	0.1785	-9.755	< 2e-16	***
clinic	-0.9863	0.3089	-3.193	0.00141	**
loc	-0.1503	0.3302	-0.455	0.64894	

Signif. codes:

0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 16.91763 on 3 degrees of freedom
Residual deviance: 0.10693 on 1 degrees of freedom
AIC: 23.262

Number of Fisher Scoring iterations: 3

Ejemplo 3.2 Regresión para datos binarios (Cuidado prenatal)

De acuerdo con el resultado de M_{12} ya no hay evidencia de la relación entre nivel de cuidado y moralidad. La asociación que vimos anteriormente en M_2 es explicada ahora por la clínica a la que atienden los pacientes.

Para ver esto notemos que la prueba de hipótesis $H_0 : \beta_2 = 0$, controlando por clínica, tiene un p -value ≈ 0.645 , es interesante pero no necesariamente quiere decir que no haya un efecto del nivel de cuidado en mortalidad. Podría ser el caso de que en la interacción entre nivel de cuidado y clínica, por ejemplo, el nivel de cuidado sea significativo en una de las clínicas.

Para investigarlo actualizamos nuestro modelo incorporando nivel de cuidado, clínica y la interacción entre nivel de cuidado y clínica, le llamaremos modelo M_{123} .

Ejemplo 3.2 Regresión para datos binarios (Cuidado prenatal)

> Examine whether the association between loc and
> mortality depends on the clinic

```
M123 <- glm(resp ~ loc, family=binomial(link=logit),  
            data=d)  
summary(M123)
```

Ejemplo 3.2 Regresión para datos binarios (Cuidado prenatal)

Call:

```
glm(formula = resp ~ loc + clinic + loc * clinic ,  
     family = binomial(link = logit), data = d)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)	
(Intercept)	-1.756843	0.185709	-9.460	< 2e-16	***
loc	0.007643	0.572683	0.013	0.98935	
clinic	-0.928734	0.351430	-2.643	0.00822	**
loc:clinic	-0.229650	0.694905	-0.330	0.74104	

Signif. codes:

0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 1.6918e+01 on 3 degrees of freedom
Residual deviance: -4.3521e-14 on 0 degrees of freedom
AIC: 25.155

Number of Fisher Scoring iterations: 3

Ejemplo 3.2 Regresión para datos binarios (Cuidado prenatal)

No debería sorprendernos que el término de interacción no sea significativo dado que al tabular los datos en el Ejemplo 3.1 encontramos que la razón de momios que relaciona nivel de cuidado y mortalidad era similar entre los dos clínicas.

En este caso, efectivamente, en la presencia de clínica en el modelo el nivel de cuidado no tiene efecto y la evidencia apunta a una relación fuerte entre clínica y mortalidad.

Finalmente, ajustamos el modelo M_1 que contiene únicamente `clinic` como efecto principal.

```
> Examine the marginal relationship between mortality  
> and clinic
```

```
M1 <- glm(resp ~ clinic , family=binomial(link=logit) ,  
           data=d)  
summary(M1)
```

Ejemplo 3.2 Regresión para datos binarios (Cuidado prenatal)

Call:

```
glm(formula = resp ~ clinic, family = binomial(link = logit),  
     data = d)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-1.7560	0.1757	-9.996	< 2e-16 ***
clinic	-1.0624	0.2621	-4.053	5.06e-05 ***

Signif. codes:

0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 16.91763 on 3 degrees of freedom
Residual deviance: 0.31484 on 2 degrees of freedom
AIC: 21.47

Number of Fisher Scoring iterations: 4

Ejemplo 3.2 Regresión para datos binarios (Cuidado prenatal)

Al someter a prueba $H_0 : \beta_1 = 0$ vs. $H_1 : \beta_1 \neq 0$ obtenemos

$$p\text{-value} = 2 \times \Pr \left(Z > \left| \frac{-1.062}{0.262} \right| \right) = 2 * (1 - \text{pnorm}(4.053)) < 0.001.$$

Concluimos aquí que el riesgo de mortalidad de los pacientes que atienden la clínica A es significativamente menor el de los pacientes de la clínica B , y que la evidencia es muy fuerte. El estimador puntual de la razón de momios que refleja un riesgo disminuido de mortalidad en la clínica A respecto de la clínica B es

$$\exp\{-1.062\} = 0.346$$

y el correspondiente estimador de intervalo al 95% es

$$\begin{aligned} & (\exp\{-1.062 - 1.96(0.262)\}, \exp\{-1.062 + 1.96(0.262)\}) \\ & = (0.207, 0.578). \end{aligned}$$



Máxima verosimilitud en regresión binaria

Considera las la respuesta $y_1, \dots, y_n$ como observaciones de n variables aleatorias independientes $Y_1, \dots, Y_n$ donde $Y_i \sim \text{Bin}(n_i, \pi_i), i = 1, \dots, n$. Su función de probabilidad conjunta es

$$\Pr(Y = \mathbf{y}; \boldsymbol{\pi}) = \prod_{i=1}^n \binom{n_i}{y_i} \pi_i^{y_i} (1 - \pi_i)^{n_i - y_i}$$

y sus funciones de verosimilitud y log-verosimilitud son

$$\begin{aligned} L(\boldsymbol{\pi}; \mathbf{y}) &= \prod_{i=1}^n \pi_i^{y_i} (1 - \pi_i)^{n_i - y_i} \\ \ell(\boldsymbol{\pi}; \mathbf{y}) &= \sum_{i=1}^n y_i \log \pi_i + (n_i - y_i) \log(1 - \pi_i) \\ &= \sum_{i=1}^n y_i \log \left(\frac{\pi_i}{1 - \pi_i} \right) + n_i \log(1 - \pi_i) \end{aligned}$$

Máxima verosimilitud en regresión binaria

Un modelo de regresión para este tipo de datos consiste en expresar $\boldsymbol{\pi}^\top = [\pi_1 \dots \pi_n]$ en términos de un conjunto más reducido de parámetros, los cuales entran al modelo en forma de coeficientes de regresión, $\boldsymbol{\beta}^\top = [\beta_1 \dots \beta_p]$, (podemos verlo como una reducción). La manera de vincular $\boldsymbol{\pi}$ con $\boldsymbol{\beta}$ es mediante la función de ligadura. La ligadura logit

$$g(\pi_i) = \log \left(\frac{\pi_i}{1 - \pi_i} \right) = \mathbf{x}_i^\top \boldsymbol{\beta} = \eta_i$$

implica

$$\pi_i = \frac{e^{\mathbf{x}_i^\top \boldsymbol{\beta}}}{1 + e^{\mathbf{x}_i^\top \boldsymbol{\beta}}}.$$

La función $\log\{\pi/(1 - \pi)\}$ se conoce como la función logit y también escribimos $\logit \pi = \log\{\pi/(1 - \pi)\}$.

Máxima verosimilitud en regresión binaria

Si la dimensión de β es menor que n , decimos que el modelo es no-saturado. En este caso tomamos p como la dimensión, correspondiente a un modelo con $p - 1$ variables explicativas o covariables. Cuando en el modelo la dimensión de β es $p = n$, entonces tenemos un modelo saturado.

La función log-verosimilitud con la reparametrización $g(\pi_i) = \log\{\pi_i/(1 - \pi_i)\} = \mathbf{x}_i^\top \beta$ es

$$\begin{aligned}\ell(\boldsymbol{\pi}; \mathbf{y}) &= \sum_{i=1}^n y_i \mathbf{x}_i^\top \beta + (n_i - y_i) \log \left(\frac{1}{\mathbf{x}_i^\top \beta} \right) \\ &= \sum_{i=1}^n y_i \mathbf{x}_i^\top \beta - n_i \log \left(1 + e^{\mathbf{x}_i^\top \beta} \right).\end{aligned}$$

Máxima verosimilitud en regresión binaria

Maximizando ℓ respecto de β obtenemos $\hat{\beta}$, con lo que calculamos

$$\hat{\pi}_i = \frac{e^{\mathbf{x}_i^\top \hat{\beta}}}{1 + e^{\mathbf{x}_i^\top \hat{\beta}}}.$$

La calidad del ajuste de estos modelos de regresión será juzgada en términos de qué tan apropiadamente $\hat{\boldsymbol{\pi}}^\top = [\hat{\pi}_1 \dots \hat{\pi}_n]$ se ajusta a los datos o, equivalentemente, que tan cerca $n_i \hat{\pi}_i$ se aproxima a $y_i, i = 1, \dots, n$.

Necesitamos un criterio para evaluar cuánto peor son los modelos no-saturados respecto del modelo saturado.

Un enfoque conveniente para hipótesis anidadas es con base en el estadístico de razón de verosimilitud.

Prueba de razón de verosimilitud

El estadístico de razón de verosimilitud es central para el análisis de modelos de regresión binaria y tiene un nombre especial.

Se llama *deviance* (*devianza*) y la representamos por D si la pensamos como variable aleatoria y d si nos referimos a ella para un valor realizado. El output de R reporta la deviance y en algunos paquetes se muestra como *deviance escalada* (*scaled deviance*).

Explicamos su desarrollo e interpretación y haremos algunas consideraciones respecto de su distribución asintótica y su uso para comparar modelos anidados.

Prueba de razón de verosimilitud

$L(\boldsymbol{\theta})$ es la función de verosimilitud del parametro q -dimensional $\boldsymbol{\theta}$. Puede ser maximizada sin restricciones respecto de $\boldsymbol{\theta}$ resultando en $\tilde{\boldsymbol{\theta}}$, o sujeta a restricciones dando $\hat{\boldsymbol{\theta}}$. En el caso restringido, la dimensión efectiva de $\boldsymbol{\theta}$ será denotada por p .

Notemos que los modelos de regresión pueden interpretarse como si impusiéramos restricciones en la respuesta media. Esto es, forzamos relaciones entre los valores μ_i en regresión lineal, o en π_i en regresión logística. Podemos entonces formular una prueba de hipótesis de que la restricción es razonable evaluando qué tan consistente es con los datos. El estadístico de razón de verosimilitud es

$$D = -2r(\hat{\boldsymbol{\theta}}) = -2 \log \left(\frac{L(\hat{\boldsymbol{\theta}})}{L(\tilde{\boldsymbol{\theta}})} \right) \sim \chi^2_\nu \quad (54)$$

Prueba de razón de verosimilitud

La distribución χ^2_ν del estadístico tien $\nu = q - p$ grados de libertad asumiendo que se sostiene la hipótesis nula de que las restricciones son razonables, donde ν es la diferencia efectiva del número de parámetros con las restricciones y sin ellas. Entonces, si

$$D = -2 \log \left(\frac{L(\hat{\boldsymbol{\theta}})}{L(\tilde{\boldsymbol{\theta}})} \right) > \chi^2_\nu(1 - \alpha)$$

rechazaríamos H_0 al nivel de significancia α . Es más informativo examinar al p -value, el cual calculamos mediante

$$p\text{-value} = \Pr \left\{ \chi^2_{q-p} > -2 \log \left(\frac{L(\hat{\boldsymbol{\theta}})}{L(\tilde{\boldsymbol{\theta}})} \right) \right\}$$

Prueba de razón de verosimilitud

Regresando a la función log-verosimilitud del modelo binomial, tenemos

$$\ell(\boldsymbol{\pi}; \mathbf{y}) = \sum_{i=1}^n y_i \log \pi_i + (n_i - y_i) \log(1 - \pi_i).$$

Sea

$$\tilde{\boldsymbol{\pi}}^\top = [\tilde{\pi}_1 \dots \tilde{\pi}_n] = \left[\frac{y_1}{n_1} \dots \frac{y_n}{n_n} \right]$$

el MLE bajo el modelo saturado y sea

$$\hat{\boldsymbol{\pi}}^\top = [\hat{\pi}_1 \dots \hat{\pi}_n]$$

el MLE bajo el modelo con las restricciones impuestas por la ecuación de regresión.

Prueba de razón de verosimilitud

Sustituyendo los MLE el estadístico de razón de verosimilitud es

$$\begin{aligned} D(\boldsymbol{\pi}, \mathbf{y}) &= -2 \log \left(\frac{L(\hat{\boldsymbol{\pi}})}{L(\tilde{\boldsymbol{\pi}})} \right) = 2 (\ell(\tilde{\boldsymbol{\pi}}) - \ell(\hat{\boldsymbol{\pi}})) \\ &= 2 \left[\sum_{i=1}^n \left\{ y_i \log \left(\frac{y_i}{n_i} \right) + (n_i - y_i) \log \left(\frac{n_i - y_i}{n_i} \right) \right\} \right. \\ &\quad \left. - \sum_{i=1}^n \{ y_i \log \hat{\pi}_i + (n_i - y_i) \log(1 - \hat{\pi}_i) \} \right] \\ &= 2 \sum_{i=1}^n \left[y_i \log \left(\frac{y_i}{n_i \hat{\pi}_i} \right) + (n_i - y_i) \log \left(\frac{n_i - y_i}{n_i (1 - \hat{\pi}_i)} \right) \right] \\ &\sim \chi_{n-p}^2 \end{aligned}$$

Prueba de razón de verosimilitud

Con base en los resultados generales anteriores, esperaríamos que D tuviera una distribución χ^2 con $n - p$ grados de libertad. Desafortunadamente la distribución asintótica de D no es tan buena aproximación como lo esperaríamos. Sin embargo, funciona muy bien para probar modelos no-saturados anidados, como lo veremos en §6 y el Ejemplo 3.3.

Notemos la deviance (55) tiene la forma

$$2 \sum_{i=1}^n \sum_{j=1}^2 O_{ij} \log \frac{O_{ij}}{E_{ij}},$$

donde O_{ij} es una cantidad observada y E_{ij} una cantidad esperada. Hemos usado dos subíndices, j es para identificar las celdas de y_i y las de $(n_i - y_i)$.

Prueba de razón de verosimilitud

El *estadístico de Pearson* es otro que usamos para evaluar el ajuste global de un modelo.

$$P = \sum_{i=1}^n \frac{(y_i - n_i \hat{\pi}_i)^2}{n_i \hat{\pi}_i (1 - \hat{\pi}_i)} \sim \chi_{n-p}^2. \quad (56)$$

la cual tiene la forma

$$\sum_{i=1}^n \frac{(O_i - E_i)^2}{V_i}.$$

Tal como la deviance, el estadístico de Pearson tiene una distribución aproximada χ^2 con $n - p$ grados de libertad si el modelo tiene un ajuste razonable a los datos (i.e. si el modelo asumido es “verdadero”).

La aproximación de la distribución del estadístico de Pearson es mejor que la de la deviance.

En ambos casos la aproximación es pobre con muestras pequeñas (n_i), en cuyo caso debería complementarse con análisis de residuales §7.

Puede demostrarse mediante expansión en series de Taylor que la deviance y el estadístico de Pearson son equivalentes.

Modelos anidados no-saturados

Supongamos que tenemos dos modelos

$$M_p : \log \left(\frac{\pi_i}{1 - \pi_i} \right) = \beta_0 + \beta_1 x_{i1} + \dots + \beta_{p-1} x_{ip-1}$$

$$M_q : \log \left(\frac{\pi_i}{1 - \pi_i} \right) = \beta_0 + \beta_1 x_{i1} + \dots + \beta_{p-1} x_{ip-1} + \dots + \beta_{q-1} x_{iq-1}$$

Es de común interés investigar si M_p , el cual es un submodelo de M_q ajusta los datos tan bien como M_q . Esto es equivalente a probar la significancia de las variables $x_p, \dots, x_{q-1}$ o someter a prueba el sistema de hipótesis

$$H_0 : \beta_p = \dots = \beta_{q-1} = 0 \quad [\text{el modelo reducido es apropiado}]$$

$$\text{vs. } H_1 : \text{al menos una } \beta_k \neq 0; k = p, \dots, q - 1$$

$$[\text{el modelo extendido es apropiado}].$$

Modelos anidados no-saturados

Sea $\hat{\pi}$ el MLE de π bajo el modelo reducido M_p con p parámetros y sea $\tilde{\pi}$ el MLE de π bajo el modelo ampliado M_q con q parámetros. La estadística de razón de verosimilitud correspondiente a la prueba para comparar los dos modelos está dada por la diferencia de deviance de los dos modelos.


$$\Delta D = D_0 - D_1 \sim \chi_{q-p}^2, \quad (57)$$

donde D_0 es la deviance bajo H_0 y D_1 la deviance bajo H_1 . Para verlo, denotemos por M_{sat} el modelo saturado con n parámetros y por $\tilde{\pi}_{\text{sat}}$ su correspondiente MLE. El estadístico de razón de log-verosimilitud entre M_p y M_q es

$$\begin{aligned} -2 \log \left(\frac{L(\hat{\beta})}{L(\tilde{\beta})} \right) &= -2 \log \left(\frac{L(\hat{\pi})}{L(\tilde{\pi})} \right) = -2 \log \left(\frac{L(\hat{\pi})/L(\tilde{\pi}_{\text{sat}})}{L(\tilde{\pi})/L(\tilde{\pi}_{\text{sat}})} \right) \\ &= -2 \log \left(\frac{L(\hat{\pi})}{L(\tilde{\pi}_{\text{sat}})} \right) - \left[-2 \log \left(\frac{L(\tilde{\pi})}{L(\tilde{\pi}_{\text{sat}})} \right) \right] = D_0 - D_1 = \Delta D. \end{aligned} \quad 193$$

Modelos anidados no-saturados

D_0 tiene una distribución aproximada χ^2_{n-p} y $D_1 \sim \chi^2_{n-q}$, por lo que $\Delta D \sim \chi^2_{q-p}$ y su aproximación es muy superior que para la deviance en sí misma.



Si $\Delta D > \chi^2_{q-p}(1 - \alpha)$, entonces rechazamos H_0 y declaramos que el modelo reducido tiene un ajuste significativamente peor que el del modelo extendido o, equivalentemente, al menos una de las variables $x_p, \dots, x_{q-1}$ es importante para predecir la respuesta.

El p -value está dado por

$$p\text{-value} = \Pr(\chi^2_{q-p} > \Delta D).$$

Residuales de la deviance (Deviance Residuals)

Retomando 55, podemos escribir la ecuación como

$$\begin{aligned} D(\hat{\boldsymbol{\pi}}, \mathbf{y}) &= 2 \sum_{i=1}^n \left[y_i \log \left(\frac{y_i}{n_i \hat{\pi}_i} \right) + (n_i - y_i) \log \left(\frac{n_i - y_i}{n_i (1 - \hat{\pi}_i)} \right) \right] \\ &= \sum_{i=1}^n 2 \left[y_i \log \left(\frac{y_i}{n_i \hat{\pi}_i} \right) + (n_i - y_i) \log \left(\frac{n_i - y_i}{n_i (1 - \hat{\pi}_i)} \right) \right] \\ &= \sum_{i=1}^n d_i. \end{aligned}$$

Residuales de la deviance (Deviance Residuals)

Sea

$$r_i^D = \text{sign}(y_i - m_i \hat{\pi}_i) \sqrt{d_i} \sim \mathcal{N}(0, 1) \quad (58)$$

donde

$$\text{sign}(y_i - m_i \hat{\pi}_i) = \begin{cases} + & \text{si } y_i - m_i \hat{\pi}_i \geq 0 \\ - & \text{si } y_i - m_i \hat{\pi}_i < 0. \end{cases}$$

Llamamos a r_i^D los *residuales de deviance* (*deviance residuals*) y cuando el modelo es adecuado éstos tienen una distribución aproximada $\mathcal{N}(0, 1)$.

Residuales de Pearson (Pearson's Residuals)

Los residuales de Pearson tienen la forma

$$r_i^P = \frac{y_i - n_i \hat{\pi}_i}{\sqrt{n_i \hat{\pi}_i (1 - \hat{\pi}_i)}} \sim \mathcal{N}(0, 1) \quad (59)$$

Su distribución $\mathcal{N}(0, 1)$ es aproximada cuando el modelo es adecuado. Como regla general, si $n_i \hat{\pi}_i < 5$ para alguna i , debemos cuestionar la validez de la aproximación $\mathcal{N}(0, 1)$ (o χ_1^2) y, por lo tanto, las conclusiones (misma advertencia para $n_i(1 - \hat{\pi}_i)$).

Ejemplo 3.3 Efecto de covariables (Neuroblastoma)

Se condujo un estudio en 246 pacientes diagnosticados con neuroblastoma. El propósito del estudio es investigar la relación entre la probabilidad de sobrevivir 2 años libre de la enfermedad, a partir de la fecha de diagnóstico, edad y estado de la enfermedad. Los datos se resumen en la Tabla 13 donde las entradas de cada celda son de la forma y/n , siendo y el número de pacientes que sobreviven 2 años y n el número de pacientes en la respectiva combinación de edad & etapa al inicio del estudio.

Ejemplo 3.3 Efecto de covariables (Neuroblastoma)

Analicemos las distribuciones marginales en la Tabla 13.

Edad (meses)	Etapa					Total	
	I	II	III	IV	V		
0 – 11	11/12	15/16	2/4	5/18	18/19	51/69	(0.74)
12 – 23	3/4	3/7	5/8	0/25	1/3	12/47	(0.26)
24+	4/5	4/12	3/15	3/93	2/5	16/130	(0.12)
Total	18/21	22/35	10/27	8/136	21/27	79/246	(0.32)
	(0.86)	(0.62)	(0.37)	(0.06)	(0.78)		

Table 13: Number of patients surviving neuroblastoma / total number of patients.

Ejemplo 3.3 Efecto de covariables (Neuroblastoma)

Definimos las siguientes covariables para los rangos de edad y la etapa de la enfermedad en el diagnóstico.

$$\begin{aligned}x_{i1} &= \begin{cases} 1 & \text{si } 12 \leq \text{edad} \leq 23 \text{ meses} \\ 0 & \text{c.o.} \end{cases} & x_{i3} &= \begin{cases} 1 & \text{si etapa II} \\ 0 & \text{c.o.} \end{cases} & x_{i5} &= \begin{cases} 1 & \text{si etapa IV} \\ 0 & \text{c.o.} \end{cases} \\x_{i2} &= \begin{cases} 1 & \text{si edad} \geq 24 \text{ meses} \\ 0 & \text{c.o.} \end{cases} & x_{i4} &= \begin{cases} 1 & \text{si etapa III} \\ 0 & \text{c.o.} \end{cases} & x_{i6} &= \begin{cases} 1 & \text{si etapa V} \\ 0 & \text{c.o.} \end{cases}\end{aligned}$$

Queremos reducir los parámetros del modelo.

Ejemplo 3.3 Efecto de covariables (Neuroblastoma)

Consideremos 3 modelos: el modelo con todos los efectos principales (M_{main}), el modelo con solo las covariables de edad (M_{age}) y el modelo con las covariables del estado de la enfermedad (M_{sta}).

$$M_{\text{main}} : \text{logit } \pi_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \beta_3 x_{i3} + \beta_4 x_{i4} + \beta_5 x_{i5} + \beta_6 x_{i6}$$

$$M_{\text{age}} : \text{logit } \pi_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2}$$

$$M_{\text{sta}} : \text{logit } \pi_i = \beta_0 + \beta_3 x_{i3} + \beta_4 x_{i4} + \beta_5 x_{i5} + \beta_6 x_{i6}$$

El objetivo de esta parte del análisis es elegir alguno de los modelos propuestos para reducir los parámetros del modelo. Hacemos el análisis en R y se muestra el código.

Ejemplo 3.3 Efecto de covariables (Neuroblastoma)

Los datos están almacenados en el archivo `neuro.txt`. El primer renglón es de los encabezados y las siguientes 15 líneas son los datos.

En esta tabla `age` y `stage` son variables categóricas (ordinales) por lo que tendremos que generar variables indicadoras en R usando la función `factor()`.

También construimos la variable respuesta de la forma en dos columnas de la forma y_i y $n_i - y_i$.

Ejemplo 3.3 Efecto de covariables (Neuroblastoma)

```
setwd(datwd); getwd()  
d <- read.table('neuro.txt', header=TRUE, sep='\t')  
d
```

	age	stage	y	n
1	1	1	11	12
2	1	2	15	16
3	1	3	2	4
4	1	4	5	18
5	1	5	18	19
6	2	1	3	4
7	2	2	3	7
8	2	3	5	8
9	2	4	0	25
10	2	5	1	3
11	3	1	4	5
12	3	2	4	12
13	3	3	3	15
14	3	4	3	93
15	3	5	2	5

Ejemplo 3.3 Efecto de covariables (Neuroblastoma)

> Since age and stage are categorical (ordinal) variables ,
> we create factor variables agef and stagef using
> the factor() function

```
d$agef <- factor(d$age)  
d$stagef <- factor(d$stage)
```

Ejemplo 3.3 Efecto de covariables (Neuroblastoma)

> Construct the **response variable** for logistic regression.

```
d$resp <- cbind(d$y, d$n-d$y)
```

d

	age	stage	y	n	agef	stagef	resp.1	resp.2
1	1	1	11	12	1	1	11	1
2	1	2	15	16	1	2	15	1
3	1	3	2	4	1	3	2	2
4	1	4	5	18	1	4	5	13
5	1	5	18	19	1	5	18	1
6	2	1	3	4	2	1	3	1
7	2	2	3	7	2	2	3	4
8	2	3	5	8	2	3	5	3
9	2	4	0	25	2	4	0	25
10	2	5	1	3	2	5	1	2
11	3	1	4	5	3	1	4	1
12	3	2	4	12	3	2	4	8
13	3	3	3	15	3	3	3	12
14	3	4	3	93	3	4	3	90
15	3	5	2	5	3	5	2	3

Ejemplo 3.3 Efecto de covariables (Neuroblastoma)

Ajustamos el modelo M_{main} y mostramos los resultados.

> We will fit three models:

> – M_main: main effects

> – M_age: effect of age

> – M_sta: effect of stage disease

> First fit the main effects model i.e. with age and stage

```
M_main <- glm(resp ~ agef+stagef ,  
              family=binomial(link=logit), data=d)  
summary(M_main)
```

Ejemplo 3.3 Efecto de covariables (Neuroblastoma)

Call:

```
glm(formula = resp ~ agef + stagef,  
     family = binomial(link = logit), data = d)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)	
(Intercept)	3.3175	0.7721	4.297	1.73e-05	***
agef2	-2.1181	0.5736	-3.693	0.000222	***
agef3	-2.6130	0.5017	-5.208	1.91e-07	***
stagef2	-1.2529	0.7837	-1.599	0.109860	
stagef3	-1.7759	0.8003	-2.219	0.026478	*
stagef4	-4.3678	0.7902	-5.528	3.25e-08	***
stagef5	-1.0222	0.8644	-1.183	0.236980	

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 162.832 on 14 degrees of freedom
Residual deviance: 9.625 on 8 degrees of freedom
AIC: 55.382

Number of Fisher Scoring iterations: 4

Ejemplo 3.3 Efecto de covariables (Neuroblastoma)

Antes de interpretar los resultados, veamos qué tan bueno es el ajuste de los datos analizando los residuales. Primero extraemos los residuales de la deviance, el predictor lineal y los valores ajustados $(\hat{\pi}_i) = e^{\mathbf{x}_i^T \hat{\beta}} / (1 + e^{\mathbf{x}_i^T \hat{\beta}})$ [asegúrese de poder repetir estos resultados tanto en la computadora como a mano].

```
> Record deviance residuals (rd1), linear predictor (lp1),  
> and fitted values (fv1)
```

```
rd1 <- residuals.glm(m1, 'deviance')  
lp1 <- m1$linear.predictors  
fv1 <- m1$fitted.values
```

```
> Compute the Pearson residual as an exercise.
```

```
rp1 <- (d$y - d$n * fv1) / sqrt(d$n * fv1 * (1 - fv1))
```

```
> Verify the fitted values calculations.  
rbind(fv1, exp(lp1) / (1 + exp(lp1)))
```

Ejemplo 3.3 Efecto de covariables (Neuroblastoma)

```
> Show the linear predictor , fitted values and Pearsons and  
> deviance residuals
```

```
cbind(lp1 , fv1 , rp1 , rd1)
```

```
> Plot the deviance and Pearson residuals .
```

```
plot(fv1 , rd1 , ylim=c(-3,3), xlab=bquote(hat(pi[i])),  
      ylab='Residuals ' , las=1, pch=22, cex=1.5)  
points(fv1 , rp1 , pch=20, col=4)  
abline(h=-2, lty=2)  
abline(h=2, lty=2)  
title('Residuals Plotted Against Fitted Values')  
legend('topleft ' , inset=0.01,  
       c('Deviance Residual ' , 'Pearson Residual ' ) ,  
       pch=c(22,20) , col=c(1,4) , bty='n')
```

Ejemplo 3.3 Efecto de covariables (Neuroblastoma)




Figure 6: Residuals by fitted values for Neuroblastoma model with Age and Stage as covariates.

La gráfica de la Figura 6 muestra la gráfica de los residuales vs. valores ajustados, y sugiere que el ajuste es adecuado al no haber observaciones con residuales demasiado grandes. Este análisis lo hicimos con los residuales de deviance porque por lo regular se comportan mejor que los residuales de Pearson, aunque en este ejemplo llegaríamos a la misma conclusión con los residuales de Pearson.

Ejemplo 3.3 Efecto de covariables (Neuroblastoma)

Consideremos simplificar el modelo examinando el deterioro en la calidad del ajuste cuando dejamos las covariables de Estado fuera del modelo (M_{sta}) y cuando dejamos fuera las variables de Edad (M_{sta}). Se muestra el resumen de estos dos modelos.

```
> Fit two reduced models to help us test the importance  
  of age and stage.
```

```
M_age <- glm(resp ~ agef, family=binomial(link=logit),  
             data=d)  
M_sta <- glm(resp ~ stagef, family=binomial(link=logit),  
             data=d)
```

Ejemplo 3.3 Efecto de covariables (Neuroblastoma)

```
summary(M_age)
```

```
Call:
```

```
glm(formula = resp ~ agef, family = binomial(link = logit),  
     data = d)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)	
(Intercept)	1.0415	0.2742	3.799	0.000145	***
agef2	-2.1119	0.4325	-4.883	1.05e-06	***
agef3	-3.0051	0.3827	-7.853	4.06e-15	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 162.832 on 14 degrees of freedom
Residual deviance: 83.583 on 12 degrees of freedom
AIC: 121.34

Number of Fisher Scoring iterations: 5

Ejemplo 3.3 Efecto de covariables (Neuroblastoma)

```
summary(M_sta)
```

```
Call:
```

```
glm(formula = resp ~ stagef, family = binomial(link = logit),  
     data = d)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)	
(Intercept)	1.7918	0.6236	2.873	0.00406	**
stagef2	-1.2657	0.7150	-1.770	0.07671	.
stagef3	-2.3224	0.7401	-3.138	0.00170	**
stagef4	-4.5643	0.7223	-6.319	2.63e-10	***
stagef5	-0.5390	0.7766	-0.694	0.48768	

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 162.832 on 14 degrees of freedom
Residual deviance: 42.446 on 10 degrees of freedom
AIC: 84.203

Number of Fisher Scoring iterations: 5

Ejemplo 3.3 Efecto de covariables (Neuroblastoma)

Someteremos a prueba estos modelos anidados usando la prueba de razón de verosimilitud, en este contexto denominamos como cambio en la deviance y la denotamos por ΔD

Factores en el modelo	deviance	Grados de libertad
Edad & Etapa	9.63	8
Edad	83.58	12
Etapa	42.45	10

Ejemplo 3.3 Efecto de covariables (Neuroblastoma)

En el primer sistema de hipótesis se somete a prueba el escenario en que Etapa no está relacionada con la probabilidad de supervivencia o, equivalentemente,

$$H_0 : \beta_3 = \dots = \beta_6 = 0$$

$$\text{vs. } H_1 : \text{al menos una } \beta_k \neq 0; \quad k = 3, \dots, 6.$$

El cambio en la deviance de ir de M_{main} a M_{age} es

$$\Delta D = 83.58 - 9.63 = 73.93.$$

Recordemos que $\Delta D \sim \chi_{q-p}^2$ y en este caso $q - p = 12 - 8 = 4$.

Por lo tanto, el p -value estaría dado por

$$p\text{-value} = \Pr(\chi_4^2 > 73.96) < 0.0001,$$

y debemos rechazar la hipótesis de que Estado no está relacionada con la supervivencia y la evidencia en los datos es fuerte.

Ejemplo 3.3 Efecto de covariables (Neuroblastoma)

Consideremos ahora someter a prueba el escenario en el que Edad no está relacionada con la probabilidad de supervivencia. El sistema de hipótesis es

$$H_0 : \beta_1 = \beta_2 = 0$$

$$\text{vs. } H_1 : \beta_1 \neq 0 \text{ o } \beta_2 \neq 0 \text{ o ambas}$$

El cambio en la deviance de ir de M_{main} a M_{sta} es

$$\Delta D = 42.45 - 9.63 = 32.82.$$

En este caso $q - p = 10 - 8 = 2$, por lo que la distribución de ΔD sería χ^2_2 y el p -value la asociado a la prueba de hipótesis es

$$p\text{-value} = \Pr(\chi^2_2 > 32.82) < 0.0001.$$


Rechazamos, por tanto, la hipótesis nula de que Edad no está relacionada con la supervivencia.

Ejemplo 3.3 Efecto de covariables (Neuroblastoma)


Debemos concluir entonces que ambas Edad y Estado juegan un papel importante en el pronóstico de supervivencia, aún después de controlar por la otra variable.

Como elemento de análisis adicional, vemos en las gráficas de residuales vs. valores ajustados de las Figuras 7a, 7b que los residuales son bastante más dispersos que los del M_{main} , incluso hay observaciones tienen residuales fuera de la banda ± 2 .

Ejemplo 3.3 Efecto de covariables (Neuroblastoma)



(a) M_{age} : Residuals by fitted values for Neuroblastoma model with Age as covariates.



(b) M_{sta} : Residuals by fitted values for Neuroblastoma model with Stage as covariates.

Figure 7: Residuals vs fitted values Neuroblastoma data.

Ejemplo 3.3 Efecto de covariables (Neuroblastoma)

Usemos el output de R para contestar las siguientes preguntas.

1. ¿Cuál es la razón de momios de supervivencia dos años para un paciente enfermo en etapa IV respecto de etapa I?

age	stage	$\mathbf{x}_i^\top$	$\pi/(1 - \pi_i)$
NA	IV	$[1 \ x_1 \ x_2 \ 0 \ 0 \ 1 \ 0]$	$\exp\{\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_5\}$
NA	I	$[1 \ x_1 \ x_2 \ 0 \ 0 \ 0 \ 0]$	$\exp\{\beta_0 + \beta_1 x_1 + \beta_2 x_2\}$

Esta razón de momios es e^{β_5} , y su valor estimado es

$$e^{\hat{\beta}_5} = e^{-4.368} = 0.013.$$

Ejemplo 3.3 Efecto de covariables (Neuroblastoma)

1. Interpretamos este resultado de la siguiente manera:
“Controlando por edad, los momios de sobrevivir dos años entre los pacientes diagnosticados en etapa IV es 0.013 veces los momios de pacientes diagnosticados en etapa.I”. Es claro que haber sido diagnosticado en etapa IV tiene un efecto importante al disminuir la probabilidad de supervivencia.
2. Calcule la razón de momios de supervivencia para un paciente en el rango de edad 12 – 23 meses respecto de 0 – 11 meses.

age	stage	$\mathbf{x}_i^T$	$\pi/(1 - \pi_i)$
12-23	NA	$[1 \ 1 \ 0 \ x_3 \ x_4 \ x_5 \ x_6]$	$\exp\{\beta_0 + \beta_1 + \beta_3x_3 + \beta_4x_4 + \beta_5x_5 + \beta_6x_6\}$
0-11	NA	$[1 \ 0 \ 0 \ x_3 \ x_4 \ x_5 \ x_6]$	$\exp\{\beta_0 + \beta_3x_3 + \beta_4x_4 + \beta_5x_5 + \beta_6x_6\}$

Ejemplo 3.3 Efecto de covariables (Neuroblastoma)

Esta razón es e^{β_1} y su valor estimado es

$$e^{\hat{\beta}_1} = e^{-2.12} = 0.12.$$

Por lo tanto, “Controlando por etapa de la enfermedad, los momios de sobrevivir dos años habiendo sido diagnosticado a una edad de entre 12-23 meses es 0.12 veces los momios de sobrevivir dos años entre pacientes diagnosticados a una edad de entre 0-11 meses.”. Ser diagnosticado en el rango de edad intermedio reduce mucho la probabilidad de sobrevivir dos años respecto del menor rango de edad.

3. Calcule la razón de momios de supervivencia para un paciente en el rango de edad 24+ meses respecto de 12 – 23 meses.

Ejemplo 3.3 Efecto de covariables (Neuroblastoma)

age	stage	$\mathbf{x}_i^\top$	$\pi/(1 - \pi_i)$
24+	NA	$[1 \ 0 \ 1 \ x_3 \ x_4 \ x_5 \ x_6]$	$\exp\{\beta_0 + \beta_2 + \beta_3 x_3 + \beta_4 x_4 + \beta_5 x_5 + \beta_6 x_6\}$
12-23	NA	$[1 \ 1 \ 0 \ x_3 \ x_4 \ x_5 \ x_6]$	$\exp\{\beta_0 + \beta_1 + \beta_3 x_3 + \beta_4 x_4 + \beta_5 x_5 + \beta_6 x_6\}$

Esta razón de momios es $e^{\beta_2 - \beta_1}$ y su valor estimado

$$e^{\hat{\beta}_2 - \hat{\beta}_1} = e^{-2.61 + 2.12} = e^{-0.495} = 0.61.$$

Esto es, “Controlando por etapa de la enfermedad, los momios de sobrevivir dos años entre pacientes diagnosticados a partir de los 24 meses de edad es 0.61 veces los momios de sobrevivir dos años enter pacientes diagnosticados a una edad de entre 12-23 meses.”. Notemos que en este caso la razón de momios es una función de dos coeficientes de regresión y su valor estimado función de dos coeficientes estimados.

Ejemplo 3.3 Efecto de covariables (Neuroblastoma)

4. Dado el modelo final, calcule la razón de momios de supervivencia para un paciente en el rango de edad 12 – 23 meses y en etapa II de la enfermedad respecto de un paciente en el rango de edad 0 – 11 meses y enfermedad en etapa I.

age	stage	$\mathbf{x}_i^\top$	$\pi/(1 - \pi_i)$
12-23	II	[1 1 0 1 0 0 0]	$\exp\{\beta_0 + \beta_1 + \beta_3\}$
0-11	I	[1 0 0 0 0 0 0]	$\exp\{\beta_0\}$

Esta razón es $e^{\beta_1 + \beta_3}$ y su valor estimado

$$e^{\hat{\beta}_1 + \hat{\beta}_3} = e^{-2.12 - 1.25} = e^{-3.37} = 0.03.$$

Ejemplo 3.3 Efecto de covariables (Neuroblastoma)

“Entre los pacientes diagnosticados en etapa II a una edad de entre 12-23 meses, los momios de sobrevivir dos años son 0.03 veces los momios de los pacientes en etapa I diagnosticados a una edad de entre 0-11 meses.”. Notemos que en este caso no decimos “Controlando por X” pues los grupos que comparamos están definidos por ambos factores.

5. Dado el modelo final, calcule la razón de momios de supervivencia para un paciente en el rango de edad 24+ meses y enfermedad en etapa IV respecto de un paciente en el rango de edad 12 – 23 meses y enfermedad en etapa III.

Ejemplo 3.3 Efecto de covariables (Neuroblastoma)

age	stage	$\mathbf{x}_i^\top$	$\pi/(1 - \pi_i)$
24+	IV	[1 0 1 0 0 1 0]	$\exp\{\beta_0 + \beta_2 + \beta_5\}$
12-23	III	[1 1 0 0 1 0 0]	$\exp\{\beta_0 + \beta_1 + \beta_4\}$

La razón de momios es $e^{\beta_2 + \beta_5 - \beta_1 - \beta_4}$ y su valor estimado

$$e^{\hat{\beta}_2 + \hat{\beta}_5 - \hat{\beta}_1 - \hat{\beta}_4} = e^{-2.61 - 4.37 + 2.12 + 1.78} = e^{-3.09} = 0.046.$$

Interpretamos esta razón de momios como sigue: “Los momios de sobrevivir dos años entre los pacientes diagnosticados en etapa IV a una edad de 24 meses o más es 0.046 veces los momios de pacientes diagnosticados en etapa III a una edad de entre 12-23 meses.”.

Ejemplo 3.3 Efecto de covariables (Neuroblastoma)

Revise el código de R en `GLM_Examples.R`



Intervalos de confianza para contrastes en η_i

Recordemos, dado que $\hat{\beta}$ es un MLE, $\hat{\beta} \sim \mathcal{N}_p(\beta, I^{-1}(\hat{\beta}))$ aproximadamente. Esto significa que

$$\mathbf{x}_i^\top \hat{\beta} \sim \mathcal{N}\left(\mathbf{x}_i^\top \beta, \mathbf{x}_i^\top I^{-1}(\hat{\beta}) \mathbf{x}_i\right)$$

y

$$\frac{\mathbf{x}_i^\top \hat{\beta} - \mathbf{x}_i^\top \beta}{\sqrt{\mathbf{x}_i^\top \hat{\beta} \sim \mathcal{N}\left(\mathbf{x}_i^\top \beta, \mathbf{x}_i^\top I^{-1}(\hat{\beta}) \mathbf{x}_i\right)}} \sim \mathcal{N}(0, 1).$$

Se derivan los siguientes resultados:

1. Un intervalo de confianza aproximado al 95% para $\eta_i = \mathbf{x}_i^\top \beta$ está dado por

$$(\hat{\eta}_{iL}, \hat{\eta}_{iU}) = \left\{ \mathbf{x}_i^\top \hat{\beta} \pm 1.96 \sqrt{\mathbf{x}_i^\top I^{-1}(\hat{\beta}) \mathbf{x}_i} \right\}. \quad (60)$$

Intervalos de confianza para contrastes en η_i)

2. Si la razón de momios de interés está expresada como $\psi = \exp\{\mathbf{c}^\top \boldsymbol{\beta}\}$ donde $\mathbf{c}$ es un vector columna definiendo contrastes de los coeficientes de regresión, entonces un intervalo de confianza aproximado para $\exp\{\mathbf{c}^\top \boldsymbol{\beta}\}$ es

$$(\hat{\psi}_L, \hat{\psi}_U) = \left\{ \exp \left(\mathbf{c}^\top \hat{\boldsymbol{\beta}} \pm 1.96 \sqrt{\mathbf{c}^\top I^{-1}(\hat{\boldsymbol{\beta}}) \mathbf{c}} \right) \right\} \quad (61)$$

3. Un intervalo de confianza aproximado al 95% para $\hat{\pi}_i = \exp\{\mathbf{x}_i^\top \boldsymbol{\beta}\} / (1 + \exp\{\mathbf{x}_i^\top \boldsymbol{\beta}\})$ está dado por

$$(\hat{\pi}_{iL}, \hat{\pi}_{iU}) = \left(\frac{\exp \{\hat{\eta}_{iL}\}}{1 + \exp \{\hat{\eta}_{iL}\}}, \quad \frac{\exp \{\hat{\eta}_{iU}\}}{1 + \exp \{\hat{\eta}_{iU}\}} \right) \quad (62)$$

Ejemplo 3.4 Intervalos de confianza para contrastes

Calcularemos los intervalos de confianza aproximados al 95% de las razones de momios del Ejemplo 3.3. Los CIs de las primeras dos razones de momios son directos pues solo involucran un coeficiente estimado, los otros tres sí son para un contraste de coeficientes y deberá calcularlos como parte de los ejercicios de tarea.

El output de R contiene la matriz de varianza de los coeficientes de regresión estimados, $I^{-1}(\hat{\beta})$, en el objeto `cov.unscaled`. La guardaremos en `v` y de ahí obtendremos los errores estándar para calcular los intervalos de confianza.

```
> Compute the variance of a contrast  
> Use the summary.glm() function and store the result in ms  
  
ms <- summary.glm(M_main)
```

Ejemplo 3.4 Intervalos de confianza para contrastes

```
> Examine the contents of the ms object and store the  
> covariance matrix in v.
```

```
names(ms)  
v <- ms$cov.unscaled  
dim(v)  
[1] 7 7  
round(v,3)
```

	(Intercept)	agef2	agef3	stagef2	stagef3	stagef4	stagef5
(Intercept)	0.596	-0.184	-0.176	-0.464	-0.437	-0.510	-0.497
agef2	-0.184	0.329	0.158	0.018	-0.016	0.083	0.060
agef3	-0.176	0.158	0.252	0.016	-0.015	0.068	0.056
stagef2	-0.464	0.018	0.016	0.614	0.448	0.456	0.454
stagef3	-0.437	-0.016	-0.015	0.448	0.640	0.444	0.446
stagef4	-0.510	0.083	0.068	0.456	0.444	0.624	0.469
stagef5	-0.497	0.060	0.056	0.454	0.446	0.469	0.747

```
> Calculate the  $(1-0.05/2)\%$  quantile  $N(0,1)$ 
```

```
z <- qnorm(0.975); z  
[1] 1.959964
```

Ejemplo 3.4 Intervalos de confianza para contrastes

1. La razón de momios es e^{β_5} y el intervalo de confianza para su estimado $e^{\hat{\beta}_5}$ es

$$\left(e^{-4.368-1.96\sqrt{0.624}}, e^{-4.368+1.96\sqrt{0.624}} \right) = (0.003, 0.060).$$

Mostramos el código de R de estos cálculos. Note el uso la función `as.numeric()`.

```
x21 <- c(1,1,0,0,0,0,0);
x22 <- c(1,0,0,0,0,0,0);
con2 <- matrix(x21-x22, ncol=1); t(con2)
      [,1] [,2] [,3] [,4] [,5] [,6] [,7]
[1,]    0    1    0    0    0    0    0
lp2 <- crossprod(con2, bhat); lp2
      [,1]
[1,] -2.118085
lp2 <- as.numeric(crossprod(con2, bhat)); lp2
[1] -2.118085
se_con2 <- as.numeric(sqrt(t(con2) %*% v %*% con2)); se_con2
[1] 0.5735955
ci2 <- exp(lp2 + c(-1,1)*z*se_con2); ci2
[1] 0.03907348 0.37014589
```

Ejemplo 3.4 Intervalos de confianza para contrastes

2. la razón es $e^{\hat{\beta}_1}$ y el intervalo de confianza para su estimado $e^{\hat{\beta}_1}$ es

$$\left(e^{-2.12-1.96\sqrt{0.329}}, e^{-2.12+1.96\sqrt{0.329}} \right) = (0.039, 0.370).$$

```
x21      <- c(1,1,0,0,0,0,0);
x22      <- c(1,0,0,0,0,0,0);
con2     <- matrix(x21-x22, ncol=1); t(con2)
      [,1] [,2] [,3] [,4] [,5] [,6] [,7]
[1,]      0      1      0      0      0      0      0
lp2      <- crossprod(con2, bhat); lp2
      [,1]
[1,] -2.118085
lp2      <- as.numeric(crossprod(con2, bhat)); lp2
[1] -2.118085
se_con2 <- as.numeric(sqrt(t(con2) %*% v %*% con2)); se_con2
[1] 0.5735955
ci2     <- exp(lp2 + c(-1,1)*z*se_con2); ci2
[1] 0.03907348 0.37014589
```

Ejemplo 3.4 Intervalos de confianza para contrastes

3. La razón de momios es $e^{\beta_2 - \beta_1}$. Para calcular el intervalo de confianza de $e^{\hat{\beta}_2 - \hat{\beta}_1}$ necesitamos calcular la varianza del contraste entre los coeficientes de regresión $\hat{\beta}_2 - \hat{\beta}_1$, esto es

$$\begin{aligned}\text{var}(\hat{\beta}_2 - \hat{\beta}_1) &= \text{var}(\hat{\beta}_2) + \text{var}(\hat{\beta}_1) - 2 \text{cov}(\hat{\beta}_2, \hat{\beta}_1) \\ &= 0.25 + 0.33 - 2(0.16) = 0.265.\end{aligned}$$

Entonces el intervalo de confianza de $e^{\hat{\beta}_2 - \hat{\beta}_1}$ es

$$\left(e^{-2.61+2.12-1.96\sqrt{0.264}}, e^{-2.61+2.12+1.96\sqrt{0.264}} \right) = (0.222, 1.672).$$

```
x31 <- c(1,0,1,0,0,0,0);
x32 <- c(1,1,0,0,0,0,0);
con3 <- matrix(x31-x32, ncol=1); t(con3)
      [,1] [,2] [,3] [,4] [,5] [,6] [,7]
[1,]    0   -1    1    0    0    0    0
lp3 <- as.numeric(crossprod(con3,bhat)); lp3
[1] -0.4948848
se_con3 <- as.numeric(sqrt(t(con3) %*% v %*% con3)); se_con3
[1] 0.5146558
ci3 <- exp(lp3 + c(-1,1)*z*se_con3); ci3
[1] 0.2223302 1.6716681
```

Ejemplo 3.4 Intervalos de confianza para contrastes

Como parte de los ejercicios de tarea, calculará los intervalos de confianza de

1. $e^{\beta_1 + \beta_3}$ y

2. $e^{\beta_2 + \beta_5 - \beta_1 - \beta_4}$



Bioensayos y modelos dosis-respuesta (Definiciones)

Un bioensayo (bioassay) o ensayo biológico es un experimento, típicamente en animales, diseñado para investigar la toxicidad de algún agente o sustancia.

Consiste en dividir una muestra de animales en varios grupos y exponer cada uno a distintas concentraciones de la sustancia.

El impacto de la exposición a la sustancia es evaluada examinando qué le sucedió a cada animal habiendo transcurrido un cierto tiempo desde el momento de la exposición.

Definamos algunos conceptos relevantes.

Estímulo (Stimulus): es el agente o sustancia cuya toxicidad se desea poner a prueba. También se conoce como toxina. Cada grupo de animales está sujeto a una cierta dosis preestablecida de esta toxina. La dosis indica la intensidad y usualmente se especifica como log-concentración. La dosis puede variar de un grupo a otro, pero se asume que es constante dentro de un grupo.

Respuesta (Response): como resultado del estímulo, los animales manifestarán algún tipo de respuesta binaria: muere/sobrevive, sano/enfermo, etc.


Tolerancia (Tolerance): Para cualquier sujeto hay un cierto nivel de intensidad debajo del cual la respuesta no ocurrirá y sí ocurrirá arriba de éste. Este nivel se denomina *tolerancia* o *umbral*. La tolerancia varía entre individuos en la población y, por lo tanto, de un sujeto a otro dentro de la muestra, tiene una distribución.

Distribución de tolerancia (Tolerance distribution): Sea z = concentración de la toxina. Trabajemos con $x = \log z$ para medir la intensidad del estímulo, i.e. la dosis. Sea $f(x)$ la función de densidad de la distribución de tolerancia en una población. Entonces, si una dosis x_0 fuera dada a la población completa, la proporción


$$\pi = \int_{-\infty}^{x_0} f(s)ds \quad (63)$$

respondería. Esta idea se ilustra en las Figuras 8a y 8b, donde $\pi = \pi(x_0)$ puede interpretarse como la probabilidad de respuesta a la dosis x_0 para un individuo en esta población.

Notemos que $\int_{-\infty}^{\infty} f(s)ds = 1$ dado que todos responderán en alguna dosis.



(a) Tolerance distribution



(b) CDF

Figure 8: Tolerance distribution and link

Supongamos dos agentes con distribuciones de tolerancia $f(x; \mu_1, \sigma_1)$ y $f(x; \mu_2, \sigma_2)$, respectivamente, con $\mu_1 > \mu_2$ como se muestra en la Figura 9.




Figure 9: Tolerance distribution

¿Qué agente es más tóxico?

- $f(x; \mu_1, \sigma_1)$ se corresponde con agente muy tóxico. Comparativamente, dosis pequeñas tienen alta probabilidad de respuesta.
- $f(x; \mu_2, \sigma_2)$ es un agente menos tóxico. También, un determinado aumento en la dosis conduce a un menor aumento en la probabilidad del evento (la densidad es más alargada).




Figure 10: Tolerance distribution (cumulative)

Modelo para la relación dosis-respuesta

Sea y_i el número muertes (tengamos claro que puede ser cualquier otro evento), por ejemplo, ocurridos en una muestra de tamaño n_j , donde asumimos $Y_j \sim \text{Bin}(n_j, \pi_j)$, donde π_j es la probabilidad de muerte para el j -ésimo grupo, $j = 1, \dots, J$.

Sea x_j la dosis del estímulo (en escala logarítmica) suministrada al j -ésimo grupo.

Es de interés modelar $\pi_j, j = 1, 2, \dots, J$ como una función de la variable continua x_j .

En general, usamos también la notación $\pi(x)$ para indicar que la probabilidad del evento depende de x .

Dado que $0 \leq \pi \leq 1$, la configuración usual es reparametrizar $\eta = g(\pi)$ tal que $-\infty < \eta < \infty$. Esto es, modelamos

$$g(\pi) = \beta_0 + \beta_1 x$$

donde g es la función de ligadura y $\eta = \beta_0 + \beta_1 x$ es el predictor lineal.

Equivalentemente,

$$\pi(x) = F^*(\beta_0 + \beta_1 x), \text{ donde } F^* = g^{-1}.$$

Es común observar curvas empíricas dosis-respuesta de forma sigmoide. Esto sugiere elegir funciones de ligadura tales que su inversa F^* sea una CDF. Si

$$\pi(x) = g^{-1}(\beta_0 + \beta_1 x) = F^*(\beta_0 + \beta_1 x) = \int_{-\infty}^x f(s)ds$$

entonces la PDF es la distribución de la tolerancia y determina el cambio en “la probabilidad de una respuesta positiva” con el valor de la dosis, i.e.

$$\frac{\partial \pi(x)}{\partial x} = \frac{\partial}{\partial x} F^*(\beta_0 + \beta_1 x) = (F^*)'(\beta_0 + \beta_1 x)(\beta_1) = f(x).$$

Considere una única respuesta binaria, v.gr. muere/sobrevive, que ocurre con probabilidad $\pi(x)$ y siendo x la única covariable representando la dosis. Los Ejemplos 3.5-3.7 explicaremos los modelos de regresión dosis-respuesta más comunes.

Ejemplo 3.5 Modelo probit

Supongamos que un agente tiene una distribución de tolerancia dada por la siguiente densidad

$$f(x; \mu, \sigma) = \frac{1}{\sqrt{2\pi}\sigma} \exp \left\{ -\frac{(x - \mu)^2}{\sigma^2} \right\}.$$

Supongamos también que $Y = 1$ significa una respuesta y $Y = 0$ que no hay respuesta. Entonces

$$\begin{aligned} \pi(x) &= \Pr(Y = 1 \mid x, \mu, \sigma) = \int_{-\infty}^x f(x; \mu, \sigma) ds \\ &= \int_{-\infty}^x \frac{1}{\sqrt{2\pi}\sigma} \exp \left\{ -\frac{(s - \mu)^2}{\sigma^2} \right\} ds = \Phi \left(\frac{x - \mu}{\sigma} \right). \end{aligned}$$

Por lo tanto

$$\Phi^{-1}(\pi(x)) = \frac{x - \mu}{\sigma} = \beta_0 + \beta_1 x, \text{ donde}$$

$$\beta_0 = -\frac{\mu}{\sigma}; \quad \beta_1 = \frac{1}{\sigma}.$$

Ejemplo 3.5 Modelo probit

Note la relación inversa entre β y la dispersión de la tolerancia σ , i.e. β crece a medida que σ decrece. Asimismo, cuando σ es grande, incrementos en la dosis x tendrán un impacto grande en la probabilidad de respuesta π .

Este es un modelo *probit*. Usualmente es de interés la curva

$$\hat{\pi} = \Phi \left(\hat{\beta}_0 + \hat{\beta}_i x, \right)$$

la cual se conoce como *curva dosis-respuesta*.

Hay otras distribuciones que podemos considerar para la tolerancia $f(x)$ y en cada caso tendremos un modelo de regresión distinto.



Ejemplo 3.6 Modelo logit

Supongamos que un agente tiene una distribución de tolerancia dada por la densidad

$$f(x; \mu, \sigma) = \frac{1}{\sigma} \cdot \frac{\exp\{(s - \mu)/\sigma\}}{(1 + \exp\{(s - \mu)/\sigma\})^2}.$$

Entonces,

$$\begin{aligned}\pi(x) &= \Pr(Y = 1 \mid x, \mu, \sigma) = \int_{-\infty}^x f(x; \mu, \sigma) ds \\ &= \int_{-\infty}^x \frac{1}{\sigma} \cdot \frac{\exp\{(s - \mu)/\sigma\}}{(1 + \exp\{(s - \mu)/\sigma\})^2} ds.\end{aligned}$$

haciendo el cambio de variable $w = (s - \mu)/\sigma$ y $dw = ds/\sigma$ tenemos

$$\pi(x) = \int_{-\infty}^{(x-\mu)/\sigma} \frac{e^w}{(1 + e^w)^2} dw = -\frac{1}{1 + e^w} \Big|_{-\infty}^{(x-\mu)/\sigma} = \dots$$

Ejemplo 3.6 Modelo logit

$$\pi(x) = 1 - \frac{1}{1 - \exp\{(x - \mu)/\sigma\}} = \frac{\exp\{(s - \mu)/\sigma\}}{1 + \exp\{(s - \mu)/\sigma\}}.$$

Esto implica que

$$\log \left(\frac{\pi(x)}{1 - \pi(x)} \right) = \frac{x - \mu}{\sigma} = \beta_0 + \beta_1 x$$

donde

$$\beta_0 = -\frac{\mu}{\sigma}; \quad \beta_1 = \frac{1}{\sigma}.$$

Este es el modelo de regresión logística o logit.

▽

Ejemplo 3.7 Modelo valor extremo

Supongamos que un agente tiene una distribución de tolerancia dada por la densidad

$$f(x; \mu, \sigma) = \frac{1}{\sigma} \exp \left\{ \frac{x - \mu}{\sigma} - \exp \left\{ \frac{x - \mu}{\sigma} \right\} \right\}.$$

Entonces,

$$\begin{aligned} \pi(x) &= \Pr(Y = 1 \mid x, \mu, \sigma) = \int_{-\infty}^x f(x; \mu, \sigma) ds \\ &= \int_{-\infty}^x \frac{1}{\sigma} \exp \left\{ \frac{s - \mu}{\sigma} - \exp \left\{ \frac{s - \mu}{\sigma} \right\} \right\} ds. \end{aligned}$$

Haciendo el cambio de variable $w = e^{(s-\mu)/\sigma}$ y $dw = \frac{1}{\sigma} e^{(s-\mu)/\sigma} ds$ tenemos

Ejemplo 3.7 Modelo valor extremo

$$\begin{aligned}\pi(x) &= \int_0^{\exp\{(x-\mu)/\sigma\}} e^{-w} dw = -e^{-w} \Big|_0^{\exp\{(x-\mu)/\sigma\}} \\ &= 1 - \exp \left\{ -\exp \left(\frac{x-\mu}{\sigma} \right) \right\}.\end{aligned}$$

Esto implica que

$$\log \{-\log (1 - \pi(x))\} = \frac{x - \mu}{\sigma} = \beta_0 + \beta_1 x$$

donde


$$\beta_0 = -\frac{\mu}{\sigma}; \quad \beta_1 = \frac{1}{\sigma}.$$

Este es el modelo de regresión valor extremo.


▽

Las Figuras 11a y 11a muestran la distribución de la tolerancia y las curvas de las funciones de ligadura de los modelos dosis-respuesta probit, logístico y valor extremo. Tabla 14 resume estos tres modelos en términos de, su distribución de tolerancia $f(x)$, distribución de tolerancia acumulativa $\pi(x) = F^*(x) = g^{-1}(\eta)$ y función de ligadura $g(\pi)$.

Ejemplo 3.5 Modelo probit



(a) Tolerance distribution of probit, logistic and extreme value models.



(b) Link functions of probit, logistic and extreme value models.

Definiciones

Nombre	Forma de $f(x)$	$\pi = g^{-1}(\eta)$	$\eta = g(\pi)$ [link]
Normal	$\frac{\beta_1}{2\pi} \exp \left\{ -\frac{(\beta_0 + \beta_1 x)^2}{2} \right\}$	$\int_{-\infty}^x \frac{\beta_1}{\sqrt{2\pi}} \exp \left\{ -\frac{(\beta_0 + \beta_1 s)^2}{2} \right\} ds$ $= \Phi(\beta_0 + \beta_1 x)$ $= \Phi(\eta)$	$\Phi^{-1}(\pi)$ [probit]
Logistic	$\frac{\beta_1 e^{\beta_0 + \beta_1 x}}{(1 + e^{\beta_0 + \beta_1 x})^2}$	$\int_{-\infty}^x \frac{\beta_1 e^{\beta_0 + \beta_1 s}}{(1 + e^{\beta_0 + \beta_1 s})^2} ds$ $= \frac{e^{\beta_0 + \beta_1 x}}{1 + e^{\beta_0 + \beta_1 x}}$ $= \frac{e^{\eta}}{1 + e^{\eta}}$	$\log \left(\frac{\pi}{1 - \pi} \right)$ [logit]
Extreme value	$\beta_1 \exp\{\beta_0 + \beta_1 x - e^{\beta_0 + \beta_1 x}\}$	$\int_{-\infty}^x \beta_1 \exp\{\beta_0 + \beta_1 s - e^{\beta_0 + \beta_1 s}\} ds$ $= \int_{-\infty}^{\eta} \exp\{\nu - e^{\nu}\} d\nu$ $= 1 - \exp\{-e^{\eta}\}$	$\log(-\log(1 - \pi))$ [cloglog]

Table 14: Reparametrizaciones normal inversa, logit y complementary-log-log del modelo dosis-respuesta, su distribución de tolerancia, tolerancia acumulativa y función de ligadura.

Ejemplo 3.8 Dosis-respuesta (Escarabajos)

En este ejemplo analizamos los datos de Bliss (1935) que también están en Dobson and Barnett (2018). En este experimento dos grupos de cucarhachas fueron expuestas a distintas concentraciones de gas de disulfuro de carbono (CS_2 carbon disuphide).

i	dose (x_i)	Muertes (y_i)	Muestra (n_i)	y_i/n_i
1	1.69	6	59	0.10
2	1.72	13	60	0.22
3	1.76	18	62	0.29
4	1.78	28	56	0.50
5	1.81	52	63	0.83
6	1.84	53	59	0.90
7	1.86	61	62	0.98
8	1.88	60	60	1.00

Table 15: Datos de mortalidad de cucarhachas. La dosis está dada en $\log_{10} \text{CS}_2 \text{mg l}^{-1}$.

Ejemplo 3.8 Dosis-respuesta (Escarabajos)

Estamos interesados en conocer cómo cambia la probabilidad de muerte π_i conforme la concentración del agente aumenta. Esto lo haremos con un modelo para datos binarios con tres diferentes opciones de la función de ligadura. Los modelos son los siguientes:

$$M_l : g(\pi) = \log\{\pi/(1 - \pi)\} = \beta_0 + \beta_1 x_i; \quad g = \text{logit}$$

$$M_p : g(\pi) = \Phi^{-1}(\pi) = \beta_0 + \beta_1 x_i; \quad g = \text{probit}$$

$$M_c : g(\pi) = \log(-\log(1 - \pi)) = \beta_0 + \beta_1 x_i; \quad g = \text{cloglog}$$

Los datos están en el archivo `beetle.dat`, en donde el primer renglón es para los nombres de las variables y las siguientes 8 líneas son los datos. El programa de R para analizar los datos se muestra a continuación.

Ejemplo 3.8 Dosis-respuesta (Escarabajos)

```
setwd(datwd); getwd()  
d <- read.table('dose.txt', header=TRUE, sep='\t')
```

```
d  
      dose  y  n  
1 1.6907   6 59  
2 1.7242  13 60  
3 1.7552  18 62  
4 1.7842  28 56  
5 1.8113  52 63  
6 1.8369  53 59  
7 1.8610  61 62  
8 1.8839  60 60
```

```
> Construct the response variable for logistic regression.  
d$resp <- cbind(d$y, d$n-d$y)
```

Ejemplo 3.8 Dosis-respuesta (Escarabajos)

Primero ajustamos los modelos M_l , M_p y M_c con las tres funciones de ligadura que elegimos: logit, probit y cloglog. Para cada modelo guardamos los residuales (deviance r_i^D) y los valores ajustados ($\hat{\pi}_i$) en los objetos rd_i y $fv1_i$, y graficamos ($\hat{\pi}_i$) vs r_i^D .

```
> Fit the model for each of the three links: logit, probit and cloglog.  
> We do this by specifying in the glm() function the corresponding link.
```

```
MI <- glm(resp ~ dose, family=binomial(link=logit), data=d)  
Mp <- glm(resp ~ dose, family=binomial(link=probit), data=d)  
Mc <- glm(resp ~ dose, family=binomial(link=cloglog), data=d)
```

```
> Make a list with the output of the three models.
```

```
Mlist <- list(MI, Mp, Mc)
```

```
> Show the output of each model
```

```
lapply(Mlist, summary)
```

Ejemplo 3.8 Dosis-respuesta (Escarabajos)

Call:

```
glm(formula = resp ~ dose, family = binomial(link = logit),  
     data = d)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-60.717	5.181	-11.72	<2e-16 ***
dose	34.270	2.912	11.77	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 284.202 on 7 degrees of freedom
Residual deviance: 11.232 on 6 degrees of freedom
AIC: 41.43

Number of Fisher Scoring iterations: 4

Ejemplo 3.8 Dosis-respuesta (Escarabajos)

Call:

```
glm(formula = resp ~ dose, family = binomial(link = probit),  
     data = d)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-34.935	2.648	-13.19	<2e-16 ***
dose	19.728	1.487	13.27	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 284.20 on 7 degrees of freedom
Residual deviance: 10.12 on 6 degrees of freedom
AIC: 40.318

Number of Fisher Scoring iterations: 4

Ejemplo 3.8 Dosis-respuesta (Escarabajos)

Call:

```
glm(formula = resp ~ dose, family = binomial(link = cloglog),  
    data = d)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-39.572	3.240	-12.21	<2e-16 ***
dose	22.041	1.799	12.25	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 284.2024 on 7 degrees of freedom
Residual deviance: 3.4464 on 6 degrees of freedom
AIC: 33.644

Number of Fisher Scoring iterations: 4

Ejemplo 3.8 Dosis-respuesta (Escarabajos)

Del output del ajuste del modelo destacaremos únicamente la estadística de deviance, las tres con 6 grados de libertad.

$$D_{\text{logit}} = 11.23$$

$$D_{\text{probit}} = 10.12$$

$$D_{\text{cloglog}} = 3.45$$

Recordemos que la deviance compara el error de un determinado modelo respecto del modelo saturado, por lo que a menor deviance mejor ajuste. Siguiendo este razonamiento, el modelo con la ligadura cloglog tiene mejor ajuste que los otros dos. Notemos que no podemos comparar estos modelos con ΔD pues no son modelos anidados. En las gráficas de las Figuras 12a, 13a y 14a los errores del modelo con la ligadura cloglog son más cercanos a cero y en ninguno de los tres modelos hay observaciones aberrantes (Figuras 12b, 13b y 14b).

Ejemplo 3.8 Dosis-respuesta (Escarabajos)

> Record the `deviance residuals` in `rd` and the `fitted` values in `fv`.


```
rd <- lapply(Mlist, function(x) residuals.glm(x, 'deviance'))
fv <- lapply(Mlist, function(x) x$fitted.values)
```

> Plot the `deviance residuals by dose` and `deviance residuals by fitted` values.


> Make a `vector` with the `names` of the `link` functions

```
link <- sapply(c(bquote(logit~link),
                 bquote(probit~link),
                 bquote(cloglog~link)), as.expression)
X11(); par(mfrow=c(3,2))
lapply(seq(Mlist), function(x){
  plot(d$dose, rd[[x]], ylim=c(-5,5), las=1, xlab='Dose',
       ylab='Deviance residuals')
  abline(h=-2, lty=2); abline(h=2, lty=2); title(link[x])
  plot(fv[[x]], rd[[x]], ylim=c(-5,5), las=1, xlab=bquote(hat(pi[i])),
       ylab='Deviance residuals')
  abline(h=-2, lty=2); abline(h=2, lty=2); title(link[x])
})
```

Ejemplo 3.8 Dosis-respuesta (Escarabajos)




(a) Residuales vs. dosis




(b) Residuales vs. valores ajustados

Figure 12

Ejemplo 3.8 Dosis-respuesta (Escarabajos)




(a) Residuales vs. dosis




(b) Residuales vs. valores ajustados

Figure 13

Ejemplo 3.8 Dosis-respuesta (Escarabajos)



(a) Residuales vs. dosis



(b) Residuales vs. valores ajustados

Figure 14

Ejemplo 3.8 Dosis-respuesta (Escarabajos)

Análogamente a la regresión lineal normal, podemos graficar los datos observados (y_i/n_i) contra la dosis (x_i) y evaluar qué tan bien la curva dosis-respuesta ajusta los datos, esto se muestra en la Figura 15.

Notemos que la curva para el modelo con la ligadura cloglog ajusta mejor a los datos que las otras dos ligaduras, lo cual deberíamos esperarlo dadas las curvas de residuales que analizamos y la estadística de deviance.

Ejemplo 3.8 Dosis-respuesta (Escarabajos)




Figure 15: Datos observados vs. curva dosis-respuesta para tres funciones de ligadura: logit, probit y cloglog.

Ejemplo 3.8 Dosis-respuesta (Escarabajos)

```
> Plot the actual data (as yi/ni) against dose,  
> and see how well the dose-response curves fit the data.
```

```
par(mfrow=c(1,1))
```

```
plot(d$dose, d$y/d$n, xlim=c(1.65,1.95), las=1, col=8,  
      ylim=c(0,1), xlab='dose', ylab='Probability of death')  
x <- seq(1.65,1.95,by=0.001)  
X <- cbind(1,x)
```

```
b <- lapply(Mlist, coef)
```

```
> Inverse of link functions
```

```
invlogit <- function(beta,X){  
  lp <- X %*% beta  
  return(1/(1+exp(-lp)))  
}  
invprobit <- function(beta,X){  
  lp <- X %*% beta  
  return(pnorm(lp))  
}  
invloglog <- function(beta,X){  
  lp <- X %*% beta  
  return(1-exp(-exp(lp)))  
}
```

Ejemplo 3.8 Dosis-respuesta (Escarabajos)

> Estimated probabilities

```
pi_link <- sapply(c(bquote(observed~y[i]/n[i]),  
                    bquote(hat(pi)[i(logit~link)]),  
                    bquote(hat(pi)[i(probit~link)]),  
                    bquote(hat(pi)[i(cloglog~link)])), as.expression)
```

```
pihat <- list(  
  invlogit(b[[1]], X), invprobit(b[[2]], X), invloglog(b[[3]], X))
```

> Add lines of fitted dose-response curves

```
lapply(1:3, function(i) lines(x, pihat[[i]], col=(i)))  
legend('topleft', pi_link, lty=c(NA, 1,1,1), col=c(8,1:3),  
       pch=c(1,NA,NA,NA), bty='n', y.intersp = 1.5)
```



Modelo dosis-respuesta (Interpretación)

¿Cómo interpretamos β_1 ?

x	$\pi(x)$
$x_0 + c$	$\pi(x_0 + c)$
x_0	$\pi(x_0)$

No hay una interpretación simple de β_1 porque un cambio en la dosis en c unidades depende del valor x_0 .

La función de ligadura cloglog es más útil cuando hay otro modelo probabilístico (e.g. exponencial, Poisson) generando datos resumidos como datos binarios.

En estos contextos, los coeficientes de regresión con frecuencia son efectos multiplicativos.

Especificaciones alternativas del modelo

Supongamos $Y_i \sim \text{Bin}(n_i, \pi_i)$, $i = 1, 2, \dots, n$ y una covariable indicando el grupo de edad en años al cual pertenecen los individuos de la muestra, estos son: 18-44 , 45-64 y 65+.

Sean

$$x_{i1} = \begin{cases} 1 & 45 - 64 \text{ años} \\ 0 & \text{c.o.} \end{cases} \quad x_{i2} = \begin{cases} 1 & 65 + \text{ años} \\ 0 & \text{c.o.} \end{cases} .$$

Entonces, el modelo logístico podría tomar la forma

$$\log\{\pi_i/(1 - \pi_i)\} = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2}. \quad (64)$$

Podríamos tener la siguiente configuración alternativa del modelo de regresión logística,

$$\log\{\pi_i/(1 - \pi_i)\} = \alpha + \beta_j; \quad j = 1, 2, 3 \quad (65)$$

donde $\beta_1 = 0$ es la restricción requerida.

Especificaciones alternativas del modelo

Esta forma de escribir el modelo es particularmente conveniente cuando hay varias covariables en el modelo y cada una con múltiples niveles.

Por ejemplo, si tuviéramos dos variables categóricas con 3 y 4 niveles respectivamente, podríamos escribir el modelo con 5 variables indicadoras explícitamente o escribir

$$\log\{\pi_{ij}/(1 - \pi_{ij})\} = \alpha + \beta_j + \gamma_k; \quad j = 1, 2, 3; \quad k = 1, 2, 3, 4. \quad (66)$$

En este caso necesitamos dos restricciones que especificamos como

$$\beta_1 = 0, \quad \gamma_1 = 0.$$

Estas restricciones se llaman *restricciones de esquina* (*corner-point constraints*) o *restricciones de tratamiento* (*treatment constraints*).

Regresaremos a este tema en §Modelos log-lineales.

Nota sobre la estadística χ^2 de Pearson

Considere las n respuestas binarias en la tabla siguiente,

Muestra (i)	Covariable (x_i)	Eventos (y_i)	Fallas $n_i - y_i$	Total (n_i)
1	x_1	y_1	$n_1 - y_1$	n_1
2	x_2	y_2	$n_2 - y_2$	n_2
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
i	x_i	y_i	$n_i - y_i$	n_i
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
n	x_n	y_n	$n_n - y_n$	n_n

Asumimos $Y_i \sim \text{Bin}(n_i, \pi_i)$, $i = 1, \dots, n$. Las entradas de las columnas Eventos y Fallas la son los valores observados y para cada renglón podemos calcular sus valores esperados

$$\mathbb{E}(Y_i) = n_i \pi_i$$

$$\text{y } \mathbb{E}(n_i - Y_i) = n_i(1 - \pi_i).$$

Nota sobre la estadística χ^2 de Pearson

Sean o_{ij} $i = 1, \dots, n; j = 1, 2$ los valores observados del renglón i y la columna j de tabla reducida $n \times 2$ formada por las columnas Eventos y Fallas de la Tabla siguiente, y e_{ij} sus valores esperados. i.e.

Eventos (y_i)	Fallas $n_i - y_i$
y_1	$n_1 - y_1$
y_2	$n_2 - y_2$
$\vdots$	$\vdots$
y_n	$n_n - y_n$

Nota sobre la estadística χ^2 de Pearson

Consideremos un estadístico que toma la siguiente forma:

$$\begin{aligned} \sum_{j=1}^2 \sum_{i=1}^n \frac{(o_{ij} - e_{ij})^2}{e_{ij}} &= \frac{(o_{i1} - e_{i1})^2}{e_{i1}} + \frac{(o_{i2} - e_{i2})^2}{e_{i2}} \\ &= \sum_{i=1}^n \left[\frac{(y_i - n_i \hat{\pi}_i)^2}{n_i \hat{\pi}_i} + \frac{\{(n_i - y_i) - n_i(1 - \hat{\pi}_i)\}^2}{n_i(1 - \hat{\pi}_i)} \right] \\ &= \sum_{i=1}^n \left[\frac{(y_i - n_i \hat{\pi}_i)^2}{n_i \hat{\pi}_i} + \frac{(y_i - n_i \hat{\pi}_i)^2}{n_i(1 - \hat{\pi}_i)} \right] \\ &= \sum_{i=1}^n \left[\frac{(y_i - n_i \hat{\pi}_i)^2(1 - \hat{\pi}_i)}{n_i \hat{\pi}_i(1 - \hat{\pi}_i)} + \frac{(y_i - n_i \hat{\pi}_i)^2 \hat{\pi}}{n_i \hat{\pi}_i(1 - \hat{\pi}_i)} \right] \\ &= \sum_{i=1}^n \left[\frac{(y_i - n_i \hat{\pi}_i)^2}{n_i \hat{\pi}_i(1 - \hat{\pi}_i)} \right], \end{aligned} \tag{67}$$

que es la misma expresión del estadístico de Pearson (56).

Hemos demostrado que el estadístico de Pearson para una prueba χ^2 puede escribirse en términos de los valores observados de una tabla cruzada $n \times 2$ de la forma $\sum_j \sum_i (o_{ij} - e_{ij})^2 / e_{ij}$ o en términos de respuestas binomiales de la forma $\sum_i (o_i - e_i)^2 / v_i$, donde v_i es la varianza de la i -ésima respuesta.

Escribir este estadístico en la forma (67) tiene la ventaja de que se generaliza directamente a tablas de $n \times q$; $q \geq 2$, esto es, para variables que tienen más de dos categorías.

Retomaremos esta idea en §Modelos log-lineales.

Preguntas importantes

1. Dados los coeficientes estimados $\hat{\beta}$, ¿cuál es la probabilidad estimada ($\hat{\pi}(x)$) de que un individuo responda a la dosis $x = x_0$? Dé un intervalo de confianza al 95%.

$$g(\hat{\pi}^*) = \hat{\beta}_0 + \hat{\beta}_1 x^* \quad \Longleftrightarrow \quad x^* = \frac{g(\hat{\pi}^*) - \hat{\beta}_0}{\hat{\beta}_1}$$

donde

$$(\hat{\eta}_L, \hat{\eta}_U) = \left\{ \hat{\eta} \pm 1.96 \sqrt{\text{var}(\hat{\eta})} \right\} = \left\{ \hat{\beta}_0 + \hat{\beta}_1 \pm 1.96 \sqrt{\text{var}(\hat{\beta}_0 + \hat{\beta}_1 x_0)} \right\}$$

$$\text{var}(\hat{\eta}) = \text{var}(\hat{\beta}_0 + \hat{\beta}_1 x_0) = \text{var}(\hat{\beta}_0) + x_0^2 \text{var}(\hat{\beta}_1) + 2x_0 \text{cov}(\hat{\beta}_0, \hat{\beta}_1)$$

$$\text{cov}(\hat{\beta}_0, \hat{\beta}_1) = \text{cor}(\hat{\beta}_0, \hat{\beta}_1) \sqrt{\text{var}(\hat{\beta}_0) \text{var}(\hat{\beta}_1)}.$$

Preguntas importantes

2. La pregunta relevante de salud pública es **¿Cuál es la dosis para la cual la probabilidad de respuesta es $\hat{\pi}^*$?**

$$g(\hat{\pi}^*) = \hat{\beta}_0 + \hat{\beta}_1 x^* \quad \Longleftrightarrow \quad x^* = \frac{g(\hat{\pi}^*) - \hat{\beta}_0}{\hat{\beta}_1}$$

Equivalentemente, **¿Cuál es la dosis que haría que el 100 p % de la población respondiera al estímulo?**

La respuesta a la pregunta es el cuantil p de la distribución de tolerancia. Por lo general, la mediana es uno de los cuantiles de interés y se conoce como **dosis efectiva media** o **dosis efectiva 50**, se denota por ED50 (*median effective dose*) y está dado por

$$\text{ED50} = \frac{g(0.5) - \hat{\beta}_0}{\hat{\beta}_1}.$$

Simulación de datos con el modelo de regresión binomial

Simular datos de algún modelo estadístico es útil para, por ejemplo, para los propósitos siguientes:

1. Verificar la teoría sobre la que se desarrollan los métodos.
2. Validar los supuestos, comparar modelos y evaluar métodos estadísticos bajo condiciones conocidas y controladas.
3. Explorar el impacto de diferentes parámetros de en modelo, relaciones entre las covariables y la respuesta y relaciones entre las covariables (inferencia causal).
4. Investigar la robustez de los métodos cuando los supuestos no se sostienen.

Supongamos que la respuesta Y_i sigue una distribución P (binomial, Poisson, normal, etc.) miembro de la familia exponencial con parámetro θ_i , denotémoslo por $Y_i \sim P(\theta_i)$.

El Algoritmo 1 lista los pasos para simular datos de un modelo lineal generalizado donde el parámetro de interés es θ_i y la distribución de las respuestas siguen una distribución $P(\theta_i)$.

Algorithm 1 Simulación de datos con GLMs.

- 1: Decidir sobre (a) la función de ligadura g , (b) parámetros de la distribución P que se asumen fijos, (c) coeficientes de regresión β , (d) el tamaño de muestra n y (e) matriz de diseño X .
- 2: Calcular el valor del parámetro de la distribución

$$\theta_i = g^{-1}(\mathbf{x}_i^\top \beta), \quad \text{equivalentemente} \quad \boldsymbol{\theta} = g^{-1}(X\beta)$$

- 3: Generar n instancias de la distribución elegida $y_1, \dots, y_n$, donde $Y_i \sim P(\theta_i)$, $i = 1, \dots, n$.
- 4: La base de datos simulada consta del vector de respuestas $\mathbf{y}$, los efectos principales de X y los parámetros de la distribución de Y_i que se hayan asumido fijos.

Simulación de datos con el modelo de regresión binomial

En un modelo dosis-respuesta, como en otros modelos para datos binarios, el parámetro de interés es π_i , tal que

$$\pi_i = \Pr(Y_i = 1) \text{ donde } Y_i \sim \text{Bin}(\pi_i, n_i), \quad i = 1, \dots, n.$$

El parámetro n_i se asume como fijo por lo que debemos elegir su valor y sería una columna más de la base de datos simulada.

En el modelo probit se asume que el agente $x = \log z$ es una variable aleatoria gobernada por la función de densidad

$$f(x; \mu, \sigma) = \frac{1}{\sqrt{2\pi}\sigma} \exp \left\{ -\frac{(x - \mu)^2}{\sigma^2} \right\}.$$

Esto implica que la función de ligadura $g = \Phi^{-1}$ es la inversa de la función de distribución de una variable aleatoria normal. Se muestra el código de R con la función de densidad y la inversa de la ligadura probit (como referencia se incluyen logit y cloglog).

Simulación de datos con el modelo de regresión binomial

> Densities

```
f.dens <- function(link ,x,m,s){  
  flist <- list(  
    logit = function(x,m,s){ return(dlogis(x,m,s))} ,  
    probit = function(x,m,s){ return(dnorm(x,m,s))} ,  
    cloglog = function(x,m,s){  
      y <- (x-m)/s  
      dev <- 1/s * exp(y-exp(y))  
      return(dev)}  
  )  
  f <- flist [[match(link , names(flist))]]  
  return(f(x,m,s))  
}
```

> Inverse of link functions

```
f.invlink <- function(link ,linpred){  
  flist <- list(  
    logit = function(linpred){ return(1/(1+exp(-linpred)))} ,  
    probit = function(linpred){ return(pnorm(linpred))} ,  
    cloglog = function(linpred){ return(1-exp(-exp(linpred)))}  
  )  
  f <- flist [[match(link , names(flist))]]  
  return(f(linpred))  
}
```


Simulación de datos con el modelo de regresión binomial

Para esta simulación usaremos un model probit con dos variables explicativas (x_1 y x_2) y la interacción entre ellas, i.e.

$$g(\pi_i) = \Phi^{-1}(\pi_i) = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \beta_3 x_{i1} x_{i2}$$

donde x_1 es una variable binaria, $x_2 = \log z$ representa la dosis de un agente y z la concentración, esto es

$$x_{i1} = \begin{cases} 0 & \text{si la instancia } i \text{ es del Grupo 0} \\ 1 & \text{si la instancia } i \text{ es del Grupo 1} \end{cases}$$

$$x_{i2} = \log(z_i)$$

Por lo tanto el modelo es

$$\Phi^{-1}(\pi_i) = \begin{cases} \frac{x_{i2} - \mu_0}{\sigma_0} = \beta_0 + \beta_2 x_{i2} & \text{si la instancia } i \in \text{Grupo 0,} \\ \frac{x_{i2} - \mu_1}{\sigma_1} = (\beta_0 + \beta_1) + (\beta_2 + \beta_3) x_{i2} & \text{si la instancia } i \in \text{Grupo 1.} \end{cases}$$

Simulación de datos con el modelo de regresión binomial

De acuerdo con esta configuración, en cada uno de estos grupos la distribución de tolerancia tiene la misma forma funcional (normal) pero distintos parámetros μ y σ , esto es,

$$f(x; \mu_k, \sigma_k) = \frac{1}{\sqrt{2\pi}\sigma_k} \exp \left\{ -\frac{(x - \mu_k)^2}{\sigma_k^2} \right\}, \quad k = 0, 1.$$

Este modelo podría representar un experimento donde:

- se evalúa la toxicidad de una sustancia en dos poblaciones distintas, o
- donde se compara la toxicidad de un agente con dos tipos de preparación y a cada individuo se le asigna una preparación.

Usaremos los siguientes valores de los parámetros μ y σ :

$$\text{Grupo 0} \rightarrow \mu_0 = 1.5, \quad \sigma_0 = 2$$

$$\text{Grupo 1} \rightarrow \mu_1 = 5.5, \quad \sigma_1 = 3$$

Simulación de datos con el modelo de regresión binomial

> + (1) Set up the parameters _____

> Choose the `link` and tolerance distribution parameters

```
mylink <- 'probit'
mu <- c(1.5, 5.5)          > mean
s <- c(sqrt(4), sqrt(9))   > deviation
k <- 5                     > a constant to set the plotting limits.
```

> Legends

```
legs <- sapply(sapply(seq(mu), function(i)
bquote(f(x*'; '*mu[.(i-1)]==.(mu[i]), sigma[.(i-1)]==.(s[i]))))
), as.expression)
```

```
curve(f.dens(link=mylink, x, mu[1], s[1]),
from=min(mu)-k*max(s), to=max(mu)+k*max(s), las=1, col=2,
ylim=c(0,1/5), lwd=2, bty='l', ylab='Density',
main=bquote('Tolerance distribution '~.(mylink)~link)))
curve(f.dens(mylink, x, mu[2], s[2]), add=TRUE, col=4, lwd=2)
text(mu[1]-1, f.dens(mylink, mu[1]-1, mu[1], s[1]),
legs[1], adj=1.1, col=2)
text(mu[2]+0.5, f.dens(mylink, mu[2], mu[2], s[2]),
legs[2], adj=-0.1, col=4)
```

Simulación de datos con el modelo de regresión binomial




Figure 16: Tolerance distribution, Groups 0 and 1

La Figura 18 muestra las densidades de la distribución de tolerancia de ambos grupos y vemos que claramente el Grupo 1 tiene una menor media y varianza que el Grupo 0. Si pensamos en x_2 como un agente tóxico, esperaríamos mayor toxicidad en Grupo 0 i.e. para una determinada dosis, x_0 por ejemplo, la probabilidad de respuesta es mayor en el Grupo 0 que en el Grupo 1.

Simulación de datos con el modelo de regresión binomial

De (68a) obtenemos los valores para β_0 y β_2 , y sustituyéndolos en (68b) obtenemos β_1 y β_3 , resultando en

$$\beta_0 = -\frac{\mu_0}{\sigma_0} = -0.75$$

$$\beta_2 = \frac{1}{\sigma_0} = 0.5$$

$$\beta_1 = \frac{\mu_0}{\sigma_0} - \frac{\mu_1}{\sigma_1} = -1.083$$

$$\beta_3 = \frac{1}{\sigma_1} - \frac{1}{\sigma_0} = 0.167$$

```
> Regression coefficients
```

```
b <- c(-mu[1]/s[1], mu[1]/s[1]-mu[2]/s[2], 1/s[1], 1/s[2]-1/s[1])  
b  
[1] -0.7500000 -1.0833333 0.5000000 -0.1666667
```

Simulación de datos con el modelo de regresión binomial

La matriz de diseño tiene una columna para el intercepto $[1 \ 1 \ \dots \ 1]$ y una columna de la interacción $x_1 \times x_2$. El predictor lineal es $\eta_i = \mathbf{x}_i^\top \boldsymbol{\beta}$ o en forma matricial $\boldsymbol{\eta} = X\boldsymbol{\beta}$.

> Design `matrix`

```
n <- 50      > total sample size
n0 <- n/2    > sample size of Group 0
n1 <- n/2    > sample size of Group 1
z  <- 1.3^seq(0,n/2-1) > concentration
x  <- log(z)  > dose
rbind(z,x)

X <- rbind(cbind(int=rep(1,n0), grp=rep(0,n0), dose=x),
           cbind(int=rep(1,n1), grp=rep(1,n1), dose=x))

> Add a column for the interaction x1*x2

X <- cbind(X, interaction=X[, 'grp'] * X[, 'dose'])
rbind(head(X), tail(X))
```

Simulación de datos con el modelo de regresión binomial

Usamos la función inversa de la ligadura elegida y el predictor lineal para calcular el valor del parámetro de interés, θ_i , que en este caso es π_i

$$\pi_i = g^{-1}(\mathbf{x}_i^\top \boldsymbol{\beta}) = \Phi(\mathbf{x}_i^\top \boldsymbol{\beta}).$$

Las Figuras 17a y 17b muestran estos valores π_i calculados y podemos ver cómo las distribuciones de tolerancia se traducen en probabilidades de respuesta, el Grupo 0 que tiene menores media y varianza tiene, en consecuencia, mayor probabilidad de respuesta que el Grupo 1 para cualquier dosis (x_2). Se muestra el código de R.

Simulación de datos con el modelo de regresión binomial

> + (2) Calculate the value of the distribution parameter (theta) —————

> In the binary regression model $\theta = \pi$ (probabilities)

```
f.invlink
function(link, linpred){
  flist <- list(
    logit = function(linpred){ return(1/(1+exp(-linpred))) },
    probit = function(linpred){ return(pnorm(linpred)) },
    cloglog = function(linpred){ return(1-exp(-exp(linpred))) }
  )
  f <- flist[[match(link, names(flist))]]
  return(f(linpred))
}
```

```
mylink
[1] 'probit '
```


```
prob <- f.invlink(mylink, lp)
```

```
X <- cbind(as.data.frame(X), prob=prob)
```


> Plot these probabilities to have an idea of how different
> they are in the two groups

```
lapply(split(X, f=X$grp), function(d)
plot(d$dose, d$prob, ylim=c(0,1), xlab='dose',
ylab=bquote(pi[i]), main=bquote(Group~.(d$grp[1])),
pch=19, col=c(2,4)[1+as.numeric(d$grp[1]==1)])
)
```


Simulación de datos con el modelo de regresión binomial



(a) $\pi_i = \Phi(\beta_0 + \beta_2 x_{i2})$



(b)

$\pi_i = \Phi([\beta_0 + \beta_1] + [\beta_2 + \beta_3]x_{i2})$

Figure 17: Probabilities

Simulación de datos con el modelo de regresión binomial

Lo siguiente es seleccionar muestras $Y_i \sim \text{Bin}(\pi_i, n_i)$, $i = 1, \dots, n$ para lo cual debemos elegir valores de n_i .

Para este ejemplo usaremos el mismo valor $n_i = 30, i = 1, \dots, n$.

La función de R `rbinom(n,size,prob)` es útil para generar números aleatorios de la distribución binomial, donde los valores de sus argumentos son, en este caso: `n = n_i = 30`, `size = 1` y `prob =  $\pi_i$` .

Podemos fijar la semilla `set.seed()` para obtener la misma muestra cada vez que ejecutemos el código.

Simulación de datos con el modelo de regresión binomial

> + (3) Sample from the **response** distribution _____
> In the binary regression **model**, we **sample** from the
> $\text{Binomial}(\pi_{-i}, n_{-i})$ distribution

```
set.seed(2)
ni <- rep(30, n)
yi <- lapply(1:n, function(i) sum(rbinom(n=ni[i], size=1,
      prob=prob[i])))
y <- unlist(yi)
```

Finalmente, la base de datos la construimos con las columnas `y`, `ni`, y las columnas de la matriz de diseño `X` correspondientes a la concentración, el grupo y la dosis (`z`, `grp` y `dose`).

Simulación de datos con el modelo de regresión binomial

> + (4) Create **data frame** with Response and covariates

```
d <- data.frame(cbind(y, ni, z, X[, which(colnames(X)%in%  
c('grp', 'dose'))]))  
names(d) <- c('y', 'n', 'con', 'grp', 'dose')  
rbind(head(d), tail(d))
```

y	n	con	grp	dose
1	7	30	1.00000	0 0.0000000
2	12	30	1.30000	0 0.2623643
3	8	30	1.69000	0 0.5247285
4	9	30	2.19700	0 0.7870928
5	11	30	2.85610	0 1.0494571
6	14	30	3.71293	0 1.3118213
45	13	30	146.19203	1 4.9849210
46	6	30	190.04964	1 5.2472853
47	14	30	247.06453	1 5.5096496
48	12	30	321.18389	1 5.7720138
49	13	30	417.53905	1 6.0343781
50	16	30	542.80077	1 6.2967423

Simulación de datos con el modelo de regresión binomial

La Figura 18 muestra las respuestas simuladas como proporción de n_i , esto es y_i/n_i ($\circ\circ$). Como referencia se grafican las curvas de la respuesta estimada mediante el modelo probit ($\hat{\pi}$ —) y las curvas de respuesta obtenidas con los coeficientes verdaderos ($X\beta$ - -). La Tabla 16 muestra intervalos de confianza al 95% y los valores verdaderos de los coeficientes, pudiéndose observar que éstos están contenidos en los intervalos ($\hat{\beta}_L, \hat{\beta}_U$).

	$\hat{\beta}_L$	$\hat{\beta}_U$	β
(Intercept)	-0.91	-0.51	-0.75
grpfl	-1.14	-0.53	-1.08
dose	0.41	0.56	0.50
grpfl:dose	-0.32	-0.13	-0.17

Table 16: 95% CIs and true values of regression coefficients.




Figure 18: Observed proportions ($\circ$), estimated probabilities (—) and actual probabilities (— -).

Simulación de datos con el modelo de regresión binomial

```
> + Use the simulation model _____  
  
> Verify that the estimated regression coefficients are in agreement  
> with the simulation model  
  
> Construct the response variable for logistic regression and  
> define a factor variable for 'Group'.  
  
d$resp <- cbind(d$y, d$n-d$y)  
grpfn <- relevel(factor(d$grp), '0')  
rbind(head(d), tail(d))  
  
> Fit the model  
  
M <- glm(resp ~ grpfn + dose + grpfn:dose, data = d,  
family=binomial(link=mylink))  
summary(M)  
  
> 95% Confidence intervals (Wald)  
  
bhat <- coefficients(M)  
se <- sqrt(diag(summary(M)$cov.unscaled))  
tab <- round(cbind(bhat - 1.96*se, bhat + 1.96*se, b), 2); tab
```

Simulación de datos con el modelo de regresión binomial

> Plot the observed responses

```
leg.pi <- supply(c(
  bquote(hat(pi)[0]), bquote(hat(pi)[1]), bquote(pi[0]), bquote(pi[1])
), as.expression)

plot(d$dose, d$y/d$n, las=1, col=c(2,4)[1+d$grp],
     pch=1, ylim=c(0,1), xlab=bquote(x[2]^(dose)),
     ylab='Probability of response')
legend('bottomright', bty='n', legend=c('Group 0', 'Group 1'),
       pch=rep(1,2), col=c(2,4), y.intersp = 1.5)
```

> Plot estimated response curves

```
f.pi <- function(link, beta, group, x){
  grp <- as.numeric(group==1)
  X <- as.matrix(cbind(1, grp, x, x*grp))
  lp <- as.numeric(X %*% beta)
  pi.val <- f.invlink(link, lp)
  return(pi.val)
}

curve(f.pi(mylink, bhat, 0, x), col=2, add=TRUE, lwd=1)
curve(f.pi(mylink, bhat, 1, x), col=4, add=TRUE, lwd=1)
```

Simulación de datos con el modelo de regresión binomial

> Plot the 'true' response curves

```
curve(f.pi(mylink, b, 0, x), col=2, add=TRUE, lwd=1, lty=2)
curve(f.pi(mylink, b, 1, x), col=4, add=TRUE, lwd=1, lty=2)
legend('topleft', bty='n', legend=leg.pi, inset=0,
pch=NA, col=rep(c(2,4),2), lty=c(1,1,2,2), y.intersp = 1.5)
```



Tema pendiente, lo veremos dependiendo del progreso del curso.

Modelos log-lineales

La distribución Poisson

Supongamos que $Y_1, \dots, Y_n$ es una muestra de variables aleatorias con $Y_i \sim \text{Poisson}(\mu_i), i = 1, \dots, n$.

Las funciones de verosimilitud y log-verosimilitud son

$$L(\boldsymbol{\mu}) = \prod_{i=1}^n \frac{\mu_i^{y_i} e^{-\mu_i}}{y_i!}$$
$$\ell(\boldsymbol{\mu}) = \sum_{i=1}^n \{y_i \log \mu_i - \mu_i - \log y_i!\}$$

Regresión Poisson y modelos para conteos

Sea $\log \mu_i = \mathbf{x}_i^\top \boldsymbol{\beta}$, entonces

$$\ell(\boldsymbol{\beta}) = \sum_{i=1}^n \left\{ y_i \mathbf{x}_i^\top \boldsymbol{\beta} - e^{\mathbf{x}_i^\top \boldsymbol{\beta}} - \log y_i! \right\}$$

Maximizando $\ell(\boldsymbol{\beta})$ obtenemos $\hat{\boldsymbol{\beta}}$ y

$$\hat{\mu}_i = \exp\{\mathbf{x}_i^\top \hat{\boldsymbol{\beta}}\}.$$

Denotemos por $\tilde{\mu}_i$ el MLE de μ_i del modelo Poisson saturado (i.e. $\tilde{\mu}_i = y_i$).

En el modelo saturado tenemos n parámetros funcionalmente independientes $\mu_1, \dots, \mu_n$ estimados por $y_1, \dots, y_n$.

En cambio en el modelo log-lineal $\log \mu_i$ son estimados por $\mathbf{x}_i^\top \boldsymbol{\beta}$, p parámetros funcionalmente independientes, i.e. $\mu_1, \dots, \mu_n$ son determinados por $\beta_0, \dots, \beta_{p-1}$ donde $p < n$.

Regresión Poisson y modelos para conteos

Un sistema de hipótesis para probar si el modelo log-lineal es apropiado respecto del modelo saturado sería,

$H_0 : \log \mu_i = \beta_0 + \beta_1 x_{i1} + \dots + \beta_{p-1} x_{i,p-1}$ es apropiado

vs. $H_1 : \text{el modelo log-lineal no es apropiado.}$

El estadístico de razón de verosimilitud para este es

$$\begin{aligned} -2r(\hat{\mu}) &= -2 \log \left(\frac{L(\hat{\mu})}{L(\tilde{\mu})} \right) = 2[\ell(\tilde{\mu}) - \ell(\hat{\mu})] \\ &= 2 \sum_{i=1}^n \{ (y_i \log \tilde{\mu}_i - \tilde{\mu}_i) - (y_i \log \hat{\mu}_i - \hat{\mu}_i) \} \\ &= \sum_{i=1}^n 2 \left\{ y_i \log \left(\frac{y_i}{\hat{\mu}_i} \right) - (y_i - \hat{\mu}_i) \right\} \\ &= \sum_{i=1}^n d_i. \end{aligned}$$

Regresión Poisson y modelos para conteos

Intuitivamente, lo que está sucediendo al comparar el modelo reducido ($\hat{\mu}$) y el modelo saturado ($\tilde{\mu}$) es que cuanto más cercano esté $\hat{\mu}_i$ de y_i , más pequeña será la contribución de la i -ésima observación a la deviance y esto significa mayor congruencia entre el modelo reducido y el modelo saturado (full model or saturated model).

Tenemos que bajo la hipótesis nula la distribución asintótica de la deviance es *chisq* con $n - p$ grados de libertad,

$$D \sim \chi_{n-p}^2.$$

Asimismo, tenemos que los residuales están dados por

$$r_i^D = \text{sign}(y_i - \hat{\mu}_i) \sqrt{|d_i|} \sim \mathcal{N}(0, 1) \quad (69)$$

y bajo H_0 estos residuales siguen una distribución normal estándar.

Regresión Poisson y modelos para conteos

La estadística de Pearson es

$$T = \frac{\sum_i^n (y_i - \hat{\mu}_i)^2}{\hat{\mu}_i} \sim \chi_{n-p}^2 \quad (70)$$

y los residuales de Pearson están dados por

$$r_i^P = \frac{y_i - \hat{\mu}_i}{\sqrt{\hat{\mu}_i}} \sim \mathcal{N}(0, 1) \quad (71)$$

Para someter a prueba modelos saturados plantamos el sistema de hipótesis

$$H_0 : \eta_i = \beta_0 + \beta_1 x_{i1} + \dots + \beta_{p-1} x_{i,p-1}$$

$$\text{vs. } H_1 : \eta_i = \beta_0 + \beta_1 x_{i1} + \dots + \beta_{p-1} x_{i,p-1} + \beta_p x_{ip} + \dots + \beta_q x_{iq}.$$

El modelo reducido tiene p parámetros y el modelo expandido q , donde $p < q < n$. Nótese que ninguno de estos dos modelos anidados es tan completo como el modelo saturado.

Regresión Poisson y modelos para conteos

Sean $\hat{\mu}$ y $\tilde{\mu}$ los MLE bajo H_0 y bajo H_1 respectivamente. El estadístico de razón de verosimilitud para comparar estos modelos anidados está dada por

$$\begin{aligned}\Delta D &= 2[\ell(\tilde{\mu}) - \ell(\hat{\mu})] \\&= \sum_{i=1}^n 2 \{ (y_i \log \tilde{\mu}_i - \tilde{\mu}_i) - (y_i \log \hat{\mu}_i - \hat{\mu}_i) \} \\&= \sum_{i=1}^n 2 \{ (y_i \log \tilde{\mu}_i - \tilde{\mu}_i) - (y_i \log y_i - y_i) \\&\quad - (y_i \log \hat{\mu}_i - \hat{\mu}_i) - (y_i \log y_i - y_i) \} \\&= D_0 - D_1\end{aligned}$$


donde D_0 y D_1 son las deviances de H_0 y H_1 respectivamente.

Bajo H_0 ,


$$\Delta D \sim \chi_{p-q}^2 \quad (72) \quad 305$$

Regresión Poisson y modelos para conteos

Por lo tanto, rechazamos H_0 cuando $\Delta D > \chi^2_{q-p}(1 - \alpha)$ y declaramos que el modelo reducido significativamente inferior que el del modelo extendido.



Regresión para procesos Poisson observados en $(0, \tau]$



$\{N(s), 0 < s\}$ es un proceso de conteo si

- $N(s) \geq 0$
- $N(s)$ es entero
- $s < t$ implica $N(s) \leq N(t)$
- $N(t) - N(s)$ es el # eventos en $(s, t]$.

1

Figure 19: Counting process

En ocasiones es de interés modelar datos de un proceso Poisson.

Regresión para procesos Poisson observados en $(0, \tau]$

Un proceso de conteo $N(t)$ es cualquier función entera no-decreciente del tiempo tal que $N(0) = 0$ y $N(t)$ es el número de eventos entre $(0, t]$.

Un proceso de conteo es un proceso Poisson si tiene incrementos independientes, i.e. $N(s_1 + t_1) - N(s_1)$ es independiente de $N(s_2 + t_2) - N(s_2)$ donde $s_1 < t_1 < s_2 < t_2$ y el número de eventos que ocurren en $(0, t]$ se distribuye como

$$\Pr\{N(t) = n; \lambda\} = \frac{(\lambda t)^n e^{-\lambda t}}{n!} = \frac{[\mu(t)]^n e^{-\mu(t)}}{n!}; \quad n = 0, 1, 2, \dots$$

donde

$$\mathbb{E}\{N(t)\} = \mu(t) = \lambda t,$$

y $N(t)$ es un tipo especial de variable aleatoria Poisson porque su media depende del tiempo de seguimiento.

Regresión para procesos Poisson observados en $(0, \tau]$

Con la función de ligadura log damos paso a métodos de regresión y modelar la relación entre θ y $\mathbf{x}_i$ mediante la relación

$$\theta = \log \mu(t) = e^{\mathbf{x}_i^\top \boldsymbol{\beta}}.$$

Sin embargo,

$$\log \mu(t) = \log \lambda t = \log \lambda + \log t.$$

En esta configuración del modelo de regresión tenemos que $N_i(t), i = 1, 2, \dots, n$ se corresponde con el conteo de eventos que el i -ésimo individuo observó en $(0, t_i]$. Como es usual, sea $\mathbf{x}_i$ un p -vector de variables explicativas del i -ésimo sujeto, entonces

$$\log \mu_i(t_i) = \log \lambda_i + \log t_i = \mathbf{x}_i^\top \boldsymbol{\beta} + \log t_i. \quad (73)$$

El término $\log t_i$ se denomina *offset* y es una constante conocida. Explica cierta variación en el proceso de conteo entre individuos pero lo hace de manera determinística.

Diseño de la simulación

Investigaremos el efecto del offset ($\log t$) en el modelo de regresión Poisson mediante la simulación de dos bases de datos con $n = 100$ observaciones y utilizando las mismas covariables: u, v, w y x definidas como

$$u = \begin{cases} \text{etapa I} \\ \text{etapa II} \end{cases} \quad v = \begin{cases} \text{tipo A} \\ \text{tipo B} \\ \text{tipo C} \\ \text{tipo D} \end{cases}$$

$$w \sim \mathcal{N}(\mu = 5, \sigma^2 = 9)$$

$$x \sim \mathcal{U}(1, 50) \leftarrow (\text{tiempo})$$

Simulación con el modelo Poisson para explorar con el offset

> Choose the `link` and `fix` the seed

```
n <- 100  
set.seed(1)
```

> Define covariates (raw covariates)

```
r <- data.frame(  
  int = rep(1, n),  
  u = rep(c('I', 'II'), each=n/2),  
  v = rep(LETTERS[1:4], n/4),  
  w = rnorm(n, mean=5, sd=sqrt(9)),  
  t = sample(1:n/5, n, replace=TRUE)  
)
```

Simulación con el modelo Poisson para explorar con el offset

La variable t es continua, en este ejemplo debemos entender cómo el offset y entrará a los modelos como en escala logarítmica, i.e. $\log t$.

Ambos modelos de simulación contienen los efectos principales y difieren únicamente en la manera en como ingresa al modelo el término $\log t$. En el modelo SM_1 es el offset y en el modelo SM_2 es una covariable más.

$$SM_1 : \log \mu_i(x_i) = \alpha + u_i^\top \beta_u + v_i^\top \beta_v + \beta_w w_i + \log(t_i) \quad (74a)$$

$$SM_2 : \log \mu_i(x_i) = \delta + u_i^\top \gamma_u + v_i^\top \gamma_v + \gamma_w w_i + \gamma_t \log(t_i) \quad (74b)$$

Simulación con el modelo Poisson para explorar con el offset

Como las variables u y v son factores con 2 y 4 niveles respectivamente, para producir las matrices de diseño (X para el modelo SM_1 y W para SM_2) generamos variables dummy para cada nivel excepto I para la variable u y A para la variable v , los cuales serán los niveles de referencia.

```
> From the raw covariates create the design matrices
```

```
r$uI <- ifelse(r$u=='I', 1, 0)
r$vB <- ifelse(r$v=='B', 1, 0)
r$vC <- ifelse(r$v=='C', 1, 0)
r$vD <- ifelse(r$v=='D', 1, 0)
```

```
> Design matrix of simulation model 1 and model 2
```

```
X <- as.matrix(subset(r, select=c('int', 'uI', 'vB', 'vC', 'vD', 'w')))
W <- cbind(X, log(r$t))
```

```
dim(X); dim(W)
```


Simulación con el modelo Poisson para explorar con el offset

Los coeficientes de regresión $\mathbf{b} = [\alpha, \beta^\top]^\top$ para el modelo SM_1 y $\mathbf{g} = [\delta, \gamma^\top]^\top$ para el modelo SM_2 .

$$\mathbf{b}^\top = \begin{bmatrix} 2 & 0.5 & -0.5 & 0.5 & -0.5 & 0.5 \end{bmatrix}$$

$$\mathbf{g}^\top = \begin{bmatrix} 2 & 0.5 & -0.5 & 0.5 & -0.5 & 0.5 & -0.5 \end{bmatrix}$$

El predictor lineal de cada modelo es

$$\boldsymbol{\eta}^{(b)} = X\mathbf{b}$$

$$\boldsymbol{\eta}^{(g)} = W\mathbf{g}$$

Por lo tanto, las respuestas simuladas $y_1^{(b)}, \dots, y_{100}^{(b)}$ y $y_1^{(g)}, \dots, y_{100}^{(g)}$ son instancias de la distribución Poisson donde el logaritmo del parámetro de tasa es el predictor lineal. Esto es,

$$Y_i^{(b)} \sim \text{Poisson} \left(e^{\mathbf{x}_i^\top \mathbf{b} + \log t_i} \right), \quad i = 1, \dots, 100$$

$$Y_i^{(g)} \sim \text{Poisson} \left(e^{\mathbf{w}_i^\top \mathbf{g}} \right), \quad i = 1, \dots, 100$$

Simulación con el modelo Poisson para explorar con el offset

Usamos la función `rpois()` de R para generar números aleatorios de la distribución Poisson.

> Decide `on` the values of the regression `coefficients`

```
b <- c(2, 0.5, -0.5, 0.5, -0.5, 0.5) > beta  
g <- c(b, -0.5) > gamma
```

> Linear predictor

```
lpb <- X%*%b  
lpg <- W%*%g
```

> Sample the `response` from the Poisson distribution with

> `lambda = linear predictor + offset` —> Model SM1

> `lambda = linear predictor` —————> Model SM2

```
yib <- lapply(1:n, function(i) rpois(1,  
  lambda=exp(lpb[i]+log(t[i]))))  
yig <- lapply(1:n, function(i) rpois(1,  
  lambda=exp(lpg[i])))
```


Simulación con el modelo Poisson para explorar con el offset

> Plot the simulated responses (counts)


```
dh <- rbind(  
  data.frame(y=unlist(yib), simulation='SM1'),  
  data.frame(y=unlist(yig), simulation='SM2'))  
boxplot(y ~ simulation, data=dh)  
> par(mfrow=c(1,2), las=1)  
yl <- c(0,80)  
xl <- c(0,1500)  
hist(d$y, ylim=yl, nclass=30, xlab='Counts', main=NA)  
hist(h$y, ylim=yl, nclass=30, xlab='Counts', main=NA)
```

Simulación con el modelo Poisson para explorar con el offset

Los conteos simulados con el modelo SM_1 son mucho mayores que los simulados con SM_2 (ver Figuras 20a y 20b).



(a) Simulated response with model SM_1



(b) Simulated response with model SM_2

Figure 20: Simulated response with models SM_1 and SM_2 .

Análisis

Usaremos la función `glm()` de R para estimar los coeficientes de regresión de ambas simulaciones. Primero debemos construir las bases de datos con la estructura requerida por R y definiendo los factores.

```
> Create the data sets of both models
```

```
d <- data.frame(  
  y=unlist(yib),  
  x=r$x,  
  u=relevel(factor(r$u), 'II'),  
  v=relevel(factor(r$v), 'A'),  
  w=r$w)
```

```
h <- data.frame(  
  y=unlist(yig),  
  x=r$x,  
  u=relevel(factor(r$u), 'II'),  
  v=relevel(factor(r$v), 'A'),  
  w=r$w)
```

Simulación con el modelo Poisson para explorar con el offset

```
str(d)
> str(d)
'data.frame': 100 obs. of 5 variables:
 $ y: int 8028 94 334 19008 2145 5994 7992 1658 2317 125 ...
 $ x: num 4.8 18.6 2 15.4 12.4 8.4 14 14.8 3.8 16.4 ...
 $ u: Factor w/ 2 levels 'II','I': 2 2 2 2 2 2 2 2 2 2 ...
 $ v: Factor w/ 4 levels 'A','B','C','D': 1 2 3 4 1 2 3 4 1 2 ...
 $ w: num 9.85 -0.569 4.14 10.251 5.349 ...

str(h)
> str(h)
'data.frame': 100 obs. of 5 variables:
 $ y: int 744 1 114 273 46 242 159 27 315 0 ...
 $ x: num 4.8 18.6 2 15.4 12.4 8.4 14 14.8 3.8 16.4 ...
 $ u: Factor w/ 2 levels 'II','I': 2 2 2 2 2 2 2 2 2 2 ...
 $ v: Factor w/ 4 levels 'A','B','C','D': 1 2 3 4 1 2 3 4 1 2 ...
 $ w: num 9.85 -0.569 4.14 10.251 5.349 ...
```

Simulación con el modelo Poisson para explorar con el offset

En ambos casos, ajustaremos el modelo con el offset y el modelo con $\log t_i$ como covariable. Denominamos M_{b1} y M_{b2} a los modelos para estimar SM_1 y M_{g1} y M_{g2} a los modelos para estimar SM_2 . Los modelos M_{j1} incluyen el offset y los modelos M_{j2} incluyen $\log t$ como covariable. De esta forma M_{b1} es el modelo correcto para los datos simulados con SM_1 y M_{g2} es el modelo correcto para los datos simulados con SM_2 .

```
> Fit models
```

```
Mb1 <- glm(y ~ u + v + w + offset(log(x)), family=poisson, data=d)
```

```
Mb2 <- glm(y ~ u + v + w + log(x), family=poisson, data=d)
```

```
Mg1 <- glm(y ~ u + v + w + offset(log(x)), family=poisson, data=h)
```

```
Mg2 <- glm(y ~ u + v + w + log(x), family=poisson, data=h)
```

Simulación con el modelo Poisson para explorar con el offset

Mostramos el código de R y el output y, para facilitar la comparación de los coeficientes, construimos una tabla con los MLE, intervalos de confianza al 95% y el valor verdadero de los coeficientes de regresión.

Simulación con el modelo Poisson para explorar con el offset

```
> Display models summaries
```

```
lapply(Mb, summary)
```

```
$Mb1
```

```
Call:
```

```
glm(formula = y ~ u + v + w + offset(log(t)), family = poisson,  
     data = d)
```

```
Coefficients:
```

	Estimate	Std. Error	z value	Pr(> z)	
(Intercept)	2.0050489	0.0054701	366.5	<2e-16	***
u1	0.4977325	0.0023123	215.2	<2e-16	***
vB	-0.4995279	0.0035470	-140.8	<2e-16	***
vC	0.5019565	0.0027691	181.3	<2e-16	***
vD	-0.5001060	0.0036016	-138.9	<2e-16	***
w	0.4995417	0.0004976	1003.9	<2e-16	***

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
(Dispersion parameter for poisson family taken to be 1)
```

```
Null deviance: 1505552.13 on 99 degrees of freedom  
Residual deviance: 113.96 on 94 degrees of freedom  
AIC: 1084.1
```

```
Number of Fisher Scoring iterations: 3
```

Simulación con el modelo Poisson para explorar con el offset

\$Mb2

Call:

```
glm(formula = y ~ u + v + w + log(t), family = poisson, data = d)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)	
(Intercept)	1.9997581	0.0091549	218.4	<2e-16	***
uI	0.4977934	0.0023139	215.1	<2e-16	***
vB	-0.4998699	0.0035786	-139.7	<2e-16	***
vC	0.5017487	0.0027841	180.2	<2e-16	***
vD	-0.5000193	0.0036037	-138.8	<2e-16	***
w	0.4994800	0.0005049	989.3	<2e-16	***
log(t)	1.0016893	0.0023437	427.4	<2e-16	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for poisson family taken to be 1)

Null deviance: 2051578.58 on 99 degrees of freedom
Residual deviance: 113.44 on 93 degrees of freedom
AIC: 1085.6

Number of Fisher Scoring iterations: 3

Simulación con el modelo Poisson para explorar con el offset

```
lapply(Mg, summary)
$Mg1
```

Call:

```
glm(formula = y ~ u + v + w + offset(log(t)), family = poisson,
     data = h)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-1.995312	0.054540	-36.584	< 2e-16 ***
u1	0.913125	0.026442	34.534	< 2e-16 ***
vB	-1.060858	0.044753	-23.705	< 2e-16 ***
vC	0.177652	0.029751	5.971	2.35e-09 ***
vD	-0.744008	0.039115	-19.021	< 2e-16 ***
w	0.400629	0.005377	74.505	< 2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for poisson family taken to be 1)

Null deviance: 17577.7 on 99 degrees of freedom
Residual deviance: 8740.5 on 94 degrees of freedom
AIC: 9262

Number of Fisher Scoring iterations: 6

Simulación con el modelo Poisson para explorar con el offset

\$Mg2

Call:

```
glm(formula = y ~ u + v + w + log(t), family = poisson, data = h)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)	
(Intercept)	1.956488	0.060626	32.27	<2e-16	***
u1	0.539067	0.026865	20.07	<2e-16	***
vB	-0.548851	0.045781	-11.99	<2e-16	***
vC	0.493235	0.029949	16.47	<2e-16	***
vD	-0.519090	0.038582	-13.45	<2e-16	***
w	0.501089	0.006159	81.35	<2e-16	***
log(t)	-0.492290	0.013723	-35.87	<2e-16	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for poisson family taken to be 1)

Null deviance: 11477.963 on 99 degrees of freedom
Residual deviance: 82.971 on 93 degrees of freedom
AIC: 606.49

Number of Fisher Scoring iterations: 4

Simulación con el modelo Poisson para explorar con el offset

```
> 95% Confidence intervals (Wald) of beta
```

```
blist <- list(b, c(b,1))
bhat <- lapply(Mb, coefficients); bhat
bse <- lapply(Mb, function(k) sqrt(diag(summary(k)$cov.unscaled)))
bci <- lapply(seq(Mb), function(k)
  round(cbind(bhat=bhat[[k]], bhat_L=bhat[[k]] - 1.96*bse[[k]],
    bhat_U=bhat[[k]] + 1.96*bse[[k]], blist[[k]]),2))
```

```
> 95% Confidence intervals (Wald)
```

```
glist <- list(g[-length(g)], g) of gamma

ghat <- lapply(Mg, coefficients); ghat
gse <- lapply(Mg, function(k) sqrt(diag(summary(k)$cov.unscaled)))
gci <- lapply(seq(Mg), function(k)
  round(cbind(ghat=ghat[[k]], ghat_L=ghat[[k]] - 1.96*gse[[k]],
    ghat_U=ghat[[k]] + 1.96*gse[[k]], glist[[k]]),2))

bci
gci
```

Simulación con el modelo Poisson para explorar con el offset

	MLE	LCL	UCL	β
$\hat{\alpha}$	2.01	1.99	2.02	2.00
ul	0.50	0.49	0.50	0.50
vB	-0.50	-0.51	-0.49	-0.50
vC	0.50	0.50	0.51	0.50
vD	-0.50	-0.51	-0.49	-0.50
w	0.50	0.50	0.50	0.50

Table 17: Model M_{b1}
estimating SM_1

	MLE	LCL	UCL	γ
$\hat{\delta}$	-2.00	-2.10	-1.89	2.00
ul	0.91	0.86	0.96	0.50
vB	-1.06	-1.15	-0.97	-0.50
vC	0.18	0.12	0.24	0.50
vD	-0.74	-0.82	-0.67	-0.50
w	0.40	0.39	0.41	0.50

Table 19: Model M_{g1}
estimating SM_2

	MLE	LCL	UCL	β
$\hat{\alpha}$	2.00	1.98	2.02	2.00
ul	0.50	0.49	0.50	0.50
vB	-0.50	-0.51	-0.49	-0.50
vC	0.50	0.50	0.51	0.50
vD	-0.50	-0.51	-0.49	-0.50
w	0.50	0.50	0.50	0.50
log(t)	1.00	1.00	1.01	1.00

Table 18: Model M_{b2}
estimating SM_1

	MLE	LCL	UCL	γ
$\hat{\delta}$	1.96	1.84	2.08	2.00
ul	0.54	0.49	0.59	0.50
vB	-0.55	-0.64	-0.46	-0.50
vC	0.49	0.43	0.55	0.50
vD	-0.52	-0.59	-0.44	-0.50
w	0.50	0.49	0.51	0.50
log(t)	-0.49	-0.52	-0.47	-0.50

Table 20: Model M_{g2}
estimating SM_2

Comentarios:

1. Como es de esperarse, cuando el modelo ajustado coincide con el modelo de simulación los coeficientes estimados coinciden con los coeficientes definidos para simular los datos. Las Tablas 17 y 20 los intervalos de confianza incluyen los valores verdaderos de los coeficientes.

Comentarios:

2. Si intentamos modelar $\log t$ cuando los datos generados incluyen este término con offset (Tabla 18) vemos que su coeficiente estimado es 1, lo cual es consistente con el modelo que generó los datos (74a). En este caso los MLE de los otros coeficientes y sus errores estándar son prácticamente los mismos valores que si modeláramos este término como offset. En la práctica la recomendación es someter a prueba la hipótesis nula de que el coeficiente estimado del término $\log t$ es 1 y si no podemos rechazarla entonces incluir este término en el modelo como offset.

Comentarios:

3. El modelo SM_2 implica que la intensidad del proceso Poisson no es lineal en el tiempo, esto es

$$\mu(t) = \lambda t^{\gamma_t}.$$

Por lo tanto, si en un modelo para estos datos incluimos $\log t$ como offset los MLE serán equivocados, como lo muestra la Tabla 19 donde ninguno de los intervalos de confianza contiene el valor verdadero del coeficiente correspondiente, incluso el intercepto estimado tiene signo contrario. El intervalo de confianza de $\hat{\gamma}_t$ en la Tabla 20 nos lleva a rechazar la hipótesis nula de que $\hat{\gamma}_t = 1$ y, por lo tanto, debemos modelar el término $\log t$ como una covariable.

Ejemplo 4.1 Proceso Poisson (Incidentes de barcos)

En McCullagh (2019) se analizan y discuten datos de un cierto tipo de daño causado por las olas en barcos de carga que transportan vasijas. Buscando prevenir estos daños en el futuro, los investigadores desean identificar sus factores de riesgo incluyendo

- tipo de barco: A–E
- Año de construcción: 1960-1964, 1965-1969, 1970-1974, 1975-1979
- Periodo de operaciones: 1960-1974, 1975-1979

Para ingresar estas variables al modelo de regresión, adoptamos la convención de codificar las variables como factores asignándoles un número consecutivo, esto es

Ejemplo 4.1 Proceso Poisson (Incidentes de barcos)

$$\text{type} = \begin{cases} 1 & \text{barco tipo A} \\ 2 & \text{barco tipo B} \\ 3 & \text{barco tipo C} \\ 4 & \text{barco tipo D} \\ 5 & \text{barco tipo E} \end{cases}$$
$$\text{cyr} = \begin{cases} 1 & \text{construcción entre 1960-1964} \\ 2 & \text{construcción entre 1965-1969} \\ 3 & \text{construcción entre 1970-1974} \\ 4 & \text{construcción entre 1975-1979} \end{cases}$$
$$\text{oys} = \begin{cases} 1 & \text{operación entre 1960-1974} \\ 2 & \text{operación entre 1975-1979} \end{cases}$$

Los datos están en el archivo `ship.txt` donde el primer renglón es de los nombres de las variables `type` es el tipo de embarcación, `cyr` indica el año de construcción, `oys` es el periodo de operación, `months` se refiere el tiempo (en meses) que estuvo en operación la embarcación y `y` es el número de incidentes registrados.

Ejemplo 4.1 Proceso Poisson (Incidentes de barcos)

```
setwd(datwd); getwd()
d <- read.table('ship.txt', header=T)
d
```

	type	cyr	oyr	months	y
1	1	1	1	127	0
2	1	1	2	63	0
3	1	2	1	1095	3
4	1	2	2	1095	4
5	1	3	1	1512	6
6	1	3	2	3353	18
7	1	4	2	2244	11
8	2	1	1	44882	39
9	2	1	2	17176	29
10	2	2	1	28609	58
11	2	2	2	20370	53
12	2	3	1	7064	12
13	2	3	2	13099	44
14	2	4	2	7117	18
15	3	1	1	1179	1
16	3	1	2	552	1
17	3	2	1	781	0
18	3	2	2	676	1
19	3	3	1	783	6
20	3	3	2	1948	2
...					

Ejemplo 4.1 Proceso Poisson (Incidentes de barcos)

Antes de analizar y tratar de modelar estos datos, convertimos las variables explicativas en variables tipo factor.

```
> Create indicator variables for ship type, construction year and  
> operation year
```

```
d$typef=factor(d$type)  
d$cyrf=factor(d$cyr)  
d$oyrf=factor(d$oyr)
```

Haremos el análisis mediante una serie de modelos. Iniciamos con el modelo con los 3 efectos principales M_{main} y hacemos una prueba tratando el offset como si fuera una variable continua M_{maio} para someter a prueba $H_0 : \hat{\gamma} = 1$ vs. $H_1 : \hat{\gamma} \neq 1$. Los siguientes 3 son modelos anidados del modelo M_{main} , quitamos de M_{main} una variable a la vez para quedarnos con 2 efectos principales (M_{co} , M_{to} , M_{tc}). Finalmente, expandimos el modelo M_{main} para probar si alguna de las interacciones a pares es significativa.

Ejemplo 4.1 Proceso Poisson (Incidentes de barcos)

$$M_{\text{main}} : \log \mu_i(t_i) = \alpha + \text{type}_i^\top \beta_t + \text{cyr}_i^\top \beta_c + \text{oyr}_i^\top \beta_o + \log(\text{months}_i)$$

$$M_{\text{maio}} : \log \mu_i(t_i) = \alpha + \text{type}_i^\top \beta_t + \text{cyr}_i^\top \beta_c + \text{oyr}_i^\top \beta_o + \gamma \log(\text{months}_i)$$

$$M_{\text{co}} : \log \mu_i(t_i) = \alpha + \text{cyr}_i^\top \beta_c + \text{oyr}_i^\top \beta_o + \log(\text{months}_i)$$

$$M_{\text{to}} : \log \mu_i(t_i) = \alpha + \text{type}_i^\top \beta_t + \text{oyr}_i^\top \beta_o + \log(\text{months}_i)$$

$$M_{\text{tc}} : \log \mu_i(t_i) = \alpha + \text{type}_i^\top \beta_t + \text{cyr}_i^\top \beta_c + \log(\text{months}_i)$$

$$M_{\text{itc}} : \log \mu_i(t_i) = \alpha + \text{type}_i^\top \beta_t + \text{cyr}_i^\top \beta_c + \text{oyr}_i^\top \beta_o + (\text{type}_i * \text{cyr}_i)^\top \delta + \log(\text{months}_i)$$

$$M_{\text{ito}} : \log \mu_i(t_i) = \alpha + \text{type}_i^\top \beta_t + \text{cyr}_i^\top \beta_c + \text{oyr}_i^\top \beta_o + (\text{type}_i * \text{oyr}_i)^\top \delta + \log(\text{months}_i)$$

$$M_{\text{ico}} : \log \mu_i(t_i) = \alpha + \text{type}_i^\top \beta_t + \text{cyr}_i^\top \beta_c + \text{oyr}_i^\top \beta_o + (\text{cyr}_i * \text{oyr}_i)^\top \delta + \log(\text{months}_i)$$

Usamos la función `glm()` de R y especificamos `family=poisson`. R utiliza por default la ligadura canónica cuando se especifica la familia Poisson. Ajustamos primero todos los modelos y los organizamos en una lista usando la función `list()` para hacer las mismas manipulaciones en todos ellos.

Ejemplo 4.1 Proceso Poisson (Incidentes de barcos)

```
> Specify 'family=poisson'. The canonical link is the default in R
> (log link).
> It is necessary to explicitly add the offset.

> Fit all models:

M_main <- glm(y ~ typef + cyrf + oyrf + offset(log(months)),
              family=poisson, data=d)
M_maio <- glm(y ~ typef + cyrf + oyrf + log(months), family=poisson,
              data=d)
M_co <- glm(y ~ cyrf + oyrf + offset(log(months)), family=poisson,
            data=d)
M_to <- glm(y ~ typef + oyrf + offset(log(months)), family=poisson,
            data=d)
M_tc <- glm(y ~ typef + cyrf + offset(log(months)), family=poisson,
            data=d)
M_itc <- glm(y ~ typef + cyrf + oyrf + typef*cyrf + offset(log(months)),
              family=poisson, data=d)
M_ito <- glm(y ~ typef + cyrf + oyrf + typef*oyrf + offset(log(months)),
              family=poisson, data=d)
M_ico <- glm(y ~ typef + cyrf + oyrf + cyrf*oyrf + offset(log(months)),
              family=poisson, data=d)

> Make a list with the model output and name accordingly

Mlist <- list(M_main, M_maio, M_co, M_to, M_tc, M_itc, M_ito, M_ico)
Mnames <- c('M_main', 'M_maio', 'M_co', 'M_to', 'M_tc', 'M_itc', 'M_ito', 'M_ico')
```

Ejemplo 4.1 Proceso Poisson (Incidentes de barcos)

Mostramos el output de M_{main} y M_{maio} .

```
summary(M_main)
```

Call:

```
glm(formula = y ~ typef + cyrf + oyrf + offset(log(months)),  
     family = poisson, data = d)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-6.40590	0.21744	-29.460	< 2e-16 ***
typef2	-0.54334	0.17759	-3.060	0.00222 **
typef3	-0.68740	0.32904	-2.089	0.03670 *
typef4	-0.07596	0.29058	-0.261	0.79377
typef5	0.32558	0.23588	1.380	0.16750
cyrf2	0.69714	0.14964	4.659	3.18e-06 ***
cyrf3	0.81843	0.16977	4.821	1.43e-06 ***
cyrf4	0.45343	0.23317	1.945	0.05182 .
oyrf2	0.38447	0.11827	3.251	0.00115 **

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for poisson family taken to be 1)

Null deviance: 146.328 on 33 degrees of freedom
Residual deviance: 38.695 on 25 degrees of freedom
AIC: 154.56

Number of Fisher Scoring iterations: 5

Ejemplo 4.1 Proceso Poisson (Incidentes de barcos)

```
summary(M_maio)
```

Call:

```
glm(formula = y ~ typef + cyrf + oyrf + log(months), family = poisson,  
     data = d)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)	
(Intercept)	-5.5940	0.8724	-6.412	1.43e-10	***
typef2	-0.3499	0.2702	-1.295	0.19539	
typef3	-0.7631	0.3382	-2.257	0.02404	*
typef4	-0.1355	0.2971	-0.456	0.64842	
typef5	0.2739	0.2418	1.133	0.25719	
cyrf2	0.6625	0.1536	4.312	1.61e-05	***
cyrf3	0.7597	0.1777	4.276	1.90e-05	***
cyrf4	0.3697	0.2458	1.504	0.13259	
oyrf2	0.3703	0.1181	3.134	0.00172	**
log(months)	0.9027	0.1018	8.867	< 2e-16	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for poisson family taken to be 1)

Null deviance: 614.539 on 33 degrees of freedom
Residual deviance: 37.804 on 24 degrees of freedom
AIC: 155.67

Number of Fisher Scoring iterations: 5

Ejemplo 4.1 Proceso Poisson (Incidentes de barcos)

Notemos que el coeficiente estimado $\hat{\gamma} = 0.91$ del término $\log(\text{offset})$ del modelo M_{maio} no es significativamente distinto de 1 ($0.91 \pm 1.96 \times 0.10$) = (0.70, 1.1). Esto significa que los datos no son inconsistentes con el modelo Poisson en tiempo homogéneo, como se indica en (73).

Ahora consideremos los modelos anidados de M_{main} .

Dado que los efectos principales son factores con varios niveles, hacemos estas pruebas con base en el cambio de la deviance.

Recordemos que $\Delta D \sim \chi^2_1$.

Se muestra el código de R para calcular el p -value de las hipótesis relacionadas con los efectos principales.

Ejemplo 4.1 Proceso Poisson (Incidentes de barcos)

```
> likelihood ratio test for nested models vs M_main via  
> difference in deviance.  
> We can do this using Mlist.  
> Retrieve deviances and degrees of freedom of each model  
deviance <- lapply(Mlist, function(x) x$deviance)  
round(unlist(deviance),3)
```

M_main	M_maio	M_co	M_to	M_tc	M_itc	M_ito	M_ico
38.695	37.804	62.365	70.103	49.355	14.587	33.756	36.908

```
df <- lapply(Mlist, function(x) x$df.residual)  
unlist(df)
```

M_main	M_maio	M_co	M_to	M_tc	M_itc	M_ito	M_ico
25	24	29	28	26	13	21	23

```
> Compute the p-value of the likelihood ratio test of  
> difference in deviance for the nested models of M_main
```

```
pv1 <- lapply(3:5, function(x)  
  1-pchisq(deviance[[x]]-deviance[[1]], df[[x]]-df[[1]]))  
unlist(pv1)  
[1] 9.299568e-05 6.974977e-07 1.094692e-03
```

Ejemplo 4.1 Proceso Poisson (Incidentes de barcos)

El p -value de la prueba de razón de verosimilitud de la hipótesis de que no hay variación en la tasa de accidentes entre barcos de distinto tipo es $9.299568e - 05$, i.e. hay fuerte evidencia de la necesidad de ajustar por diferencia en las tasas de accidentes entre barcos de distintos tipos.

La interpretación para los otros dos efectos principales es similar a la del tipo de barco pues los p -value son muy pequeños. Hay evidencia fuerte de la necesidad de ajustar por la diferencia en las tasas de accidentes por periodo de manufactura ($p\text{-value} = 6.974977e-07$) y por años de operación ($p\text{-value} = 1.094692e-03$).

Ejemplo 4.1 Proceso Poisson (Incidentes de barcos)

Una conclusión preliminar en este punto del análisis es que el modelo final debe tener los tres efectos principales.

Investigaremos a continuación si es necesario incorporar interacciones entre pares de factores. Los p -value de las pruebas de razón de verosimilitud de los modelos con interacciones a pares respecto del modelo M_{main} son los siguientes.

```
pv2 <- lapply(6:8, function(x)
  1 - pchisq(deviance[[1]] - deviance[[x]], df[[1]] - df[[x]]))
unlist(pv2)
[1] 0.01966268 0.29363165 0.40912682
```

Ejemplo 4.1 Proceso Poisson (Incidentes de barcos)

Al comparar los modelos M_{main} y M_{itc} entre ellos, vemos que el p -value = 0.01966268 sugiere que debería incluirse en el modelo el término de interacción entre tipo de barco y periodo de construcción. Sin embargo, al examinar los errores estándar de los coeficientes estimados de M_{itc} vemos que son extremadamente grandes, como se muestra en el siguiente output de R.

```
summary(M_itc)
```

```
Call:
```

```
glm(formula = y ~ typef + cyrf + oyrf + typef * cyrf +  
      offset(log(months)), family = poisson, data = d)
```

Ejemplo 4.1 Proceso Poisson (Incidentes de barcos)

Coefficients :

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-23.9891	6625.5246	-0.004	0.99711
typef2	17.0506	6625.5246	0.003	0.99795
typef3	17.0863	6625.5246	0.003	0.99794
typef4	-0.5962	9331.1044	0.000	0.99995
typef5	0.8799	11522.0953	0.000	0.99994
cyrf2	18.0324	6625.5246	0.003	0.99783
cyrf3	18.3969	6625.5246	0.003	0.99778
cyrf4	18.2860	6625.5246	0.003	0.99780
oyrf2	0.3850	0.1186	3.246	0.00117 **
typef2 : cyrf2	-17.3620	6625.5246	-0.003	0.99791
typef3 : cyrf2	-18.6108	6625.5247	-0.003	0.99776
typef4 : cyrf2	-18.4024	11467.2827	-0.002	0.99872
typef5 : cyrf2	0.4496	11522.0953	0.000	0.99997
typef2 : cyrf3	-17.6110	6625.5246	-0.003	0.99788
typef3 : cyrf3	-17.6160	6625.5246	-0.003	0.99788
typef4 : cyrf3	1.0922	9331.1044	0.000	0.99991
typef5 : cyrf3	-0.8285	11522.0953	0.000	0.99994
typef2 : cyrf4	-17.7124	6625.5246	-0.003	0.99787
typef3 : cyrf4	-17.3813	6625.5247	-0.003	0.99791
typef4 : cyrf4	-0.3254	9331.1044	0.000	0.99997
typef5 : cyrf4	-1.8570	11522.0954	0.000	0.99987

(Dispersion parameter for poisson family taken to be 1)

Null deviance: 146.328 on 33 degrees of freedom

Residual deviance: 14.587 on 13 degrees of freedom

AIC: 154.45

Number of Fisher Scoring iterations: 17

Ejemplo 4.1 Proceso Poisson (Incidentes de barcos)

Un examen de la matriz de correlación de los coeficientes estimados sugiere que el modelo está sobre parametrizado, hay correlaciones de 1 o muy cercanas a 1 en valor absoluto.

```
names(summary(M_its))  
J <- summary(M_its)$cov.unscaled  
D <- diag(sqrt(1/diag(J)))  
corr <- D %*% J %*% D  
round(corr,2)
```



Ejemplo 4.1 Proceso Poisson (Incidentes de barcos)

	[,1]	[,2]	[,3]	[,4]	[,5]	[,6]	[,7]	[,8]	[,9]	[,10]	[,11]
[1,]	1.00	-1.00	-1.00	-0.71	-0.58	-1.00	-1.00	-1.00	0	1.00	1.00
[2,]	-1.00	1.00	1.00	0.71	0.58	1.00	1.00	1.00	0	-1.00	-1.00
[3,]	-1.00	1.00	1.00	0.71	0.58	1.00	1.00	1.00	0	-1.00	-1.00
[4,]	-0.71	0.71	0.71	1.00	0.41	0.71	0.71	0.71	0	-0.71	-0.71
[5,]	-0.58	0.58	0.58	0.41	1.00	0.58	0.58	0.58	0	-0.58	-0.58
[6,]	-1.00	1.00	1.00	0.71	0.58	1.00	1.00	1.00	0	-1.00	-1.00
[7,]	-1.00	1.00	1.00	0.71	0.58	1.00	1.00	1.00	0	-1.00	-1.00
[8,]	-1.00	1.00	1.00	0.71	0.58	1.00	1.00	1.00	0	-1.00	-1.00
[9,]	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	1	0.00	0.00
[10,]	1.00	-1.00	-1.00	-0.71	-0.58	-1.00	-1.00	-1.00	0	1.00	1.00
[11,]	1.00	-1.00	-1.00	-0.71	-0.58	-1.00	-1.00	-1.00	0	1.00	1.00
[12,]	0.58	-0.58	-0.58	-0.81	-0.33	-0.58	-0.58	-0.58	0	0.58	0.58
[13,]	0.58	-0.58	-0.58	-0.41	-1.00	-0.58	-0.58	-0.58	0	0.58	0.58
[14,]	1.00	-1.00	-1.00	-0.71	-0.58	-1.00	-1.00	-1.00	0	1.00	1.00
[15,]	1.00	-1.00	-1.00	-0.71	-0.58	-1.00	-1.00	-1.00	0	1.00	1.00
[16,]	0.71	-0.71	-0.71	-1.00	-0.41	-0.71	-0.71	-0.71	0	0.71	0.71
[17,]	0.58	-0.58	-0.58	-0.41	-1.00	-0.58	-0.58	-0.58	0	0.58	0.58
[18,]	1.00	-1.00	-1.00	-0.71	-0.58	-1.00	-1.00	-1.00	0	1.00	1.00
[19,]	1.00	-1.00	-1.00	-0.71	-0.58	-1.00	-1.00	-1.00	0	1.00	1.00
[20,]	0.71	-0.71	-0.71	-1.00	-0.41	-0.71	-0.71	-0.71	0	0.71	0.71
[21,]	0.58	-0.58	-0.58	-0.41	-1.00	-0.58	-0.58	-0.58	0	0.58	0.58
	[,12]	[,13]	[,14]	[,15]	[,16]	[,17]	[,18]	[,19]	[,20]	[,21]	
[1,]	0.58	0.58	1.00	1.00	0.71	0.58	1.00	1.00	0.71	0.58	
[2,]	-0.58	-0.58	-1.00	-1.00	-0.71	-0.58	-1.00	-1.00	-0.71	-0.58	
[3,]	-0.58	-0.58	-1.00	-1.00	-0.71	-0.58	-1.00	-1.00	-0.71	-0.58	
[4,]	-0.81	-0.41	-0.71	-0.71	-1.00	-0.41	-0.71	-0.71	-1.00	-0.41	
[5,]	-0.33	-1.00	-0.58	-0.58	-0.41	-1.00	-0.58	-0.58	-0.41	-1.00	

...

Ejemplo 4.1 Proceso Poisson (Incidentes de barcos)

La interacción entre tipo de barco y año de operación es no-significativa $p\text{-value} = 0.29363165$ (M_{ito}). También es no-significativa la interacción entre año de construcción y año de operación (M_{ico}).



Como último aspecto de análisis, observamos en la gráfica de residuales vs. valores ajustados que el modelo de efectos principales (M_{main}) es adecuado para inferencias.

Ejemplo 4.1 Proceso Poisson (Incidentes de barcos)

```
#' Plot deviance residuals vs. fitted values

X11()
par(mfrow=c(4,2), las=1)
lapply(Mlist, function(x) {
  plot(x$fitted.values, residuals.glm(x, type="deviance"), las=1,
       ylim=c(-7,7), xlab="Fitted values", ylab="Deviance residuals")
  abline(h=c(-2,2), lty=c(2,2), col=c(2,2))
})

d$deviance <- residuals.glm(M_main, type="deviance")
plot(M_main$fitted.values, d$deviance, ylim=c(-4,4),
     xlab="Fitted values", ylab="Deviance residuals")
abline(h=c(-2,2), lty=c(2,2), col=c(2,2))
```

Ejemplo 4.1 Proceso Poisson (Incidentes de barcos)

Finalmente, conteste las siguientes preguntas.

1. ¿Cuál es valor estimado de la tasa relativa de accidentes para embarcaciones tipo A vs. tipo B?
2. ¿Cuál es valor estimado del número esperado de accidentes para 10,000 meses agregados de servicio para embarcaciones tipo A construidas en 1960-1964 y operando en 1975-1979?
3. ¿Como calcularía un intervalo de confianza al 95% para $\mu(10,000)$ de la pregunta anterior?

Ejemplo 4.1 Proceso Poisson (Incidentes de barcos)

Respuestas.

1.

Tipo	cyr	oyr	$\mathbf{x}_i^\top$	$\lambda(\mathbf{x}_i)$
<i>B</i>	NA	NA	$[1 \ 1 \ 0 \ 0 \ x_5 \ x_6 \ x_7 \ x_8]$	$\lambda_B = e^{\beta_0 + \beta_1 + \beta_5 + \beta_6 + \beta_7 + \beta_8}$
<i>A</i>	NA	NA	$[1 \ 0 \ 0 \ 0 \ x_5 \ x_6 \ x_7 \ x_8]$	$\lambda_A = e^{\beta_0 + \beta_5 + \beta_6 + \beta_7 + \beta_8}$

$$\frac{\lambda_B}{\lambda_A} = e^{\beta_1},$$

por lo tanto el valor estimado de la tasa relativa de accidentes de barcos tipos B vs. A es

$$\frac{\hat{\lambda}_B}{\hat{\lambda}_A} = e^{\hat{\beta}_1} = e^{-0.54334} = 0.581.$$

Ejemplo 4.1 Proceso Poisson (Incidentes de barcos)

2. La siguiente es la configuración de un barco de este tipo,

Tipo	cyr	oyr	$\mathbf{x}_i^\top$	$\lambda(\mathbf{x}_i)$
A	1964-1964	1970-1979	[1 0 0 0 0 0 0 0]	$\lambda_A = e^{\beta_0 + \beta_8}$

Recordemos la función de ligadura

$$\log \mu_i(t_i) = \log \lambda_i + \log t_i = \mathbf{x}_i^\top \boldsymbol{\beta} + \log t_i = \eta_i.$$

Entonces,

$$\begin{aligned}\hat{\mu}(10^4) &= \hat{\lambda} \times 10^4 = \exp\{\hat{\beta}_0 + \hat{\beta}_8\} \times 10^4 \\ &= \exp\{-6.4059 + 0.3845\} \times 10^4 = 24.26.\end{aligned}$$

Por lo tanto, esperaríamos observar (en promedio) 24.26 accidentes en un periodo de 10,000 meses agregados de servicio.

Ejemplo 4.1 Proceso Poisson (Incidentes de barcos)

3. El intervalo de confianza requerido está dado por

$$\begin{aligned}(\hat{\mu}_L(10^4), \hat{\mu}_U(10^4)) &= (e^{\hat{\eta}_L}, e^{\hat{\eta}_U}) \\&= \left(10^4 e^{\hat{\beta}_0 + \hat{\beta}_8 - 1.96\sqrt{\text{var}(\hat{\beta}_0 + \hat{\beta}_8)}}, 10^4 e^{\hat{\beta}_0 + \hat{\beta}_8 + 1.96\sqrt{\text{var}(\hat{\beta}_0 + \hat{\beta}_8)}}\right).\end{aligned}$$

Primero calculamos

$$\begin{aligned}\text{var}(\hat{\beta}_0 + \hat{\beta}_8) &= \text{var}(\hat{\beta}_0) + \text{var}(\hat{\beta}_8) + 2 \text{cov}(\hat{\beta}_0, \hat{\beta}_8) \\&= 0.047 + 0.014 + 2(-0.006) = 0.05015403\end{aligned}$$

Entonces el intervalo de confianza requerido es

$$\begin{aligned}(\hat{\mu}_L(10^4), \hat{\mu}_U(10^4)) &= \left(10^4 e^{-6.41 + 0.38 - 1.96\sqrt{0.050}}, 10^4 e^{-6.41 + 0.38 + 1.96\sqrt{0.050}}\right) \\&= (10^4 e^{-6.02 - 1.96 \times 0.22}, 10^4 e^{-6.02 + 1.96 \times 0.22}) \\&= (10^4 e^{-6.46}, 10^4 e^{-5.58}) = (15.64, 37.63)\end{aligned}$$

Análisis de tablas de contingencia (Introducción)

El propósito de las tablas de contingencia resumir datos cuando todas las variables son categóricas.

Una *tabla de contingencia bidimensional de doble entrada* se forma con la clasificación cruzada de dos variables, U y V por ejemplo, y las entradas en cada celda son los conteos de cada nivel de U contra cada nivel de V .

El supuesto básico en una tabla de contingencia es que los conteos en las celdas son variables aleatorias Poisson independientes con media μ_{ij} para la celda (i, j) .

Cuando condicionamos en las frecuencias totales de filas y columnas (a veces son fijos por diseño), obtenemos distribuciones multinomial, producto-multinomial o hipergeométrica no-centrada.

La distribución multinomial

Supongamos que hacemos una clasificación cruzada una muestra de $Y_{..} = y_{..}$ individuos de acuerdo con dos variables categóricas U y V con I y J niveles respectivamente. Los datos podemos resumirlos en una tabla de contingencia con la siguiente estructura

		Factor V						Totales U	
		1	2	...	j	...	J		
Factor U	1	y_{11}	y_{12}	...	y_{1j}	...	y_{1J}	$y_{1.}$	(75)
	2	y_{21}	y_{22}	...	y_{2j}	...	y_{2J}	$y_{2.}$	
	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	
	i	y_{i1}	y_{i2}	...	y_{ij}	...	y_{iJ}	$y_{i.}$	
	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	
	I	y_{I1}	y_{I2}	...	y_{Ij}	...	y_{IJ}	$y_{I.}$	
	Totales V	$y_{.1}$	$y_{.2}$	...	$y_{.j}$	...	$y_{.J}$	$y_{..}$	

La distribución multinomial

Recordemos el supuesto básico

$$\Pr(Y_{ij} = y_{ij}) = \frac{\mu_{ij}^{y_{ij}} e^{-\mu_{ij}}}{y_{ij}!}.$$

Dado el supuesto de independencia de las celdas, tenemos

$$\Pr(Y_{ij} = y_{ij}, \quad i = 1, \dots, I, \quad j = 1, \dots, J) = \prod_{i=1}^I \prod_{j=1}^J \left(\frac{\mu_{ij}^{y_{ij}} e^{-\mu_{ij}}}{y_{ij}!} \right).$$

Condicionamos respecto de el total $Y_{..} = y_{..}$ asumiendo que es fijo por diseño y sabemos que

$$\Pr(Y_{..} = y_{..}) = \frac{\mu_{..}^{y_{..}} e^{-\mu_{..}}}{y_{..}!}.$$

donde

$$\mu_{..} = \sum_{i=1}^I \sum_{j=1}^J \mu_{ij}$$

La distribución multinomial

Entonces

$$\begin{aligned}
 \Pr(Y_{ij} = y_{ij}, \quad i = 1, \dots, I, \quad j = 1, \dots, J \mid Y_{..} = y_{..}) &= \frac{\prod_{i=1}^I \prod_{j=1}^J \left(\frac{\mu_{ij}^{y_{ij}} e^{-\mu_{ij}}}{y_{ij}!} \right)}{\frac{\mu_{..}^{y_{..}} e^{-\mu_{..}}}{y_{..}!}} \\
 &= \frac{\prod_{i=1}^I \prod_{j=1}^J \mu_{ij}^{y_{ij}} \prod_{i=1}^I \prod_{j=1}^J e^{-\mu_{ij}} \prod_{i=1}^I \prod_{j=1}^J \frac{1}{y_{ij}!}}{\frac{\mu_{..}^{y_{..}} e^{-\mu_{..}}}{y_{..}!}} \\
 &= \frac{y_{..}!}{\prod_{i=1}^I \prod_{j=1}^J y_{ij}!} \prod_{i=1}^I \prod_{j=1}^J \left(\frac{\mu_{ij}}{\mu_{..}} \right)^{y_{ij}} \\
 &= \frac{y_{..}!}{\prod_{i=1}^I \prod_{j=1}^J y_{ij}!} \prod_{i=1}^I \prod_{j=1}^J \pi_{ij}^{y_{ij}} = \underbrace{\left(\frac{y_{..}!}{y_{11} \dots y_{IJ}} \right) \prod_{i=1}^I \prod_{j=1}^J \pi_{ij}^{y_{ij}}}_{\text{multinomial}(y_{11}, \dots, y_{IJ}; \pi_{11}, \dots, \pi_{IJ})}
 \end{aligned}$$

La distribución multinomial

donde

$$\pi_{ij} = \frac{\mu_{ij}}{\mu_{..}} \quad (76)$$

y la cual reconocemos como la distribución multinomial dado que

$$\sum_{i=1}^I \sum_{j=1}^J \pi_{ij} = 1.$$

La función de log-verosimilitud es

$$\ell(\boldsymbol{\pi}) = \sum_{i=1}^I \sum_{j=1}^J y_{ij} \log \pi_{ij} \quad (77)$$

donde $\boldsymbol{\pi}^\top = [\pi_{11} \quad \dots \quad \pi_{IJ}]$.

La distribución multinomial

Usualmente es de interés someter a prueba hipótesis de independencia entre los dos criterios de clasificación, U y V por ejemplo, que se formaliza en el sistema de hipótesis,

$$H_0 : \pi_{ij} = \pi_{i.}\pi_{.j} \quad \forall i, j \text{ vs.}$$

$$H_1 : \pi_{ij} \neq \pi_{i.}\pi_{.j} \text{ i.e. hay alguna asociación}$$

La función de log-verosimilitud bajo H_0 es

$$\begin{aligned}\ell(\boldsymbol{\pi}) &= \sum_{i=1}^I \sum_{j=1}^J y_{ij} \log(\pi_{i.}\pi_{.j}) \\ &= \sum_{i=1}^I \sum_{j=1}^J y_{ij} \log(\pi_{i.}) + \sum_{j=1}^J \sum_{i=1}^I y_{ij} \log(\pi_{.j}) \\ &= \sum_{i=1}^I y_{i.} \log \pi_{i.} + \sum_{j=1}^J y_{.j} \log \pi_{.j}\end{aligned}$$

La distribución multinomial

Los estimadores de máxima verosimilitud MLE están dados por

$$\begin{aligned}\hat{\pi}_{i\cdot} &= \frac{y_{i\cdot}}{y_{\cdot\cdot}}, & i &= 1, \dots, I \\ \hat{\pi}_{\cdot j} &= \frac{y_{\cdot j}}{y_{\cdot\cdot}}, & j &= 1, \dots, J\end{aligned}\tag{78}$$

y los valores ajustados son

$$\hat{\mu}_{ij\cdot} = y_{\cdot\cdot} \hat{\pi}_{ij} = y_{\cdot\cdot} \left(\frac{y_{i\cdot}}{y_{\cdot\cdot}} \right) \left(\frac{y_{\cdot j}}{y_{\cdot\cdot}} \right)\tag{79}$$

y los valores ajustados son

$$\hat{\mu}_{ij\cdot} = y_{\cdot\cdot} \hat{\pi}_{ij} = y_{\cdot\cdot} \left(\frac{y_{i\cdot}}{y_{\cdot\cdot}} \right) \left(\frac{y_{\cdot j}}{y_{\cdot\cdot}} \right)\tag{80}$$

La distribución multinomial

Por lo tanto,

$$\ell(\hat{\boldsymbol{\pi}}) = \sum_{i=1}^I \sum_{j=1}^J y_{ij} \log \hat{\pi}_{ij} = \sum_{i=1}^I \sum_{j=1}^J y_{ij} \log \left(\frac{y_{i\cdot} y_{\cdot j}}{y_{\cdot\cdot}^2} \right).$$

Los MLE bajo H_1 están dados por

$$\tilde{\pi}_{ij} = \frac{y_{ij}}{y_{\cdot\cdot}} \quad (81)$$

y la función log-verosimilitud bajo H_1 es

$$\ell(\tilde{\boldsymbol{\pi}}) = \sum_{i=1}^I \sum_{j=1}^J y_{ij} \log \tilde{\pi}_{ij} = \sum_{i=1}^I \sum_{j=1}^J y_{ij} \log \left(\frac{y_{ij}}{y_{\cdot\cdot}} \right)$$

La distribución multinomial

El estadístico de razón de verosimilitud está dado por

$$\begin{aligned} D &= -2[\ell(\hat{\pi}) - \ell(\tilde{\pi})] = 2[\ell(\tilde{\pi}) - \ell(\hat{\pi})] \\ &= 2 \sum_{i=1}^I \sum_{j=1}^J \log \left(\frac{y_{ij}/y_{..}}{y_{i\cdot}y_{\cdot j}/y_{..}^2} \right) = 2 \sum_{i=1}^I \sum_{j=1}^J \log \left(\frac{y_{ij}}{y_{i\cdot}y_{\cdot j}/y_{..}} \right) \\ &= 2 \sum_{i=1}^I \sum_{j=1}^J O_{ij} \log \left(\frac{O_{ij}}{E_{ij}} \right) \end{aligned} \tag{82}$$

donde O_{ij} son los conteos observados en las celdas y E_{ij} los valores esperados bajo la hipótesis nula. Los grados de libertad son 361

Alternativamente, podemos usar el estadístico de Pearson,

$$T = \sum_{i=1}^I \sum_{j=1}^J \frac{(O_{ij} - E_{ij})^2}{E_{ij}} \sim \chi^2_{(I-1)(J-1)} \quad (84)$$

que también tiene una distribución asintótica con los mismos grados de libertad que la deviance.

La distribución producto multinomial

Supongamos que J variables Poisson(μ_{ij}) independientes son observadas in cada una de I poblaciones.

		Factor V						Totales U	
		1	2	$\cdots$	j	$\cdots$	J		
Población	1	y_{11}	y_{12}	$\cdots$	y_{1j}	$\cdots$	y_{1J}	$y_{1\cdot}$	(85)
	2	y_{21}	y_{22}	$\cdots$	y_{2j}	$\cdots$	y_{2J}	$y_{2\cdot}$	
	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	
	i	y_{i1}	y_{i2}	$\cdots$	y_{ij}	$\cdots$	y_{iJ}	$y_{i\cdot}$	
	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	
	I	y_{I1}	y_{I2}	$\cdots$	y_{Ij}	$\cdots$	y_{IJ}	$y_{I\cdot}$	
Totales V		$y_{\cdot 1}$	$y_{\cdot 2}$	$\cdots$	$y_{\cdot j}$	$\cdots$	$y_{\cdot J}$	$y_{\cdot \cdot}$	

Recordemos el supuesto inicial

$$\Pr(Y_{ij} = y_{ij}) = \frac{\mu_{ij}^{y_{ij}} e^{-\mu_{ij}}}{y_{ij}!}.$$

La distribución producto multinomial

Si $y_{..}$ es fijo por diseño, como es usual, trabajamos con la distribución condicional de $y_{ij}, i = 1, \dots, I, j = 1, \dots, J$ dado $y_{..}$

Anteriormente demostramos que esto es una distribución multinomial,

$$\begin{aligned} \Pr(Y_{ij} = y_{ij}, i = 1, \dots, I, j = 1, \dots, J \mid Y_{..} = y_{..}) \\ = \frac{y_{..}!}{\prod_{i=1}^I \prod_{j=1}^J y_{ij}!} \prod_{i=1}^I \prod_{j=1}^J \pi_{ij}^{y_{ij}} \end{aligned}$$

donde

$$\pi_{ij} = \frac{\mu_{ij}}{\mu_{..}}$$

La distribución producto multinomial

Para esta muestra multinomial usualmente estamos interesados en el siguiente sistema de hipótesis

$$H_0 : \pi_{ij} = \pi_i \cdot \pi_j \quad \forall i, j$$

vs. $H_1 : \pi_{ij} \neq \pi_i \cdot \pi_j$ i.e. hay alguna asociación

o, equivalentemente,

$$\mathbb{E}(Y_{ij}) = y_{..} \pi_i \cdot \pi_j.$$

Típicamente procederíamos, primero, estimando π_i y π_j para $i = 1, \dots, I$ y $j = 1, \dots, J$ con base en los totales marginales.

Después estimaríamos los valores esperados para la entrada (i, j) usando estos estimados muestrales y finalmente computando el estadístico de Pearson o la deviance para llevar a cabo una prueba formal.

La distribución producto multinomial

Es posible ajustar un modelo log-lineal para someter a prueba este sistema de hipótesis y, si este modelo ajusta a los datos apropiadamente, entonces concluiríamos que la evidencia en los datos es débil para refutar la hipótesis de independencia (i.e. no se rechaza). En este caso, el modelo log-lineal correspondiente bajo la H_0 es

$$\log \mu_{ij} = a + u_i + v_j; \quad i = 1, \dots, I, \quad j = 1, \dots, J \quad (86)$$

donde a es el intercepto, u_i son coeficientes de los niveles de del factor U y v_i coeficientes de los niveles del factor V . La notación difiere de la que hemos utilizado hasta el momento porque en los modelos log-lineales es común que haya varios factores cada uno tenga varios factores y la expresión usual del predictor lineal como combinación lineal de coeficientes y covariables se vuelve demasiado larga.

La distribución producto multinomial

Bajo $H_1 : \pi_{ij} \neq \pi_{i.}\pi_{.j}$ o, equivalentemente,

$$\mathbb{E}(Y_{ij} \neq y_{..}\pi_{i.}\pi_{.j}).$$

El modelo loglineal correspondiente es el modelo saturado dado por

$$\log \mu_{ij} = a + u_i + v_j + (uv)_{ij}; \quad i = 1, I, \quad j = 1, \dots, J \quad (87)$$

donde $(uv)_{ij}$ son coeficientes de las interacciones entre U y V .

La prueba de independencia está basada en comparar el ajuste del modelo (86) vs. el ajuste del modelo (87).

La distribución producto multinomial

El modelo (87) define el modelo log-lineal más general para una tabla de doble entrada. Introduce $1 + I + J + IJ$ parámetros, por lo que es necesario introducir restricciones dado que en los datos hay un total de IJ observaciones. Las **restricciones de esquina** son

$$u_1 = 0$$

$$v_1 = 0$$

$$(uv)_{1j} = 0; \quad j = 1, \dots, J$$

$$(uv)_{i1} = 0; \quad i = 1, \dots, I.$$

Quedan, entonces, $1 + (I - 1) + (J - 1) + (I - 1)(J - 1) = IJ$ parámetros.

Los parámetros pueden interpretarse como desviaciones respecto del nivel de referencia para el efecto correspondiente.

La distribución producto multinomial

Las restricciones de ANOVA son las siguientes,

$$\sum_{i=1}^I u_i = 0$$

$$\sum_{j=1}^J v_j = 0$$

$$u_{..} = 0$$

$$v_{..} = 0$$

$$\sum_{i=1}^I (uv)_{1j} = 0; \quad j = 1, \dots, J \quad (uv)_{.j} = 0; \quad j = 1, \dots, J$$
$$(uv)_{i.} = 0; \quad i = 1, \dots, I.$$

$$\sum_{j=1}^J (uv)_{1j} = 0; \quad j = 1, \dots, J$$

$$\sum_{i=1}^I \sum_{j=1}^J \pi_{ij} = 1.$$

La distribución producto multinomial

La función de log-verosimilitud es

$$\ell(\boldsymbol{\pi}) = \sum_{i=1}^I \sum_{j=1}^J y_{ij} \log \pi_{ij} \quad (88)$$

Nos quedamos con $1 + (I - 1)(J - 1) + (IJ - (I + J - 1)) = IJ$ parámetros.

Comenzando con el modelo saturado, bajo las restricciones de ANOVA tenemos

$$\begin{aligned} \log \mu_{ij} &= a + u_i + v_j + (uv)_{ij} & \sum_{j=1}^J \log \mu_{ij} &= Ja + Ju_i + 0 + 0 \\ \sum_{i=1}^I \log \mu_{ij} &= Ia + 0 + Iv_j + 0 & \sum_{i=1}^I \sum_{j=1}^J \log \mu_{ij} &= IJa + 0 + 0 + 0 \end{aligned}$$

La distribución producto multinomial

A su vez, esto resulta en

$$v_j = \frac{1}{I} \sum_{i=1}^I \log \mu_{ij} - a$$

$$u_i = \frac{1}{J} \sum_{j=1}^J \log \mu_{ij} - a$$

$$a = \frac{1}{IJ} \sum_{i=1}^I \sum_{j=1}^J \log \mu_{ij}$$

y

$$(uv)_{ij} = \log \mu_{ij} - a - u_i - v_j$$

$$= \log \mu_{ij} - a - \left(\frac{1}{I} \sum_{i=1}^I \log \mu_{ij} - a \right) - \left(\frac{1}{J} \sum_{j=1}^J \log \mu_{ij} - a \right)$$

La distribución producto multinomial

Podemos ver que éstas son análogas a las restricciones e interpretaciones de los efectos que se originan de los modelos ANOVA ordinarios. Aquí los parámetros se interpretan como desviaciones de los términos de orden más bajo.

Para obtener los valores estimados por máxima verosimilitud para modelos de tablas de contingencia de doble entrada notemos

$$\begin{aligned}\Pr(Y_{ij} = y_{ij}, \quad i = 1, \dots, I, \quad j = 1, \dots, J) &= \prod_{i=1}^I \prod_{j=1}^J \left(\frac{\mu_{ij}^{y_{ij}} e^{-\mu_{ij}}}{y_{ij}!} \right) \\ &= \prod_{i=1}^I \prod_{j=1}^J \exp \{y_{ij} \log \mu_{ij} - \mu_{ij} - \log y_{ij}!\}\end{aligned}$$

y como antes, la función de log-verosimilitud toma la forma

$$\ell(\boldsymbol{\mu}) = \sum_{i=1}^I \sum_{j=1}^J y_{ij} \log \mu_{ij} - \log y_{ij}!.$$

La distribución producto multinomial

Podemos hacer sustituciones para adaptar cualquier modelo log-lineal particular. Para el modelo saturado, por ejemplo, sea

$$\log \mu_{ij} = a + u_i + v_j + (uv)_{ij}; \quad i = 1, \dots, I, \quad j = 1, \dots, J$$

sustituyendo $\mu_{ij} = \exp \{a + u_i + v_j + (uv)_{ij}\}$ en la función de log-verosimilitud y maximizar sujeto a las restricciones de esquina o ANOVA.

La distribución producto multinomial

¿Por qué podemos usar la distribución Poisson para derivar los MLE en este contexto cuando de hecho $Y_{..} = y_{..}$ es fijo y la distribución multinomial era apropiada?

Mostramos la relación entre la función log-verosimilitud Poisson y la función log-verosimilitud multinomial para un caso especial, pero el resultado se sostiene para casos más generales.

Si las funciones log-verosimilitud están relacionadas entonces no debería sorprendernos que los MLE de la media para algunos modelos log-lineales sean los mismos para la distribución Poisson y para la distribución multinomial o producto-multinomial.

Para que esto se sostenga hay ciertos términos que deben incluirse en el modelo log-lineal. Los términos apropiados son los parámetros que se corresponden con los totales marginales fijos por diseño.

La distribución producto multinomial

Por ejemplo,

- Si $y_{..}$ es fijo, inclúyase el término a (caso multinomial).
- Si $y_{i.}$ es fijo, inclúyanse los términos $a + u_i$ (caso producto-multinomial)
- Si $y_{.j}$ es fijo, inclúyanse los términos $a + v_j$ (caso producto-multinomial)

Total fijo	Incluir términos	Caso
$y_{..}$	a	multinomial
$y_{i.}$	$a + u_i$	producto-multinomial
$y_{.j}$	$a + v_j$	producto-multinomial

Consideraciones:

1. Los modelos log-lineales toman su nombre del hecho de que los efectos son lineales en escala logarítmica.
2. En los modelos log-lineales no hay distinción entre variables explicativas y respuesta.
3. Los modelos log-lineales pueden usarse para analizar relaciones entre varias variables. Una consecuencia de esto es que los términos de interacción se vuelven de interés prioritario.

4. Se dice que los modelos log-lineales son jerárquicos (hierarchical) en el sentido de que términos de mayor orden no se incluyen en el modelo a menos que todos los términos de orden menor se incluyan. Esto es

$$\log \mu_{ij} = a + u_i + (uv)_{ij}$$

nunca podrá un modelo log-linear apropiado debido a que el término v_j no es parte del modelo.

5. Dado que la distribución Poisson es miembro de la familia exponencial podemos usar IRWLS para estimar los MLE.

Ejemplo 4.2 Tabla de contingencia 2-way (Melanoma)

Se condujo un estudio de corte transversal de $y.. = 400$ pacientes con melanoma maligno donde los pacientes fueron clasificados de acuerdo con dos factores: *sitio del tumor* y *tipo histológico*.

Tipo de tumor	Cabeza y cuello	Torso	Extremidades	Total
Peca de Hutchinson	22	2	10	34
Esparcimiento superficial	16	54	115	185
Nodular	19	33	73	125
Indeterminado	11	17	28	56

Es de interés investigar si es igualmente verosímil que aparezcan los distintos tipos de tumor en distintos sitios. Esto es, evaluaremos si hay o no asociación entre tipo histológico del tumor y sitio.

Ejemplo 4.2 Tabla de contingencia 2-way (Melanoma)

El supuesto básico es que los datos siguen una distribución

Poisson, i.e. $y_{ij} \sim \text{Poisson}(\mu_{ij}), i = 1, 2, 3, 4 \quad j = 1, 2, 3$.

Condicionamos por $Y_{..} = y_{..}$ dado que el total esta fijo por diseño, lo que nos conduce a la distribución multinomial.

$$\Pr(Y_{ij} = y_{ij}, \forall(i, j) \mid Y_{..} = y_{..}) = \frac{y_{..}!}{\prod_{i=1}^I \prod_{j=1}^J y_{ij}!} \prod_{i=1}^I \prod_{j=1}^J \pi_{ij}^{y_{ij}}$$

donde

$$\pi_{ij} = \frac{\mu_{ij}}{\mu_{..}}$$

Nuestra hipótesis de trabajo es que el el tipo del tumor y sitio son independientes, esto es

$$H_0 : \pi_{ij} = \pi_{i.} \pi_{.j} \quad \forall(i, j)$$

$$\text{vs. } H_1 : \pi_{ij} \neq \pi_{i.} \pi_{.j} \text{ i.e. hay alguna asociación}$$

Ejemplo 4.2 Tabla de contingencia 2-way (Melanoma)

Bajo H_0

$$\mathbb{E}(Y_{ij}) = y_{..}\pi_{i.}\pi_{.j}$$

lo que significa que tenemos que estimar los totales por fila y columna ($y_{i.}, y_{.j}$) para a su vez poder estimar $\pi_{i.}, i = 1, 2, 3, 4$ y $\pi_{.j}, j = 1, 2, 3$. Por lo tanto, el modelo log-lineal bajo H_0 es

$$M_{\text{main}} : \log \mu_{ij} = a + u_i + v_j; \quad i = 1, 2, 3, 4, \quad j = 1, 2, 3$$

donde u_i se corresponde con la variable tipo de tumor (i indica el nivel del tipo) y v_j se corresponde con la variable sitio del tumor (j indica el nivel del sitio).

Ejemplo 4.2 Tabla de contingencia 2-way (Melanoma)

Si el modelo ajustara los datos entonces tendríamos poca evidencia para rechazar la hipótesis de independencia entre tipo y sitio del tumor (no rechazamos H_0).

Por el contrario, si el modelo no ajustara los datos apropiadamente significaría que ciertos tipos de tumor aparecen con mayor frecuencia en algunos sitios.

```
setwd(datwd); getwd()  
d <- read.table('derm.txt', header=T)
```

	type	locat	y
1	1	1	22
2	1	2	2
3	1	3	10
4	2	1	16
5	2	2	54
6	2	3	115
7	3	1	19
8	3	2	33
9	3	3	73
10	4	1	11
11	4	2	17
12	4	3	28

Ejemplo 4.2 Tabla de contingencia 2-way (Melanoma)

```
> Create factor variables for type and site
```

```
d$typef=factor(d$type)  
d$sitef=factor(d$locat)
```

```
> Fit the main effects model:
```

```
> - M_main: both main effects ('site' and 'histological type')
```

```
M_main <- glm(y ~ typef + sitef, family=poisson, data=d)  
summary(M_main)
```

```
> Create factor variables for type and site
```

```
d$typef=factor(d$type)  
d$sitef=factor(d$locat)
```

```
> Fit the main effects model:
```

```
> - M_main: both main effects ('site' and 'histological type')
```

```
M_main <- glm(y ~ typef + sitef, family=poisson, data=d)  
summary(M_main)
```

Ejemplo 4.2 Tabla de contingencia 2-way (Melanoma)

Call:

```
glm(formula = y ~ typef + sitef, family = poisson, data = d)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	1.7544	0.2040	8.600	< 2e-16 ***
typef2	1.6940	0.1866	9.079	< 2e-16 ***
typef3	1.3020	0.1934	6.731	1.68e-11 ***
typef4	0.4990	0.2174	2.295	0.02173 *
sitef2	0.4439	0.1554	2.857	0.00427 **
sitef3	1.2010	0.1383	8.683	< 2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for poisson family taken to be 1)

Null deviance: 295.203 on 11 degrees of freedom
Residual deviance: 51.795 on 6 degrees of freedom
AIC: 122.91

Number of Fisher Scoring iterations: 5

Ejemplo 4.2 Tabla de contingencia 2-way (Melanoma)

> Append to the `data set` columns for `fitted` values and `deviance residuals`

```
d <- cbind(d, yhat = M_main$fitted.values ,  
           rdeviance = round(residuals.glm(M_main, type='deviance'),2))
```

```
d
```

	type	locat	y	typef	sitef	yhat	rdeviance
1	1	1	22	1	1	5.780	5.14
2	1	2	2	1	2	9.010	-2.83
3	1	3	10	1	3	19.210	-2.32
4	2	1	16	2	1	31.450	-3.05
5	2	2	54	2	2	49.025	0.70
6	2	3	115	2	3	104.525	1.01
7	3	1	19	3	1	21.250	-0.50
8	3	2	33	3	2	33.125	-0.02
9	3	3	73	3	3	70.625	0.28
10	4	1	11	4	1	9.520	0.47
11	4	2	17	4	2	14.840	0.55
12	4	3	28	4	3	31.640	-0.66

> Produce a `table` of the expected values

```
yhat <- with(d, tapply(yhat, list(type=typef,site=sitef), sum))  
cbind(rbind(yhat,colSums(yhat)), c(rowSums(yhat),sum(yhat)))
```

	1	2	3	
1	5.78	9.010	19.210	34
2	31.45	49.025	104.525	185
3	21.25	33.125	70.625	125
4	9.52	14.840	31.640	56
	68.00	106.000	226.000	400

Ejemplo 4.2 Tabla de contingencia 2-way (Melanoma)

Notemos en la tabla de los valores ajustados que los totales por fila y por columna tienen un ajuste exacto. Este modelo no es adecuado, por las siguientes razones:

1. A un nivel de significancia del 5% todos los coeficientes estimados son significativos.
2. Algunos de los residuales de la deviance tienen valor grandes, en particular aquellos de las dos primeras observaciones y la cuarta de la tabla.
3. El tumor tipo Hutchinson ocurre con mayor frecuencia en la cabeza y el cuello que lo esperado bajo el supuesto de independencia (22 vs. 5.8) y ocurre con menor frecuencia que lo esperado en torzo y extremidades (2 vs. 9 & 10 vs. 19.2).

Ejemplo 4.2 Tabla de contingencia 2-way (Melanoma)

4. Melanoma de esparcimiento superficial ocurre con menor frecuencia que lo esperado bajo el supuesto de independencia en cabeza y cuello (16 vs. 31.5).

Por lo tanto, la hipótesis de independencia entre tipo y locación de los tumores no se sostiene en con estos datos.

Las Tablas 21 y 21 nos ofrecen una representación alternativa de las distintas distribuciones de por por tipo y por sitio de los tumores.

Ejemplo 4.2 Tabla de contingencia 2-way (Melanoma)

	Cabeza & Cuello	Torzo	Extremidades Extremidades	Todos los sitios
Peca de Hutchinson	64.7	5.9	29.4	100
Esparcimiento superficial	8.6	29.2	62.2	100
Nodular	15.2	26.4	58.4	100
Indeterminado	19.6	30.4	50.0	100

Table 21: Porcentajes de Fila

	Cabeza & Cuello	Torzo	Extremidades
Peca de Hutchinson	32.4	1.9	4.4
Esparcimiento superficial	23.5	50.9	50.9
Nodular	27.9	31.1	32.3
Indeterminado	16.2	16.0	12.4
Todos los tipos	100	100	100

Table 22: Porcentajes de Columna

Ejemplo 4.2 Tabla de contingencia 2-way (Melanoma)

Para efectos ilustrativos, consideremos los siguientes dos modelos, cada uno con una única variable

$$M_{\text{type}} : \log \mu_{ij} = a + u_i; \quad i = 1, 2, 3, 4$$

$$M_{\text{site}} : \log \mu_{ij} = a + v_j; \quad j = 1, 2, 3$$

Comparando estos modelos contra el modelo de efectos principales M_{main} estaríamos sometiendo a prueba la hipótesis ya sea de que diferentes tipos de tumor ocurren con la misma frecuencia (M_{type} vs. M_{main}) o que los tumores ocurren en con la misma frecuencia en los tres sitios del cuerpo (M_{site} vs. M_{main}).

Ejemplo 4.2 Tabla de contingencia 2-way (Melanoma)

Para efectos ilustrativos, consideremos los siguientes dos modelos, cada uno con una única variable

$$M_{\text{type}} : \log \mu_{ij} = a + u_i; \quad i = 1, 2, 3, 4$$

$$M_{\text{site}} : \log \mu_{ij} = a + v_j; \quad j = 1, 2, 3$$

Comparando estos modelos contra el modelo de efectos principales M_{main} estaríamos sometiendo a prueba la hipótesis ya sea de que diferentes tipos de tumor ocurren con la misma frecuencia (M_{type} vs. M_{main}) o que los tumores ocurren en con la misma frecuencia en los tres sitios del cuerpo (M_{site} vs. M_{main}).

Ejemplo 4.2 Tabla de contingencia 2-way (Melanoma)

```
> Fit two additional models:  
> - M_type: Verify if different tumour types occur equally often  
> - M_site: Verify if tumour occur equally often at different sites
```

```
M_type <- glm(y ~ typef, family=poisson, data=d)  
M_site <- update(M_main, .~.-typef)
```

```
Mlist <- list(M_main, M_type, M_site)  
Mnames <- c('Main effects', 'type', 'site')  
names(Mlist) <- Mnames
```

```
deviance <- lapply(Mlist, function(x) x$deviance)  
df <- lapply(Mlist, function(x) x$df.residual)
```

```
pvals <- lapply(2:3, function(x) {  
  1-pchisq(deviance[[x]]-deviance[[1]], df[[x]]-df[[1]])  
})  
unlist(pvals)  
[1] 0 0
```

De acuerdo con las pruebas: (1) los tipos de tumor no ocurren con la misma frecuencia y (2) el melanoma tampoco ocurre con misma frecuencia en los distintos sitios del cuerpo.

Modelos log-lineales para tablas de triple entrada

Consideremos el problema general en donde los individuos son clasificados de acuerdo con tres variables factores U, V y W con I, J y K niveles, respectivamente. Como en las tablas de doble entrada, inicialmente asumimos que $Y_{ijk} \sim \text{Poisson}(\mu_{ijk})$, $i = 1, \dots, I, j = 1, \dots, J, k = 1, \dots, K$. Si $Y_{...} = y_{...}$ es fijo por diseño, como usualmente sería, debemos condicionar en este total para dar la distribución multinomial.

$$\begin{aligned} & \Pr(Y_{ijk}, \forall(i, j, k) \mid Y_{...} = y_{...}) \\ &= \frac{y_{...}!}{\prod_{i=1}^I \prod_{j=1}^J \prod_{k=1}^K y_{ijk}!} \prod_{i=1}^I \prod_{j=1}^J \prod_{k=1}^K \pi_{ijk}^{y_{ijk}} \end{aligned} \quad (89)$$

donde $\pi_{ijk} = \frac{\mu_{ijk}}{\mu_{...}}$ son ahora los parámetros de interés.

Modelos log-lineales para tablas de triple entrada

En la sección anterior [??] discutimos la conexión entre los modelos log-lineales y cuestiones de independencia en el caso de tablas de contingencia de doble entrada.

Recapitulando, los términos de los efectos principales modelan la distribución no-uniforme de los totales de filas y columnas, y los términos de interacción representan la asociación entre los dos factores de interés. En términos de asociaciones, éstas eran ya sea ausentes o presentes.

Veremos a continuación que con tablas de triple entrada (tablas de contingencia que involucran tres factores), la naturaleza de las asociaciones presentes puede ser bastante más complicada.

(a) Independencia mutua (Mutual Independence)

$$H_0 : \pi_{ijk} = \pi_{i..}\pi_{.j.}\pi_{..k}$$

Las variables U, V y W se dice que son *mutuamente independientes* si podemos calcular las celdas de la tabla como producto de los tres totales marginales, i.e.

$\pi_{ijk} = \pi_{i..}\pi_{.j.}\pi_{..k}$. Esto es, las tres variables U, V y W son independientes entre ellas. Esto implica que

$$y_{...}\pi_{ijk} = y_{...}\pi_{i..}\pi_{.j.}\pi_{..k}$$

El modelo log-lineal correspondiente está dado por

$$\log \mu_{ijk} = a + u_i + v_j + w_k \quad (90)$$

con las restricciones de esquina $u_1 = v_1 = w_1 = 0$.

Sabemos que este es el modelo correspondiente porque en la hipótesis de que podemos modelar las probabilidades individuales de la tabla como producto de los totales marginales, el modelo anterior ajustará los datos perfectamente. Es conveniente tener notación abreviada para identificar este modelo log-lineal, y en ocasiones se denota con (U, V, W) , donde listamos los términos de orden superior que involucran cada uno de los factores. Los grados de libertad del modelo son

$$1 + (I - 1) + (J - 1) + (K - 1) = I + J + K - 2$$

y los grados de libertad residuales son

$$IJK - (I + J + K - 2)$$

(b) Independencia conjunta (joint independence).

$$H_0 : \pi_{ijk} = \pi_{i \cdot k} \pi_{\cdot j}.$$

Decimos que V es conjuntamente independiente de U y W si podemos calcular las frecuencias relativas como producto de los totales marginales de U y W , i.e. $\pi_{ijk} = \pi_{i \cdot k} \pi_{\cdot j}$. Esto es, V es independiente de la “nueva variable” con IK niveles definida por la combinación de niveles de U y W . Esto implica que dados los niveles de U y W , no dan ninguna información acerca de la distribución del factor V . Equivalentemente, podríamos decir que la naturaleza de la asociación existente entre U y W no varía con diferentes niveles del factor W .

Independencia conjunta

El modelo log-lineal correspondiente tiene la forma

$$\log \mu_{ijk} = a + u_i + v_j + w_k + u_i w_k \quad (91)$$

dado que este modelo asegurará que las probabilidades marginales requeridas para modelar π_{ijk} ajustarán los datos exactamente. Si la hipótesis se sostiene, entonces estimar estos marginales totales debería ser suficiente para obtener un ajuste correcto de los datos. En notación abreviada, este modelo lo denotamos por (UW, V) . Los grados de libertad del modelo son

$$1 + (I - 1) + (J - 1) + (K - 1) + (I - 1)(K - 1)$$

y los grados de libertad residuales

$$(IJK) - [1 + (I - 1) + (J - 1) + (K - 1) + (I - 1)(K - 1)].$$

Independencia condicional

Podría ser el caso que U fuera conjuntamente independiente de V y W , modelo denotado por (VW, U) o W conjuntamente independiente de U, V , modelo que denotamos por (UV, W) .

(c) Independencia condicional (Conditional Independence)

$$H_0 : \pi_{ij|k} = \pi_{i\cdot|k}$$

donde $\pi_{ij|k} = \pi_{i\cdot|k}$ determina la distribución conjunta de U y V en cada nivel k de W . Entonces decimos que U y V son condicionalmente independientes de W si podemos expresar las frecuencias relativas $\pi_{ij|k} = \pi_{i\cdot|k}$, $i = 1, \dots, I$, $j = 1, \dots, J$. La hipótesis nula implica

$$\frac{\pi_{ijk}}{\pi_{\cdot\cdot k}} = \left(\frac{\pi_{i\cdot k}}{\pi_{\cdot\cdot k}} \right) \left(\frac{\pi_{\cdot j k}}{\pi_{\cdot\cdot k}} \right) \implies \pi_{ijk} = \frac{\pi_{i\cdot k} \pi_{\cdot j k}}{\pi_{\cdot\cdot k}}$$

Independencia condicional

El modelo log-lineal correspondiente es de la forma

$$\log \mu_{ijk} = a + u_i + v_j + w_k + u_i w_k + v_j w_k \quad (92)$$

y el cual denotamos por (UW, VW) . De nuevo, sabemos que este es el modelo correspondiente porque bajo éste todo lo que se requiere es estimar las probabilidades π_{ijk} son las probabilidades marginales $\pi_{i \cdot k}$ y $\pi_{\cdot ji}$. Los grados de libertad del model son

$$1 + (I - 1) + (J - 1) + (K - 1) + (I - 1)(K - 1) + (J - 1)(K - 1)$$

y los grados de libertad residuales

$$IJK - [1 + (I - 1) + (J - 1) + (K - 1) + (I - 1)(K - 1) + (J - 1)(K - 1)]$$

Podrían ser también los casos de modelos (UV, VW) , (UV, UW) , donde el segundo por ejemplo indica que condicionando por V , U y W son independientes.

Independencia condicional a pares

- (d) Independencia condicional a pares (All Pairs Conditionally Independent)

Este caso está relacionado con el anterior (c). La hipótesis nula es

$$H_0 : \pi_{ij|k} = \pi_{i\cdot|k}\pi_{\cdot j|k},$$

$$\pi_{ik|j} = \pi_{i\cdot|j}\pi_{\cdot k|j},$$

$$\pi_{jk|i} = \pi_{j\cdot|i}\pi_{\cdot k|i}$$

Tenemos, entonces, la asociación entre cualquier par de variables constante a lo largo de la tercera variable. Una manera alternativa de pensar en este modelo es que hay una asociación entre todos los pares de variables, pero la naturaleza de la asociación es constante respecto de cambios en el nivel de la variable restante.

Independencia condicional a pares

El modelo es

$$\log \mu_{ijk} = a + u_i + v_j + w_k + u_i v_j + u_i w_k + v_j w_k \quad (93)$$

el cual denotamos por (UV, UW, VW) . Los grados de libertad del modelo son Los grados de libertad del model son

$$1 + (I-1) + (J-1) + (K-1) + (I-1)(J-1) + (I-1)(K-1) + (J-1)(K-1)$$

y los grados de libertad residuales

$$IJK - [1 + (I-1) + (J-1) + (K-1) + (I-1)(J-1) + (I-1)(K-1) + (J-1)(K-1)]$$

El siguiente y más complejo es el modelo satiado, el cual involucra el término de todas las interacciones triples con un total de IJK parámetros.

El ajuste de un modelo log-lineal puede juzgarse con base en la deviance asumiendo una distribución Poisson subyacente en los conteos (entradas de las celdas de la tabla de contingencia). El estadístico de deviance tiene la forma

$$D = \sum_{i=1}^I \sum_{j=1}^J \sum_{k=1}^K O_{ijk} \log \left(\frac{O_{ijk}}{E_{ijk}} \right) \sim \chi_{IJK-q}^2 \quad (94)$$

donde los grados de libertad son $(IJK) - q$ y q es el número de parámetros bajo H_0 . La distribución $\sim \chi_{IJK-q}^2$ es aproximada.

Ejemplo 4.2 Tabla de contingencia 2-way (Melanoma)

Alternativamente, puede usarse el estadístico de Pearson

$$P = \sum_{i=1}^I \sum_{j=1}^J \sum_{k=1}^K \frac{(O_{ijk} - E_{ijk})^2}{E_{ijk}} \sim \chi_{IJK-q}^2 \quad (95)$$

donde O_{ijk} es el valor observado en la celda (ijk) y E_{ijk} es su valor esperado bajo H_0 . De nuevo, la distribución $P \sim \chi_{IJK-q}^2$ es aproximada bajo H_0 .

Los residuales de la deviance tienen la misma forma que en el modelo Poisson. Los residuales estandarizados de Pearson toman la forma

$$r_{ijk}^P = \frac{O_{ijk} - E_{ijk}}{\sqrt{E_{ijk}}}. \quad (96)$$

Ejemplo 4.3 Tabla de contingencia múltiple (Suicidio)

Supongamos que estamos interesados en examinar la naturaleza de la asociación entre tres variables: sexo, grupo de edad y método de suicidio de acuerdo con los datos de la Tabla 23.

Sexo	Edad	Causa de muerte					
		Sólido/Líquido	Gas	Respiratorio	Arma	Salto	Otro
Hombre	10-40	398	121	455	155	55	124
Hombre	41-70	399	82	797	168	51	82
Hombre	> 70	93	6	316	33	26	14
Mujer	10-40	259	15	95	14	40	38
Mujer	41-70	450	13	450	26	71	60
Mujer	> 70	154	5	185	7	38	10

Table 23: Método de suicidio

Notemos primero que no hay una variable que podamos distinguir claramente como variable respuesta.

Ejemplo 4.3 Tabla de contingencia múltiple (Suicidio)

Es de interés investigar la asociación entre las sexo, edad y método de suicidio, lo haremos mediante métodos basados en modelos log-lineales. Denotemos por U la variable sexo, por V edad y W el método de suicidio. La Tabla 24 reemplaza los datos por notación de modelos lineales generalizados.

Sexo (U)	Edad (V)	Causa de muerte (W)					
		w_1	w_2	w_3	w_4	w_5	w_6
u_1	v_1	y_{111}	y_{112}	y_{113}	y_{114}	y_{115}	y_{116}
u_1	v_2	y_{121}	y_{122}	y_{123}	y_{124}	y_{125}	y_{126}
u_1	v_3	y_{131}	y_{132}	y_{133}	y_{134}	y_{135}	y_{136}
u_2	v_1	y_{211}	y_{212}	y_{213}	y_{214}	y_{215}	y_{216}
u_2	v_2	y_{221}	y_{222}	y_{223}	y_{224}	y_{225}	y_{226}
u_2	v_3	y_{231}	y_{232}	y_{233}	y_{234}	y_{235}	y_{236}

Table 24: Datos en notación de GLM.

Ejemplo 4.3 Tabla de contingencia múltiple (Suicidio)

Con esta notación definimos el modelo log-lineal saturado que denotado en este ejemplo por M_{full} es

$$M_{\text{full}} : \log \mu_{ijk} = a + u_i + v_j + w_k + (uv)_{ij} + (uw)_{ik} + (vw)_{jk} + (uvw)_{ijk}$$

y dará un ajuste perfecto a los datos (hay un parámetro para cada observación). Deseamos encontrar un modelo más simple que describa los datos apropiadamente, una representación más sencilla de la relación entre sexo, edad y método de suicidio. Los modelos candidatos que se analizaron son

$$M_{2\text{way}} : \log \mu_{ijk} = a + u_i + v_j + w_k + (uv)_{ij} + (uw)_{ik} + (vw)_{jk}$$

$$M_{\text{sasm}} : \log \mu_{ijk} = a + u_i + v_j + w_k + (uv)_{ij} + (uw)_{ik}$$

$$M_{\text{saam}} : \log \mu_{ijk} = a + u_i + v_j + w_k + (uv)_{ij} + (vw)_{jk}$$

$$M_{\text{smam}} : \log \mu_{ijk} = a + u_i + v_j + w_k + (uw)_{ik} + (vw)_{jk}$$

Ejemplo 4.3 Tabla de contingencia múltiple (Suicidio)

Se muestra el código de R utilizado en el análisis y una selección del output. Nótese que usamos la función de R `update()` para que a partir de un modelo previamente ajustado podamos remover términos (o agregar si fuera necesario).

```
setwd(datwd); getwd()  
d <- read.table('suic.txt', header=T)  
d
```

	sex	age	method	y
1	1	1	1	398
2	1	1	2	121
3	1	1	3	455
4	1	1	4	155
5	1	1	5	55
6	1	1	6	124
7	1	2	1	399
8	1	2	2	82
9	1	2	3	797
...				
30	2	2	6	60
31	2	3	1	154
32	2	3	2	5
33	2	3	3	185
34	2	3	4	7
35	2	3	5	38
36	2	3	6	10

Ejemplo 4.3 Tabla de contingencia múltiple (Suicidio)

```
d$sexf <- factor(d$sex)
d$agef <- factor(d$age)
d$methodf <- factor(d$method)

> Models:
> - M_full: Model with all main effects and all interactions
> - M_2way: Remove from M_full the 3-way interaction sex*age*method
> - M_sasm: Remove from M_2way the 2-way interaction age*method
> - M_saam: Remove from M_2way the 2-way interaction
> - M_smam: Remove from M_2way the 2-way interaction

M_full <- glm(y ~ sexf + agef + methodf + sexf*agef + sexf*methodf +
              agef*methodf + sexf*agef*methodf, family=poisson, data=d)
M_2way <- update(M_full, . ~. - sexf:agef:methodf)
M_sasm <- update(M_2way, . ~. - agef:methodf)
M_saam <- update(M_2way, . ~. - sexf:methodf)
M_smam <- update(M_2way, . ~. - sexf:agef)

Mlist <- list(M_full, M_2way, M_sasm, M_saam, M_smam)
Mnames <- c('Full ', '2-way interactions ', 'Drop age:method ', 'Drop sex:method ',
            'Drop sex:age ')
names(Mlist) <- Mnames

lapply(Mlist, summary)
```

Ejemplo 4.3 Tabla de contingencia múltiple (Suicidio)

> Create a `list` to keep the `deviance` statistic of `all` models
> and another one `for` the degrees of freedom

```
deviance <- lapply(Mlist, function(x) x$deviance)  
df <- lapply(Mlist, function(x) x$df.residual)
```

```
cbind(Deviance=(round(unlist(deviance),4)),  
      'Degrees of freedom'=unlist(df))
```

	Deviance	Degrees of freedom
Full	0.000	0
2-way interactions	2.854	1
Drop expulsed:injury	1680.412	2
Drop seatbelt:injury	1144.636	2
Drop seatbelt:expulsed	7133.978	

Como es de esperarse en el modelo saturado M_{full} , el estadístico de deviance y los grados de libertad tienen valor de 0.

Ejemplo 4.3 Tabla de contingencia múltiple (Suicidio)

Comparemos ahora M_{2way} vs. M_{full} para saber si es conveniente simplificar quitando la triple interacción.

- > Calculate the p-value of the difference in **deviance**
- > comparing a candidate **model** (**model** under H0) vs.
- > a reference **model** (more **complete** and under H1)

```
f.pvals <- function(M_h1, M_h0){  
  pval <- 1-pchisq( deviance [[M_h0]]-deviance [[M_h1]] ,  
                  df [[M_h0]]-df [[M_h1]] )  
  return(pval)}
```

- > Compare M_{2away} vs. M_{full} to **find** out **if** the 3-way **interaction**
- > **is** relevant **for** these **data**.

```
f.pvals(1,2)  
[1] 0.1357257
```

Al quitar la triple interacción vemos una pequeña disminución (no-significativa) en la calidad del ajuste $p\text{-value} = 0.14$.

Ejemplo 4.3 Tabla de contingencia múltiple (Suicidio)

Para saber si las interacciones dobles son relevantes tomamos ahora como referencia el modelo más completo, i.e. el modelo con todas las interacciones dobles $M_{2\text{way}}$, y lo comparamos contra cada uno de los modelos que quita una interacción doble. El sistema de hipótesis es del tipo:

H_0 : El modelo simple es apropiado

vs. H_0 : $M_{2\text{way}}$ es apropiado

Los p -value siguientes muestran no hay mayor simplificación posible del modelo, i.e. quitando cualquier interacción doble disminuye significativamente la calidad del ajuste del modelo.

```
f.pvals(2,3)
[1] 0
```

```
f.pvals(2,4)
[1] 0
```

```
f.pvals(2,5)
[1] 0
```

Ejemplo 4.3 Tabla de contingencia múltiple (Suicidio)

Finalmente, en la Figura 21 graficamos los valores ajustados contra los residuales de la deviance para complementar el análisis.

> Creating **deviance residuals** for 2-way interactions models


```
fv <- lapply(Mlist, function(x) x$fitted.values)
rd <- lapply(Mlist, function(x) residuals.glm(x, type='deviance'))

par(mfrow=c(2,2), las=1)
lapply(2:length(Mlist), function(x){
  plot(fv[[x]], rd[[x]], main='Deviance residuals vs. Fitted values',
       ylim=c(-7,7))
  abline(h=-2, lty=2)
  abline(h=2, lty=2)
})
```


> Plot **fitted** values against **residuals**

```
> par(mfrow=c(2,2), las=1)
lapply(2:length(Mlist), function(x){
  plot(fv[[x]], rd[[x]], main='Deviance residuals vs. Fitted values',
       ylim=c(-7,7), las=1)
  abline(h=-2, lty=2, col=2)
  abline(h=2, lty=2, col=2)
})
```


Ejemplo 4.3 Tabla de contingencia múltiple (Suicidio)




(a) M_{2way}



(b) M_{sasm}



(c) M_{sam}



(d) M_{sam}

Ejemplo 4.3 Tabla de contingencia múltiple (Suicidio)

Resumimos los análisis y hallazgos en la tabla siguiente,

Modelo	Forma	Deviance	df	p -value	Modelo bajo H_1
M_{full}	(UVW)	0	0	NA	NA
M_{2way}	(UV, UW, VW)	14.9	10	0.14	M_{full}
M_{sasm}	(UV, UW)	293.2	20	< 0.001	M_{2way}
M_{saam}	(UV, VW)	389.0	15	< 0.001	M_{2way}
M_{smam}	(UW, VW)	154.7	12	< 0.001	M_{2way}

Concluimos que el modelo M_{2way} es apropiado y, por lo tanto, que todos los pares de variables son condicionalmente independientes. Esto es, todas las variables están asociadas en pares, pero el grado de asociación no depende del nivel que tome la tercera variable.



Ejemplo 4.4 Tabla de contingencia múltiple (Cinturón)

Consideremos ahora el caso especial de una tabla de contingencia de $2 \times 2 \times 2$, i.e. tres variables con dos niveles cada una.

Analizaremos los datos del Florida Department of Highway Safety Motor vehicles, resumidos en la Tabla 25 y que se refieren a accidentes automovilísticos.

Las variables se refieren a si los conductores usaban cinturón de seguridad, si la víctima fue expulsada del vehículo y si las lesiones fueron fatales o no.

Ejemplo 4.4 Tabla de contingencia múltiple (Cinturón)

Cinturón (U)	Expulsada (V)	Lesión (W)	
		No-fatal	Fatal
$u_1 = \text{No-usado}$	$v_1 = \text{No}$	$y_{111} = 157,342$	$y_{112} = 1,008$
$u_1 = \text{No-usado}$	$v_2 = \text{Sí}$	$y_{121} = 4,624$	$y_{122} = 497$
$u_2 = \text{Usado}$	$v_1 = \text{No}$	$y_{211} = 411,111$	$y_{212} = 483$
$u_2 = \text{Usado}$	$v_2 = \text{Sí}$	$y_{221} = 1,105$	$y_{222} = 14$

Table 25: Resumen de las variables de accidentes vehiculares.

En la tabla también hemos incluido la notación general para el modelo, donde $Y_{ijk} \sim \text{Poisson}(\mu_{ijk})$, $i = 1, \dots, I$, $j = 1, \dots, J$, $k = 1, \dots, K$. El modelo saturado es

$$M_{\text{full}} : \log \mu_{ijk} = a + u_i + v_j + w_k + (uv)_{ij} + (uw)_{ik} + (vw)_{jk} + (uvw)_{ijk}$$

Investigaremos si es posible un modelo más simple que ajuste a los datos correctamente y sea más fácil de interpretar.

Ejemplo 4.4 Tabla de contingencia múltiple (Cinturón)

En estos datos solo $y...$ está fija por lo que solo el intercepto es necesario para el modelo.

La estrategia es la misma que en el Ejemplo 4.3, comenzamos con el modelo saturado y tratamos de simplificarlo probando la triple interacción y luego una interacción doble a la vez:

M_{2way} : Remove from M_{full} seatbelt*expulsed*injury

$$\log \mu_{ijk} = a + u_i + v_j + w_k + (uv)_{ij} + (uw)_{ik} + (vw)_{jk}$$

M_{sesi} : Remove from M_{2way} expulsed*injury

$$\log \mu_{ijk} = a + u_i + v_j + w_k + (uv)_{ij} + (uw)_{ik}$$

M_{seei} : Remove from M_{2way} seatbelt*injury

$$\log \mu_{ijk} = a + u_i + v_j + w_k + (uv)_{ij} + (vw)_{jk}$$

M_{siei} : Remove from M_{2way} seatbelt*expulsed

$$\log \mu_{ijk} = a + u_i + v_j + w_k + (uw)_{ik} + (vw)_{jk}$$

Ejemplo 4.4 Tabla de contingencia múltiple (Cinturón)

```
setwd(datwd); getwd()  
d <- read.table('seat.txt', header=T)  
d
```

	seat	eject	injury	y
1	1	1	1	157342
2	1	1	2	1008
3	1	2	1	4624
4	1	2	2	497
5	2	1	1	411111
6	2	1	2	483
7	2	2	1	1105
8	2	2	2	14

> Create **factor** variables

```
d$s <- factor(d$seat)  
d$e <- factor(d$eject)  
d$i <- factor(d$injury)
```

Ejemplo 4.4 Tabla de contingencia múltiple (Cinturón)

```
> Models:
>   - M_full: Model with all main effects and all interactions
>   - M_2way: Remove from M_full the interaction s*e*i
>   - M_sesi: Remove from M_2way the interaction e*i
>   - M_seei: Remove from M_2way the interaction s*i
>   - M_siei: Remove from M_2way the interaction s*e
```

```
M_full <- glm(y ~ s*e*i , family=poisson , data=d)
```

```
M_2way <- update(M_full , . ~ . - s:e:i)
```

```
M_sesi <- update(M_2way , . ~ . - e:i)
```

```
M_seei <- update(M_2way , . ~ . - s:i)
```

```
M_siei <- update(M_2way , . ~ . - s:e)
```

```
Mlist <- list(M_full , M_2way , M_sesi , M_seei , M_siei)
```

```
Mnames <- c('Full' , '2-way interactions' , 'Drop expulsed:injury' ,  
            'Drop seatbelt:injury' , 'Drop seatbelt:expulsed')
```

```
names(Mlist) <- Mnames
```

```
lapply(Mlist , summary)
```

Ejemplo 4.4 Tabla de contingencia múltiple (Cinturón)

> Create a `list` to keep the `deviance` statistic of `all` models
> and another one `for` the degrees of freedom

```
deviance <- lapply(Mlist, function(x) x$deviance)  
df <- lapply(Mlist, function(x) x$df.residual)
```

```
cbind(Deviance=(round(unlist(deviance),4)),  
      'Degrees of freedom'=unlist(df))
```

	Deviance	Degrees of freedom
Full	0.0000	0
2-way interactions	14.9007	10
Drop age:method	293.1775	20
Drop sex:method	388.9973	15
Drop sex:age	154.7015	12

Como es de esperarse en el modelo saturado M_{full} , el estadístico de deviance y los grados de libertad tienen valor de 0.

Ejemplo 4.4 Tabla de contingencia múltiple (Cinturón)

Comparemos ahora M_{2way} contra M_{full} para saber si el modelo sin la triple interacción es apropiado.

```
> Calculate the p-value of the difference in deviance  
> comparing a candidate model (model under H0) vs.  
> a reference model (more complete and under H1)
```

```
f.pvals <- function(M_h1, M_h0){  
  pval <- 1-pchisq( deviance [[M_h0]]-deviance [[M_h1]] ,  
                  df [[M_h0]]-df [[M_h1]] )  
  return(pval)}
```

```
> Compare M_2away vs. M_full to find out if the 3-way interaction  
> is relevant for these data.
```

```
f.pvals(1,2)  
[1] 0.1357257
```

Al quitar la triple interacción vemos una pequeña disminución (no-significativa) en la calidad del ajuste $p\text{-value} = 0.14$.

Ejemplo 4.4 Tabla de contingencia múltiple (Cinturón)

Para seguir investigando si las interacciones a pares son relevantes, tomamos ahora como referencia el modelo $M_{2\text{way}}$. El sistema de hipótesis es del tipo:

H_0 : El modelo simple es apropiado

vs. H_0 : $M_{2\text{way}}$ es apropiado

Los p -value siguientes muestran que no hay mayor simplificación posible del modelo, i.e. quitando cualquier interacción doble disminuye significativamente la calidad del ajuste.

```
f.pvals(2,3)
[1] 0
```

```
f.pvals(2,4)
[1] 0
```

```
f.pvals(2,5)
[1] 0
```

Ejemplo 4.4 Tabla de contingencia múltiple (Cinturón)


Finalmente, graficamos los valores ajustados contra los residuales de la deviance para complementar el análisis.

> Creating `deviance residuals` for 2-way interactions models


```
fv <- lapply(Mlist, function(x) x$fitted.values)
rd <- lapply(Mlist, function(x) residuals.glm(x, type='deviance'))

par(mfrow=c(2,2), las=1)
lapply(2:length(Mlist), function(x){
  plot(fv[[x]], rd[[x]],
       main='Deviance residuals vs. Fitted values',
       ylim=c(-7,7))
  abline(h=-2, lty=2)
  abline(h=2, lty=2)
})
```


Ejemplo 4.4 Tabla de contingencia múltiple (Cinturón)




(a) M_{2way}



(b) M_{sesi}



(c) M_{seei}



(d) M_{siei}

Ejemplo 4.4 Tabla de contingencia múltiple (Cinturón)

Resumimos los análisis y hallazgos en la tabla siguiente,

Modelo	Forma	Deviance	df	p-value	Modelo bajo H_1
M_{full}	(UVW)	0	0	NA	NA
M_{2way}	(UV, UW, VW)	2.9	2	0.09	M_{full}
M_{sesi}	(UV, UW)	1680.4	2	< 0.001	M_{2way}
M_{seei}	(UV, VW)	1144.6	2	< 0.001	M_{2way}
M_{siei}	(UW, VW)	7134.0	2	< 0.001	M_{2way}

Concluimos que el modelo M_{2way} (UV, UW, VW) es el más apropiado y, por lo tanto, que todos los pares de variables son condicionalmente independientes. Esto es, todas las variables están asociadas en pares, pero el grado de asociación no depende del nivel que tome la tercera variable. Mostramos el output de R para este modelo.

```
> Display the output of M_2way
```

```
summary(M_2way)
```


Ejemplo 4.4 Tabla de contingencia múltiple (Cinturón)

Call:

```
glm(formula = y ~ s + e + i + s:e + s:i + e:i,  
     family = poisson, data = d)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)	
(Intercept)	11.966133	0.002521	4746.70	<2e-16	***
s2	0.960502	0.002964	324.03	<2e-16	***
e2	-3.525634	0.014879	-236.95	<2e-16	***
i2	-5.043620	0.031202	-161.65	<2e-16	***
s2:e2	-2.399636	0.033340	-71.97	<2e-16	***
s2:i2	-1.717321	0.054015	-31.79	<2e-16	***
e2:i2	2.797795	0.055256	50.63	<2e-16	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for poisson family taken to be 1)

Null deviance: 1.6249e+06 on 7 degrees of freedom
Residual deviance: 2.8540e+00 on 1 degrees of freedom
AIC: 93.853

Number of Fisher Scoring iterations: 3

Ejemplo 4.4 Tabla de contingencia múltiple (Cinturón)

Buscando una interpretación más sencilla para las asociaciones, considere la siguientes tablas.

Ejemplo 4.4 Tabla de contingencia múltiple (Cinturón)

Cinturón (U)	Expulsada (V)	Lesión (W)	
		No-fatal	Fatal
$u_1 = \text{No-usado}$	$v_1 = \text{No}$	$\hat{\mu}_{111} = 157,335.1$	$\hat{\mu}_{112} = 1,014.9$
$u_1 = \text{No-usado}$	$v_2 = \text{Sí}$	$\hat{\mu}_{121} = 4,630.9$	$\hat{\mu}_{122} = 490.1$
$u_2 = \text{Usado}$	$v_1 = \text{No}$	$\hat{\mu}_{211} = 411,117.9$	$\hat{\mu}_{212} = 476.1$
$u_2 = \text{Usado}$	$v_2 = \text{Sí}$	$\hat{\mu}_{221} = 1,098.1$	$\hat{\mu}_{222} = 20.9$

Table 26: Fitted values.

Cinturón (U)	Expulsada (V)	Lesión (W)			
		Observados		Estimados	
		No-fatal	Fatal	No-fatal	Fatal
		π_{ij1}	π_{ij2}	$\hat{\pi}_{ij1}$	$\hat{\pi}_{ij2}$
$u_1 = \text{No-usado}$	$v_1 = \text{No}$	99.36	0.64	99.36	0.64
$u_1 = \text{No-usado}$	$v_2 = \text{Sí}$	90.43	9.57	90.43	9.57
$u_2 = \text{Usado}$	$v_1 = \text{No}$	99.88	0.12	99.88	0.12
$u_2 = \text{Usado}$	$v_2 = \text{Sí}$	98.14	1.86	98.14	1.86

Table 27: Observed (π_{ijk}) and expected proportions ($\hat{\pi}_{ijk}$).

Ejemplo 4.4 Tabla de contingencia múltiple (Cinturón)

Notemos que podemos interpretar $\log(\mu_{112}/\mu_{111})$ como log-momios dado que

$$\frac{\mu_{112}}{\mu_{111}} = \frac{\mu_{112}/\mu_{11\cdot}}{\mu_{111}/\mu_{11\cdot}} = \frac{\pi_{112}}{\pi_{111}} = \frac{\pi_{112}}{1 - \pi_{112}}$$

Comparando estas dos observaciones tenemos

$$\begin{aligned}\log \mu_{112} &= a + u_1 + v_1 + w_2 + (uv)_{11} + (uw)_{12} + (vw)_{12} \\ &= a + w_2\end{aligned}$$

$$\begin{aligned}\log \mu_{111} &= a + u_1 + v_1 + w_1 + (uv)_{11} + (uw)_{11} + (vw)_{11} \\ &= a\end{aligned}$$

$$\log \mu_{112} - \log \mu_{111} = \log \left(\frac{\pi_{112}}{\pi_{111}} \right) = w_2.$$

Por lo tanto, w_2 representa log-momios de un accidente fatal en el primer renglón de la Tabla 27, i.e. entre quienes no usan cinturón de seguridad y que no fueron expulsados del vehículo.

Ejemplo 4.4 Tabla de contingencia múltiple (Cinturón)

En el segundo renglón tenemos

$$\begin{aligned}\log \mu_{122} &= a + u_1 + v_2 + w_2 + (uv)_{12} + (uw)_{12} + (vw)_{22} \\ &= a + v_2 + w_2 + (vw)_{22}\end{aligned}$$

$$\begin{aligned}\log \mu_{121} &= a + u_1 + v_2 + w_1 + (uv)_{12} + (uw)_{11} + (vw)_{21} \\ &= a + v_2\end{aligned}$$

$$\log \mu_{122} - \log \mu_{121} = \log \left(\frac{\pi_{122}}{\pi_{121}} \right) = w_2 + (vw)_{22}.$$

Por lo tanto, $w_2 + (vw)_{22}$ representa log-momios de fatalidad entre quienes no usan cinturón de seguridad y fueron expulsados.

Ejemplo 4.4 Tabla de contingencia múltiple (Cinturón)

Esto implica que

$$\begin{aligned}\log\left(\frac{\mu_{122}}{\mu_{121}}\right) - \log\left(\frac{\mu_{112}}{\mu_{111}}\right) &= \log\left(\frac{\pi_{122}/\pi_{121}}{\pi_{112}/\pi_{111}}\right) \\ &= \log\left(\frac{\pi_{122}/(1 - \pi_{122})}{\pi_{112}/(1 - \pi_{112})}\right) = (vw)_{22}\end{aligned}$$

es una log-razón de momios! Específicamente es el log-razón de momios (log-riesgo relativo) de un accidente fatal para aquellos expulsados respecto de los no-expulsados y que no usan cinturón de seguridad.

Los mismos cálculos para la mitad de abajo de la tabla revelan que también se trata de una razón de momios representando el cambio en el riesgo de un accidente fatal para aquellos expulsados del vehículo y que sí usan el cinturón de seguridad.

[¡verifíquelo!]

Ejemplo 4.4 Tabla de contingencia múltiple (Cinturón)

Supongamos que el término de interacción de las tres variables hubiera terminado en el modelo final. En este caso tendríamos

$$\log \mu_{222} = a + u_2 + v_2 + w_2 + (uv)_{22} + (uw)_{22} + (vw)_{22} + (uvw)_{222}$$

$$\log \mu_{221} = a + u_2 + v_2 + w_1 + (uv)_{22} + (uw)_{21} + (vw)_{21} + (uvw)_{221}$$

$$\log \mu_{222} - \log \mu_{221} = \log \left(\frac{\pi_{222}}{\pi_{221}} \right) = w_2 + (uw)_{22} + (vw)_{22} + (uvw)_{222}$$

y

$$\log \mu_{212} = a + u_2 + v_1 + w_2 + (uv)_{21} + (uw)_{22} + (vw)_{12} + (uvw)_{212}$$

$$\log \mu_{211} = a + u_2 + v_1 + w_1 + (uv)_{21} + (uw)_{21} + (vw)_{11} + (uvw)_{211}$$

$$\log \mu_{212} - \log \mu_{211} = \log \left(\frac{\pi_{212}}{\pi_{211}} \right) = w_2 + (uw)_{22}$$

Ejemplo 4.4 Tabla de contingencia múltiple (Cinturón)

el logaritmo de la razón de momios sería

$$\begin{aligned}\log \left(\frac{\mu_{222}}{\mu_{221}} \right) - \log \left(\frac{\mu_{212}}{\mu_{211}} \right) &= \log \left(\frac{\pi_{222}/\pi_{221}}{\pi_{212}/\pi_{211}} \right) \\ &= \log \left(\frac{\pi_{222}/(1 - \pi_{222})}{\pi_{212}/(1 - \pi_{212})} \right) \\ &= (vw)_{22} + (uvw)_{222}\end{aligned}$$

Esto es, $(uvw)_{ijk}$ desempeña el papel de un término de interacción permitiendo que el efecto de una variable sobre otra varíe con el nivel de una tercera variable.



Datos sobredispersos

Uno de los supuestos que hemos mantenido hasta ahora es el de respuestas independientes. Hay situaciones en las que este supuesto no es plausible,

- La respuesta se refiere a mediciones repetidas (o eventos recurrentes si la respuesta no es continua) en el mismo individuo a lo largo del tiempo (*datos longitudinales*). Mediciones en el mismo individuo tienden a ser más parecidas que mediciones entre distintos individuos (datos multinivel o jerárquicos).

- La población de donde se selecciona la muestra de los datos disponibles está formada por clusters (subgrupos) que asu vez están definidos por individuos con características comunes.

Las mediciones en un mismo individuo o entre individuos de un mismo cluster tienden a estar fuertemente correlacionadas.

Esta correlación tiene implicaciones en la varianza y, en consecuencia, en los errores estándar de los coeficientes estimados por lo que las inferencias dejan de ser válidas.

Es necesario, entonces, adaptar la metodología vista hasta el momento de forma que modelen tanto la media como la estructura de correlación de los datos.

Datos dependientes, distribución normal

Sea Y_{ij} la respuesta del j -ésimo individuo del i -ésimo cluster.

Supongamos una variable aleatoria a nivel de cluster con distribución normal con media cero y varianza constante $u_i \stackrel{\text{iid}}{\sim} \mathcal{N}(0, \phi)$ y un término de error a nivel de individuo, aleatorio con distribución normal, con media cero y con varianza constante $e_{ij} \stackrel{\text{iid}}{\sim} \mathcal{N}(0, \sigma^2)$ con $u_i \perp e_{ij}$.

Dados u_i y e_{ij} , la respuesta puede expresarse como

$$Y_{ij} \mid u_i, e_{ij} = \mu + u_i + e_{ij}, \quad j = 1, 2, \dots, n_i, \quad i = 1, 2, \dots, n$$

$$u_i \stackrel{\text{iid}}{\sim} \mathcal{N}(0, \phi) \rightarrow \text{modela la variabilidad a nivel de cluster}$$

$$e_{ij} \stackrel{\text{iid}}{\sim} \mathcal{N}(0, \sigma^2) \rightarrow \text{modela la variabilidad intra-cluster}$$

donde μ es la media poblacional.

u_i se conoce como *factor aleatorio* o *efecto aleatorio*.

Supongamos que la densidad de u_i es $g(u_i; \phi)$. Entonces, la probabilidad incondicional (marginal) de las respuestas del i -ésimo cluster está dada por

$$\begin{aligned} & \Pr(Y_{i1}, \dots, Y_{in_i} = y_{i1}, \dots, y_{in_i}) \\ &= \int_{\mathbb{R}} \Pr(Y_{i1}, \dots, Y_{in_i} = y_{i1}, \dots, y_{in_i}, u_i) du_i \\ &= \int_{\mathbb{R}} f(\mathbf{y}_i \mid u_i) g(u_i; \phi) du_i \\ &= \int_{\mathbb{R}} \prod_{j=1}^{n_i} \Pr(Y_{ij} = y_{ij} \mid u_i) g(u_i; \phi) du_i \end{aligned}$$

La función de verosimilitud con n individuos tiene la forma de una normal multivariada $\mathcal{N}_{n_i}(\boldsymbol{\mu}, \Sigma)$, donde los elementos de la matriz de varianza Σ están dados por

Datos dependientes, distribución normal

$$\begin{aligned}\text{var}(Y_{ij}) &= \text{var}\{\mathbb{E}(Y_{ij} \mid u_i)\} + \mathbb{E}\{\text{var}(Y_{ij} \mid u_i)\} \\ &= \text{var}(\mu + u_i) + \mathbb{E}(\sigma^2) \\ &= \phi + \sigma^2,\end{aligned}$$

$$\begin{aligned}\text{cov}(Y_{ij}, Y_{ik}) &= \text{cov}\{\mathbb{E}(Y_{ij} \mid u_i), \mathbb{E}(Y_{ik} \mid u_i)\} + \mathbb{E}\{\text{cov}(Y_{ij}, Y_{ik} \mid u_i)\} \\ &= \text{cov}(\mu + u_i, \mu + u_i) + 0 \\ &= \phi,\end{aligned}$$

$$\Rightarrow \Sigma = \begin{bmatrix} \phi + \sigma^2 & \phi & \dots & \phi \\ \phi & \phi + \sigma^2 & \dots & \phi \\ \vdots & \vdots & \ddots & \vdots \\ \phi & \phi & \dots & \phi + \sigma^2 \end{bmatrix},$$

$$\Rightarrow \text{cor}(Y_{ij}, Y_{ik}) = \frac{\phi}{\phi + \sigma^2} \rightarrow \text{coeficiente de correlación intraclase.}$$

Se sigue que:

- $\mathbb{E}(Y_{ij} \mid u_i) = \mu + u_i$: Media del i -ésimo cluster.
- $\mathbb{E}(Y_{ij}) = \mu$: Media de la población.
- $\text{var}(u_i) = \phi$: Caracteriza cómo difieren las medias entre distintos clusters.
- $\phi = 0$: Implica observaciones independientes al interior de los clusters.
- $\frac{\phi/\sigma^2}{1 + \phi/\sigma^2}$: La variación relativa entre- e intra-cluster es lo que determina la correlación.



Extra variación binomial

Como vimos en §2.3.3 (??), si $V \sim \text{Bin}(n, \pi)$ entonces su función de probabilidad es

$$f(v; \pi) = \binom{n}{v} \pi^v (1 - \pi)^{n-v}; \quad v = 0, 1, 2, \dots, n.$$

Sea $Y = V/n$, entonces

$$f(y; \pi) = \binom{n}{ny} \pi^{ny} (1 - \pi)^{n-ny}, \quad y = 0, \frac{1}{n}, \frac{2}{n}, \dots, 1.$$

Para una observación,

$$\begin{aligned} f(y; \pi) &= \exp \left\{ ny \log \pi + (n - ny) \log(1 - \pi) + \log \binom{n}{ny} \right\} \\ &= \exp \left\{ \frac{y \log \{\pi / (1 - \pi)\} + n \log(1 - \pi)}{n^{-1}} + \log \binom{n}{ny} \right\}. \end{aligned}$$

Extra variación binomial

Comparando esta expresión con la forma general de la familia exponencial

$$f(y_i; \theta_i, \phi) = \exp \left\{ \frac{y_i \theta_i - b(\theta_i)}{a_i(\phi)} + c(y_i; \phi) \right\}$$

tenemos,

$$\theta = \log \left(\frac{\pi}{1 - \pi} \right)$$

$$\phi = 1; w = n$$

$$a(\phi) = \frac{\phi}{w} = \frac{1}{n}$$

$$b(\theta) = \log(1 + \exp\{\theta\}) = -\log(1 - \pi)$$

$$c(y; \phi) = \log \binom{n}{ny}$$

$$\text{media : } b'(\theta) = \frac{e^\theta}{1 + e^\theta} = \mu = \pi$$

$$\begin{aligned}\text{función de varianza : } V(\mu) = b''(\theta) &= \left(\frac{e^\theta}{1 + e^\theta} \right) \left(\frac{1}{1 + e^\theta} \right) \\ &= \mu(1 - \mu) \\ &= \pi(1 - \pi)\end{aligned}$$

$$\begin{aligned}\text{varianza : } \text{var}(Y) = b''(\theta)a(\phi) &= \left(\frac{e^\theta}{1 + e^\theta} \right) \left(\frac{1}{1 + e^\theta} \right) \left(\frac{1}{n} \right) \\ &= \mu(1 - \mu) \left(\frac{1}{n} \right) \\ &= \pi(1 - \pi) \left(\frac{1}{n} \right)\end{aligned}$$

Por lo tanto, cuando la distribución binomial es exacta, la varianza de Y está determinada por su media dada por

$$\begin{aligned}\text{var}(Y) &= b''(\theta)a(\phi) = \left(\frac{e^\theta}{1+e^\theta}\right) \left(\frac{1}{1+e^\theta}\right) \left(\frac{1}{n}\right) \\ &= \mu(1-\mu) \left(\frac{1}{n}\right) \\ &= \pi(1-\pi) \left(\frac{1}{n}\right).\end{aligned}$$

Sin embargo, cuando la relación media-varianza no se satisface exactamente y la variación es mayor que la esperada en el modelo binomial, se dice hay *extra variación binomial*.

Extra variación binomial

En §13 estudiamos el algoritmo Fisher-scoring. La forma general de la función log-verosimilitud para la familia exponencial es

$$\ell(\theta, \phi; y) \propto \log f(y; \theta, \phi) = \frac{y\theta - b(\theta)}{a(\phi)} + c(y; \phi).$$

Podemos escribir la función de puntuación para β_j como

$$\frac{\partial \ell}{\partial \beta_j} = \left(\frac{y - \mu}{a(\phi)} \right) \left(W^* \cdot \frac{\partial \eta}{\partial \mu} \cdot x_j \right)$$

donde

$$\mu = b'(\theta),$$

$$V = b''(\theta) \text{ y}$$

$$W^* = \frac{1}{V} \left(\frac{\partial \mu}{\partial \eta} \right)^2$$

Nótese que en este caso la definición del peso W^* difiere de $W = \frac{1}{\text{var}(Y)} \left(\frac{\partial \mu}{\partial \eta} \right)^2$ (definido en el material adicional [(??)] §[(??)]). Señalamos entonces que, asumiendo $a(\pi) = \phi/w$ y ϕ constante, podemos factorizar este término. En el caso de la distribución binomial $a(\phi) = 1/n$ y obtenemos la ecuación

$$\frac{\partial \ell}{\partial \beta_j} = \left(\frac{y - \mu}{1/n} \right) \left(W^* \cdot \frac{\partial \eta}{\partial \mu} \cdot x_j \right) = (y - \mu) W \left(\frac{\partial \eta}{\partial \mu} \right) x_j, \quad (97)$$

donde $W = nW^*$.

En una muestra de n observaciones tenemos

$$S_j(\boldsymbol{\theta}) = \sum_{i=1}^n (y_i - \mu_i) W_i \left(\frac{\partial \eta_i}{\partial \mu_i} \right) x_{ij}$$

$$I_{jk} = -\frac{\partial^2 \ell}{\partial \beta_j \partial \beta_k} = -(y - \mu) \frac{\partial}{\partial \beta_k} \left\{ W \left(\frac{\partial \eta}{\partial \mu} \right) x_j \right\} + x_j W x_k.$$

$$\mathcal{I}_{jk} = \sum_{i=1}^n x_{ij} W_i x_{ik} = (X^\top \mathcal{W} X)_{jk},$$

donde $\mathcal{W} = \text{diag}(W_1, \dots, W_n)$ es una matriz diagonal con entradas $W_1, \dots, W_n$.

Extra variación binomial

Supongamos que estamos interesados en tomar en cuenta extra variación binomial (la cual es fundamental para inferencias válidas). Podemos considerar un modelo más general definiendo

$$a(\phi) = \frac{\phi}{n} = \frac{\sigma^2}{n} \quad (98)$$

en lugar de $a(\phi) = 1/n$. Entonces la función log-verosimilitud para la distribución binomial es

$$\begin{aligned} \ell(\theta, \phi; y) &= \frac{y\theta - b(\theta)}{a(\phi)} + c(y; \phi) \\ &= \frac{y\theta - b(\theta)}{\sigma^2/n} + c(y; \sigma^2) \\ &= \frac{y \log\{\pi/(1 - \pi)\} + n \log(1 - \pi)}{\sigma^2/n} + \log \binom{n}{ny}. \end{aligned} \quad (99)$$

Entonces

$$\theta = \log \left(\frac{\pi}{1 - \pi} \right)$$

$$\phi = \sigma^2; w = n$$

$$a(\phi) = \frac{\sigma^2}{n}$$

$$b(\theta) = -\log(1 - \pi)$$

$$c(y; \sigma^2) = \log \binom{n}{ny}$$

La media y la función de varianza están dadas como antes por π y $\pi(1 - \pi)$, respectivamente, pero ahora la varianza $\text{var}(Y)$ es rescalada por σ^2 .

Extra variación binomial

Esto es,

$$\begin{aligned}b'(\theta) &= \frac{e^\theta}{1 + e^\theta} = \mu = \pi \\V(\mu) = b''(\theta) &= \left(\frac{e^\theta}{1 + e^\theta} \right) \left(\frac{1}{1 + e^\theta} \right) \\&= \mu(1 - \mu) = \pi(1 - \pi) \\ \text{var}(Y) = b''(\theta)a(\phi) &= \left(\frac{e^\theta}{1 + e^\theta} \right) \left(\frac{1}{1 + e^\theta} \right) \left(\frac{\sigma^2}{n} \right) \\&= \mu(1 - \mu) \left(\frac{\sigma^2}{n} \right) = \pi(1 - \pi) \left(\frac{\sigma^2}{n} \right)\end{aligned}$$

El término σ^2 no entra a la ecuación para estimar β pues el término es constante para todas las observaciones y, por lo tanto, no interfiere en la estimación de β . Sin embargo, afecta el grado de precisión con el que β es estimado.

Estimación de σ^2 para cualquier GLM

Para aplicaciones más generales que involucran a la familia exponencial tenemos la densidad

$$f(y_i; \theta_i, \phi) = \exp \left\{ \frac{y_i \theta_i - b(\theta_i)}{a_i(\phi)} + c(y_i; \phi) \right\}$$

donde $a_i(\phi) = \phi/w_i$. La función log-verosimilitud para la i -ésima observación es entonces

$$\ell_i(\theta_i, \phi) = w_i \left(\frac{y_i \theta_i - b(\theta_i)}{\phi} \right) + c(y_i; \phi)$$

y para una muestra de n individuos

$$\ell(\boldsymbol{\theta}, \phi) = \sum_{i=1}^n \ell_i(\theta_i, \phi).$$

Estimación de σ^2 para cualquier GLM

El estadístico de razón de verosimilitud para someter a prueba el modelo restringido (donde el MLE es $\hat{\theta}_i$ contra el modelo sin restricciones (donde el MLE es $\tilde{\theta}_i$) es

$$\begin{aligned} D^* &= 2 \left\{ \ell(\tilde{\theta}, \phi) - \ell(\hat{\theta}, \phi) \right\} \\ &= 2 \sum_{i=1}^n \frac{w_i}{\phi} \left\{ y_i(\tilde{\theta}_i - \hat{\theta}_i) - \left[b(\tilde{\theta}_i) - b(\hat{\theta}_i) \right] \right\} \\ &= \frac{D}{\phi} \sim \chi_{q-p}^2, \end{aligned} \tag{100}$$

donde D^* (la deviance escalada) tiene una distribución asintótica χ_{q-p}^2 bajo H_0 , q y p son el número de parámetros funcionalmente independientes de los modelos bajo la hipótesis alternativa y nula, respectivamente. Asimismo, D (la deviance) tiene una distribución asintótica $\phi \chi_{q-p}^2$ bajo H_0 .

Estimación de σ^2 para cualquier GLM

Podemos usar ya sea D^* o D para someter a prueba modelos anidados donde uno de ellos no es necesariamente un modelo saturado.

Con el parámetro de escala adicional, IRWLS opera como en el modelo sin sobredispersión. Sin embargo, notemos que si ahora $\hat{\theta}$ es el MLE y $\mathcal{W}$ la matriz de ponderadores usual del modelo binomial (i.e. con $\phi = 1$), bajo este modelo más general la matriz de varianza de $\hat{\beta}$ es

$$\text{cov}(\hat{\beta}) \approx \phi(X^\top \mathcal{W} X)^{-1} = \sigma^2(X^\top \mathcal{W} X)^{-1} \quad (101)$$

en contraste con

$$\text{cov}(\hat{\beta}) = (X^\top \mathcal{W} X)^{-1}$$

del modelo sin sobredispersión.

Estimación de σ^2 para cualquier GLM

Por lo tanto, cuando introducimos el parámetro de dispersión la expresión de la matriz de varianza de los coeficientes de regresión (y en consecuencia sus errores estándar) deben ajustarse.

Típicamente en esta definición del modelo $\phi > 1$ y, entonces, los errores estándar ajustados son más grandes que los no-ajustados.

Deseamos estimar $\phi = \sigma^2$ de un modelo particular con p parámetros. Si p es un número pequeño respecto de n (el tamaño de muestra), entonces haciendo que la deviance escalada (D^*) sea igual que su valor esperado podemos obtener un estimador por el método de momentos para σ^2 dado por la razón de la deviance entre sus grados de libertad, i.e.

$$\tilde{\sigma}_M^2 = \frac{D}{n - p} \quad (102)$$

Estimación de σ^2 para cualquier GLM

Con base en la estadística de Pearson obtendríamos

$$\tilde{\sigma}^2 = \frac{1}{n-p} \sum_{i=1}^n \frac{(y_i - \hat{\mu}_i)^2}{\text{var}(Y_i)} = \frac{1}{n-p} \sum_{i=1}^n \frac{(y_i - \hat{\mu}_i)^2}{a(\phi)V(\hat{\mu}_i)} \quad (103)$$

como otro estimador de momentos para σ^2 .

Este tipo de valor estimado puede usarse para escalar los errores estándar que reporta R al ajustar un modelo en particular.

En el caso del modelo Poisson $a(\phi) = 1$ y $V(\hat{\mu}) = \hat{\mu}$, por lo que el estimador (103) está dado por

$$\tilde{\sigma}^2 = \frac{1}{n-p} \sum_{i=1}^n \frac{(y_i - \hat{\mu}_i)^2}{\hat{\mu}_i}$$

y nos indica el tamaño relativo de la varianza respecto de la media. Al escalar los errores estándar multiplicándolos por $\sqrt{\tilde{\sigma}^2}$ resulta en el modelo *quasi-Poisson* (ver Ejemplo 5.1).

Origen de la sobredispersión para respuestas binomiales

La variación binomial extra surge cuando hay clustering en la población y no se tomó en cuenta en la muestra analizada.

Cuando se selecciona una muestra de una población con clusters, los supuestos básicos de la distribución binomial son violados, i.e. respuestas binarias iid.

Supongamos que la población consiste en un cierto número clusters, cada uno de tamaño k y que n individuos son seleccionados de n/k clusters.

Sea $Y_{ij} = 1$ si el j -ésimo sujeto en el cluster i es una respuesta (i.e. un éxito) y $Y_{ij} = 0$ en otro caso.

Sea $Y_{i\cdot} = \sum_j Y_{ij}$ el número de respuestas en el i -ésimo cluster.

Origen de la sobredispersión para respuestas binomiales

Entonces $Y_i. \mid \pi_i \sim \text{Bin}(k, \pi_i)$ y el número total de respuestas es

$$Y = \sum_{i=1}^{n/k} Y_i.$$

Si $\mathbb{E}(\pi_i) = \pi$ y $\text{var}(\pi_i) = \rho\pi(1 - \pi)$, entonces

$$\begin{aligned}\mathbb{E}(Y) &= \mathbb{E} \left\{ \mathbb{E}(Y_{1.} + Y_{2.} + \dots + Y_{n/k.} \mid \pi_1, \dots, \pi_{n/k}) \right\} \\ &= \mathbb{E}(k\pi_1 + k\pi_2 + \dots + k\pi_{n/k}) \\ &= k \left(\frac{n}{k} \right) \pi \\ &= n\pi, \quad y\end{aligned}$$

Origen de la sobredispersión para respuestas binomiales

$$\begin{aligned}\text{var}(Y) &= \mathbb{E}\{\text{var}(Y_{1\cdot} + \dots + Y_{n/k\cdot} \mid \pi_1, \dots, \pi_{n/k})\} \\ &\quad + \text{var}\{\mathbb{E}(Y_{1\cdot} + \dots + Y_{n/k\cdot} \mid \pi_1, \dots, \pi_{n/k})\} \\ &= \mathbb{E}\left\{\sum_{i=1}^{n/k} k\pi_i(1 - \pi_i)\right\} + \text{var}\left(k \sum_{i=1}^{n/k} \pi_i\right) \\ &= k \sum_{i=1}^{n/k} \{\mathbb{E}(\pi_i) - \mathbb{E}(\pi_i^2)\} + k^2 \left(\frac{n}{k}\right) \rho\pi(1 - \pi) \\ &= k \sum_{i=1}^{n/k} \{\mathbb{E}(\pi_i) - [\text{var}(\pi_i) + \{\mathbb{E}(\pi_i)\}^2]\} + kn\rho\pi(1 - \pi) \\ &= k \left(\frac{n}{k}\right) \{\pi - \rho\pi(1 - \pi) - \pi^2\} + kn\rho\pi(1 - \pi) \\ &= n \{\pi(1 - \pi) - \rho\pi(1 - \pi)\} + kn\rho\pi(1 - \pi) \\ &= n\pi(1 - \pi)\{1 + (k - 1)\rho\} = n\pi(1 - \pi)\sigma^2.\end{aligned}$$

Origen de la sobredispersión para respuestas binomiales

En este caso, el parámetro de dispersión $\sigma^2 = 1 + (k - 1)\rho$ depende del tamaño de cluster (k) y la variabilidad entre clusters.

Esto sugiere que la manera usual de escalar los errores estándar por $\tilde{\sigma}^2$ es ineficiente.

Por lo tanto, consideramos **modelos de efectos aleatorios** que modelen la variación entre clusters como lo haremos en §5.

Modelando extra variación binomial con la distribución beta

Una manera tomar en cuenta posible extra variación binomial es introduciendo el supuestos respecto del parámetro π . Suponemos que π es una variable aleatoria que varía entre clusters y, por lo tanto, tiene una distribución paramétrica. Supongamos que $f(\pi_i)$ es la función de densidad de π_i .

La distribución condicional de Y_i dado π_i la denotamos por

$$\Pr(Y_i = y_i \mid \pi_i) = \binom{k_i}{y_i} \pi_i^{y_i} (1 - \pi_i)^{k_i - y_i}. \quad (104)$$

y la distribución incondicional (marginal) de Y_i es entonces

$$\begin{aligned} \Pr(Y_i = y_i) &= \int_{\mathbb{R}} f(y_i, \pi_i) d\pi_i = \int_{\mathbb{R}} f(y_i \mid \pi_i) g(\pi_i) d\pi_i \\ &= \int_0^1 \binom{k_i}{y_i} \pi_i^{y_i} (1 - \pi_i)^{k_i - y_i} g(\pi_i) d\pi_i \end{aligned} \quad (105)$$

donde $g(\pi_i)$ es la densidad de π_i .

Recordemos

$$\begin{aligned}\mathbb{E}(\pi_i) &= \int_0^1 \pi_i \frac{1}{B(\gamma_1, \gamma_2)} \pi_i^{\gamma_1-1} (1 - \pi_1)^{\gamma_2-1} d\pi_i \\&= \int_0^1 \frac{\Gamma(\gamma_1 + \gamma_2)}{\Gamma(\gamma_1)\Gamma(\gamma_2)} \pi_i^{(\gamma_1+1)-1} (1 - \pi_1)^{\gamma_2-1} d\pi_i \\&= \int_0^1 \frac{\gamma_1}{\gamma_1 + \gamma_2} \underbrace{\frac{\Gamma(\gamma_1 + 1 + \gamma_2)}{\Gamma(\gamma_1 + 1)\Gamma(\gamma_2)} \pi_i^{(\gamma_1+1)-1} (1 - \pi_1)^{\gamma_2-1} d\pi_i}_{\text{p.d.f. of Beta}(\gamma_1 + 1, \gamma_2) \text{ r.v.}} \\&= \frac{\gamma_1}{\gamma_1 + \gamma_2}.\end{aligned}$$

Recordemos también que $\text{var}(\pi_i) = \mathbb{E}(\pi_i^2) - \{\mathbb{E}(\pi_i)\}^2$.

$$\begin{aligned}\mathbb{E}\{\pi_i(1 - \pi_i)\} &= \int_0^1 \frac{\Gamma(\gamma_1 + \gamma_2)}{\Gamma(\gamma_1)\Gamma(\gamma_2)} \pi_i^{(\gamma_1+1)-1} (1 - \pi_i)^{(\gamma_2+1)-1} d\pi_i \\ &= \frac{\gamma_1 \gamma_2}{(\gamma_1 + \gamma_2 + 1)(\gamma_1 + \gamma_2)} \\ &\quad \underbrace{\int_0^1 \frac{\Gamma(\gamma_1 + 1 + \gamma_2 + 1)}{\Gamma(\gamma_1 + 1)\Gamma(\gamma_2 + 1)} \pi_i^{(\gamma_1+1)-1} (1 - \pi_i)^{(\gamma_2+1)-1} d\pi_i}_{\text{p.d.f. of Beta}(\gamma_1 + 1, \gamma_2 + 1) \text{ r.v.}} \\ &= \frac{\gamma_1 \gamma_2}{(\gamma_1 + \gamma_2)(\gamma_1 + \gamma_2 + 1)}\end{aligned}$$

Por lo tanto,

$$\begin{aligned}\mathbb{E}(\pi_i^2) &= \mathbb{E}(\pi_i) - \mathbb{E}\{\pi_i(1 - \pi_i)\} = \frac{\gamma_1}{\gamma_1 + \gamma_2} - \frac{\gamma_1\gamma_2}{(\gamma_1 + \gamma_2)(\gamma_1 + \gamma_2 + 1)} \\ &= \frac{\gamma_1}{\gamma_1 + \gamma_2} \frac{(\gamma_1 + \gamma_2 + 1)}{(\gamma_1 + \gamma_2 + 1)} - \frac{\gamma_1\gamma_2}{(\gamma_1 + \gamma_2)(\gamma_1 + \gamma_2 + 1)} \\ &= \frac{\gamma_1^2 + \gamma_1\gamma_2 + \gamma_1 - \gamma_1\gamma_2}{(\gamma_1 + \gamma_2)(\gamma_1 + \gamma_2 + 1)} \\ &= \frac{\gamma_1^2 + \gamma_1}{(\gamma_1 + \gamma_2)(\gamma_1 + \gamma_2 + 1)}\end{aligned}$$

y

$$\begin{aligned}\text{var}(\pi_i) &= \mathbb{E}(\pi_i^2) - \{\mathbb{E}(\pi_i)\}^2 = \frac{\gamma_1^2 + \gamma_1}{(\gamma_1 + \gamma_2)(\gamma_1 + \gamma_2 + 1)} - \frac{\gamma_1^2}{(\gamma_1 + \gamma_2)^2} \\&= \frac{(\gamma_1^2 + \gamma_1)(\gamma_1 + \gamma_2)}{(\gamma_1 + \gamma_2)^2(\gamma_1 + \gamma_2 + 1)} - \frac{\gamma_1^2(\gamma_1 + \gamma_2 + 1)}{(\gamma_1 + \gamma_2)^2(\gamma_1 + \gamma_2 + 1)} \\&= \frac{\gamma_1^2(\gamma_1 + \gamma_2) + \gamma_1^2 + \gamma_1\gamma_2 - \gamma_1^2(\gamma_1 + \gamma_2) - \gamma_1^2}{(\gamma_1 + \gamma_2)^2(\gamma_1 + \gamma_2 + 1)} \\&= \frac{\gamma_1}{(\gamma_1 + \gamma_2)} \frac{\gamma_2}{(\gamma_1 + \gamma_2)} \frac{1}{(\gamma_1 + \gamma_2 + 1)} \\&= \mu(1 - \mu) \frac{1}{(\gamma_1 + \gamma_2 + 1)} \\&= \pi(1 - \pi) \frac{1}{(\gamma_1 + \gamma_2 + 1)}\end{aligned}$$

donde $\mu = \frac{\gamma_1}{\gamma_1 + \gamma_2}$.

La distribución marginal de los conteos totales está dada por

$$\begin{aligned}\Pr(Y_{i\cdot} = y_{i\cdot}) &= \int_0^1 \binom{k_i}{y_{i\cdot}} \pi_i^{y_{i\cdot}} (1 - \pi_i)^{k_i - y_{i\cdot}} \frac{1}{B(\gamma_1, \gamma_2)} \pi_i^{\gamma_1 - 1} (1 - \pi_i)^{\gamma_2 - 1} d\pi_i \\ &= \binom{k_i}{y_{i\cdot}} \frac{1}{B(\gamma_1, \gamma_2)} \underbrace{\int_0^1 \pi_i^{y_{i\cdot} + \gamma_1 - 1} (1 - \pi_i)^{k_i - y_{i\cdot} + \gamma_2 - 1} d\pi_i}_{B(y_{i\cdot} + \gamma_1, k_i - y_{i\cdot} + \gamma_2)} \\ &= \binom{k_i}{y_{i\cdot}} \frac{B(y_{i\cdot} + \gamma_1, k_i - y_{i\cdot} + \gamma_2)}{B(\gamma_1, \gamma_2)}.\end{aligned}$$

A esta mixtura de densidades se le conoce como la distribución *beta-binomial*, la cual puede reescribirse como

$$\begin{aligned}\Pr(Y_{i\cdot} = y_{i\cdot}) &= \binom{k_i}{y_{i\cdot}} \frac{\Gamma(\gamma_1 + \gamma_2)}{\Gamma(\gamma_1)\Gamma(\gamma_2)} \cdot \frac{\Gamma(y_{i\cdot} + \gamma_1 k_i - y_{i\cdot} + \gamma_2)}{\Gamma(y_{i\cdot} + \gamma_1 + k_i - y_{i\cdot} + \gamma_2)} \\ &= \binom{k_i}{y_{i\cdot}} \frac{\Gamma(y_{i\cdot} + \gamma_1)}{\Gamma(\gamma_1)} \cdot \frac{\Gamma(k_i - y_{i\cdot} + \gamma_2)}{\Gamma(\gamma_2)} \cdot \frac{\Gamma(\gamma_1 + \gamma_2)}{\Gamma(k_i + \gamma_1 + \gamma_2)}.\end{aligned}$$

(106)

Modelando extra variación binomial con la distribución beta

Dado que $\frac{\Gamma(x+a)}{\Gamma(x)} = \prod_{r=0}^{a-1} (x+r)$, podemos expresar (106) como

$$\Pr(Y_{i\cdot} = y_{i\cdot}) = \binom{k_i}{y_{i\cdot}} \frac{\prod_{r=0}^{y_{i\cdot}-1} (\gamma_1 + r) \prod_{r=0}^{k_i-y_{i\cdot}-1} (\gamma_2 + r)}{\prod_{r=0}^{k_i-1} (\gamma_1 + \gamma_2 + r)}. \quad (107)$$

Puede demostrarse que el valor esperado y la varianza de la distribución marginal del total de conteos están dados por

$$\mathbb{E}(Y_{i\cdot}) = k_i \left(\frac{\gamma_1}{\gamma_1 + \gamma_2} \right) \quad (108a)$$

$$\text{var}(Y_{i\cdot}) = k_i \left(\frac{\gamma_1}{\gamma_1 + \gamma_2} \right) \left(\frac{\gamma_2}{\gamma_1 + \gamma_2} \right) \left(\frac{k_i + \gamma_1 + \gamma_2}{1 + \gamma_1 + \gamma_2} \right) \quad (108b)$$

Si $\pi = \frac{\gamma_1}{\gamma_1 + \gamma_2}$ y $\theta = \frac{1}{\gamma_1 + \gamma_2}$, podemos expresar (108a) y (108b) como

$$\mathbb{E}(Y_{i.}) = k_i \pi \quad (109a)$$

$$\text{var}(Y_{i.}) = k_i \pi (1 - \pi) \left(\frac{k_i \theta + 1}{\theta + 1} \right) \quad (109b)$$

Si $\theta \rightarrow 0$, la varianza tiene a la varianza binomial y significa que no es evidente la sobredispersión. Por lo tanto, es razonable someter a prueba el sistema de hipótesis

$$H_0 : \theta = 0$$

$$\text{vs. } H_1 : \theta \neq 0.$$

Un estadístico de prueba para $H_0 : \theta = 0$ lo derivamos expresando la distribución beta-binomial en términos de π y θ .

$$\begin{aligned}\pi &= \frac{\gamma_1}{\gamma_1 + \gamma_2} &\implies \gamma_1 &= \frac{\pi}{\theta} \\ \theta &= \frac{1}{\gamma_1 + \gamma_2} &\implies \gamma_2 &= \frac{1 - \pi}{\theta}\end{aligned}$$

Esto es,

$$\begin{aligned}
 \Pr(Y_{i\cdot} = y_{i\cdot}) &= \binom{k_i}{y_{i\cdot}} \frac{\prod_{r=0}^{y_{i\cdot}-1} (\gamma_1 + r) \prod_{r=0}^{k_i-y_{i\cdot}-1} (\gamma_2 + r)}{\prod_{r=0}^{k_i-1} (\gamma_1 + \gamma_2 + r)} \\
 &= \binom{k_i}{y_{i\cdot}} \frac{\prod_{r=0}^{y_{i\cdot}-1} \left(\frac{\pi}{\theta} + r\right) \prod_{r=0}^{k_i-y_{i\cdot}-1} \left(\frac{1-\pi}{\theta} + r\right)}{\prod_{r=0}^{k_i-1} \left(\frac{1}{\theta} + r\right)} \\
 &= \binom{k_i}{y_{i\cdot}} \frac{\prod_{r=0}^{y_{i\cdot}-1} (\pi + \theta r) \prod_{r=0}^{k_i-y_{i\cdot}-1} (1 - \pi + \theta r)}{\prod_{r=0}^{k_i-1} (1 + \theta r)}.
 \end{aligned}$$

Modelando extra variación binomial con la distribución beta

Podemos usar la fórmula de la covarianza condicional para derivar los resultados siguientes,

$$\begin{aligned}\text{cov}(Y_{ij}, Y_{ik}) &= \mathbb{E}\{\text{cov}(Y_{ij}, Y_{ik} \mid \pi_i)\} + \text{cov}\{\mathbb{E}(Y_{ij} \mid \pi_i), \mathbb{E}(Y_{ik} \mid \pi_i)\} \\ &= \pi(1 - \pi) \frac{1}{\gamma_1 + \gamma_2 + 1}.\end{aligned}$$

$$\begin{aligned}\text{var}(Y_{ij}) &= \mathbb{E}\{\text{var}(Y_{ij} \mid \pi_i)\} + \text{var}\{\mathbb{E}(Y_{ij} \mid \pi_i)\} \\ &= \mathbb{E}\{\pi(1 - \pi)\} + \text{var}(\pi) \\ &= \mathbb{E}(\pi) - \{\mathbb{E}(\pi)\}^2 + [\mathbb{E}(\pi^2) - \{\mathbb{E}(\pi)\}^2] \\ &= \pi(1 - \pi).\end{aligned}$$

$$\text{cor}(Y_{ij}, Y_{ik}) = \frac{\pi(1 - \pi)(\gamma_1 + \gamma_2 + 1)^{-1}}{\pi(1 - \pi)} = \frac{1}{\gamma_1 + \gamma_2 + 1} = \rho.$$

$$\begin{aligned}\text{var}(Y_{i.}) &= \text{var}\left(\sum_{j=1}^{k_i} Y_{ij}\right) = \sum_{j=1}^{k_i} \text{var}(Y_{ij}) + \sum_{k < \ell} \sum \text{cov}(Y_{ik}, Y_{i\ell}) \\&= k_i \pi(1 - \pi) + k_i(k_i - 1)\pi(1 - \pi) \frac{1}{\gamma_1 + \gamma_2 + 1} \\&= k_i \pi(1 - \pi) \{1 + (k_i - 1)\rho\} \\&= k_i \pi(1 - \pi) \left(\frac{\gamma_1 + \gamma_2 + 1 + k_i - 1}{\gamma_1 + \gamma_2 + 1} \right).\end{aligned}$$

$$\text{var}(Y_{..}) = \sum_{i=1}^{n/k} k_i \pi(1 - \pi) \left(\frac{\gamma_1 + \gamma_2 + k_i}{\gamma_1 + \gamma_2 + 1} \right).$$

Modelando extra variación binomial con la distribución beta

Si contamos con datos de la forma

y	y_1	y_2	$\dots$	$y_{n/k}$
k	k_1	k_2	$\dots$	$k_{n/k}$

la función log-verosimilitud asumiendo la distribución beta-binomial es

$$\ell(\pi, \theta, \mathbf{y})$$

$$= \sum_{i=1}^{n/k} \left\{ \sum_{r=0}^{y_i-1} \log(\pi + \theta r) + \sum_{r=0}^{k_i-y_i-1} \log(1 - \pi + \theta r) - \sum_{r=0}^{k_i-1} (1 + \theta r) \right\},$$

y asumiendo la distribución binomial

$$\ell(\pi, \mathbf{y}) = \sum_{i=1}^{n/k} \{y_i \log \pi + (k_i - y_i) \log(1 - \pi)\}.$$

Sea ℓ_A la función log-verosimilitud maximizada bajo la distribución beta-binomial y ℓ_0 bajo la distribución binomial. Entonces podemos someter a prueba $H_0 : \theta = 0$ con el estadístico de prueba siguiente

$$2(\ell_A - \ell_0) \sim \chi_1^2 \quad (110)$$

el cual sigue una distribución χ^2 con 1 grado de libertad.

La probabilidad condicional (104) implica

$$\mathbb{E}(Y_i = y_i \mid \pi_i) = \pi_i$$

Supongamos que Y_i y u_i , $i = 1, \dots, n$, son variables aleatorias con distribución condicional $Y_i | u_i \sim \text{Poisson}(u_i \lambda)$. Supongamos por el momento que la distribución de u_i depende de un único parámetro ϕ . Entonces, la distribución condicional de $Y_i | u_i$ tiene función de probabilidad

$$f(y_i | u_i; \lambda) = \frac{(u_i \lambda)^{y_i} e^{-u_i \lambda}}{y_i!}; \quad y_i = 0, 1, 2, \dots$$

El factor u_i tiene el efecto de “inflar” ($u_i > 1$) o “desinflar” ($u_i < 1$) la respuesta media del i -ésimo sujeto respecto de λ . Si asumimos además $\mathbb{E}(u_i) = 1$ y $\text{var}(u_i) = \phi$, entonces esta configuración se conoce como *proceso Poisson mixto* (mixed Poisson process) o *modelo Poisson mixto*.

Consideraciones:

1. Tomando la esperanza condicional tenemos

$$\mathbb{E}(Y_i | u_i) = u_i \lambda$$

$$\mathbb{E}(Y_i) = \mathbb{E}\{\mathbb{E}(Y_i | u_i)\} = \lambda \mathbb{E}(u_i) = \lambda,$$

y, por lo tanto, denominamos λ como *la media poblacional (o respuesta media de la población)*.

2. Usando la fórmula de la varianza condicional,

$$\begin{aligned}\text{var}(Y_i) &= \text{var}\{\mathbb{E}(Y_i | u_i)\} + \mathbb{E}\{\text{var}(Y_i | u_i)\} \\ &= \text{var}(u_i \lambda) + \mathbb{E}(u_i \lambda) \\ &= \lambda^2 \phi + \lambda \\ &= \lambda(1 + \lambda \phi)\end{aligned}$$

Esto es, la varianza se infla por un factor $1 + \lambda \phi$.

Proceso Poisson mixto

Para construir una función de verosimilitud apropiada necesitamos hallar la distribución marginal de los datos observados

$y_1, \dots, y_n$.

Requerimos, por lo tanto, $\Pr(Y_i; \lambda, \phi)$. Para derivar esta probabilidad supongamos que $u_i \stackrel{\text{iid}}{\sim} \text{Gamma}(\alpha, \beta)$.

Recordemos, si $u \sim \text{Gamma}(b, a)$ entonces

$$f(u) = \frac{1}{\Gamma(a)b^a} u^{a-1} e^{-u/b}; \quad x \in \mathbb{R}^+, \quad a, b > 0$$

$$\mathbb{E}(u) = ab$$

$$\text{var}(u) = ab^2.$$

Tenemos entonces,

Proceso Poisson mixto

$$\begin{aligned}
 \Pr(Y_i; \lambda\phi) &= \int_{\mathbb{R}^+} f(y_i | u_i, \lambda) g(u_i; \phi) du_i \\
 &= \int_{\mathbb{R}^+} \frac{(u_i \lambda)^{y_i} \exp\{-u_i \lambda\}}{y_i!} \frac{u_i^{\alpha-1} \exp\left\{\frac{-u_i}{\beta}\right\}}{\Gamma(\alpha) \beta^\alpha} du_i \\
 &= \frac{\lambda^{y_i}}{y_i! \Gamma(\alpha) \beta^\alpha} \int_{\mathbb{R}^+} u_i^{y_i+\alpha-1} \exp\left\{-u_i \left(\frac{1}{\beta} + \lambda\right)\right\} du_i \\
 &= \frac{\lambda^{y_i}}{y_i! \Gamma(\alpha) \beta^\alpha} \int_{\mathbb{R}^+} u_i^{y_i+\alpha-1} e^{-u_i / \left(\frac{\beta}{1+\beta\lambda}\right)} du_i \\
 &= \frac{\lambda^{y_i}}{y_i! \Gamma(\alpha) \beta^\alpha} \Gamma(y_i + \alpha) \left(\frac{\beta}{1 + \beta\lambda}\right)^{y_i+\alpha} \underbrace{\int_{\mathbb{R}^+} \frac{u_i^{y_i+\alpha-1} e^{-u_i / \left(\frac{\beta}{1+\beta\lambda}\right)}}{\Gamma(y_i + \alpha) \left(\frac{\beta}{1+\beta\lambda}\right)^{y_i+\alpha}} du_i}_{\text{This is the p.d.f. of a Gamma}\left(y_i + \alpha, \frac{\beta}{1+\beta\lambda}\right) \text{ r.v.}} \\
 &= \frac{\Gamma(y_i + \alpha)}{y_i! \Gamma(\alpha)} \left(\frac{\beta\lambda}{1 + \beta\lambda}\right)^{y_i} \left(\frac{1}{1 + \beta\lambda}\right)^\alpha.
 \end{aligned}$$

Queremos que $\mathbb{E}(u_i) = 1$ y $\text{var}(u_i) = \phi$ lo cual logramos si $\phi = \beta = \alpha^{-1}$. Bajo esta parametrización, la probabilidad anterior toma la forma

$$\Pr(Y_i; \lambda, \phi) = \frac{\Gamma(y_i + \phi^{-1})}{y_i! \Gamma(\phi^{-1})} \left(\frac{\lambda \phi}{1 + \lambda \phi} \right)^{y_i} \left(\frac{1}{1 + \lambda \phi} \right)^{\phi^{-1}} \quad (111)$$

Podemos ver que (111) se corresponde con la función de probabilidad de la distribución binomial negativa.

En la derivación de (111) no consideramos covariables, pero puede extenderse directamente para así examinar el efecto de covariables, como veremos en la siguiente sección [§??].

Modelo de regresión Poisson con efectos mixtos

Supongamos $Y_{ij} \mid u_i \sim \text{Poisson}(u_i \lambda)$, donde $\mathbf{y}_i^\top = (y_{i1}, y_{i2}, \dots, y_{in_i})$ es el vector de conteos observados del i -ésimo cluster y u_i es una variable aleatoria a nivel de cluster que tiene una distribución paramétrica con $\mathbb{E}(u_i) = 1$ y $\text{var}(u_i) = \phi > 0$.

Entonces

$$\begin{aligned} \Pr(\underbrace{Y_{i1}, Y_{i2}, \dots, Y_{in_i}}_{\text{conteos del cluster } i}) &= \int_0^\infty \Pr(Y_{i1}, Y_{i2}, \dots, Y_{in_i} \mid u_i) g(u_i, \theta) du_i \\ &= \int_0^\infty \prod_{j=1}^{n_i} \left[\frac{(u_i \lambda)^{y_{ij}} e^{-u_i \lambda}}{y_{ij}!} \right] g(u_i; \phi) du_i \\ &= \int_0^\infty \left[\frac{(u_i \lambda)^{y_{i\cdot}} e^{-u_i \lambda}}{\prod_{j=1}^{n_i} y_{ij}!} \right] g(u_i; \phi) du_i \end{aligned}$$

Modelo de regresión Poisson con efectos mixtos

Si $u_i \stackrel{\text{iid}}{\sim} \text{Gamma}(\alpha = \phi^{-1}, \beta = \phi)$ tal que $\mathbb{E}(u_i) = \alpha\beta = 1$ y $\text{var}(u_i) = \alpha\beta^2 = \phi$ entonces tenemos

$$\begin{aligned}
 \Pr(\underbrace{Y_{i1}, \dots, Y_{in_i}}_{\text{conteos del cluster } i}) &= \int_0^\infty \left[\frac{(u_i \lambda)^{y_{i\cdot}} e^{-u_i \lambda}}{\prod_{j=1}^{n_i} y_{ij}!} \right] \left[\frac{u_i^{\alpha-1} e^{-u_i/\beta}}{\Gamma(\alpha) \beta^\alpha} \right] du_i \\
 &= \frac{\lambda^{y_{i\cdot}}}{\prod_{j=1}^{n_i} y_{ij}!} \int_0^\infty \left[u_i^{y_{i\cdot}} e^{-u_i \lambda} \right] \left[\frac{u_i^{1/\phi-1} e^{-u_i/\phi}}{\Gamma(\phi^{-1}) \phi^{1/\phi}} \right] du_i \\
 &= \frac{\phi^\phi \lambda^{y_{i\cdot}}}{\Gamma(\phi^{-1}) \prod_{j=1}^{n_i} y_{ij}!} \int_0^\infty u_i^{1/\phi+y_{i\cdot}-1} \exp \left\{ -u_i \left(\lambda + \frac{1}{\phi} \right) \right\} du_i \\
 &= \frac{\Gamma(\phi^{-1} + y_{i\cdot}) \left(\frac{\phi}{1+\lambda\phi} \right)^{\phi^{-1}+y_{i\cdot}} \phi^\phi \lambda^{y_{i\cdot}}}{\Gamma(\phi^{-1}) \prod_{j=1}^{n_i} y_{ij}!} \int_0^\infty \underbrace{\frac{u_i^{\phi^{-1}+y_{i\cdot}-1} e^{-u_i \left(\frac{\phi}{1+\lambda\phi} \right)^{-1}}}{\Gamma(\phi^{-1} + y_{i\cdot}) \left(\frac{\phi}{1+\lambda\phi} \right)^{\phi^{-1}+y_{i\cdot}}}}_{\substack{\text{This is the p.d.f. of a} \\ \text{Gamma} \left(\phi^{-1} + y_{i\cdot}, \frac{\phi}{1+\lambda\phi} \right) \text{ r.v.}}} du_i \\
 &= \dots
 \end{aligned}$$

Modelo de regresión Poisson con efectos mixtos

$$\Pr(Y_{i1}, \dots, Y_{in_i}) = \frac{\Gamma(\phi^{-1} + y_{i\cdot})}{\Gamma(\phi^{-1}) \prod_{j=1}^{n_i} y_{ij}!} \left(\frac{1}{1 + \lambda\phi} \right)^{\phi^{-1}} \left(\frac{\lambda\phi}{1 + \lambda\phi} \right)^{y_{i\cdot}} \quad (112)$$

Como vimos anteriormente, esta es la distribución binomial negativa.

En la derivación de (112) no consideramos covariables, pero en este punto puede extenderse directamente para así examinar el efecto de covariables a nivel de cluster. Supongamos que

$$\lambda_i = u_i \lambda_i^* = u_i e^{\mathbf{x}_i^\top \boldsymbol{\beta}}$$

esto es, $\log \lambda_i^* = \mathbf{x}_i^\top \boldsymbol{\beta}$. Consideremos los casos siguientes.

Modelo de regresión Poisson con efectos mixtos

1. **Covariables a nivel de cluster.** Sea $\mathbf{x}_{ij}$ el vector de variables explicativas para Y_{ij} . Tenemos covariables a nivel de cluster cuando $\mathbf{x}_{ij} = \mathbf{x}_i$ para todo $j = 1, \dots, n_i$. En este caso la probabilidad marginal $\Pr(Y_{i1}, Y_{i2}, \dots, Y_{in_i})$ la obtenemos reemplazando λ por $e^{\mathbf{x}_i^\top \boldsymbol{\beta}}$, resultando en

$$\begin{aligned} & \Pr(Y_{i1}, \dots, Y_{in_i}; \boldsymbol{\beta}, \phi) \\ &= \frac{\Gamma(\phi^{-1} + y_{i\cdot})}{\Gamma(\phi^{-1}) \prod_{j=1}^{n_i} y_{ij}!} \left(\frac{1}{1 + \phi e^{\mathbf{x}_i^\top \boldsymbol{\beta}}} \right)^{\phi^{-1}} \left(\frac{\phi e^{\mathbf{x}_i^\top \boldsymbol{\beta}}}{1 + \phi e^{\mathbf{x}_i^\top \boldsymbol{\beta}}} \right)^{y_{i\cdot}} \end{aligned}$$

y la función de verosimilitud para los n clusters está dada por

$$\begin{aligned} & L(\boldsymbol{\beta}, \phi; \mathbf{y}_1, \dots, \mathbf{y}_n) \\ &= \prod_{i=1}^n \left\{ \frac{\Gamma(\phi^{-1} + y_{i\cdot})}{\Gamma(\phi^{-1}) \prod_{j=1}^{n_i} y_{ij}!} \left(\frac{1}{1 + \phi e^{\mathbf{x}_i^\top \boldsymbol{\beta}}} \right)^{\phi^{-1}} \left(\frac{\phi e^{\mathbf{x}_i^\top \boldsymbol{\beta}}}{1 + \phi e^{\mathbf{x}_i^\top \boldsymbol{\beta}}} \right)^{y_{i\cdot}} \right\} \end{aligned}$$

Modelo de regresión Poisson con efectos mixtos

2. Supongamos, además, que **en cada cluster hay una única observación**, i.e. $n_i = 1$, y sea y_i la respuesta observada del i -ésimo cluster. Entonces la función de probabilidad binomial negativa para Y_i está dada por

$$\begin{aligned} \Pr(Y_i = y_i; \beta, \phi) \\ = \frac{\Gamma(\phi^{-1} + y_i)}{\Gamma(\phi^{-1})y_i!} \left(\frac{1}{1 + \phi e^{\mathbf{x}_i^\top \beta}} \right)^{\phi^{-1}} \left(\frac{\phi e^{\mathbf{x}_i^\top \beta}}{1 + \phi e^{\mathbf{x}_i^\top \beta}} \right)^{y_i} \end{aligned}$$

y la función de verosimilitud está dada por

$$\begin{aligned} L(\beta, \phi; \mathbf{y}_1, \dots, \mathbf{y}_n) \\ = \prod_{i=1}^n \left\{ \frac{\Gamma(\phi^{-1} + y_i)}{\Gamma(\phi^{-1})y_i!} \left(\frac{1}{1 + \phi e^{\mathbf{x}_i^\top \beta}} \right)^{\phi^{-1}} \left(\frac{\phi e^{\mathbf{x}_i^\top \beta}}{1 + \phi e^{\mathbf{x}_i^\top \beta}} \right)^{y_i} \right\} \end{aligned}$$

Este es un modelo más general y flexible para conteos.

Modelo de regresión Poisson con efectos mixtos

Para maximizar las funciones de verosimilitud (??) y (??) procedemos de acuerdo con el Algoritmo 2

Algorithm 2 Maximización de $L(\beta, \phi)$ del modelo binomial negativo.

- 1: Fijar $\phi = \phi^{(0)}$ como valor inicial.
 - 2: [inner loop] Maximizar $\ell(\beta, \phi^{(0)})$ respecto de β para obtener $\hat{\beta}^{(1)}$. Puede usarse el método de puntuación de Fisher.
 - 3: [outer loop] Maximizar $\ell(\hat{\beta}^{(1)}, \phi)$ respecto de ϕ para obtener $\hat{\phi}^{(1)}$. Esto puede hacerse con cualquier optimizador genérico
 - 4: Repetir (2)–(3) hasta convergencia.
-

Una alternativa para maximizar estas funciones de verosimilitud es mediante el algoritmo E-M.

Modelo de regresión Poisson con efectos mixtos

Consideraciones:

1. Con covariables a nivel de cluster, $\mathbf{x}_i$, la forma funcional de los modelos 1 y 2 anteriores [(??) y (??)] sería

$$\begin{aligned}\mathbb{E}(Y_{ij} \mid u_i, \mathbf{x}_i) &= u_i \lambda_i = u_i \exp \left\{ \mathbf{x}_i^\top \boldsymbol{\beta} \right\} = \exp \left\{ \mathbf{x}_i^\top \boldsymbol{\beta} + \log u_i \right\} \\ &= \exp \left\{ \mathbf{x}_i^\top \boldsymbol{\beta} + v_i \right\},\end{aligned}$$

donde $v_i = \log u_i$. Equivalentemente,

$$\log \{ \mathbb{E}(Y_{ij} \mid u_i) \} = \mathbf{x}_i^\top \boldsymbol{\beta} + v_i$$

2. Sus funciones de verosimilitud [(??) y (??)] se originan de la distribución binomial negativa, por lo que un modelo Poisson definido de esta manera para modelar tanto la media como sobredispersión con $u_i \stackrel{\text{iid}}{\sim} \text{Gamma}(\phi^{-1}, \phi)$ se conoce también como *modelo de regresión binomial negativo*.

Modelo de regresión Poisson con efectos mixtos

Consideraciones:

3. En ambos modelos 1 y 2 [(??) y (??)] se sostienen los resultados de §6, esto es,

$$\mathbb{E}(Y_{ij} \mid u_i) = u_i \lambda_i \quad \forall j = 1, \dots, n_i$$

$$\mathbb{E}(Y_{ij}) = \lambda_i \mathbb{E}(u_i) = \lambda_i \quad \forall j = 1, \dots, n_i$$

$$\text{var}(Y_{ij}) = \lambda_i(1 + \lambda_i \phi) \quad \forall j = 1, \dots, n_i$$

4. Ambos modelos [(??) y (??)] son proporcionales por lo que podemos usar software con capacidad para el modelo binomial negativo para tratar con datos de conteo en clusters asegurando que $\mathbf{x}_{ij} = \mathbf{x}_i$.
5. Estos modelos [(??) y (??)] no son miembros de la familia exponencial a menos que especifiquemos un valor numérico para ϕ .

Consideraciones:

6. Los modelos desarrollados en esta sección se conocen como *modelos de efectos mixtos* porque tiene ambos efectos fijos β y aleatorios u_i, v_i . Específicamente, el término u_i es un *intercepto aleatorio*, lo que resultaría en valores ajustados paralelos entre clusters (i.e. perfiles por cluster con distinto intercepto pero misma pendiente). Podemos extender los desarrollos de esta sección para incorporar *pendientes aleatorias*.

Adaptación para conteos agrupados

Suponga que tenemos $\mathbf{y}_1^\top = (y_{11}, \dots, y_{1n_1})$, $\mathbf{y}_2^\top = (y_{21}, \dots, y_{2n_2})$, $\dots$, $\mathbf{y}_K^\top = (y_{K1}, \dots, y_{Kn_K})$, donde $\mathbf{y}_k^\top = (y_{k1}, \dots, y_{kn_k})$ es el conjunto de respuestas del k -ésimo cluster. Supongamos también que $Y_{ij} \mid u_i \sim \text{Poisson}(u_i \lambda)$, esto es, los datos provienen de K clusters donde cada cluster tiene su propia media. Como antes,

$$\begin{aligned} \mathbb{E}(Y_{ij}) &= \lambda & \mathbb{E}(u_i) &= 1 \quad \text{y} \\ \text{var}(Y_{ij}) &= \lambda + \lambda^2 \phi & \text{var}(u_{ij}) &= \phi. \end{aligned}$$

Adaptación para conteos agrupados

Sin embargo, hay cierta correlación en cada cluster,

$$\begin{aligned}\text{cov}(Y_{ij}, Y_{ik}) &= \mathbb{E}\{\text{cov}(Y_{ij}, Y_{ik} \mid u_i)\} + \text{cov}\{\mathbb{E}(Y_{ij} \mid u_i), \mathbb{E}(Y_{ik} \mid u_i)\} \\ &= \mathbb{E}(0) + \text{cov}(u_i \lambda, u_i \lambda) \\ &= \lambda^2 \text{var}(u_i) \\ &= \lambda^2 \phi\end{aligned}$$

$$\begin{aligned}\implies \text{cor}(Y_{ij}, Y_{ik}) &= \frac{\lambda^2 \phi}{\lambda + \lambda^2 \phi} \\ &= \frac{\lambda \phi}{1 + \lambda \phi}\end{aligned}$$

Ahora tenemos un modelo que admite correlaciones de las respuestas al interior de los clusters.

Introduciendo covariables a nivel de cluster tenemos

$Y_{ij} \mid u_i \sim \text{Poisson}(u_i \lambda_i)$, donde $\lambda_i = e^{\mathbf{x}_i^\top \boldsymbol{\beta}}$ con resultados análogos a los anteriores.

Modelo de regresión binomial con efectos mixtos

Un modelo de regresión binomial con efectos mixtos análogo al modelo Poisson mixto [(??)] es de la forma

$$\Pr(Y_{ij} = y_{ij} \mid \mathbf{x}_i, v_i) = \frac{\exp \{ \mathbf{x}_i^\top \boldsymbol{\beta} + v_i \}}{1 + \exp \{ \mathbf{x}_i^\top \boldsymbol{\beta} + v_i \}} \quad (113)$$

Esto implica que la forma funcional del modelo sería

$$\log \left(\frac{\pi_i}{1 - \pi_i} \right) = \mathbf{x}_i^\top \boldsymbol{\beta} + v_i \quad (114)$$

donde $v_i = \log u_i$ y u_i es una variable aleatoria a nivel de cluster con $\mathbb{E}(u_i) = 1$ y $\text{var}(u_i) = \phi$.

Modelo de regresión binomial con efectos mixtos

La función de verosimilitud para el i -ésimo cluster está dada por

$$L_i(\beta; \phi) = \Pr(\mathbf{Y}_i = \mathbf{y}_i; \beta, \phi) \\ \propto \prod_{j=1}^{n_i} \int_{-\infty}^{\infty} \left(\frac{e^{\mathbf{x}_i^T \beta + v_i}}{1 + e^{\mathbf{x}_i^T \beta + v_i}} \right)^{y_{ij}} \left(\frac{1}{e^{\mathbf{x}_i^T \beta + v_i}} \right)^{1-y_{ij}} g(u_i; \phi) du_i$$

Requerimos métodos numéricos para estimación e inferencia con base en esta función de verosimilitud. Algunas opciones para la distribución de u_i serían $\text{Gamma}(\phi^{-1}, \phi)$, $\log \mathcal{N}(1, \phi)$.

Un enfoque alternativo es utilizar *modelos de transición* si los clusters están definidos por *eventos recurrentes* (*recurrent events*) en el mismo individuo a lo largo del tiempo.

[Este tema no lo cubriremos con más detalle en el curso.]

Modelo binomial negativo con efectos mixtos (longitudinal)

Finalmente, el caso más general para conteos es cuando las covariables son a nivel de observación, i.e. cuando $\mathbf{x}_{ij}$ es el vector de variables explicativas para Y_{ij} . Los cálculos para $\Pr(Y_{i1}, \dots, Y_{in_i})$ esencialmente son los mismos, pero ahora reemplazamos λ por $e^{\mathbf{x}_{ij}^\top \boldsymbol{\beta}}$. Entonces tenemos,

$$\begin{aligned}\Pr(Y_{i1}, \dots, Y_{in_i}) &= \int_0^\infty \Pr(Y_{i1}, \dots, Y_{in_i} \mid u_i) g(u_i, \theta) du_i \\&= \int_0^\infty \prod_{j=1}^{n_i} \left[\frac{\left(u_i e^{\mathbf{x}_{ij}^\top \boldsymbol{\beta}}\right)^{y_{ij}} \exp\left\{-u_i e^{\mathbf{x}_{ij}^\top \boldsymbol{\beta}}\right\}}{y_{ij}!} \right] g(u_i; \phi) du_i \\&= \int_0^\infty \left[\frac{u_i^{y_i \cdot} \left(\prod_{j=1}^{n_i} e^{y_{ij} \mathbf{x}_{ij}^\top \boldsymbol{\beta}}\right) \left(\prod_{j=1}^{n_i} \exp\left\{-u_i e^{\mathbf{x}_{ij}^\top \boldsymbol{\beta}}\right\}\right)}{\prod_{j=1}^{n_i} y_{ij}!} \right] g(u_i; \phi) du_i \\&= \dots\end{aligned}$$

Modelo binomial negativo con efectos mixtos (longitudinal)

$$\begin{aligned}\Pr(Y_{i1}, \dots, Y_{in_i}) \\&= \int_0^\infty \left[\frac{u_i^{y_{i\cdot}} e^{\sum_{j=1}^{n_i} y_{ij} \mathbf{x}_{ij}^\top \boldsymbol{\beta}} \exp \left\{ -u_i \sum_{j=1}^{n_i} e^{\mathbf{x}_{ij}^\top \boldsymbol{\beta}} \right\}}{\prod_{j=1}^{n_i} y_{ij}!} \right] g(u_i; \phi) du_i \\&= \int_0^\infty \left[\frac{u_i^{y_{i\cdot}} e^{a_{i\cdot}} e^{-u_i b_{i\cdot}}}{\prod_{j=1}^{n_i} y_{ij}!} \right] g(u_i; \phi) du_i\end{aligned}$$

donde

$$\begin{aligned}a_{i\cdot} &= \sum_{j=1}^{n_i} y_{ij} \mathbf{x}_{ij}^\top \boldsymbol{\beta} \\y \ b_{i\cdot} &= \sum_{j=1}^{n_i} e^{\mathbf{x}_{ij}^\top \boldsymbol{\beta}}\end{aligned}$$

Modelo binomial negativo con efectos mixtos (longitudinal)

Si $u_i \stackrel{\text{iid}}{\sim} \text{Gamma}(\alpha = \phi^{-1}, \beta = \phi)$ entonces tenemos

$$\begin{aligned}
 \Pr(Y_{i1}, \dots, Y_{in_i}) &= \int_0^\infty \left[\frac{u_i^{y_{i\cdot}} e^{a_{i\cdot}} e^{-u_i b_{i\cdot}}}{\prod_{j=1}^{n_i} y_{ij}!} \right] \left[\frac{u_i^{\alpha-1} e^{-u_i/\beta}}{\Gamma(\alpha) \beta^\alpha} \right] du_i \\
 &= \frac{e^{a_{i\cdot}}}{\prod_{j=1}^{n_i} y_{ij}!} \int_0^\infty \left[u_i^{y_{i\cdot}} e^{-u_i b_{i\cdot}} \right] \left[\frac{u_i^{1/\phi-1} e^{-u_i/\phi}}{\Gamma(\phi^{-1}) \phi^{1/\phi}} \right] du_i \\
 &= \frac{\phi^\phi e^{a_{i\cdot}}}{\Gamma(\phi^{-1}) \prod_{j=1}^{n_i} y_{ij}!} \int_0^\infty u_i^{1/\phi+y_{i\cdot}-1} \exp \left\{ -u_i \left(b_{i\cdot} + \frac{1}{\phi} \right) \right\} du_i \\
 &= \frac{\Gamma(\phi^{-1} + y_{i\cdot}) \left(\frac{\phi}{1+\phi b_{i\cdot}} \right)^{\phi^{-1}+y_{i\cdot}} \phi^\phi e^{a_{i\cdot}}}{\Gamma(\phi^{-1}) \prod_{j=1}^{n_i} y_{ij}!} \int_0^\infty \underbrace{\frac{u_i^{\phi^{-1}+y_{i\cdot}-1} e^{-u_i \left(\frac{\phi}{1+\phi b_{i\cdot}} \right)^{-1}}}{\Gamma(\phi^{-1} + y_{i\cdot}) \left(\frac{\phi}{1+\phi b_{i\cdot}} \right)^{\phi^{-1}+y_{i\cdot}}}}_{\substack{\text{This is the p.d.f. of a} \\ \text{Gamma} \left(\phi^{-1} + y_{i\cdot}, \frac{\phi}{1+\phi b_{i\cdot}} \right) \text{ r.v.}}} du_i \\
 &= \dots
 \end{aligned}$$

Modelo binomial negativo con efectos mixtos (longitudinal)

$$\begin{aligned}\Pr(Y_{i1}, \dots, Y_{in_i}) &= \frac{\Gamma(\phi^{-1} + y_{i\cdot})}{\Gamma(\phi^{-1}) \prod_{j=1}^{n_i} y_{ij}!} \left(\frac{\phi}{1 + \phi \sum_{j=1}^{n_i} e^{\mathbf{x}_{ij}^\top \boldsymbol{\beta}}} \right)^{\phi^{-1}} \left(\frac{\phi}{1 + \phi \sum_{j=1}^{n_i} e^{\mathbf{x}_{ij}^\top \boldsymbol{\beta}}} \right)^{y_{i\cdot}} \\ &\quad \phi^\phi \left(\prod_{j=1}^{n_i} \exp\{y_{ij} \mathbf{x}_{ij}^\top \boldsymbol{\beta}\} \right) \\ &= \frac{\Gamma(\phi^{-1} + y_{i\cdot})}{\Gamma(\phi^{-1}) \prod_{j=1}^{n_i} y_{ij}!} \left(\frac{1}{1 + \lambda \phi} \right)^{\phi^{-1}} \left(\frac{\phi}{1 + \lambda \phi} \right)^{y_{i\cdot}} \left(\prod_{j=1}^{n_i} \exp\{y_{ij} \mathbf{x}_{ij}^\top \boldsymbol{\beta}\} \right)\end{aligned}$$

Un caso especial de covariables a nivel de respuesta es cuando los clusters son individuos y observamos múltiples respuestas en cada individuo a lo largo de un periodo de seguimiento. Entonces, y_{ij} serían los conteos del i -ésimo individuo en el j -ésimo periodo de observación. Las covariables serían $\mathbf{x}_{ij}$ para la respuesta y_{ij} . Esta estructura de datos se conoce como *datos longitudinales*.

Modelo binomial negativo con efectos mixtos (longitudinal)

Consideraciones:

1. Supongamos que los vectores de covariables contienen únicamente el intercepto y una covariable que cambia en el tiempo, t_{ij} , esto es, $\mathbf{x}_{ij}^\top = [1, t_{ij}]$. Podemos definir un modelo de regresión de la forma

$$\log \lambda_{ij} = (\beta_1 + u_{i0}) + (\beta_1 + u_{i1})t_{ij}$$

donde u_{i0} es un intercepto aleatorio y u_{i1} una pendiente aleatoria, ambas con distribución bivariada con media 0 y matriz de varianza Σ_u .

[Este tema no lo cubriremos con más detalle en el curso.]

Ejemplo 5.1 Modelos Poisson y binomial negativo - epilepsia

Se condujo un ensayo clínico en 59 pacientes con epilepsia para investigar la efectividad de un nuevo medicamento experimental diseñado para reducir el número de ataques epilépticos.

Los pacientes fueron asignados aleatoriamente a uno de los dos tratamientos: estándar y experimental.

Una vez asignados al tratamiento, se dio seguimiento a los pacientes por 4 periodos consecutivos de 2 semanas cada uno, i.e. un total de 8 semanas.

En cada uno de los periodos se registró el número de ataques sufridos durante esas 2 semanas.

Sea y_{ij} el número de ataques del i -ésimo paciente ($i = 1, \dots, 59$) en el j -ésimo periodo ($j = 1, 2, 3, 4$).

Ejemplo 5.1 Modelos Poisson y binomial negativo - epilepsia

$$M_1 : \log \lambda_i = \beta_0 + \beta_1 \text{trt}_i + \beta_2 \text{prior}_i + \beta_3 \text{age}_i + u_i \quad (115a)$$

$$M_2 : \log \lambda_i = \beta_0 + \beta_1 \text{trt}_i + \beta_2 \text{prior}_i + \beta_3 \text{age}_i + \beta_4 \text{period}_i + u_{i0} \quad (115b)$$

$$M_3 : \log \lambda_i = \beta_0 + \beta_1 \text{trt}_i + \beta_2 \text{prior}_i + \beta_3 \text{age}_i + \beta_4 \text{period}_i + u_{i0} + u_{i1} \text{period}_i \quad (115c)$$

Ejemplo 5.1 Modelos Poisson y binomial negativo - epilepsia

El archivo `epilepsy.txt` contiene los datos para el análisis las columnas `y1`–`y4` son los conteos de ataques epilépticos en cada uno de los 4 periodos; `trt` = 1 para el tratamiento experimental y `trt` = 0 para el estándar; `prior` es el conteo de los ataques epilépticos sufridos el mes previo al inicio del estudio, y `age` es la edad en años de los pacientes al momento de la randomización.

Ejemplo 5.1 Modelos Poisson y binomial negativo - epilepsia

Análisis univariado

En esta etapa analizaremos los conteos de ataques únicamente en el primer periodo, esto es, $Y_{i1}, i = 1, \dots, n = 59$.

```
> Example 5.1 Overdispersion , Negative Binomial
```

```
datwd <- 'C:/...'
```

```
setwd(datwd); getwd()
```

```
d <- read.table('epilepsy.txt', header=TRUE); rbind(head(d), tail(d))
```

	id	yi1	yi2	yi3	yi4	trt	prior	age
1	1	5	3	3	3	0	11	31
2	2	3	5	3	3	0	11	30
3	3	0	2	4	5	0	6	25
4	4	1	4	4	4	0	8	36
5	5	18	21	7	9	0	66	22
6	6	2	5	7	8	0	27	29
54	54	0	3	4	6	1	24	41
55	55	3	3	4	5	1	16	32
56	56	1	19	23	8	1	22	26
57	57	0	1	2	3	1	25	21
58	58	0	0	0	0	1	13	36
59	59	1	4	3	2	1	12	37

```
> Declare treatment as factor
```

```
d$trt_f <- factor(d$trt); table(d$trt_f)
```

Ejemplo 5.1 Modelos Poisson y binomial negativo - epilepsia

Ajustaremos los modelos Poisson, quasi-Poisson y binomial negativo a estos datos con el predictor lineal

$$\log \lambda_i = \beta_0 + \beta_1 \text{trt_f}_i + \beta_2 \text{prior}_i + \beta_3 \text{age}_i$$

El modelo quasi-Poisson ajusta el modelo Poisson haciendo un ajuste en los errores estándar, los escala multiplicándolos por $\sqrt{\phi} = \sqrt{\tilde{\sigma}^2}$ definido en (103).

En contraste, el modelo binomial negativo estima el parámetro de dispersión ϕ , maximizando la función de verosimilitud (??).

Se muestra el código de R y el output.

Ejemplo 5.1 Modelos Poisson y binomial negativo - epilepsia

```
> Fit the Poisson, quasi-Poisson and negative binomial models

Mpo <- glm(yi1 ~ trt_f + prior + age, family=poisson, data=d)
Mqp <- glm(yi1 ~ trt_f + prior + age, family=quasipoisson, data=d)
Mnb <- glm.nb(yi1 ~ trt_f + prior + age, link=log, init.theta=1,
              trace=TRUE, data=d)
MI <- list('Poisson'=Mpo, 'quasi-Poisson'=Mqp, 'Negative_Binomial'=Mnb)
lapply(MI, summary)
```


Ejemplo 5.1 Modelos Poisson y binomial negativo - epilepsia

\$Poisson

Call:

```
glm(formula = yi1 ~ trt_f + prior + age, family = poisson,  
     data = d)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	0.491136	0.274180	1.791	0.0732 .
trt_f1	-0.042151	0.105702	-0.399	0.6901
prior	0.026606	0.001045	25.469	<2e-16 ***
age	0.007198	0.008031	0.896	0.3701

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for poisson family taken to be 1)

Null deviance: 809.85 on 58 degrees of freedom
Residual deviance: 245.19 on 55 degrees of freedom
AIC: 405.32

Number of Fisher Scoring iterations: 5

Ejemplo 5.1 Modelos Poisson y binomial negativo - epilepsia

```
$ 'quasi-Poisson '
```

```
Call:
```

```
glm(formula = yi1 ~ trt_f + prior + age, family = quasipoisson,  
     data = d)
```

```
Coefficients:
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.491136	0.572817	0.857	0.395
trt_f1	-0.042151	0.220832	-0.191	0.849
prior	0.026606	0.002182	12.191	<2e-16 ***
age	0.007198	0.016778	0.429	0.670

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
(Dispersion parameter for quasipoisson family taken to be 4.364777)
```

```
Null deviance: 809.85 on 58 degrees of freedom  
Residual deviance: 245.19 on 55 degrees of freedom  
AIC: NA
```

```
Number of Fisher Scoring iterations: 5
```

Ejemplo 5.1 Modelos Poisson y binomial negativo - epilepsia

\$Negative_Binomial

Call:

```
glm.nb(formula = yil ~ trt_f + prior + age, data = d, trace = TRUE,  
       init.theta = 1.1963668, link = log)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	0.182229	0.639307	0.285	0.776
trt_f1	-0.157373	0.278001	-0.566	0.571
prior	0.037312	0.004886	7.636	2.24e-14 ***
age	0.004740	0.018932	0.250	0.802

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for Negative Binomial(1.1964)
family taken to be 1)

Null deviance: 132.718 on 58 degrees of freedom
Residual deviance: 66.624 on 55 degrees of freedom
AIC: 308.27

Number of Fisher Scoring iterations: 1

Theta: 1.196
Std. Err.: 0.325

2 x log-likelihood: -298.268

Ejemplo 5.1 Modelos Poisson y binomial negativo - epilepsia

```
> Retrieve some results that will be used later on: estimated  
> coefficients, standard errors, residuals (Pearson and  
> deviance), fitted values deviance statistic and degrees of freedom.
```

```
bhat <- lapply(MI, coefficients)  
std.err <- lapply(MI, function(x) sqrt(diag(vcov(x)))); std.err  
p.res <- lapply(MI, function(x) residuals(x, 'pearson'))  
dev.res <- lapply(MI, function(x) residuals(x, 'deviance'))  
fv <- lapply(MI, fitted.values)  
dev <- lapply(MI, deviance)  
df <- lapply(MI, df.residual)
```

```
> The quasi-Poisson model scales the standard errors multiplying  
> them by the factor  
> sqrt(Pearson chi-squared / degrees of freedom)
```

```
sig2 <- lapply(seq(MI), function(x) sum(p.res[[x]]^2)/df[[x]])  
unlist(sig2)  
[1] 4.364673 4.364673 0.989949  
sqrt(unlist(sig2))  
[1] 2.0891801 2.0891801 0.9949618
```

Ejemplo 5.1 Modelos Poisson y binomial negativo - epilepsia

```
> Verify that standard errors of quasi-Poisson estimates are  
> scaled by a factor of sqrt(phi)
```

```
est <- cbind(round(do.call(cbind, bhat),4),  
             round(do.call(cbind, std.err),4))  
est  -> (See Table)
```

```
std.err[[2]]/std.err[[1]]  
(Intercept)      trt_f1      prior      age  
    2.089205    2.089205    2.089205    2.089205
```

```
> Verify some calculations:
```

```
>
```

```
> (a) Calculate the fitted values and compare against R output
```

```
X <- as.matrix(cbind(1,d[,c('trt','prior','age')]))  
fvh <- lapply(seq(MI), function(j) cbind(fv[[j]], exp(X%%bhat[[j]])))
```

```
> (b) Pearson's chi-square statistic
```

```
sum((d$yi1-fv[[1]])^2 / fv[[1]])  
sum(p.res[[1]]^2)
```

Ejemplo 5.1 Modelos Poisson y binomial negativo - epilepsia

Comentarios:

1. El estadístico de Pearson del modelo Poisson es $\tilde{\sigma}^2 = 4.365$, lo cual es una señal de que hay sobredispersión en los datos pues la varianza es más de 4 veces el valor de la media.
2. La Tabla siguiente, construida con el output de R, muestra que los coeficientes estimados del modelo quasi-Poisson son iguales que los del modelo Poisson pero sus errores estandar son el doble al ser escalados por factor $\sqrt{\tilde{\sigma}^2} = 2.089$ (verifique los cálculos).

	Coefficient			Standard Error		
	Poisson	quasi-Poisson	NB	Poisson	quasi-Poisson	NB
$\hat{\beta}_0$	0.4911	0.4911	0.1822	0.2742	0.5728	0.6393
$\hat{\beta}_1$	-0.0422	-0.0422	-0.1574	0.1057	0.2208	0.2780
$\hat{\beta}_2$	0.0266	0.0266	0.0373	0.0010	0.0022	0.0049
$\hat{\beta}_3$	0.0072	0.0072	0.0047	0.0080	0.0168	0.0189

Ejemplo 5.1 Modelos Poisson y binomial negativo - epilepsia

3. Tanto los coeficientes estimados como los errores estándar estimados del modelo binomial negativo difieren de los de los modelos Poisson y quasi-Poisson. Esto se debe en parte a que las observaciones tienen ponderadores distintos en cada uno de los dos modelos. Los errores estándar son más grandes en el modelo binomial negativo porque éste incorpora en su definición la variabilidad de los datos (necesario en este caso), la cual es modelada por el parámetro ϕ .
4. $\theta = 1.964 = \phi^{-1}$ en el output del modelo binomial negativo incluye es el recíproco de la precisión del efecto aleatorio multiplicativo u_i . Por lo tanto $\phi = \theta^{-1} = 0.84$ es una varianza estimada y es significativa con un p -value = 0.0001

```
> ls theta significantly different from 0?  
z <- Mnb$theta/Mnb$SE.theta; z  
pnorm(z, lower.tail=FALSE)  
[1] 0.000115802
```

Ejemplo 5.1 Modelos Poisson y binomial negativo - epilepsia

5. La función de R `glm()` tiene la opción `family=negative.binomial`, para la cual necesitamos especificar el valor del parámetro `theta`. Esta opción se basa en el resultado de que la distribución binomial negativa es miembro de la familia exponencial cuando la varianza es fija (o el número de éxitos es fijo). El output siguiente muestra que al especificar `family=negative.binomial(Mnb\theta)` en la función `glm()` los coeficientes estimados son los mismos que en el modelo binomial negativo y la diferencia entre los errores estándar de estos dos enfoques se debe a que en el modelo binomial negativo estimamos el parámetro de dispersión mientras que en `glm()` es fijo.

Ejemplo 5.1 Modelos Poisson y binomial negativo - epilepsia

```
> Negative binomial with fixed theta with the
> glm() function

theta <- Mnb$theta
Mnbg <- glm(yi1 ~ trt_f + prior + age,
            family=negative.binomial(theta), data=d)
summary(Mnbg)
Call:
glm(formula = yi1 ~ trt_f + prior + age,
    family = negative.binomial(Mnb$theta), data = d)

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  0.182262    0.636083   0.287    0.776
trt_f1       -0.157369    0.276600  -0.569    0.572
prior         0.037310    0.004862   7.674 2.97e-10 ***
age           0.004740    0.018837   0.252    0.802
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for Negative Binomial(1.1964)
    family taken to be 0.9899536)

Null deviance: 132.718 on 58 degrees of freedom
Residual deviance: 66.624 on 55 degrees of freedom
AIC: 306.27

Number of Fisher Scoring iterations: 12
```

Ejemplo 5.1 Modelos Poisson y binomial negativo - epilepsia

La distribución binomial negativa tiende a la distribución Poisson cuando $\phi \rightarrow 0$ (equivalentemente, $\theta \rightarrow \infty$). Por lo tanto, si damos un valor suficientemente grande para θ en la familia `family=negative.binomial()`, los coeficientes estimados serán idénticos a los del modelo Poisson y los errores estándar serán los del modelo quasi-Poisson [¡verifíquelo en R!].

6. Ajustemos el modelo binomial negativo pero ahora quitando las variables `prior` y `age`, esto es, $\lambda_i = \beta_0 + \beta_1 \text{trt_f}$ y veamos qué sucede con el valor estimado del parámetro de dispersión ϕ .

Ejemplo 5.1 Modelos Poisson y binomial negativo - epilepsia

```
> Explore what happens with the dispersion parameter estimate  
> phi if we remove from the negative binomial model two  
> variables, say prior and age.
```

```
Mnb_red <- update(Mnb, ~.-prior - age)  
1/Mnb_red$theta  
[1] 2.174053
```

```
summary(Mnb_red)
```

```
> Update the relevant lists
```

```
MI <- append(MI, list('Negative_Binomial_reduced' = Mnb_red))  
unlist(lapply(MI, logLik))  
fv <- append(fv, list('Negative_Binomial_reduced' = Mnb_red$fitted.values))  
dev.res <- append(dev.res, list(  
  'Negative_Binomial_reduced' = residuals(Mnb_red, 'deviance')))
```


Vemos que $\hat{\phi} = 2.17$ es mayor que el valor estimado de este parámetro con el modelo binomial negativo con todas las variables $\hat{\phi} = 0.84$. Esto tiene sentido, pues estas dos variables explican mucho de la variabilidad entre los individuos y al incluirse en el modelo hay menos variabilidad que explique el efecto aleatorio u_i y, por lo tanto, su varianza debe ser menor.

Ejemplo 5.1 Modelos Poisson y binomial negativo - epilepsia


```
> Plot fitted values vs. deviance residuals
main_leg <- c('Poisson', 'quasi-Poisson', 'Negative Binomial',
              'Negative Binomial reduced')
max(unlist(fv))
xl <- c(0,320)
lapply(seq(MI), function(x){
  plot(fv[[x]], dev.res[[x]], las=1, ylab='Deviance residuals',
       xlab=bquote('Fitted values '~(hat(lambda))[i])),
       main=main_leg[x], ylim=c(-5,5), xlim=xl)
  abline(h=2, col=2, lty=2)
  abline(h=-2, col=2, lty=2)
}))
```

7. En las gráficas de valores ajustados contra residuales de la deviance en la Figura 24 (Poisson y binomial negativo **quasi-Poisson es igual que Poisson** vemos que al estimar el parámetro de dispersión ϕ con el modelo binomial negativo la magnitud de los residuales disminuye (variabilidad no explicada por el modelo) pues ahora parte de la variabilidad en los datos la explicamos con el efecto aleatorio u_i .

Ejemplo 5.1 Modelos Poisson y binomial negativo - epilepsia



(a) Poisson model



(b) Negative binomial model

Figure 23: Residuals vs fitted values epilepsy attacks during the first two weeks after randomization.

Ejemplo 5.1 Modelos Poisson y binomial negativo - epilepsia

Análisis conjunto de las 4 respuestas agregadas

Para este análisis, sumamos las respuestas de los 4 periodos para cada individuo, esto es, $y_i. = y_{i1} + y_{i2} + y_{i3} + y_{i4}$. La estadística χ^2 de Pearson del modelo Poisson es $\tilde{\sigma}^2 = 11.8$, lo cual sugiere una fuerte sobredispersión en los datos. Por lo tanto, ajustaremos el modelo binomial negativo y para ello usaremos la función `glm.nb()`

```
> Sum individual responses across the 4 periods.
```

```
d$yidot <- d$yi1 + d$yi2 + d$yi3 + d$yi4  
rbind(head(d), tail(d))
```

```
> Fit the Poisson model and see if there are signs of  
> overdispersion.
```

```
Mpoj <- glm(yidot ~ trt + prior + age, family=poisson, data=d)  
sum(residuals(Mpoj, 'pearson')^2)/df.residual(Mpoj)  
[1] 11.82549
```

Ejemplo 5.1 Modelos Poisson y binomial negativo - epilepsia

Call:

```
glm.nb(formula = yidot ~ trt + prior + age, data = d, trace = TRUE,  
       init.theta = 3.35735873, link = log)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	2.060124	0.347696	5.925	3.12e-09 ***
trt	-0.212428	0.153399	-1.385	0.166
prior	0.027540	0.002811	9.796	< 2e-16 ***
age	0.012689	0.010326	1.229	0.219

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for Negative Binomial(3.3574) family taken to be 1)

Null deviance: 181.136 on 58 degrees of freedom
Residual deviance: 63.697 on 55 degrees of freedom
AIC: 476.77

Number of Fisher Scoring iterations: 1

Theta: 3.357
Std. Err.: 0.709

2 x log-likelihood: -466.767

```
1/Mnjb$theta  
[1] 0.2978532
```

Ejemplo 5.1 Modelos Poisson y binomial negativo - epilepsia

Comentarios:

1. El valor estimado del parámetro de dispersión es $\hat{\phi} = 0.2979$.
2. Sólo el coeficiente estimado de los ataques epilépticos en el mes previo al tratamiento es significativo. Esto es consistente con el análisis univariado, aunque la magnitud del efecto es menor en el análisis de las respuestas agregadas.
3. La gráfica de la Figura 24a muestra residuales más grandes que los del análisis univariado, excepto por una observación todos los demás contenidos en el intervalo $(-3, 3)$.
4. La Figura 24b sugiere, en la escala logarítmica, algunas discrepancias entre valores ajustados y observados. Esto podría deberse a pacientes con un número de ataques mucho mayor que el resto de los pacientes.

Ejemplo 5.1 Modelos Poisson y binomial negativo - epilepsia


> Plot fitted values vs. deviance residuals

```
plot(Mnbj$fitted.values, residuals(Mnbj, 'deviance'), ylab='Deviance',  
     xlab=bquote('Fitted values' ~ (hat(lambda)[i])),  
     main='Negative Binomial', ylim=c(-5,5), xlim=x1)  
abline(h=2, col=2, lty=2)  
abline(h=-2, col=2, lty=2)
```


> Fitted vs. observed values

```
plot(Mnbj$fitted.values, d$yidot, ylab='Observed values',  
     xlab=bquote('Fitted values' ~ (hat(lambda)[i])),  
     main='Negative Binomial')  
abline(a=0, b=1, col=2, lty=2)
```

Ejemplo 5.1 Modelos Poisson y binomial negativo - epilepsia



(a) Fitted values vs. deviance residuals



(b) Fitted values vs. observed counts

Figure 24: Residuals vs fitted values epilepsy attacks during the first two weeks of follow-up.

Ejemplo 5.1 Modelos Poisson y binomial negativo - epilepsia

Longitudinal data analysis

Podemos hacer mejor uso de los datos si los analizamos en su diseño natural como datos longitudinales.

Comúnmente los paquetes informáticos para el análisis de datos longitudinales requieren que las respuestas estén en una sola columna y que en otra se identifique a qué periodo se corresponde cada observación, además de un identificador de individuo (o cluster).

Podemos transformar los datos de un formato “ancho” a un formato “largo” con la función `reshape2::melt()` y con el formato largo graficamos el perfil de respuesta de cada individuo, separándolos por el régimen de tratamiento al que fueron aleatoriamente asignados.

Ejemplo 5.1 Modelos Poisson y binomial negativo - epilepsia

> Transform the `data` from wide to long formats

```
library(reshape2); melt
```

```
dl <- melt(d, id.vars=c('id', 'trt', 'prior', 'age', 'trt_f'),  
          variable.name='period', value.name='y')  
dl$period <- as.factor(gsub('\\D+', '', dl$period))  
head(dl)
```

> Plot individual profiles

```
p <- ggplot(data=dl, aes(x=period, y=y, group=id, color=as.factor(id))) +  
  labs(x='Period', y='no. of epileptic attacks', group='Treatment')  
  
p + geom_line(show.legend=FALSE) + facet_grid(. ~ trt_f) + ylim(0,120) +  
  stat_summary(aes(group=0), geom='point',  
    fun.y=mean, shape=19, size=3, show.legend=FALSE) +  
  stat_smooth(aes(group=1), show.legend=FALSE)
```

Ejemplo 5.1 Modelos Poisson y binomial negativo - epilepsia




Figure 25: Individual profiles of number of epilepsy attacks across the 4 biweekly periods by treatment (1 for experimental and 0 for standard).

Ejemplo 5.1 Modelos Poisson y binomial negativo - epilepsia

La Figura 28 sugiere que los pacientes del medicamento experimental tienen ligeramente menos ataques epilépticos, menor variabilidad y que en las cuatro semanas muestran una reducción ligeramente mayor que la de los del medicamento estándar; sin embargo, con este análisis visual es difícil decirlo contundentemente.

Destaca un paciente en el grupo experimental por tener un número de ataques mayor que el resto de la muestra. Posiblemente el número extremo de ataques se deba a la severidad de su enfermedad.

Al analizar los datos longitudinales podríamos evaluar la trayectoria del perfil de respuesta a nivel de individuo y estudiar la estructura de correlación a un nivel más fino que agregando las respuestas como lo hicimos en el análisis anterior.

Ejemplo 5.1 Modelos Poisson y binomial negativo - epilepsia

Ajustamos los modelos siguientes.

$$M_1 : \log \lambda_i = (\beta_0 + v_{i0}) + \beta_1 \text{trt}_i + \beta_2 \text{prior}_i + \beta_3 \text{age}_i$$

$$M_2 : \log \lambda_{ij} = (\beta_0 + v_{i0}) + \beta_1 \text{trt}_i + \beta_2 \text{prior}_i + \beta_3 \text{age}_i + \beta_4 \text{period}_{ij}$$

$$M_3 : \log \lambda_{ij} = (\beta_0 + v_{i0}) + \beta_1 \text{trt}_i + \beta_2 \text{prior}_i + \beta_3 \text{age}_i + (\beta_4 + v_{i1}) \times \text{period}_{ij}$$

Ejemplo 5.1 Modelos Poisson y binomial negativo - epilepsia

- M_1 incluye el intercepto aleatorio $v_{i0} = \log u_{i0}$ y no incluye la variable de tiempo `period`, por lo que se asume que la respuesta media, λ_i , es distinta en cada cluster y que se mantiene constante a lo largo del tiempo.
- M_2 sí incluye la variable de tiempo `period` además del intercepto aleatorio, lo que significa que asumimos respuesta media diferente en cada cluster λ_{ij} , que cambia en el tiempo y que este cambio es constante y el mismo para todos los clusters.
- M_3 incluye intercepto aleatorio, la variable de tiempo `period` y pendiente aleatoria v_{i1} . Esto significa que la respuesta media, λ_{ij} , varía de un cluster a otro tanto en su nivel como en el cambio a lo largo del tiempo.

Ejemplo 5.1 Modelos Poisson y binomial negativo - epilepsia

La función `lme4::glmer.nb` tiene capacidades para ajustar un modelo binomial negativo a datos longitudinales. En modelos con efectos aleatorios es necesario especificarlos como términos adicionales en el predictor lineal. Por ejemplo, el intercepto aleatorio se escribe como `(1|id)` y la pendiente aleatorio como `(period|id)`. Se muestra el código de R para configurar estos modelos y el output.

```
library(lme4)

M1 <- glmer.nb(y ~ trt_f + prior + age + (1|id), data=dl)
M2 <- glmer.nb(y ~ trt_f + prior + age + period +
               (1|id), data=dl)
M3 <- glmer.nb(y ~ trt_f + prior + age + period +
               (1|id)+(period|id), data=dl)
M <- list(M1=M1, M2=M2, M3=M3)
lapply(M, summary)
```

Ejemplo 5.1 Modelos Poisson y binomial negativo - epilepsia

\$M1

Generalized linear mixed model fit by maximum likelihood (Laplace Approximation) [glmerMod]
Family: Negative Binomial(7.208) (log)
Formula: y ~ trt_f + prior + age + (1 | id)
Data: dl

AIC	BIC	logLik	deviance	df.resid
1270.5	1291.2	-629.2	1258.5	230

Scaled residuals:

Min	1Q	Median	3Q	Max
-1.8740	-0.5802	-0.0922	0.4474	3.5777

Random effects:

Groups	Name	Variance	Std.Dev.
id	(Intercept)	0.2502	0.5002

Number of obs: 236, groups: id, 59

Fixed effects:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	0.617993	0.347345	1.779	0.0752 .
trt_f1	-0.274810	0.153164	-1.794	0.0728 .
prior	0.027075	0.002796	9.685	<2e-16 ***
age	0.011306	0.010360	1.091	0.2751

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Ejemplo 5.1 Modelos Poisson y binomial negativo - epilepsia

Correlation of Fixed Effects:

(Intr) trt_f1 prior

trt_f1 -0.244

prior -0.418 -0.023

age -0.912 0.029 0.177

Ejemplo 5.1 Modelos Poisson y binomial negativo - epilepsia

\$M2

```
Generalized linear mixed model fit by maximum likelihood (Laplace  
Approximation) [glmerMod]  
Family: Negative Binomial(8.6268) ( log )  
Formula: y ~ trt_f + prior + age + period + (1 | id)  
Data: dl
```

AIC	BIC	logLik	deviance	df.resid
1244.2	1268.4	-615.1	1230.2	229

Scaled residuals:

Min	1Q	Median	3Q	Max
-1.8058	-0.5700	-0.0683	0.3105	4.1707

Random effects:

Groups	Name	Variance	Std.Dev.
id	(Intercept)	0.2579	0.5078

Number of obs: 236, groups: id, 59

Fixed effects:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	0.165934	0.359318	0.462	0.6442
trt_f1	-0.275177	0.153777	-1.789	0.0735 .
prior	0.027454	0.002807	9.780	< 2e-16 ***
age	0.011016	0.010401	1.059	0.2895
period	0.171876	0.032138	5.348	8.89e-08 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Ejemplo 5.1 Modelos Poisson y binomial negativo - epilepsia

Correlation of Fixed Effects:

(Intr) trt_f1 prior age

trt_f1 -0.236

prior -0.415 -0.023

age -0.885 0.029 0.177

period -0.241 -0.003 0.040 -0.004

Ejemplo 5.1 Modelos Poisson y binomial negativo - epilepsia

\$M3

```
Generalized linear mixed model fit by maximum likelihood (Laplace
Approximation) [glmerMod]
Family: Negative Binomial(15.6226) ( log )
Formula: y ~ trt_f + prior + age + period + (1 | id) + (period | id)
Data: dl
```

AIC	BIC	logLik	deviance	df.resid
1239.1	1273.8	-609.6	1219.1	226

Scaled residuals:

Min	1Q	Median	3Q	Max
-2.07144	-0.48468	-0.05064	0.28954	2.58168

Random effects:

Groups	Name	Variance	Std.Dev.	Corr
id	(Intercept)	0.21323	0.4618	
id.1	(Intercept)	0.61553	0.7846	
period		0.04435	0.2106	-0.97

Number of obs: 236, groups: id, 59

Fixed effects:

	Estimate	Std.	Error	z	value	Pr(> z)
(Intercept)	0.025770	0.372429	0.069	0.9448		
trt_f1	-0.270541	0.153128	-1.767	0.0773	.	
prior	0.025286	0.003067	8.245	< 2e-16	***	
age	0.012646	0.010370	1.219	0.2227		
period	0.217625	0.045808	4.751	2.03e-06	***	

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Ejemplo 5.1 Modelos Poisson y binomial negativo - epilepsia

Correlation of Fixed Effects:

(Intr) trt_f1 prior age

trt_f1 -0.234

prior -0.301 -0.035

age -0.852 0.032 0.124

period -0.365 0.020 -0.171 0.024

optimizer (Nelder_Mead) convergence code: 0 (OK)

Model is nearly unidentifiable: large eigenvalue ratio

– Rescale variables?

Ejemplo 5.1 Modelos Poisson y binomial negativo - epilepsia

```
b <- lapply(M, fixef); b
bi <- lapply(M, coefficients); bi
fvl <- lapply(M, fitted.values)
yhat <- lapply(M, function(x) rbind(fitted.values(x), exp(predict(x))))

dl$yhat1 <- fvl[[1]]
dl$yhat2 <- fvl[[2]]
dl$yhat3 <- fvl[[3]]

p1 <- ggplot(data=dl, aes(x=period, y=yhat1, group=id, color=as.factor(id))) +
  labs(x='Period', y='Expected no. of epileptic attacks', group='Treatment')
p1 + geom_line(show.legend=FALSE) + facet_grid(. ~ trt_f) + ylim(0,120) +
  stat_summary(aes(group=0), geom='point',
    fun.y=mean, shape=19, size=3, show.legend=FALSE) +
  stat_smooth(aes(group=1), show.legend=FALSE)
p2 <- ggplot(data=dl, aes(x=period, y=yhat2, group=id, color=as.factor(id))) +
  labs(x='Period', y='Expected no. of epileptic attacks', group='Treatment')
p2 + geom_line(show.legend=FALSE) + facet_grid(. ~ trt_f) + ylim(0,120) +
  stat_summary(aes(group=0), geom='point',
    fun.y=mean, shape=19, size=3, show.legend=FALSE) +
  stat_smooth(aes(group=1), show.legend=FALSE)
p3 <- ggplot(data=dl, aes(x=period, y=yhat3, group=id, color=as.factor(id))) +
  labs(x='Period', y='Expected no. of epileptic attacks', group='Treatment')
p3 + geom_line(show.legend=FALSE) + facet_grid(. ~ trt_f) + ylim(0,120) +
  stat_summary(aes(group=0), geom='point',
    fun.y=mean, shape=19, size=3, show.legend=FALSE) +
  stat_smooth(aes(group=1), show.legend=FALSE)
```


Ejemplo 5.1 Modelos Poisson y binomial negativo - epilepsia




Figure 26: Model without period but with a random intercept.

Ejemplo 5.1 Modelos Poisson y binomial negativo - epilepsia




Figure 27: Model with period and with a random intercept

Ejemplo 5.1 Modelos Poisson y binomial negativo - epilepsia




Figure 28: Model with period, with a random intercept and a random slope (period).