

Ejercicios

MAT5508 (10182) Modelos Lineales Generalizados)

(2026)

Wednesday 1st July, 2026

1 Estimación por máxima verosimilitud

1.1 Distribución normal

Suponga que $Y_1, \dots, Y_n$ son variables aleatorias normales independientes e idénticamente distribuidas con media μ y varianza conocida σ^2 . La función de densidad de cada Y_i está dada por

$$f(y; \mu) = (2\pi\sigma^2)^{-1/2} \exp \left\{ -\frac{(y - \mu)^2}{2\sigma^2} \right\}.$$

1. Calcule las funciones de verosimilitud y log-verosimilitud para μ .
2. Obtenga las funciones de puntuación y de información y describa cómo encontrar el estimador de máxima verosimilitud $\hat{\mu}$.
3. Indique cuál es la distribución exacta de la media muestral $\bar{y} = n^{-1} \sum_{i=1}^n y_i$. Demuestre que la distribución exacta del estadístico LRS, dado por

$$-2r(\mu) = 2[\ell(\hat{\mu}) - \ell(\mu)],$$

es $-2r(\mu) \sim \chi_1^2$.

4. Ahora suponga que $Y_i \sim \mathcal{N}(\mu_i, \sigma^2)$, tal que las respuestas son independientes pero no idénticamente distribuidas (asuma σ^2 conocida). Si $\mathbf{x}_i^\top = [1 \ x_{i1} \ \dots \ x_{i,p-1}]$ es un vector $p \times 1$ de covariables asociadas con Y_i , $\boldsymbol{\beta}^\top = [\beta_0 \ \beta_1 \ \dots \ \beta_{p-1}]$ es un vector $p \times 1$ de coeficientes de regresión, y $\eta_i = \mathbf{x}_i^\top \boldsymbol{\beta}$ es el predictor lineal para la i -ésima observación, obtenga el vector de puntuación, $S(\boldsymbol{\beta})$, y la matriz de información de $\boldsymbol{\beta}$, $I(\boldsymbol{\beta})$, que resulta de especificar un modelo de regresión mediante la ligadura identidad $\mu_i = \eta_i$. Defina cualquier notación que introduzca.

2 Familia exponencial y modelos lineales generalizados

No hay ejercicios de tarea para esta sección.

3 Métodos básicos para el análisis de datos binarios

3.1 Regresión logística

Se llevó a cabo un estudio para investigar el efecto de un nuevo medicamento para reducir la mortalidad después de una cirugía abdominal mayor. Los pacientes fueron asignados a grupos de tratamiento y control en cada una de las siguientes categorías de riesgo de la cirugía: bajo, medio y alto. Los resultados se resumen en la Tabla 1

Tratamiento	Respuesta	Riesgo de cirugía		
		Bajo	Medio	Alto
Control	Murió	3	7	6
	Sobrevivió	12	6	3
Tratado	Murió	2	3	2
	Sobrevivió	10	10	8

Table 1: Efectividad de medicamento experimental en cirugía abdominal mayor.

Denotemos por $\pi_i = \Pr(Y_i = 1)$ la probabilidad de fallecimiento post-cirugía del i -ésimo paciente $i = 1, \dots, n$. Sean

$$\begin{aligned}x_{i1} &= \begin{cases} 1 & \text{si } i\text{-ésimo paciente es tratado,} \\ 0 & \text{si } i\text{-ésimo paciente es control} \end{cases} \\x_{i2} &= \begin{cases} 1 & \text{si } i\text{-ésimo paciente es riesgo medio,} \\ 0 & \text{c.o.} \end{cases} \\x_{i3} &= \begin{cases} 1 & \text{si } i\text{-ésimo paciente es riesgo alto,} \\ 0 & \text{c.o.} \end{cases}\end{aligned}$$

y las interacciones para tratamiento y nivel de riesgo

$$\begin{aligned}x_{i12} &= x_{i1}x_{i2} \quad \text{y} \\x_{i13} &= x_{i1}x_{i3}.\end{aligned}$$

Exprese cada una de las siguientes hipótesis en términos de un modelo de regresión logística para π_i en términos del predictor lineal apropiado y en cada caso determine los grados de libertad de la estadística de devianza. Absténgase de imponer restricciones adicionales a las explícitas y defina cualquier otra covariable que requiera.

- (a) H_1 : No hay asociación entre tratamiento y respuesta en cualquier categoría de riesgo.
- (b) H_2 : El logaritmo de la razón de momios que asocia tratamiento y respuesta es constante entre las categorías de riesgo.
- (c) H_3 : El logaritmo de la razón de momios que asocia tratamiento y respuesta se relaciona linealmente con una covariable continua, x_{i4} , que expresa el nivel de riesgo de la cirugía.

- (d) H_4 : La transformación logit de π_i se relaciona linealmente con x_{i4} , con pendiente común para ambos grupos: tratados y control.

3.2 Intervalos de confianza

Para concluir el Ejemplo 3.4, utilice el output de R del modelo,

$$M_{\text{main}} : \text{logit } \pi_i = \hat{\beta}_0 + \hat{\beta}_1 x_{i1} + \hat{\beta}_2 x_{i2} + \hat{\beta}_3 x_{i3} + \hat{\beta}_4 x_{i4} + \hat{\beta}_5 x_{i5} + \hat{\beta}_6 x_{i6}$$

ajustado a los datos `neuro.txt` para calcular los intervalos de confianza de las siguientes razones de momios:

1. $e^{\beta_1 + \beta_3}$ y
2. $e^{\beta_2 + \beta_5 - \beta_1 - \beta_4}$

3.3 Análisis de datos binarios

Considere un estudio sobre la ocurrencia de infección después de dar a luz por cesarea. Sea

$$Y_i = \begin{cases} 1 & \text{si hay infección,} \\ 0 & \text{no hay infección.} \end{cases}$$

Los investigadores están interesados en conocer sobre factores de riesgo de infecciones y tienen identificadas tres variables explicativas:

$$x_{i1} = \begin{cases} 1 & \text{si la cesarea fue planeada,} \\ 0 & \text{si la cesarea no fue planeada} \end{cases}$$

$$x_{i2} = \begin{cases} 1 & \text{si algún factor de riesgo estuvo presente,} \\ 0 & \text{si ningún factor de riesgo} \end{cases}$$

$$x_{i3} = \begin{cases} 1 & \text{si se administraron antibióticos como medida preventiva,} \\ 0 & \text{no se administraron antibióticos.} \end{cases}$$

Los datos se encuentran resumidos en la Tabla 2

		Cesarea planeada		Cesarea no planeada	
		Infección	Sin infección	Infección	Sin infección
Antibióticos	Factores de Riesgo	1	17	11	87
Antibióticos	Sin Factores de Riesgo	0	2	0	0
Sin Antibióticos	Factores de Riesgo	28	30	23	3
Sin Antibióticos	Sin Factores de Riesgo	8	32	0	9

Table 2: Ocurrencia de infección después de parto por cesarea.

- (a) Ajuste el modelo de regresión logística que contenga únicamente los efectos principales para las tres variables explicativas y comente sobre la importancia del uso de antibióticos, de la presencia de factores de riesgo y de haber planeado la cesarea para predecir la ocurrencia de infección.

- (b) Con base en el modelo ajustado, de un intervalo de confianza al 95% para la probabilidad de infección cuando la cesarea no fue planeada, no hubo factores de riesgo y no se administraron antibióticos.
- (c) Construya un intervalo de confianza al 95% para la razón de momios asociados a un cambio en el riesgo de infección para una mujer a la que se le administran antibióticos con factores de riesgo y cuya cesarea no fue planeada vs. una mujer sin antibióticos sin factores de riesgo y cuya cesarea fue planeada.

4 Bioensayos y modelo dosis-respuesta

4.1 Familia locación-escala

1. Supongamos una variable aleatoria U definida en $\mathbb{R}$ con función de densidad $h(\cdot)$ y función de distribución acumulativa $H(\cdot)$. Sea μ y σ dos constantes con $\sigma > 0$. Demuestre que $V = \mu + \sigma U$ tiene funciones de densidad f y distribución acumulativa F dadas por

$$f(v) = \frac{1}{\sigma} \cdot h\left(\frac{v - \mu}{\sigma}\right)$$
$$F(v) = H\left(\frac{v - \mu}{\sigma}\right),$$

respectivamente.

Esta familia de distribuciones con dos parámetros se conoce como la familia locación-escala, donde μ es el parámetro de locación y σ el parámetro de escala. [Este resultado lo aplicará en su trabajo trimestral.](#)

5 Modelos log-lineales

5.1 Distribución Poisson

Supongamos que $y_1, \dots, y_n$ es una muestra de conteos de la distribución Poisson. Sea $f_0, f_1, \dots, f_K$ las frecuencias observadas para $0, 1, \dots, K$ respectivamente, i.e. $f_k = \sum_{i=1}^n \mathbb{1}(y_i = k)$. Por conveniencia, si $y_i \geq K$ entonces truncamos los conteos y los denotamos por $y_i = K$. Si K es suficientemente grande, truncar los conteos conducirá a una pequeña pérdida de información. De acuerdo con esta notación, el tamaño de muestra total está dado por $n = \sum_{k=0}^K f_k$.

La Tabla 3 reporta la frecuencia de reparaciones en $n = 550$ vehículos del ejército a lo largo de 10 años. Asumimos que la distribución del número de reparaciones se puede representar por la distribución Poisson con media μ .

# de visitas (k)	0	1	2	3	4	5	6+
Frecuencia (f_k)	295	190	53	5	5	2	0

Table 3: Distribución de frecuencia de las visitas de reparación de vehículos del ejército.

- Plantée la hipótesis nula en término de los parámetros relevantes. Defina cualquier parámetro que decida introducir.
- Escriba la función de verosimilitud en términos de μ y las frecuencias (esto es, bajo la hipótesis nula), y bajo la hipótesis alternativa.
- Encuentre expresiones para el estimador de máxima verosimilitud de μ y $p_k(\mu)$, donde $p_k(\mu) = \Pr(y_i = k; \mu)$.
- Obtenga las frecuencias esperadas y someta a prueba si la bondad de ajuste de la distribución Poisson es razonable para los datos en cuestión.
(Pista: La estadística de Pearson tiene una distribución χ^2_ν donde los grados de libertad son $\nu = \# \text{ de categorías} - \# \text{ de parámetros} - 1$.)

5.2 Proceso Poisson homogéneo

Se condujo un estudio para examinar la tasa a la que se presentan “defectos” en rollos de tela. Entiéndase por “defectos” imperfecciones tales que provocan que no sea posible vender la porción de tela afectada. Los datos se encuentran en el archivo `fabric.txt` y la Figura 1 muestra gráficamente el conteo de fallas por longitud de los rollos de tela.




Figure 1: Number of faults by roll length.

- Escriba la función log-verosimilitud con base en el modelo del conteo de defectos por rollo de tela bajo el supuesto de que los defectos ocurren de acuerdo con un proceso Poisson homogéneo. Defina cualquier notación que introduzca.

- (b) Evalúe si un modelo Poisson es apropiado para estos datos.
- (c) Se tiene la sospecha de que los defectos ocurren a una tasa de 1 defecto cada 100 metros. Someta a prueba la hipótesis de que los defectos ocurren precisamente a una tasa de 1 cada 100 metros.

5.3 Tablas de contingencia

Korff, Taback and Beard (1952) reportan los siguientes datos de un caso de envenenamiento por comida despues de un día de campo.

Cangrejo	Ensalada de papa	Enfermó	
		Sí	No
Sí	Sí	120	80
Sí	No	4	31
No	Sí	22	24
No	No	2	23

Table 4: Frecuencias observadas de un grupo de 306 individuos que reportan haber consumido pastel de cangrejo, ensalada de papa y si enfermaron o no.

Denotemos por C la variable que indica si un individuo consumió pastel de cangrejo, P representa la variable que indica si un individuo consumió ensalada de papa y S representa la variable que indica si un individuo enfermó. Entonces, el modelo log-lineal saturado es

$$M_{\text{Sat}} : \log \mu_{ijk} = a + c_i + p_j + s_k + (cp)_{ij} + (cs)_{ik} + (ps)_{jk} + (cps)_{ijk},$$

donde $c_1 = p_1 = s_1 = (cp)_{1j} = (cs)_{1k} = (ps)_{1k} = (cp)_{i1} = (cs)_{i1} = (ps)_{j1} = (cps)_{1jk} = (cps)_{i1k} = (cps)_{ij1} = 0$; $i = 1, 2, j = 1, 2$ y $k = 1, 2$.

- (a) Usando R, seleccione el modelo que juzgue más apropiado para hacer inferencias. Justifique su elección mediante una prueba formal de ajuste del modelo.
- (b) Con base en el los datos y el modelo que eligió con mejor bondad de ajuste, presente los conteos estimados en una arreglo similar a la Tabla 4, calcule la razón de momios (así como su intervalo de confianza al 95%) de enfermedad por el consumo de ensalada de papa para:
- aquellos que sí consumieron cangrejo
 - aquellos que no consumieron cangrejo

Compare estas dos razones de momios e indique cómo difieren entre ellas.

- (c) Suponga que interesa modelar la variable “enfermedad” como respuesta. Escriba el modelo de regresión logística equivalente al modelo que eligió en (a) y ajústelo en R.