

Tarea 1 - Estimación por Máxima Verosimilitud

Carlos Guillermo Mayorga Tapia

1 Distribución Normal

Suponga que $Y_1, \dots, Y_n$ son variables aleatorias normales independientes e idénticamente distribuidas con media μ y varianza conocida σ^2 . La función de densidad de cada Y_i está dada por:

$$f(y; \mu) = (2\pi\sigma^2)^{-1/2} \exp \left\{ -\frac{(y - \mu)^2}{2\sigma^2} \right\}$$

1.1 Inciso 1: Función de Verosimilitud y Log-verosimilitud

Supuesto: Las observaciones $Y_1, \dots, Y_n$ son independientes e idénticamente distribuidas (i.i.d.).

Dado el supuesto de independencia, la función de verosimilitud conjunta $L(\mu)$ se obtiene multiplicando las funciones de densidad marginales:

$$\begin{aligned} L(\mu) &= \prod_{i=1}^n f(y_i; \mu) \\ &= \prod_{i=1}^n (2\pi\sigma^2)^{-1/2} \exp \left\{ -\frac{(y_i - \mu)^2}{2\sigma^2} \right\} \\ &= (2\pi\sigma^2)^{-n/2} \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \mu)^2 \right\} \end{aligned}$$

La función de log-verosimilitud $\ell(\mu)$ es el logaritmo natural de la función de verosimilitud, lo cual facilita los cálculos analíticos. Usando las propiedades de los logaritmos, obtenemos:

$$\begin{aligned} \ell(\mu) &= \ln L(\mu) \\ &= \ln [(2\pi\sigma^2)^{-n/2}] + \ln \left[\exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \mu)^2 \right\} \right] \\ &= -\frac{n}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \mu)^2 \end{aligned}$$

1.2 Inciso 2: Funciones de Puntuación e Información y Estimador MLE

1.2.1 Función de puntuación (Score function)

La función de puntuación, denotada por $U(\mu)$ (o $S(\mu)$), se define como la primera derivada de la log-verosimilitud con respecto al parámetro de interés μ :

$$\begin{aligned} U(\mu) &= \frac{\partial \ell(\mu)}{\partial \mu} \\ &= \frac{\partial}{\partial \mu} \left(-\frac{n}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \mu)^2 \right) \\ &= -\frac{1}{2\sigma^2} \sum_{i=1}^n [2(y_i - \mu)(-1)] \\ &= \frac{1}{\sigma^2} \sum_{i=1}^n (y_i - \mu) \end{aligned}$$

Reordenando la suma, sabemos que $\sum_{i=1}^n (y_i - \mu) = \sum_{i=1}^n y_i - n\mu$. Como la media muestral es $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$, tenemos que $\sum y_i = n\bar{y}$. Por lo tanto:

$$U(\mu) = \frac{n}{\sigma^2} (\bar{y} - \mu)$$

1.2.2 Matriz (Función) de información de Fisher

La información de Fisher esperada $I(\mu)$ se define como el valor esperado negativo de la segunda derivada de la log-verosimilitud con respecto a μ :

$$I(\mu) = -E \left[\frac{\partial^2 \ell(\mu)}{\partial \mu^2} \right]$$

Calculamos la segunda derivada:

$$\begin{aligned} \frac{\partial^2 \ell(\mu)}{\partial \mu^2} &= \frac{\partial}{\partial \mu} \left[\frac{n}{\sigma^2} (\bar{y} - \mu) \right] \\ &= -\frac{n}{\sigma^2} \end{aligned}$$

Dado que es una constante (no depende de las variables aleatorias Y_i), su valor esperado es la misma constante:

$$I(\mu) = -E \left[-\frac{n}{\sigma^2} \right] = \frac{n}{\sigma^2}$$

1.2.3 Estimador de Máxima Verosimilitud (MLE)

Para encontrar el estimador de máxima verosimilitud $\hat{\mu}$, igualamos la función de puntuación a cero y resolvemos para μ :

$$U(\hat{\mu}) = 0 \implies \frac{n}{\sigma^2}(\bar{y} - \hat{\mu}) = 0$$

Dado que $\frac{n}{\sigma^2} \neq 0$, debe cumplirse que:

$$\bar{y} - \hat{\mu} = 0 \implies \hat{\mu} = \bar{y}$$

Para asegurar que se trata de un máximo global, evaluamos la segunda derivada en $\hat{\mu}$. Como $I(\mu) = \frac{n}{\sigma^2} > 0$, la segunda derivada evaluada en el estimador es $-\frac{n}{\sigma^2} < 0$. Al ser estrictamente cóncava, $\hat{\mu} = \bar{y}$ maximiza la verosimilitud.

1.3 Inciso 3: Distribución Exacta y Estadístico LRS

1.3.1 Distribución de la media muestral

Tenemos que $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$. Al ser los Y_i variables aleatorias normales e independientes, cualquier combinación lineal de ellas también sigue una distribución normal. Calculamos su valor esperado y varianza:

$$E[\bar{Y}] = \frac{1}{n} \sum_{i=1}^n E[Y_i] = \frac{1}{n}(n\mu) = \mu$$

Por independencia:

$$Var(\bar{Y}) = \frac{1}{n^2} \sum_{i=1}^n Var(Y_i) = \frac{1}{n^2}(n\sigma^2) = \frac{\sigma^2}{n}$$

Por lo tanto, la distribución exacta de $\bar{Y}$ es:

$$\bar{Y} \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$$

1.3.2 Distribución exacta del estadístico LRS

El estadístico de razón de log-verosimilitudes (Likelihood Ratio Statistic, LRS) está dado por:

$$-2r(\mu) = 2[\ell(\hat{\mu}) - \ell(\mu)]$$

Sustituyendo el valor del MLE $\hat{\mu} = \bar{y}$ en la log-verosimilitud:

$$\begin{aligned}\ell(\hat{\mu}) &= -\frac{n}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \bar{y})^2 \\ \ell(\mu) &= -\frac{n}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \mu)^2\end{aligned}$$

Restando ambas ecuaciones:

$$\ell(\hat{\mu}) - \ell(\mu) = -\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \bar{y})^2 + \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \mu)^2$$

Utilizando el teorema algebraico $\sum (y_i - \mu)^2 = \sum (y_i - \bar{y})^2 + n(\bar{y} - \mu)^2$, obtenemos:

$$\begin{aligned}\ell(\hat{\mu}) - \ell(\mu) &= \frac{1}{2\sigma^2} \left[\sum (y_i - \bar{y})^2 + n(\bar{y} - \mu)^2 - \sum (y_i - \bar{y})^2 \right] \\ &= \frac{1}{2\sigma^2} [n(\bar{y} - \mu)^2] = \frac{n}{2\sigma^2} (\bar{y} - \mu)^2\end{aligned}$$

Entonces, el estadístico LRS se simplifica a:

$$-2r(\mu) = 2 \left[\frac{n}{2\sigma^2} (\bar{y} - \mu)^2 \right] = \frac{n}{\sigma^2} (\bar{y} - \mu)^2$$

Reescribiéndolo en la forma de estandarización normal:

$$-2r(\mu) = \left(\frac{\bar{y} - \mu}{\sigma/\sqrt{n}} \right)^2$$

Sabemos por la parte anterior que $\bar{Y} \sim \mathcal{N}(\mu, \sigma^2/n)$. Al estandarizar, la variable $Z = \frac{\bar{Y} - \mu}{\sigma/\sqrt{n}}$ sigue una distribución normal estándar $Z \sim \mathcal{N}(0, 1)$.

Por definición, el cuadrado de una variable aleatoria normal estándar tiene una distribución Chi-cuadrada con 1 grado de libertad. Concluimos que:

$$-2r(\mu) = Z^2 \sim \chi_1^2$$

1.4 Inciso 4: Modelo de Regresión con Componentes de Covariables

Supuesto: Respuestas independientes pero no idénticamente distribuidas. Sea $Y_i \sim \mathcal{N}(\mu_i, \sigma^2)$ para $i = 1, \dots, n$. El predictor lineal se define como $\eta_i = \mathbf{x}_i^\top \beta$ con un modelo de ligadura identidad $\mu_i = \eta_i = \mathbf{x}_i^\top \beta$. Donde: - $\mathbf{x}_i^\top = [1, x_{i1}, \dots, x_{i,p-1}]$ (vector fila $1 \times p$) - $\beta = [\beta_0, \beta_1, \dots, \beta_{p-1}]^\top$ (vector columna $p \times 1$)

La función de log-verosimilitud para el vector de parámetros β es:

$$\ell(\beta) = -\frac{n}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \mathbf{x}_i^\top \beta)^2$$

Podemos expresar el término de suma de cuadrados utilizando notación matricial: - $\mathbf{Y}$ es el vector columna $n \times 1$ de respuestas. - $\mathbf{X}$ es la matriz de diseño $n \times p$ donde la i -ésima fila es $\mathbf{x}_i^\top$.

$$\ell(\beta) = -\frac{n}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} (\mathbf{Y} - \mathbf{X}\beta)^\top (\mathbf{Y} - \mathbf{X}\beta)$$

1.4.1 Vector de puntuación $S(\beta)$

El vector de puntuación de dimensión $p \times 1$ se obtiene tomando el gradiente de la log-verosimilitud con respecto al vector β . Usando reglas de derivación matricial $\frac{\partial}{\partial \beta} [(\mathbf{y} - \mathbf{X}\beta)^\top (\mathbf{y} - \mathbf{X}\beta)] = -2\mathbf{X}^\top (\mathbf{y} - \mathbf{X}\beta)$:

$$\begin{aligned} S(\beta) &= \frac{\partial \ell(\beta)}{\partial \beta} \\ &= -\frac{1}{2\sigma^2} [-2\mathbf{X}^\top (\mathbf{Y} - \mathbf{X}\beta)] \\ &= \frac{1}{\sigma^2} \mathbf{X}^\top (\mathbf{Y} - \mathbf{X}\beta) \end{aligned}$$

O escrito en términos de sumatoria para la j -ésima componente:

$$\frac{\partial \ell(\beta)}{\partial \beta_j} = \frac{1}{\sigma^2} \sum_{i=1}^n (y_i - \mathbf{x}_i^\top \beta) x_{ij}$$

1.4.2 Matriz de información de Fisher $I(\beta)$

La matriz de información de dimensión $p \times p$ se obtiene tomando el valor esperado negativo del Hessiano de la log-verosimilitud:

$$I(\beta) = -E \left[\frac{\partial^2 \ell(\beta)}{\partial \beta \partial \beta^\top} \right]$$

Calculamos el Hessiano, derivando el vector de puntuación:

$$\begin{aligned}\frac{\partial^2 \ell(\beta)}{\partial \beta \partial \beta^\top} &= \frac{\partial}{\partial \beta^\top} \left[\frac{1}{\sigma^2} \mathbf{X}^\top (\mathbf{Y} - \mathbf{X}\beta) \right] \\ &= \frac{1}{\sigma^2} \mathbf{X}^\top (-\mathbf{X}) = -\frac{1}{\sigma^2} \mathbf{X}^\top \mathbf{X}\end{aligned}$$

Dado que $\mathbf{X}$ es una matriz de covariables determinista (conocida y sin variables aleatorias que dependan del error), el valor esperado de la matriz constante es la misma matriz:

$$I(\beta) = -E \left[-\frac{1}{\sigma^2} \mathbf{X}^\top \mathbf{X} \right] = \frac{1}{\sigma^2} \mathbf{X}^\top \mathbf{X}$$